

稀疏多项式逼近与压缩感知配点法

一条由 Christoffel 函数贯穿的研究线

精读对象：Guo, Narayan, Zhou, Chen (2017); Guo, Narayan, Yan, Zhou (2017);
Guo, Narayan, Zhou (2018); Guo, Li, Liu (2018); Guo, Liu, Zhou (2018);
Guo, Narayan, Liu, Zhou (2020)

上海师范大学 郭玲 · 不确定性量化方向 · arXiv 1602.00995 / 1708.01296 / 1802.08837 / 1805.05416 / 1805.10893 /
2008.10121

本笔记面向“有机器学习与数值分析基础、没接触过不确定性量化”的读者。问题只有一个：一个 PDE 的系数是随机的，解的统计量怎么算才不必把随机维数的网格铺满。六篇论文给出同一个答案的六个版本：利用稀疏性，用远少于基函数个数的样本恢复展开系数。贯穿全部六篇的数学对象是 *Christoffel* 函数，它在每篇里换一个身份出现：求积权、点列加权、列归一、预条件、采样测度。

怎么读这份笔记

- **第 1 到 5 章** 问题与工具：随机方程的维数灾难，正交多项式与 Gauss 求积，稀疏恢复的几何图像（基追踪、RIP、互不相干），以及三条主定理的证明思路。Christoffel 函数在第 1 章末尾定义，它是整条线的公共主轴。
- **第 6 到 8 章** 是前半条线：怎么采样。Gauss 求积网格的随机子采样（第 6 章），确定性的加权 Fekete 点（第 7 章），第 8 章补齐两篇的实验与一维最优性推导。
- **第 9 到 12 章** 加信息与换罚函数：把导数塞进测量矩阵（第 9 章），非凸 TL_1 （第 10 章），证明链与实现细节（第 11、12 章）。
- **第 13 到 17 章** 换数据假设：分布未知时的数据驱动基（第 13 章），稀疏恢复与数据驱动的合流 induced sampling（第 14 章），两篇各自的实现台（第 15 到 17 章）。
- **第 18 到 22 章** 用法与坐标：最小算例走查（第 18 章），符号对照（第 19 章），六篇算例与选型规则（第 20 章），前人路线谱系（第 21 章），这条线的立场与未做之事（第 22 章）。第 23、24 章是附录。

每个术语第一次出现时先说明它解决什么困难。公式后面的“读法”段落把符号翻译回问题本身。

术语地图

gPC
随机配点
维数灾难
稀疏性

广义多项式混沌：把随机系统的解展开成随机变量的正交多项式。
在随机空间选一批点，每点解一次确定性 PDE，再把解投影回多项式基。
张量积配点数随维数指数增长；本文所有方法对手。
真实解的 gPC 系数大多接近零，只有少数几个大系数。

基追踪	在数据约束下最小化系数向量的 ℓ_1 范数，用来逼出最稀疏解。
RIP	有限等距性质：采样矩阵近似保持稀疏向量的长度，是恢复保证的载体。
互不相干	测量矩阵列与列的归一化内积的最大值；越小恢复越容易。
Christoffel 函数	多项式平方和的倒数。它衡量“在某个点附近多项式空间有多挤”。
求积权	数值积分公式里每个节点的权重。
平衡测度	位势论意义下让多项式“均匀分布”的采样密度；有界域上是 Chebyshev 测度。
Fekete 点	让 Vandermonde 行列式最大的点集，插值意义下最“张得开”的点。
诱导测度	由“原密度除以 Christoffel 函数”定义的采样分布，只依赖已有样本。

目录

1 问题：随机方程的统计量为什么算不动	5
1.1 模型问题	5
1.2 多项式混沌与随机配点	5
1.3 稀疏性：压缩感知能用在随机 PDE 上的原因	5
2 预备知识（上）：正交多项式与 Gauss 求积	6
2.1 三项递推	6
2.2 Gauss 求积与 $2n-1$ 精度	6
2.3 求积权就是 Christoffel 函数	7
2.4 从递推系数到节点与权：Golub–Welsch 算法	7
2.5 一个可以手算的例子	7
2.6 为什么 Hermite 的 L 因子降不下来	7
2.7 一个容易踩的坑：两种约定	8
3 预备知识（下）：稀疏恢复的几何图像	8
3.1 从 ℓ_0 到 ℓ_1	8
3.2 两条判据的分工（与第二章衔接）	8
3.3 最小二乘一侧的稳定性问题	9
4 工具：稀疏恢复的两把尺子	9
4.1 RIP：矩阵级判据	9
4.2 MIP：列级判据	9
5 理论深处：三条主定理的证明思路	10
5.1 RIP 从哪来：一致界 + 浓缩	10
5.2 加权最小二乘的无偏性：一笔与 induced 采样相同的账	10
5.3 稀疏性从哪来：随机 PDE 解的系数衰减	11
5.4 互不相干路线的逐点界	11
6 第一篇：Gauss 求积网格上的随机子采样（SISC 2017）	11
6.1 要解决的问题	11
6.2 构造	12
6.3 主定理：样本量准则	12
7 第二篇：加权近似 Fekete 点（确定性采样）	14
7.1 换一条路：超定最小二乘	14
7.2 构造：把 Christoffel 权重塞进基	14
7.3 主定理：贪心 = 全局最优	14
8 第一、二篇补充：实验画廊与一维最优性的完整推导	16
8.1 第一篇：六组实验的完整记录	16

8.2 第二篇：一维最优性的推导链	17
8.3 第二篇：条件数与精度的完整记录	18
9 第三篇：把导数信息塞进测量矩阵（2018）	19
9.1 要解决的问题	19
9.2 问题格式	19
9.3 预条件的设计：来自导数正交性	19
9.4 恢复保证	20
10 第四篇：换罚函数（TL1, 2018）	21
10.1 要解决的问题	21
10.2 罚函数	21
10.3 恢复理论（比前人更干净）	21
10.4 在 gPC 上的落点	22
11 第三、四篇补充：梯度信息的完整记录与非凸罚的证明链	22
11.1 第三篇：三族测试函数与高维部分梯度	22
11.2 第四篇：TL1 带噪恢复的证明链	23
11.3 第四篇：参数与非稀疏目标的完整记录	24
12 第二、四篇的实现细节与推广	25
12.1 第二篇：贪心点列的实现	25
12.2 第二篇：一维引理的完整清单	25
12.3 第四篇：DCA 算法的内层细节	25
12.4 第四篇的推广：方向导数与 Hermite 型稀疏插值	25
13 第五篇：分布未知时的数据驱动基（2018）	26
13.1 换数据假设：认知不确定性	26
13.2 构基：Hankel 矩阵与 Cholesky	26
13.3 采样与拟合：平衡测度 + Christoffel 加权	26
14 第六篇：合流（induced sampling, 2020）	27
14.1 问题：两条路线各有半截	27
14.2 诱导测度：只依赖样本的采样分布	27
14.3 六篇合起来：Christoffel 函数的六副面孔	29
15 第五、六篇补充：数据驱动路线的完整记录与无偏性的推导	29
15.1 第五篇：矩问题什么时候有解	29
15.2 第五篇：条件数与精度的完整记录	30
15.3 第六篇：无偏性的完整推导	30
15.4 第六篇：稀疏恢复与函数逼近的完整记录	31
16 第五篇的实现台：采样测度、实验设置与逐图读数	31
16.1 五步流程与“可以离线”的准确含义	32
16.2 两种采样测度的可执行形式	32
16.3 稳定性实验的口径	32
16.4 精度实验的口径	33
16.5 这一篇留下的三个口子	35
17 第六篇的实现台：两个算法、三方对照与逐图读数	35
17.1 输入约定与两个算法	35
17.2 张量化牺牲了什么	36
17.3 采样与预条件：三方对照	36
17.4 手算例：16 个样本上的矩、基与诱导测度	37
17.5 实验协议与全部设置	38

17.6	逐图读数	39
17.7	这一篇没有给出的东西	40
18	工程实践：一个最小算例的走查与常见误区	40
18.1	算例走查： $d = 2$ 的稀疏恢复从头到尾	40
18.2	常见误区	41
18.3	软件与可复现性	41
19	附录补充：全书的符号对照	41
20	案例研究：同一个问题族，六种工具	42
20.1	从表里读出的三条选型规则	43
20.2	把样本量界换算成预算，以及为什么换算不动	43
20.3	六篇都没有做的事	44
21	谱系：随机方程的统计量，前人怎么算	44
21.1	谱方法线：从随机 Galerkin 到任意分布	44
21.2	压缩感知线：从计数到采样测度	44
21.3	加权最小二乘线：确定性点集	44
22	坐标：这条线站在哪里	45
22.1	每篇的最接近替代品	45
22.2	更大坐标系里的位置	45
22.3	逻辑阶梯	45
22.4	谁受影响	46
22.5	不该过度宣称的部分	46
23	附录	46
23.1	A. 记号表	46
23.2	B. 关键公式速查	47
23.3	C. 六篇论文信息	47
23.4	D. 自检清单	48
24	附录补充：术语索引、阅读路线与跨界接口	48
24.1	术语索引（按定义位置）	48
24.2	与方向 B 的接口：数据驱动思想进入深度学习	49
24.3	阅读路线	49
24.4	参考文献补充（谱系章新增条目）	49

1 问题：随机方程的统计量为什么算不动

1.1 模型问题

贯穿六篇论文模型问题是带随机参数的椭圆方程：

$$-\nabla \cdot (\kappa(x, y) \nabla u(x, y)) = f(x), \quad x \in \mathcal{D}, \quad y \in \Gamma \subset \mathbb{R}^d,$$

κ 是随机扩散系数, $y = (y_1, \dots, y_d)$ 是 d 个相互独立的随机变量, 各自的边际密度为 ρ^i , 联合密度 $\rho(y) = \prod_i \rho^i(y^i)$ 。 d 由随机场的有效维数决定, 实际应用里轻松到几十。

关心的输出是 u 的统计量: 均值 $E[u]$ 、方差 $\text{Var}[u]$, 或者某个观测量 $F(u(y))$ 作为 y 的函数。它们都是 Γ 上的高维积分。

1.2 多项式混沌与随机配点

处理这个积分的标准框架是 **gPC** (广义多项式混沌)。选一组与测度 ρ 正交的多项式基: 一元基 φ_n^i 满足

$$E[\varphi_n^i(X^i) \varphi_l^i(X^i)] = \int_{\Gamma^i} \varphi_n^i(s) \varphi_l^i(s) \rho^i(s) ds = \delta_{n,l},$$

多元基取张量积 $\varphi_n(x) = \prod_{i=1}^d \varphi_{n_i}^i(x^i)$ 。目标是把解 (或观测量) 展开成

$$f(\mathbf{X}) = \sum_{j \in \mathbb{N}_0^d} c_j \varphi_j(\mathbf{X}).$$

系数怎么算? 两条经典路。

随机 Galerkin: 把展开代入方程, 对基函数做投影, 得到一个大的确定性方程组。侵入式 (要改求解器内部)。

随机配点 (stochastic collocation): 在 Γ 上选一批配点 $\mathbf{x}_1, \dots, \mathbf{x}_M$, 每个配点上用原来的确定性求解器解一遍方程 (黑箱, 非侵入式), 然后用这 M 组数据拟合系数 c 。这是六篇论文共同采用的框架。

配点的困难全在“选点”与“拟合”两步。最直接的选法是张量积 Gauss 求积网格: 每个维度 n 个 Gauss 节点, 共 $\prod_i n_i$ 个点。 $d=20$ 、每维 3 点就是 35 亿个点, 每个点都是一次完整 PDE 求解。这就是维数灾难在配点法里的具体形态。

欠定情形是常态 总次数指标集 $\Lambda_n^T = \{\mathbf{k} : \sum_i k_i \leq n\}$ 的基函数个数是 $N = \binom{d+n}{n}$ 。实际中能负担的配点数 M 远小于 N 。 $M < N$ 时拟合问题欠定: 方程比未知数少, 普通最小二乘无解。传统的稀疏网格 (Smolyak、Gerstner–Griebel 自适应加密) 用结构化的点集 绕开张量积爆炸, 但点数仍随维数快速增长, 且适应性构造不易并行。压缩感知是另一条路: 如果系数向量本身稀疏, MN 也能恢复。

1.3 稀疏性：压缩感知能用在随机 PDE 上的原因

压缩感知 (CS) 的出发点是一个经验与理论兼备的事实: **参数化 PDE 的解在合适的多项式基下是稀疏的**。对椭圆方程做随机场的解析分析可以证明: 解的 gPC 系数按指标的大小 (某一种范数意义下) 指数衰减, 只有少数“重要方向”的系数显著非零。形式上, 真实系数向量 $\mathbf{c} \in \mathbb{R}^N$ 近似 **s-稀疏**: 只有 s 个分量显著, $s \ll N$ 。

于是问题变成: M 次黑箱求解 (M 与 s 同阶, 而不是与 N 同阶), 能否恢复出这个稀疏向量? 这就是稀疏恢复问题。给定采样点组成的测量矩阵 $\Psi_{ij} = \varphi_j(\mathbf{x}_i)$ 与观测 $\mathbf{f}$, 凸松弛的标准格式是 **基追踪** (basis pursuit):

$$\arg \min_{\mathbf{c}} \|\mathbf{c}\|_1 \quad \text{s.t.} \quad \Psi \mathbf{c} = \mathbf{f},$$

用 ℓ_1 范数 (绝对值之和) 替代 ℓ_0 计数 (非零分量个数)。 ℓ_1 最小化在什么条件下能恢复稀疏解? 这需要两个经典工具, 下一节备齐。

六篇论文对采样点分布不做“均匀随机”这种朴素假设，而是精心设计采样测度与预条件，这背后有一个统一的数学对象，先把它定义出来。

什么叫“Christoffel 函数” 给定 N 个多项式基 $\{\varphi_1, \dots, \varphi_N\}$ 与测度 ρ ，Christoffel 函数定义为

$$K(\mathbf{y}) = \frac{N}{\sum_{j=1}^N \varphi_j^2(\mathbf{y})}.$$

分母是“在点 $\mathbf{y}$ 处，把 N 个基的平方加起来”。它的倒数（即 $\sum \varphi_j^2/N$ ）有一个概率解读：若 $\mathbf{Y} \sim \rho$ ，则 $\sum_j \varphi_j^2(\mathbf{Y})$ 的期望恰好是 N （正交性保证）。所以 $1/K(\mathbf{y})$ 衡量的是“这个点上多项式的平均能量超出平均多少”：

- 分母大：这个点附近多项式可以取很大的值，采样到这里的信息少而噪声放大；
- 分母小：多项式在这里表现温和，采样信息多。

由此得到贯穿六篇论文的一对操作：加权按 K （能量大的点权重小，把加权后矩阵每行的范数摊平）；采样偏向 $1/K$ （能量大的点多采； $\kappa = 1/K$ 与原密度相乘，其位势论极限对应平衡测度。位势论把测度看成带电分布、研究其能量极小，是逼近论的经典工具；有界域上是 Chebyshev 测度 $1/(\pi^d \prod \sqrt{1-y_i^2})$ ，端点多、中间少）。两个操作相乘还原原测度（无偏），配对使用让加权矩阵在所有点上表现均匀。六篇论文的采样策略（求积网格、贪心点列、平衡测度、诱导测度）都是这对操作的变体。

2 预备知识（上）：正交多项式与 Gauss 求积

六篇论文的每一处推导都踩在正交多项式的三条性质上。这里把这三条备齐，已经熟悉的读者可以跳到本章最后一节（两种约定警告），那里有一个容易踩的坑。

2.1 三项递推

区间 Γ 上的测度 ρ 给出一列正交多项式 $\varphi_0, \varphi_1, \dots$ （ φ_n 恰好 n 次， $\int \varphi_n \varphi_m \rho = 0$ 对 $n \neq m$ ）。任何这样的序列满足三项递推：

$$x\varphi_n(x) = b_{n+1}\varphi_{n+1}(x) + a_n\varphi_n(x) + b_n\varphi_{n-1}(x),$$

系数 a_n, b_n 由测度决定。这一条是构基算法（第五篇的 Hankel–Cholesky 路线）的出口：矩序列决定 a_n, b_n ，递推决定整列基。常用四族的参数：

族	权 $\rho(x)$	支撑	对应分布
Legendre	1	$[-1, 1]$	均匀
Chebyshev	$(1-x^2)^{-1/2}$	$[-1, 1]$	（无直接对应，平衡测度）
Hermite	e^{-x^2}	$\mathbb{R}$	高斯
Laguerre	$e^{-x}x^\alpha$	$[0, \infty)$	指数

Jacobi 族把 Legendre 与 Chebyshev 统一为 $\rho \propto (1-x)^\gamma(1+x)^\delta$ 的两个端点，第一篇的“任意 Beta 权”就是任意 Jacobi 参数。

2.2 Gauss 求积与 2n-1 精度

定理（Gauss 求积精度） 设 $z_1, \dots, z_n$ 是 φ_n 的零点， w_k 是对应求积权（使 n 点法则对次数 $\leq n-1$ 的多项式精确），则该法则对一切次数 $\leq 2n-1$ 的多项式精确：

$$\int_{\Gamma} p(x)\rho(x)dx = \sum_{k=1}^n w_k p(z_k) \quad \text{对} \quad \deg p \leq 2n-1.$$

证明. 取次数 $\leq 2n-1$ 的 p , 用 φ_n 做带余除法: $p = q\varphi_n + r$, 其中 $\deg q \leq n-1$, $\deg r \leq n-1$. 在节点上求和: $\sum_k w_k p(z_k) = \sum_k w_k q(z_k) \underbrace{\varphi_n(z_k)}_0 + \sum_k w_k r(z_k) = \sum_k w_k r(z_k)$. 第一个求积 ($q\varphi_n$, 次数 $\leq 2n-1$) 超出了法则的保证精度, 但在每个节点上 $\varphi_n(z_k) = 0$ 使它逐项为零; 第二个求积 (r , 次数 $\leq n-1$) 在保证精度内, 等于 $\int r\rho$. 而正交性给出 $\int q\varphi_n\rho = 0$, 于是 $\int r\rho = \int (q\varphi_n + r)\rho = \int p\rho$. $\square$

这就是第一篇“离散正交系统”引理里求积精确性的出处: Christoffel 权重搬进取权和之后, 恰好把正交性从连续测度搬到离散网格上。

2.3 求积权就是 Christoffel 函数

引理 (Gauss 权与 Christoffel 函数) n 点 Gauss 求积在节点 z_k 处的权与 $n-1$ 阶 Christoffel 函数满足

$$w_k = \lambda_{n-1}(z_k) \cdot \int \rho, \quad \lambda_{n-1}(x) = \frac{1}{\sum_{j=0}^{n-1} \varphi_j(x)^2}.$$

证明. 取“指示插值”问题: 对单个节点 z_k , 构造次数 $\leq n-1$ 的多项式 ℓ_k 使 $\ell_k(z_k) = 1$, $\ell_k(z_j) = 0$ ($j \neq k$). 对 ℓ_k 用求积精确性: $w_k = \int \ell_k \rho$. 而 ℓ_k 可以由正交投影写出: $\ell_k(x) = \lambda_{n-1}(z_k) \sum_j \varphi_j(z_k) \varphi_j(x)$ (这是 Christoffel–Darboux 恒等式 (把核函数 $\sum_j \varphi_j(x) \varphi_j(y)$ 写成相邻次多项式的差商的标准恒等式) 的直接推论), 代入 $x = z_k$ 即得 $w_k = \lambda_{n-1}(z_k) \sum_j \varphi_j(z_k)^2 = \lambda_{n-1}(z_k)$. 测度归一 ($\int \rho = 1$) 时两者相等. $\square$

第一篇的预条件 $\sqrt{n\lambda_n^i}$ 里的 λ 因此有双重身份: 它既是离散网格上的求积权, 又是连续测度下的 Christoffel 函数. “求积权的平方根乘多项式在离散测度下正交”这条引理, 本质上是把连续正交性沿求积法则取样。

2.4 从递推系数到节点与权: Golub–Welsch 算法

三项递推系数 a_n, b_n 不仅生成基函数, 还直接给出 Gauss 节点与权: 把递推写成矩阵形式 $x\varphi(x) = J\varphi(x) + b_{n+1}\varphi_{n+1}(e)_n$, 其中 J 是对称三对角矩阵 (对角元 $a_0, \dots, a_{n-1}$, 次对角元 $\sqrt{b_1 b_2 \dots b_{n-1}}$, 即 Jacobi 矩阵)。Gauss 节点是 J 的特征值, 求积权是特征向量的首分量平方乘测度总质量。这就是 Golub–Welsch 算法 (把求积节点与权的计算化归为对称三对角矩阵特征问题的标准算法): 一次对称三对角特征分解 ($O(n^2)$) 同时给出节点与权, 数值稳定性远好于显式构造正交多项式再求根。

第五篇的构基走的就是这条路: Hankel 矩阵 Cholesky 分解给出 a_n, b_n (主章节的公式), Golub–Welsch 给出节点与权 (若需要配点), 整条链没有一处需要显式写出多项式表达式。

2.5 一个可以手算的例子

Legendre ($\rho = 1$ on $[-1, 1]$, $\int \rho = 1$): $\varphi_0 = 1$. 由正交性 $\int \varphi_1 dx = 0$ 与 $\int x\varphi_1^2 dx = 1$ 解出 $\varphi_1 = \sqrt{3}x$. 再设 $\varphi_2 = \alpha x^2 + \beta x + \gamma$, 正交于 1 与 φ_1 给出 $\gamma = -\alpha/3$, $\beta = 0$, 归一化 $\int \varphi_2^2 = 1$ 给出 $\alpha = \sqrt{5}/2$, 即 $\varphi_2 = \sqrt{5}(3x^2 - 1)/2/\sqrt{2} \dots$ (具体常数取决于归一化约定, 形状不变)。递推系数 $a_0 = 0$ (对称测度)、 $b_1 = 1/3$, $b_2 = 4/45$ 的倒数结构已经能看出: Jacobi 矩阵的三对角元里编码了测度的全部信息。

这个例子还有一个用途: 验证三项递推的次数关系。 $x\varphi_1 = \sqrt{3}x^2$ 展开到 φ_2 与 φ_0 上, φ_2 的系数是 $\sqrt{3}/(\sqrt{5}/2/\dots)$ 。读者可以用上面的结果亲手核对, 两分钟内能走完, 走完之后“递推系数决定一切”就不再是口号。

2.6 为什么 Hermite 的 L 因子降不下来

第一篇的三类界里, Jacobi 是常数、Hermite/Laguerre 是 $Cn^{2/3}$ 。差别来源可以在 Christoffel 函数的形状里看到。有界域上 (Legendre), $\sum_j \varphi_j^2(x)$ 在端点最大、内部平缓, Christoffel 函数 K 在端点趋于零但处处有正的下界型行为, 加权 $\sqrt{n\lambda_n}\varphi_j$ 全域有界, 即一致有界系统。

无界域上 (Hermite), Gauss 节点随 n 外跑, 最外节点上的 λ_n 指数式地小, 而多项式值只有代数式地大, 两者之比 $\sqrt{n\lambda_n}|\varphi_j|$ 的上界随 n 增长 (幂律 $n^{2/3}$, Mhaskar–Rahmanov–Saff 尺度 $a_n \sim n^{1/2}$ 与 Levin–Lubinsky 修正 $n^{-2/3}$ 的差就是那个幂)。这不是分析技术不够好: 换任何“只在有限网格上采样”的策略, 最外层节点都会把一致界顶到幂律上。要绕开它只能换策略 (按原密度采样, 第一篇的 $d = 10$ Hermite 数值正是这样更好), 或者接受幂律。这是“结构化网格”路线的边界, 也是第六篇 induced 采样 (网格无关) 的动机之一。

2.7 一个容易踩的坑：两种约定

Christoffel 函数的两种写法 文献里“Christoffel 函数”有两个互为倒数的版本：

$$K(x) = \frac{N}{\sum_j \Phi_j^2(x)} \quad \text{与} \quad \kappa(x) = \frac{1}{N} \sum_j \Phi_j^2(x).$$

K 在多项式能量小的地方大 (采样理论偏好这种点); κ 在能量大的地方大 (预条件用它的倒数压低能量)。本笔记第一、二、五篇用 K , 第六篇用 κ (与原文一致)。读任何一篇采样论文时, 先查它的定义式再读采样方向的陈述, 两个约定差一个倒数, 方向完全相反。

3 预备知识 (下): 稀疏恢复的几何图像

3.1 从 ℓ_0 到 ℓ_1

恢复稀疏向量的“诚实”目标是数非零分量: $\min \|c\|_0$ s.t. $\Psi c = f$ 。这是组合问题 (NP 难)。凸松弛把计数换成绝对值和:

$$\min \|c\|_1 \quad \text{s.t.} \quad \Psi c = f.$$

为什么 ℓ_1 会给出稀疏解? 二维的几何图像:




图 1 ℓ_1 促进稀疏的几何原因 (示意)。扩大 ℓ_1 球 (菱形) 时 最先碰到约束线的是菱形的**顶点**, 即只有一个非零分量的点; ℓ_2 球 (圆) 最先碰到约束线的地方一般在象限内部, 得到的解是稠密的。高维时菱形的“顶点”占绝大多数, 这个效应更强。

3.2 两条判据的分工 (与第二章衔接)

第二章给出的 RIP 与 MIP 是同一件事的两种读法。RIP 要求矩阵对**所有** 稀疏向量近似等距, 是整体性质, 随机采样下以高概率成立, 样本复杂度里有 $\log$ 因子; MIP 只看**最坏的一对列**, 条件强 ($\mu < 1/(2s-1)$), 但可以用逐点估计直接验证, 不需要概率论证。六篇论文的分工: 走概率路线的第一、六篇用 RIP, 走确定性路线的第三篇 (测量矩阵是手工拼的) 用 MIP, 第四篇 (非凸罚) 沿用 RIP 但常数更好。

还有一个实用事实值得放在这里: RIP 检验本身是 NP 难的, 实践中没人去验一个给定矩阵是否满足 RIP; 理论的法是“设计采样方式, 让高概率成立”, 而不是“拿到矩阵再检查”。这也是为什么六篇论文的全部精力都花在**采样测度**上: 测度决定矩阵的系综, 系综决定 RIP 概率。

3.3 最小二乘一侧的稳定性问题

第二、五篇走超定最小二乘路线, 那里的病态来源与欠定情形不同: 即使 $M > N$ (方程够多), Vandermonde 型矩阵的条件数仍可能爆炸。一维的极端例子: 等距节点上的单项式基, 条件数随 N 指数增长 (Lebesgue 常数发散), 数据里的浮点噪声被放大到完全淹没信号。第二篇开头的“等距 Newton–Cotes 点即使数据无穷精确也不稳定”说的就是它。

两条修复路线在谱系里都出现过: 换基 (Chebyshev 权、加权基 $\varphi/\sqrt{K}$, 把能量摊平) 与换点 (Fekete/Leja 式贪心选点)。第二篇证明加权之后两条路线合流: 贪心选出的点让加权矩阵的条件数达到理论下界 1。

4 工具: 稀疏恢复的两把尺子

4.1 RIP: 矩阵级判据

定义 (RIP, 有限等距性质) 矩阵 $D \in \mathbb{R}^{M \times N}$ 满足阶数 s 、常数 δ_s 的 RIP, 如果对所有 s -稀疏向量 v ,

$$(1 - \delta_s) \|v\|_2^2 \leq \|Dv\|_2^2 \leq (1 + \delta_s) \|v\|_2^2.$$

即 D 近似保持所有稀疏向量的长度。 δ_s 越小, 矩阵越“等距”。

RIP 下的恢复定理 (Candès 型) 如下。

定理 (ℓ_1 恢复, RIP 版) 设 D 的 RIC (受限等距常数) 满足 $\delta_s < 0.307$ 。对任意 $\tilde{c} \in \mathbb{R}^N$, $c^\#$ 是基追踪

$$\arg \min \|c\|_1 \quad \text{s.t.} \quad Dc = D\tilde{c}$$

的解, 则

$$\|c^\# - \tilde{c}\|_2 \leq C \frac{\sigma_{s,1}(\tilde{c})}{\sqrt{s}},$$

其中 $\sigma_{s,1}(\tilde{c})$ 是 $\tilde{c}$ 的最佳 s -项逼近误差 (把最小的 $N - s$ 个系数抹掉后的 ℓ_1 尾巴)。特别地, $\tilde{c}$ 恰好 s -稀疏时恢复精确。

读法: 恢复误差由“去掉 s 个最大系数后剩下的尾巴”控制。目标越稀疏 (尾巴越小), 恢复越准。整个压缩感知游戏的玩法因此清晰: 设计采样测度, 让它导出的 D 以高概率满足小 δ_s 。

样本量代价: 随机采样下 RIP 不是白来的。

定理 (随机采样的 RIP, Rauhut–Ward) 点从“正交化测度” ν 独立采样 (含义见下节), 若样本量满足

$$M \geq C\delta^{-2} Ls \log^3(s) \log(N),$$

则以概率至少 $1 - N^{-\gamma \log^3(s)}$, 矩阵 $D/\sqrt{M}$ 的 $\delta_s \leq \delta$ 。

这个形式的每一块都有具体含义: s 线性项 (稀疏度, 省不掉); δ^{-2} (要求越严越贵); 两个对数因子 ($\log$ 项是这类证明的技术代价); 以及 L , 一个由采样测度与多项式系统决定的常数。六篇论文的第一篇 就是要把它在各类分布下显式估计出来, L 越小, 需要的样本越少。

4.2 MIP: 列级判据

第二个判据更直观, 作用在矩阵的列上。

定义 (MIC, 互不相干常数)

$$\mu = \mu(\Phi) = \max_{k \neq j} \frac{|\langle \Phi_k, \Phi_j \rangle|}{\|\Phi_k\|_2 \|\Phi_j\|_2},$$

即任意两列归一化内积的绝对值的最大值。经典结论 (Donoho-Huo、Fuchs、Cai-Wang-Xu): 若 $\mu < 1/(2s-1)$, 则 s -稀疏向量被基追踪精确恢复; 带噪情形稳定。

RIP 与 MIP 的分工: RIP 给出“接近最优”的整体保证, 样本复杂度好; MIP 条件强 ($1/(2s-1)$ 难达到), 但它可以用**逐列的上界** (不依赖样本随机性, 只看基函数与采样测度) 直接验证。梯度增强那篇 (第 9 章) 走的就是 MIP 路线, 因为它的测量矩阵是拼出来的, 列的逐点结构可以手工控制。

两把尺子都指向同一个问题: **采样点从哪个分布抽, 矩阵才“好”?** 下一节开始, 六篇论文按这个问题的六个答案依次展开。

5 理论深处: 三条主定理的证明思路

主章节把六篇的定理当黑盒引用。这一章把其中三条的证明骨架摊开, 摊到“每一步在做什么”的粒度, 不展开纯技术引理。读完后, 概率路线的论文 (第一、六篇) 就不再是不可审计的公告。

5.1 RIP 从哪来: 一致界 + 浓缩

Rauhut-Ward 型定理 ($M \geq C\delta^{-2} Ls \log^3 s \log N$ 概率成立) 的证明分三层, 第一篇的附录是这套流程在“Gauss 网格子采样”上的完整执行。

第一层: 逐点一致界。 要让 $D/\sqrt{M}$ 近似等距, 先要求它的元素不至于爆: 对加权的正交多项式系统, 存在与指标无关的逐点界

$$\sup_x |\psi_{k,n}(x)|^2 \leq L_i(n),$$

$L_i(n)$ 就是主定理里的分布常数 (Jacobi: 常数; 指数型: $Cn^{2/3}$)。第一篇附录的推导 (Mhaskar-Rahmanov-Saff 数定位节点区间 + 加权多项式一致界) 就是在对三类分布分别估计这个 L_i 。所有后续都是概率机器, 这一层是唯一的“硬分析”。

第二层: 矩阵 Concentration。 把 $\|Dv\|_2^2$ 写成 独立采样量的和: 每个样本贡献一个秩一矩阵 $\psi(x_m)\psi(x_m)^T$ 。其期望恰好是单位阵 (离散正交系统的定义), 于是 $\|Dv\|_2^2$ 集中在 $M\|v\|_2^2$ 附近。集中的宽度由两个量决定: 单个秩一项的范数界 (第一层给的 L_i) 与有效维数 N 。矩阵 Bernstein 或 Mendelson 的小球法给出: 样本量 M 达到 $Ls \log^3 s \log N$ 量级时, 对所有 s -稀疏向量 (一个组合规模的族 ($\binom{N}{s}$ 个向量), 所以有 $\log N$ 与 $\log s$ 因子) 一致集中的概率超过 $1 - N^{-\gamma \log^3 s}$ 。

第三层: 从行子采样到 RIP。 满网格的加权矩阵是正交矩阵 (离散正交系统的张量化), 从中无放回抽 M 行: “正交矩阵的随机行子集保持 RIP”是压缩感知的标准引理 (Rauhut 教材的 Corollary 12.38), 其证明同样是第二层的集中论证 加上行范数一致界。

读这份骨架的收获: L 因子出现在**第一层**, 所以它对样本量的影响是乘法性的、不可通过更多采样弥补的; $\log$ 因子出现在**第二层**, 是“对所有稀疏向量一致集中”的代价, 换更精细的论证 (比如 Mendelson 的小球法) 只能改善常数与幂次。

5.2 加权最小二乘的无偏性: 一笔与 induced 采样相同的账

第五篇的加权 LS (采样自 $\kappa\rho$ 、权重 $w = K = 1/\kappa$) 与第六篇的 induced 采样 (采样自经验 $\kappa\omega$ 、权重 $1/\kappa$) 是同一笔账的连续与离散版本。

命题 (加权 LS 的无偏性, 差一个常数) 设采样密度 $\tilde{\rho}(z) = \kappa(z)\rho(z)/c$, $c = \int \kappa\rho$ (归一化常数), 权重 $w(z) = 1/\kappa(z)$ 。对任意 h :

$$E_{z \sim \tilde{\rho}}[w(z)h(z)] = \int (\kappa \rho / c)(h / \kappa) dz = \left(\frac{1}{c}\right) \int h \rho dz.$$

即加权平均等于真期望乘 $1/c$ ；常数与 h 无关，被最小二乘的尺度不变性吸收。

证明. 两个密度相除： $w\tilde{\rho} = (1/\kappa)(\kappa\rho/c) = \rho/c$ 。对 h 积分即得。逐行成立，对矩阵形式 $E[w(z)\psi(z)\psi(z)^T] = (1/c)\mathbf{I}$ 同样成立（逐元素取 $h = \varphi_j\varphi_k$ ）。□

这条命题同时解释了两个设计选择。第一，为什么权重必须是 $1/\kappa$ （而不是别的）：只有它能消掉采样偏置。第二，为什么采样要偏向 κ 大（能量高）的区域：这样 c 有限且估计的方差被 w 的有界性控制。若反过来从 $1/\kappa$ 小的区域多采样， w 会在那里爆炸，方差失控。第五篇的“平衡测度”（ $\kappa\rho$ 的极限）与第六篇的 induced 测度（ $\kappa\omega$ 的离散版）因此是同一个提案分布，一个取了位势论极限、一个停在有限样本。

5.3 稀疏性从哪来：随机 PDE 解的系数衰减

压缩感知配点法成立的前提是“解在多项式基下稀疏”。这不是经验观察，对椭圆方程有定理级的依据（Cohen– DeVore–Schwab 2010 起的分析；Babuška–Nobile–Tempone 的早期数值证据）。

定理（稀疏性，叙述形式） 设扩散系数由仿射随机场给出： $\kappa(x, y) = \bar{\kappa}(x) + \sum_{j \geq 1} \kappa_j(x)y_j$ ，其中 $\sum_j \|\kappa_j\|_{L^\infty}$ 一致可和（随机场的相关长度短时自然满足）。则解的 gPC 系数满足指数型衰减：

$$\|u_\nu\|_{L^2} \leq Ce^{-c\sum_i \nu_i} \quad \text{对某个与 } \nu \text{ 无关的 } c > 0.$$

即按系数向量的“总次数”衰减，重要的系数集中在低次数、少数活跃维度上。

读法：衰减率 c 由随机场的**能量谱**决定， $\|\kappa_j\|$ 衰减越快（相关长度越短，KL 特征值衰减越快），解越稀疏，压缩感知越省样本。这也解释了第一篇到第六篇实验里反复出现的模式：相关长度长（ l_c 大）的场难恢复，相关长度短（ l_c 小）的场好恢复。反向推论同样有用：如果实际问题里输入场的相关结构未知且可能平缓（ $\sum \|\kappa_j\|$ 接近临界），稀疏假设本身要先用数据检验（第六篇的“作者如实说明高维低次时 induced 与 MC 相当”就是这种情形）。

5.4 互不相干路线的逐点界

第三篇走的 MIP 路线不需要概率集中，它的全部内容逐点估计。对加权后的测量矩阵 $\hat{\Phi} = \mathbf{W}\tilde{\Phi}\mathbf{P}$ ，互不相干常数由逐列上界控制：

$$\mu(\hat{\Phi}) \leq \max_i \sup_z \frac{\|\hat{\Phi}_i(z)\|_2^2}{\min_i \|\hat{\Phi}_i\|_2}.$$

分子的逐点界由“Jacobi 导数恒等式 + 加权一致界”给出（第三篇定理里的 $2e(2 + \sqrt{\alpha^2 + \beta^2})$ 因子），分母由列归一矩阵 $\mathbf{P}$ 抬高。这套论证与第一层一致界是同一技术（加权多项式的逐点估计）在不同矩阵上的应用。这也是为什么六篇论文共享同一个数学工具箱。

6 第一篇：Gauss 求积网格上的随机子采样（SISC 2017）

6.1 要解决的问题

压缩感知用到随机 PDE 时，前人的采样策略有两类：直接从原密度 ρ 独立采样（Doostan–Owhadi；Yan–Guo–Xiu），或从 Chebyshev 测度采样配预条件（Rauhut–Ward 的 Legendre 情形；Tang–Zhou 把“张量积 Gauss 网格子采样”用在均匀分布 + Legendre 上）。Guo–Narayan–Zhou–Chen（SISC 2017）把 Tang–Zhou 的结构化采样推广到**几乎全部经典一元分布**：任意 Beta 权（有界域）与单、双侧指数权（无界域，含 Hermite 与 Laguerre）。

网格子采样比自由采样多两样东西。第一，点被限制在求积网格上，采样是离散抽取，实现简单且可复现；第二，求积网格自带一套权重（Christoffel 函数），用它做预条件后 测量矩阵恰好是正交矩阵的行子集，分析可以进行到底。

6.2 构造

对每个维度取 n_i 点 Gauss 求积法则：节点 z_k^i ，权重 w_k^i ，以及 Christoffel 函数

$$\lambda_n^i(x^i) = \frac{1}{\sum_{k=0}^{n-1} (\varphi_k^i(x^i))^2}.$$

构造离散经验测度 $\nu_n^i = \frac{1}{n} \sum_{k=1}^n \delta_{z_k^i}$ ，张量化为 $\nu_n = \times_i \nu_n^i$ 。采样即从这批有限网格点里无放回抽 M 个。

关键的预条件加权：定义

$$\psi_{k,n}^i(x^i) = \sqrt{n\lambda_n^i(x^i)} \varphi_k^i(x^i),$$

即“多项式乘以 Christoffel 权重的平方根”。

引理（离散正交系统） $\psi_{k,n}^i$ 在离散测度 ν_n^i 下正交归一：

$$\frac{1}{n} \sum_{p=1}^n \psi_{j,n}^i(z_p^i) \psi_{k,n}^i(z_p^i) = \delta_{j,k}.$$

多元版本 $\psi_{k,n}(z) = \prod_i \psi_{k_i, n_i}^i(z^i)$ 在 ν_n 下正交归一。

证明. 由 Gauss 求积的精确性 (n 点法则对次数 $\leq 2n-1$ 的多项式精确)：

$$\frac{1}{n} \sum_{p=1}^n n\lambda_n^i(z_p^i) \varphi_j^i(z_p^i) \varphi_k^i(z_p^i) = \sum_{p=1}^n w_p^i \varphi_j^i(z_p^i) \varphi_k^i(z_p^i) = \int \varphi_j^i \varphi_k^i \rho^i = \delta_{j,k}.$$

第一步把 $n\lambda_n$ (Christoffel 权重) 搬进取权和后恰好等于求积权；第二步用求积精确性换成连续积分；第三步用基的正交性。多元版由乘积结构直接张开。□

这个引理是全篇的引擎：它说明“带权多项式在离散测度下构成一个正交系统”，于是张量化的加权测量矩阵是**离散正交矩阵 (DOM)**，而正交矩阵的行子采样恰好是 RIP 理论最成熟的对象（无放回子采样仍保持 RIP, Rahut）。

6.3 主定理：样本量准则

定理（主定理，样本量） 设 Λ 是大小为 N 的有限指标集， $\mathbf{n}$ 是使 $\Lambda \subseteq \Lambda_{\mathbf{n}-1}^P$ 的最小多重指标。从测度 ν_n 无放回抽 M 个样本，若

$$M \geq L(\mathbf{n}) C_1 s \log^3(s) \log(N),$$

$L(\mathbf{n}) = \prod_{i=1}^d L_i(n_i)$ ，则加权 ℓ_1 优化问题的解 $\mathbf{c}^\#$ 满足

$$\Pr \left[\|\mathbf{c} - \mathbf{c}^\#\|_2 \leq C_2 \frac{\sigma_{s,1}(\mathbf{c})}{\sqrt{s}} \right] \geq 1 - N^{-\gamma \log^3(s)}.$$

读法：需要的样本数 = 稀疏度 $\times$ 分布常数 $\times$ 对数因子。分布常数 L 是唯一随分布与维数变化的部分，它的大小决定这条路在高维下是否还便宜。以下引理把 L_i 在三类分布下显式估出。

引理（三类分布的 L_i 上界）

- **Jacobi 权** ($\rho^i \propto (1-x)^\gamma(1+x)^\delta$, $\gamma, \delta \geq -1/2$, 含 Legendre 与 Chebyshev): $L_i(n) \leq C(\gamma, \delta)$, 与 n 无关 (一致有界系统);
- **双侧指数权** ($\rho^i \propto \exp(-|x|^\alpha)$, $\alpha > 3/2$, 含 Hermite): $L_i(n) \leq Cn^{2/3}$;
- **单侧指数权** ($x \geq 0$, $\alpha > 3/4$, 含 Laguerre): $L_i(n) \leq Cn^{2/3}$ 。

证明. 证明链分三步 (附录)。 **第一步, 定位节点区间。** 用 Mhaskar-Rahmanov-Saff 数 $a_n^W = (n\sqrt{\pi}\Gamma(\alpha/2)/\Gamma(\alpha/2 + 1/2))^{1/\alpha}$ 确定时间尺度, Levin-Lubinsky 定理保证 Gauss 节点落在 $[-\hat{a}_n^W, \hat{a}_n^W]$ 内, $\hat{a}_n^W = a_n(1 + cn^{-2/3})$ 。 **第二步, 逐点界。** 在该区间上引用加权多项式的一致上界 $\sup |\psi_{k,n}|^2 \leq C(\alpha)n^{2/3}$ (Jacobi 情形右端是常数: 有界区间上 Christoffel 权重恰好抵消端点的多项式增长)。 **第三步, 矩阵级。** 满 DOM 矩阵 A ($(A)_{p,q} = \sqrt{w_{l(p)}}\varphi_{k(q)}(z_{l(p)})$) 是正交矩阵; 逐项估计

$$\left(\prod_{i=1}^d \sqrt{n_i}\right) |A_{p,q}| = \prod_{i=1}^d |\psi_{n_i}| \leq \prod_{i=1}^d \sqrt{L_i(n_i)} = \sqrt{L(\mathbf{n})},$$

再引用“正交矩阵无放回行子采样仍保持 RIP”的结果完成。□




图 2 上界 L_i 的形状 (论文 1602.00995)。左: Jacobi 情形的界随参数变化, 与 n 无关; 右: Hermite/Laguerre 情形的 $n^{2/3}$ 界。有界分布 (Legendre/Chebyshev) 是这条路的最爱: L 是常数, 样本量只比最优多 C^d 的维数代价 (数值上接近 $2^d s \log^3 s \log N$)。

无界分布的 $n^{2/3}$ 是本质的 Hermite (高斯输入) 情形 $L_i \sim n^{2/3}$ 不是技术瑕疵: 子采样分析策略下 它已经是这种分析策略下的下确界(sharp), 不是技术瑕疵。直觉: 无界域上 Gauss 节点越跑越远, Christoffel 权重在尾部的增长赶不上多项式的增长。数值实验也确认: $d = 10$ 时按原密度随机采样 (L 型分析不适用) 反而更好。这提示“采样测度与多项式系统要配套”, 也是后来 induced sampling (第 14 章) 的动机之一。




图 3 左: $M = 85$ 时稀疏 Legendre 展开的恢复概率 ($d = 2$ 与 $d = 10$), Gauss 网格子采样 (Gaussian) 与其他采样策略的对比, 低维高维都不劣或更优。右: $d = 3$ 随机椭圆 PDE 的均值 ℓ_2 误差, Gauss 子采样与高精度稀疏网格参考解一致。

7 第二篇：加权近似 Fekete 点 (确定性采样)

7.1 换一条路：超定最小二乘

第一篇处理 $M < N$ (欠定 + ℓ_1)。如果样本量 M 能略超 N ($M = 1.05N$ 这类轻度过采样), 可以用普通最小二乘: 求解稳定、代价低、不需要 ℓ_1 优化器。但最小二乘对点的位置敏感: 等距的 Newton-Cotes 点即使数据无穷精确也高度不稳定 (Vandermonde 病态), 除非大量过采样。随机路线已知: 无权 Legendre + 均匀 MC 需要 $M \sim N^2$ (Cohen-Davenport-Leviatan); Christoffel 加权最小二乘 加平衡测度采样可以达到接近最优的 $M \sim N$ (Narayan-Jakeman-Zhou)。

Guo-Narayan-Yan-Zhou (2017) 走确定性路线: 贪心选点, 选出一组“条件数最优”的点集, 并证明加权之后贪心等于全局最优。

7.2 构造：把 Christoffel 权重塞进基

对指标集 Λ (大小 N), 定义未归一化 Christoffel 函数 $K_\Lambda(y) = \sum_{\alpha \in \Lambda} \psi_\alpha^2(y)$, 然后定义加权多项式空间

$$Q = Q(\Lambda) = \text{span} \left\{ \frac{\psi_\alpha}{\sqrt{K_\Lambda(y)}} \mid \alpha \in \Lambda \right\}.$$

直觉: K_Λ 大的地方 (多项式容易取大值的地方), 基函数被压低, 于是加权后的基在整个域上“能量均匀”。加权最小二乘为

$$\hat{f} = \arg \min_v \|V(A_M, Q)v - Wf\|_2, \quad (W)_{m,m} = 1/\sqrt{K_\Lambda(y_m)},$$

V 是加权 Vandermonde 矩阵 (元素为各基函数在各采样点取值的矩阵): 第 (j, k) 元是第 k 个基在第 j 个点上的值, 多项式插值的稳定性由它的条件数决定。四类点集的定义: Fekete 点 $A_N^F = \arg \max |\det V|$ (行列式最大 = 插值意义下张得最开), 最优条件数点集 $A_N^C = \arg \min \kappa(V)$, 以及两者的贪心版 (每次加一个点, 让目标最优)。

7.3 主定理：贪心 = 全局最优

定理 (nd-optimal) 设 ρ 是 $\mathbb{R}^d$ 上的概率密度 (不要求紧支撑!), Λ 是大小为 N 的任意指标集。点集 A_N 满足

$$|\det V(A_N, Q)| = 1 \quad \text{当且仅当} \quad \kappa(V(A_N, Q)) = 1.$$

且若最优集存在，贪心迭代有一条分支能取到它。

证明. 对每个加权行 $\psi(y_j) = (\psi_1(y_j)/\sqrt{K}, \dots)$ 有恒等式 $\|\psi(y_j)\|_2 = 1$ (定义直接验证: 分母就是行自身的平方和)。由 Hadamard 不等式 $|\det A| \leq \prod_i \|a_i\|_2$ 且各行范数全是 1, 所以 $|\det V| \leq 1$, 等号当且仅当各行两两正交, 即 V 是正交矩阵、条件数 $\kappa = 1$ 。贪心部分用归纳: V^T 的 QR 分解给出 $|\det(VV^T)| = r^2$, $r = \sqrt{1 - \|b\|_2^2} \leq 1$, 等号当且仅当新点与已有的加权向量正交; 只要最优集中的点可被贪心逐个达成 (每次选到与已选集合正交的点), 贪心分支就收敛到全局最优。□

一维情形的结构可以完全写出来。

定理 (1d-optimal) $\Gamma = \mathbb{R}$ 、 $\Lambda = \{0, \dots, N-1\}$ 时, 对任意密度 ρ , 最优点集由比值 $r_N(y) = \varphi_N(y)/\varphi_{N-1}(y)$ 的水平集给出 ($A_N(y) = r_N^{-1}(r_N(y))$); 它恰好是一条对次数 $\leq 2N-2$ 多项式精确的正求积法则的节点。取初值 y_1 为 φ_{N-1} 的零点时,

$$A_N^C(Q) = A_N^{C*}(Q) = A_N^{F*}(Q) = A_N^F(Q), \quad |\det V| = 1 = \kappa.$$

即: 一维任意分布下, 贪心加权 Fekete 点几乎总是产生 Gauss 求积节点。




图 4 条件数对比 (论文 1708.01296, $M = 1.05N$, 50 次试验的分位数)。左: $d = 2$ Legendre (TD 与 HC 两种指标集), CFP (加权贪心) 的条件数显著低于 AFP (无权贪心) 与 MC 随机点。右: $d = 25$ Hermite, 高维下改善幅度变小但排序不变: $CFP \geq AFP \geq MC$ 。

这篇解决了什么、放弃了什么 解决: AFP (经典近似 Fekete 点) 需要紧支撑 (平衡测度理论依赖紧性), 加权版本 $1/K_\Lambda$ 让它在高斯这类非紧集上同样良定义; 而且加权后贪心有全局最优性证明 (无权版本没有)。放弃: 确定性点集失去了随机采样的概率化误差分析; 点数固定在 N 附近, 覆盖不了 $M \ll N$ 的重欠定区, 那里仍是 ℓ_1 的适用范围。两篇论文合起来恰好覆盖超定与欠定两个区段。

随机椭圆 PDE 实验 ($\kappa(x, y) = 1 + \sigma \sum_k \cos(2\pi kx) y_k / (k^2 \pi^2)$, 类 KL 展开形式) 中, CFP 在 $d = 2$ 到 25 的全部指标集上与 AFP 相当或更好、远好于随机点, QoI 取 $u(0.5, y)$ 。




图 5 扩散方程实验 (论文 1708.01296, $d = 2$): CFP 与 AFP 的逼近误差 随样本量的下降曲线几乎重合 且都远优于 MC。确定性点集在超定区 是“免调参”的选择。

8 第一、二篇补充：实验画廊与一维最优性的完整推导

8.1 第一篇：六组实验的完整记录

主章节给出了主线结果 (Legendre 恢复、PDE)。这里补齐其余五组，它们共同回答一个问题：网格子采样在什么情况下不占优。

Chebyshev 展开 ($d = 2$ 与 $d = 10$, $M = 85$): Chebyshev 多项式在 Chebyshev 网格上的表现与 Legendre 在 Gauss-Legendre 网格上的表现平行, “基与网格配套”的原则在第二族上同样成立。

单项式基的反例: 同样的采样点换单项式基 x^α , 恢复完全失败。原因在预备章的框架下很清楚: 单项式不正交, Gram 矩阵严重病态, 加权 $\sqrt{n\lambda_n}$ 也救不了它。这组实验的作用是划界: 方法的成功绑定在“正交基 + 配套测度”上, 不是采样技巧单独的功劳。

随机 ODE ($du/dt = -k(X)u$, $k(X) = \beta X$, 高斯输入, $n = 30$): 一维 Hermite 情形, Gauss 网格子采样与按原密度采样相当, 验证无界分布的 $n^{2/3}$ 代价在实践中不严重 ($n = 30$ 时 $n^{2/3} \approx 9.7$, 常数因子级别)。

Hermite 函数 ($f_1 = 2^{-0.2x_1^2-0.2x_2^2}$, $f_2 = e^{-0.6x_1-0.6x_2}$, $d = 2$): 小 M 时各方法差距不明显, 大 M 时 Gauss 子采样领先; 与稀疏恢复实验的结论一致: **恢复阶段** (系数完全稀疏) 对采样最敏感, 逼近阶段 (系数衰减但非零) 各方法都被逼近误差主导。




图 6 左: $d = 2$ 稀疏 Chebyshev 展开的恢复概率 ($M = 85$), 网格子采样 (Gaussian 列) 与对照方法在两族基上行为平行。右: 单项式基的反例: 同样的采样点配单项式基, 误差不随 M 下降。方法的成功绑定在“正交基 + 配套测度”上。




图 7 左: 随机 ODE (高斯输入) 的逼近误差随 M : 一维 Hermite 情形 网格子采样可用。右: Hermite 函数 f_1 的逼近误差: 小 M 时各方法 差距不大, 大 M 时网格子采样领先。

8.2 第二篇：一维最优性的推导链

主章节引用了“贪心 = 全局最优”与“一维退化为 Gauss 点”两个定理。这里把一维那条的推导走完，因为它短，而且每一步都用到了预备章的材料。

设定: $\Gamma = \mathbb{R}$ 、 ρ 任意密度、 $\Lambda = \{0, \dots, N-1\}$ 。要证的: 加权贪心点集 A_N^{F*} 是一条 n 点正交求积法则的节点，因而行列式与条件数同时最优。

第一步：最优集的结构。 对任意不在 φ_{N-1} 零点集内的参数 y ，定义比值

$$r_N(y) = \varphi_N \frac{y}{\varphi_{N-1}}(y),$$

最优集是水平集 $A_N(y) = r_N^{-1}(r_N(y))$: N 个点 z 满足 $r_N(z) = r_N(y)$ 。直观: r_N 是“下一基函数的预测比值”，让所有点共享同一个比值的配置使 Gram 矩阵最平衡。

第二步：行正交性。 加权行 $\psi(z) = (\varphi_j(z)/\sqrt{K_\Lambda(z)})_{j=0}^{N-1}$ 的两两内积由 Christoffel–Darboux 恒等式 (预备章提到的核函数恒等式，把 $\sum_j \varphi_j(x)\varphi_j(y)$ 化成 $\varphi_N\varphi_{N-1}$ 的差商) 化为

$$\psi^T(z_j)\psi(z_k) \propto \frac{r_N(z_j) - r_N(z_k)}{z_j - z_k},$$

于是 $r_N(z_j) = r_N(z_k)$ ($j \neq k$) 当且仅当行正交。水平集构造让所有 $r_N(z_k)$ 相等，正交性成立，行列式达到上界 1（Hadamard 论证，主章节已给）。

第三步：与求积法则重合。 行正交的 N 个点配上权 $1/K_\Lambda(z_k)$ 恰好构成对次数 $\leq 2N - 2$ 多项式精确的正求积法则（预备章“求积权 = Christoffel 函数”的引理反过来用）；而 $2N - 2$ 精度的 N 点法则唯一，就是 Gauss 法则。取参数 y 落在 φ_{N-1} 的零点时，水平集退化成 φ_N 的零点集，正是 N 点 Gauss 节点。

这条推导的解释力在于：**一维情形贪心点列的极限是 Gauss 求积节点** 不是巧合，而是“行列式最优 $\Rightarrow$ 正交 $\Rightarrow$ 求积”三件事的等价链。高维没有这个唯一性（Gauss 求积张量积不再是唯一最优集），所以定理只在一维给出完整等式，高维只有不等式（贪心 $\leq$ 全局最优）。

8.3 第二篇：条件数与精度的完整记录




图 8 Legendre 情形的条件数 ($M = 1.05N$, 50 次试验, 20%/80% 分位)。左: $d = 6$ (TD 指标集); 右: $d = 10$ (HC 指标集)。加权 Fekete (CFP) 的条件数在最坏情形仍接近 1, 随机采样 (MC) 随 N 增长, 无权贪心 (AFP) 居中。




图 9 左: $d = 10$ Hermite (HC 指标集) 的条件数: 三种点集的差距比 Legendre 情形小, 与第一篇“无界域 L 因子较大、各方法差距缩小”的观察一致。右: 扩散方程 $d = 25$ (HC 指标集) 的 QoI 逼近误差: 高维下 CFP 与 AFP 相当、远好于 MC, 验证确定性点集可以走到 $d = 25$ 。




图 10 扩散方程 $d=2$ 与 $d=6$ 的 QoI 逼近误差 ($u(0.5, y)$, 随机系数为类 KL 展开的余弦级数)。CFP 与 AFP 的曲线几乎重合, 都显著低于随机采样。确定性点集在超定区是免调参的选择。

9 第三篇：把导数信息塞进测量矩阵 (2018)

9.1 要解决的问题

黑箱模拟的每次查询都昂贵, 但很多问题里**梯度可以廉价获得**: 伴随方程 (adjoint) 方法用一次额外求解就能给出目标泛函对全部参数的梯度 (伴随方程是原方程的对偶形式, 解它的代价与解原方程同阶, 这是它相对“逐参数差分”的根本优势)。放着不用是浪费。Peng 等 (2016) 已经在 Hermite + 高斯采样的组合里把梯度信息加进 ℓ_1 ; Guo-Narayan-Zhou (2018) 做了两件事: 给出预条件器的一般设计框架 (覆盖有界与无界域的全部经典多项式族), 并证明加入导数测量“几乎必然”改善稀疏恢复条件。

9.2 问题格式

把导数行拼进测量矩阵。函数值测量与梯度测量堆叠:

$$\tilde{f} = \begin{pmatrix} f \\ f_\partial \end{pmatrix}, \quad \tilde{\Phi} = \begin{pmatrix} \Phi \\ \Phi_\partial \end{pmatrix}, \quad \Phi_\partial = \begin{pmatrix} \frac{\partial \Phi}{\partial x_1} \\ \vdots \\ \frac{\partial \Phi}{\partial x_d} \end{pmatrix},$$

即每个采样点贡献 $d+1$ 行 (函数值 1 行 + 各方向导数 d 行), $\tilde{\Phi} \in \mathbb{R}^{N(d+1) \times M}$ 。梯度增强基追踪:

$$\arg \min_{\mathbf{c}} \|\mathbf{c}\|_1 \quad \text{s.t.} \quad \mathbf{W} \tilde{\Phi} \mathbf{P} \mathbf{c} = \mathbf{W} \tilde{f}.$$

直接拼接会坏事 两个新矩阵各有职责, 缺一不可。 $\mathbf{W}$ 是行预条件 (按基与采样测度加权), $\mathbf{P}$ 是列归一 (按指标加权)。数值实验显示: 不预条件的 $\tilde{\Phi}$ 的互不相干常数比原矩阵 Φ 更差: 导数行的引入破坏了平均各向同性 ($E[1/N \tilde{\Phi}^T \tilde{\Phi}] = \mathbf{I}$), 采样点一偏, 导数行的范数就失衡。设计 $\mathbf{W}, \mathbf{P}$ 使 widehat 矩阵恢复各向同性, 是本篇的核心贡献。

9.3 预条件的设计: 来自导数正交性

设计能显式写出, 靠的是一条正交恒等式。以 Legendre 基 + Chebyshev 采样为例: Legendre 多项式的导数关于权 $(1-x^2)$ 正交, 由此得

$$E^c \left[\frac{2^d}{\rho_c} \psi_i(z) \psi_j(z) + \sum_{k=1}^d \frac{1-z_k^2}{\rho_c} \psi_i(z) \frac{\partial \psi_i}{\partial x_k}(z) \frac{\partial \psi_j}{\partial x_k}(z) \right] = \delta_{ij} \left(1 + \sum_{k=1}^d c_k i_k (i_k + 1) \right),$$

读法: 函数值行与导数行在 Chebyshev 测度 ρ_c 下的加权内积**依然对角**, 而且对角元显式等于 $1 + \sum_k c_k i_k (i_k + 1)$ (c_k 是第 k 个导数行的权重系数, i_k 是该指标的次数)。于是取

$$(W^0)_{n,n} = \left((4/\pi^2) \left(1 - \left(z_j^{(n)} \right)^2 \right) \right)^{d/4}, \quad (W^j)_{n,n} = (W^0)_{n,n} \left(1 - \left(z_j^{(n)} \right)^2 \right)^{1/2} / \sqrt{2},$$

$$(P)_{i,i} = \left(1 + \sum_k c_k i_k (i_k + 1) \right)^{-1/2},$$

三件套合起来恰好让 $\hat{\Phi} = \mathbf{W}\tilde{\Phi}\mathbf{P}$ 满足平均各向同性。Jacobi + Chebyshev、Hermite + Gaussian 两个组合有平行公式（Hermite 最简单：导数对同一测度正交， $\mathbf{W} = \mathbf{I}$ ， $P_{ii} = \left(1 + \sum_k i_k \right)^{-1/2}$ ）。一个结构性事实限制了 this 框架的适用范围：**导数仍是同族正交多项式的一元族只有 Jacobi、Laguerre、Hermite 三族**（Hahn 1935 的经典结果），所以这套显式预条件只在这三族上闭式可写；其他基要换成导数 Gramian 矩阵（各列两两内积组成的对称矩阵）的逆平方根（数值预处理）。

9.4 恢复保证

定理(coherence 界与零空间) 记 $\mu_L(\Phi) = \sup_{i,z} |\Phi_i(z)|_2^2$ (逐列上界型 coherence, Hampton–Doostan 意义)。对 Jacobi 展开配 Chebyshev 采样：

$$\mu_L(\Phi) \leq \prod_{j=1}^d 2e \left(2 + \sqrt{\alpha_j^2 + \beta_j^2} \right), \quad \beta_L(\hat{\Phi}) \leq C \prod_{j=1}^d 2e \left(2 + \sqrt{\alpha_j^2 + \beta_j^2} \right),$$

其中 $1 \leq C \leq 1 + \sqrt{2}/2$ (与维数无关)。并且

$$\mathcal{N}(\hat{\Phi}) \subset \mathcal{N}(\Phi),$$

Φ 欠定时几乎必然是真子集。

读法有三层。第一，两个 coherence 常数都是“与次数无关的常数乘 d 次幂”，梯度增强没有恶化样本复杂度的阶。第二，零空间包含说明梯度增强的解空间严格更小：能在增强矩阵下有非零零空间向量的 ℓ_1 问题更少，恢复严格不差（ $\hat{\Phi}$ 是 Φ 的可逆后乘意义下的子矩阵）。第三，作者诚实说明：理论上没能证明 $\beta_L \leq \mu_L$ (严格更优的 coherence)， “更好”目前由零空间包含与数值实验支撑。




图 11 左：三个矩阵的 MIC 随样本数的变化 ($d = 2, n = 30, s = 8$)：预条件后的梯度增强矩阵 (GraLeCh) 常数最小且稳定，未预条件的拼接矩阵反而最差，这张图是预条件必要性的最直观证据。右：恢复率随样本数（实线）与梯度可用比例（虚线）上升， $d = 2$ 与 $d = 10$ 的部分梯度场景同样受益。

PDE 实验（随机椭圆方程， $d = 3, 10$ ，梯度由伴随方程获得）：梯度增强的均值与方差误差全面低于同信息量的标准 ℓ_1 ，也低于“把导数行换成同等数量的函数值行” (standard-double)，说明梯度行携带的信息类型本身有价值。

10 第四篇：换罚函数 (TL1, 2018)

10.1 要解决的问题

ℓ_1 有两个已知弱点：它不一定给出最稀疏的解 (ℓ_1 球与 ℓ_0 球只在正交变换下重合)；测量矩阵相干 (列相关性高) 时表现变差。非凸罚更贴近 ℓ_0 ： $\ell_p (p \in (0, 1))$ 、 ℓ_{1-2} 都有文献，Guo-Li-Liu (2018) 采用 Zhang-Xin 提出的 TL1 (transformed ℓ_1) 罚，配 DC 算法 (DCA) 求解，并改进了恢复理论。

10.2 罚函数

$$\rho_a(|t|) = \frac{(a+1)|t|}{a+|t|}, \quad P_a(x) = \sum_i \rho_a(|x_i|).$$

参数 a 是一个插值旋钮： $a \rightarrow 0^+$ 时 ρ_a 趋近逐点计数 (ℓ_0 ，强稀疏促进)； $a \rightarrow \infty$ 时 $\rho_a \rightarrow \ell_1$ (凸)。 ρ_a 单调递增且凹，导数在零点连续有界 (这是 DCA 可行的条件)。优化问题： $\min P_a(x)$ s.t. $Ax = b$ ，或带噪版本 $\min P_a(x)$ s.t. $\|Bx - b\|_2 \leq \varepsilon$ 。

算法 (DCA-TL1) 把罚写成差之差 (DC) 分解 $\min(a+1)/a\|x\|_1 - \{(a+1)/a\|x\|_1 - P_a(x)\}$ ，外层迭代算超梯度、内层 ADMM 型迭代；自适应版本对候选集 $a \in \{0.05, 0.1, 0.2, 0.3, 1\}$ 各解一次、保留最稀疏的解，解决“非稀疏目标无法先验定 a ”的问题 (稀疏函数的经验最优是 $a = 0.3$)。




图 12 罚函数的等值线 (论文 1805.05416)。左： ℓ_1 的菱形等值线；右：TL1 ($a = 1$) 的等值线，坐标轴附近更“尖”，压小系数的力度更强。 a 越小等值线越贴近坐标十字 (越像 ℓ_0)， a 越大越接近左图。

10.3 恢复理论 (比前人更干净)

定理 (无噪恢复) 设 $\delta_{2s} < \frac{1}{1+(a+1)/a\sqrt{2}}$ ，则 TL1 的解 $\hat{x}$ 满足

$$\|\hat{x} - x\|_2 \leq C_0 s^{-1/2} P_a(x - x_s), \quad C_0 = \frac{(6\sqrt{2}a - 2a + 2\sqrt{2})\delta_{2s} + 2a}{a - ((\sqrt{2} + 1)a + \sqrt{2})\delta_{2s}},$$

x 恰好 s -稀疏时恢复精确。

定理 (带噪恢复) 同样的 RIP 条件、 $\|e\|_2 \leq \varepsilon$ 时：

$$\|\hat{x} - x\|_2 \leq C_0 s^{-1/2} P_a(x - x_s) + C_1 \varepsilon, \quad C_1 = \frac{2(2a+1)\sqrt{1+\delta_{2s}}}{a - ((\sqrt{2} + 1)a + \sqrt{2})\delta_{2s}}.$$

证明链沿用 Candès 的 RIP 分析模板： $P_a(\hat{x}) \leq P_a(x)$ 出发，把残差 h 按 s 个指标分块 $h_{T_0}, h_{T_1}, \dots$ ，用三角不等式型引理 $P_a(h_{T_0^c}) \leq P_a(h_{T_0}) + 2P_a(x_{T_0^c})$ 与分块和的控制 $\sum_{j \geq 2} \|h_{T_j}\|_2 \leq s^{-1/2} P_a(h_{T_0^c})$ ，最后 RIP 配 Cauchy-Schwarz 收尾。

与前人结果的对比（选一）： ℓ_{1-2} 的恢复条件是 $\delta_{2s} < \frac{1}{1+\sqrt{2}+(2\sqrt{2})/(\sqrt{s}-1)}$ （依赖 s ），TL1 在 $a > (\sqrt{s}-1)/2$ 时条件更宽松、误差常数更简洁；Zhang–Xin 原始定理的条件含 δ_R 与 $\delta_{R+|T|}$ 两项，本篇化简为单一 δ_{2s} 。

10.4 在 gPC 上的落点

定理（稀疏 Legendre gPC 恢复） 测量矩阵由 Legendre 多项式 + 均匀测度采样构成。若

$$M \geq C\delta^{-2}3^P s \log^3(2s) \log(N), \quad \delta < \frac{1}{1 + (a+1)/a\sqrt{2}},$$

则以概率超过 $1 - N^{-\gamma \log^3(2s)}$ ：无噪 $\|\hat{x} - x\|_2 \leq C_0 s^{-1/2} P_a(x - x_s)$ ；带噪再加 $C_1 \varepsilon$ 。

证明链：Legendre 加权 $(1-x^2)^{1/4}$ 构成一致有界系统 $\rightarrow$ Rauhut–Ward RIP $\rightarrow$ 代入 TL1 恢复定理。注意采样侧完全沿用第一篇的框架：这篇换的是罚函数，不是采样，两篇是正交的改进，可以叠加。




图 13 左： $d=2$ 稀疏恢复概率随 M 与 s 的变化，排序为 $\text{TL1} > \ell_{1-2} > \ell_1$ 。右：随机 KdV 方程（随机强迫 KL 展开）的 gPC 系数幅值图：TL1 恢复出的系数最稀疏，非零系数的位置与真值一致而幅值更集中。

11 第三、四篇补充：梯度信息的完整记录与非凸罚的证明链

11.1 第三篇：三族测试函数与高维部分梯度

主章节给了 MIC 对比与恢复率。这里补齐函数逼近与 PDE 的完整记录，外加一个重要的推广讨论。

三个测试函数 ($d=2$, $n=20$, 标准 ℓ_1 与梯度增强的对比)：球面函数 $f_1 = \sum_i x_i^2$ （梯度线性，信息量最大）、高斯脉冲 $f_2 = \exp(-\sum_i 0.01(1/2(x_i+1) - 0.375)^2)$ （梯度局部化）、多频正弦 $f_3 = \sum_i 0.3 + \sin(16/15x_i - 0.7) + \sin^2(\cdot)$ （梯度振荡）。三者的共同结论：梯度增强把 RMSE 压低一半以上，对梯度结构最不敏感的是 f_1 、最敏感的是 f_3 。

梯度信息的两种“部分可用”：实际工程里往往只有一部分参数的梯度（比如只对边界条件有伴随），或只有方向导数 $D_{v_t} f(z^{(j)}) = \langle \nabla f(x), v_t \rangle|_{x=z_j}$ （某个物理方向的敏感度）。论文的框架对两者都开放：测量矩阵的“导数行”可以只拼入可用方向，预条件矩阵按可用方向缩放。 $d=10$ ($n=3$, $s=6$) 的部分梯度实验显示恢复率随可用方向的比例单调上升，全梯度与 10% 梯度之间的差距主要在小样本区。




图 14 测试函数逼近误差 ($d = 2$)。左：球面函数（梯度线性）；右：多频正弦（梯度振荡，梯度增强收益最大的情形）。两图中梯度增强（GraLeCh）都显著低于同信息量的标准 ℓ_1 。




图 15 左：MIC 随 gPC 项数的变化 ($d = 3, n = 80$)：预条件后的 梯度增强矩阵在全部项数上保持最低常数，验证预条件的尺度无关性。右：随机椭圆 PDE ($d = 10$) 的均值误差：梯度由伴随方程获得，梯度增强全面占优。

11.2 第四篇：TL1 带噪恢复的证明链

主章节给的是无噪定理。带噪版本（定理 3.6）的证明链值得完整记录，因为它是 Candès RIP 分析模板在非凸罚上的移植，读一遍就能看出“哪一步依赖凸性、哪一步不依赖”。

证明. 记 $\mathbf{h} = \hat{\mathbf{x}} - \mathbf{x}$ ，目标是 $\|\mathbf{h}\|_2 \leq C_0 s^{-1/2} P_a(\mathbf{x} - \mathbf{x}_s) + C_1 \varepsilon$ 。

第一步（罚的单调性）。 $\hat{\mathbf{x}}$ 是最优解，故 $P_a(\hat{\mathbf{x}}) \leq P_a(\mathbf{x})$ 。用三角不等式型引理 $\rho_a(|u|) - \rho_a(|v|) \leq \rho_a(|u - v|)$ 把真解的贡献拆走，得到对残差的约束 $P_a(\mathbf{h}_{T_0^c}) \leq P_a(\mathbf{h}_{T_0}) + 2P_a(\mathbf{x}_{T_0^c})$ ，其中 T_0 是 $\mathbf{x}$ 最大 s 个系数的指标集。（这一步用到 ρ_a 的凹性与次可加性，不依赖凸性。）

第二步（尾部分块和）。 把 T_0^c 的系数按大小分成 s 个一组的块 $T_1, T_2, \dots$ ，逐块比较得 $\sum_{j \geq 2} \|\mathbf{h}_{T_j}\|_2 \leq s^{-1/2} P_a(\mathbf{h}_{T_0^c})$ 。（这一步对任何满足该型不等式的罚都成立， ℓ_1 时退化为 Candès 的经典分块。）

第三步（RIP 控制块交互）。 约束 $B\hat{\mathbf{x}} - \mathbf{b}$ 的范数不超过 ε 给出 $\|B\mathbf{h}\|_2 \leq \varepsilon$ ；把 $\mathbf{h}_{T_0}$ 与 $\mathbf{h}_{T_0^c}$ 用 RIP 展开、Cauchy-Schwarz 配合 $\delta_{2s} < \frac{1}{1+(a+1)/a\sqrt{2}}$ 吸收交叉项，解出 $\|\mathbf{h}_{T_0}\|_2$ 的上界，代回第二步合并。

第四步（误差项）。 约束右端的 ε 沿第三步的链路传到最终界，系数 C_1 来自 RIP 下界对 $\|B\mathbf{x}_{T_0^c}\|_2$ 的放大。□

这个证明链的教学价值：非凸罚没有改写恢复理论的骨架，改写的只是第一步与第二步里“范数不等式”的具体形状（ P_a 替代 $\|\cdot\|_1$ ）。所以 TL1 与 ℓ_1 的差别在常数与条件，不在证明结构。

11.3 第四篇：参数与非稀疏目标的完整记录




图 16 TL1 罚的等值线随参数 a 的变化： $a = 1$ （左）、 $a = 0.1$ （中，坐标轴附近更尖，接近 ℓ_0 ）、 $a = 100$ （右，几乎退化为 ℓ_1 菱形）。 a 是从 ℓ_1 通向 ℓ_0 的连续旋钮。




图 17 左：恢复率随 a 的扫描（ $d = 2$, $k = 20$, $N = 231$, $M = 45$ ）： $a = 0.3$ 附近最优，过小（过近 ℓ_0 ，DCA 易陷局部）与过大（退化为 ℓ_1 ）都变差。右：随机 KdV 方程的相对 RMSE：TL1 与 ℓ_{1-2} 、 ℓ_1 的对比，TL1 在两个维数上都最低。




图 18 非稀疏解析函数的逼近误差：左 $f_1 = 1/\sum_i (0.5 + 0.1z_i)$ ，右 corner-peak 函数。目标本身不稀疏时，非凸罚的优势缩小但排序不变（ $\text{TL1} > \ell_{1-2} > \ell_1$ ）；这正是自适应选择 a （对候选集各解一次、保留最稀疏解）想要覆盖的场景。

12 第二、四篇的实现细节与推广

12.1 第二篇：贪心点列的实现

定理说“贪心有一条分支能取到全局最优”，实现层面有三个决定：

实现矩阵：pivoted QR 而不是行列式。 每步重算 $|\det V(A_n \cup \{y\})|$ 对所有候选 y 代价高；列主元 QR 分解（pivoted QR（带列交换的 QR 分解，每步选出使剩余范数最大的列）在分解过程中自动挑出使残差下降最快的候选列，与“最大化加权行列式增量”逐点等价（ $|\det(VV^T)| = r^2$ 关系，主章节的证明里已经出现）。贪心全过程只需一次增量式 QR，代价 $O(MN^2)$ 。

候选集不能是全空间。 $\mathbb{R}^d$ 上没有有限候选集可选；实现里取 $\tilde{M} = 10^4$ 个点：一半从原密度 ρ 独立采样（保证密度大的区域有代表），一半从“次数渐近密度”采样（一致分布取 Chebyshev 密度；高斯取半径 $\sqrt{2n}$ 球内的 $C_d(1 - 1/(2n) \sum s_k^2)^{d/2}$ ，这是 Hermite 情形平衡测度的显式猜想形式）。候选集质量决定贪心的上限。

过采样靠指标集增广。 让 $M > N$ 的做法是把指标集从 Λ 扩到 $\tilde{\Lambda} \supseteq \Lambda$ （按总次数的 graded reverse lexicographic 序加入 $\Delta N \approx 0.05N$ 个额外指标），点数随基函数个数同步增长，条件数不因此变坏。

12.2 第二篇：一维引理的完整清单

主章节给了一维最优性定理；它依托的引理（Lemma 3.6）有五条结论，完整抄录如下，每条都只依赖三项递推与 Christoffel–Darboux：

引理（一维加权 Fekete 点的结构，五条结论） 设 $\Gamma = \mathbb{R}$ 、 ρ 任意密度、 $\Lambda = \{0, \dots, N-1\}$ 。则：

1. 对任意 $y \notin \varphi_{N-1}^{-1}(0)$ ，最优集存在且唯一，由水平集 $A_N(y) = r_N^{-1}(r_N(y))$ 给出， $r_N(y) = \varphi_N(y)/\varphi_{N-1}(y)$ （比值函数）；
2. $A_N(y)$ 是一条对次数 $\leq 2N-2$ 多项式精确的正求积法则的节点，求积权为 $1/K_\Lambda(z)$ ；
3. 若 $y \in \varphi_{N-1}^{-1}(0)$ ，则 $A_N(y)$ 恰为 N 点 Gauss 求积节点；
4. 不同 y 给出的最优集互不相同（比值 $r_N(y)$ 严格单调段上）；
5. 所有这些最优集的加权行向量组两两正交（行范数恒 1）。

结论 3 的直接推论：一维情形“加权贪心 + Gauss 初值”输出的点列就是 Gauss 求积节点，第二篇与第一篇的采样点在这种极限下重合，两条路线在数学源头汇合。

12.3 第四篇：DCA 算法的内层细节

TL1 的 DC 分解把优化写成 $\min(a+1)/a\|x\|_1 - \{(a+1)/a\|x\|_1 - P_a(x)\}$ ：第一块是凸的 (ℓ_1)，第二块也是凸的（可证），标准的差之差（DCA）迭代在两块之间交替。外层每步的超梯度为

$$z_i = \frac{a+1}{a} \operatorname{sgn}(x_i^n) - \frac{a+1 \operatorname{sgn}(x_i^n)}{a + |x_i^n|} + \frac{(a+1)x_i^n}{(a + |x_i^n|)^2},$$

内层是 ADMM 型迭代：把“ Bx 接近 b ”与“ P_a 的近端步”拆成两个子问题，用收缩算子（shrinkage）闭式更新。外层三四轮即收敛（超梯度快速趋零），总代价与 ℓ_1 求解同量级。

自适应版本的完整流程：对候选集 $a \in \{0.2, 0.3, 1\}$ （低维）或 $\{0.05, 0.1, 0.2, 0.3, 1\}$ （高维）各跑一遍 DCA-TL1，记 $s(a) = |\{i : |x_i| > 10^{-6}\}|$ ，输出 $\arg \min_a s(a)$ 对应的解。判据是“最稀疏”而不是“误差最小”，因为真实误差不可得（这正是非凸罚面对非稀疏目标的处境）。

12.4 第四篇的推广：方向导数与 Hermite 型稀疏插值

梯度增强还有两个值得知道的变体。第一，**方向导数测量**：物理里常见的量是“沿某个方向的敏感度” $D_{v_i} f = (\nabla f, v_i)$ （例如对某个边界参数的偏导），测量矩阵拼入这些行时预条件矩阵按方向缩放，框架不变。

第二，更一般的 **Hermite 型稀疏插值**（函数值与各阶方向导数在不同采样点给出的插值问题）：每个采样点可以指定“函数值 + τ_j 阶方向导数”的组合，测量行来自不同的“导数阶 $\times$ 采样点”对。这把经典 Hermite

插值（同一点取多阶导数，误差理论成熟但点数稠密）与稀疏恢复结合，数学问题（什么采样配置下恢复保证成立）在第七篇之后的文献里才逐步解决，本篇的框架是它的起点。

13 第五篇：分布未知时的数据驱动基（2018）

13.1 换数据假设：认知不确定性

前四篇都假设随机变量的分布已知（至少知道它的密度类型）。但工程里常见的情形是**认知不确定性**（epistemic）：只有一批样本（或只有若干阶矩），密度本身未知。这击中了前面所有方法的要害： ℓ_1 的采样测度需要密度来定义；正交基（gPC 的 Wiener-Askey 对应）需要分布来构造。

Guo-Liu-Zhou (2018) 的两步法把两件事解耦：

1. **构基**：只从样本的矩出发构造正交多项式（data-driven aPC），与任何采样假设无关，可以离线做；
2. **采样与拟合**：Christoffel 加权最小二乘 + 平衡测度采样，采样测度只依赖“支撑是否有界”这类粗信息，不依赖具体密度。

13.2 构基：Hankel 矩阵与 Cholesky

样本矩 $\mu_k = \frac{1}{M} \sum_{m=1}^M \eta_m^k$ 。正交多项式的三项递推系数由矩匹配方程决定，把它整理成 **Hankel 矩阵**

$$\mathbf{H} = \begin{pmatrix} \mu_0 \mu_1 & \cdots & \mu_k \\ \mu_1 \mu_2 & \cdots & \mu_{k+1} \\ \vdots & & \vdots \\ \mu_k \mu_{k+1} & \cdots & \mu_{2k} \end{pmatrix},$$

要求它在 Hamburger 意义下正定（ $\det \mathbf{H} > 0$ ，即矩序列对应一个真实测度）。Cholesky 分解 $\mathbf{H} = \mathbf{R}^T \mathbf{R}$ 后，三项递推系数直接从 $\mathbf{R}$ 读出（Mysovskih 定理 + Golub-Welsch 公式）：

$$a_j = r_{j,j+1}/r_{j,j} - r_{j-1,j}/r_{j-1,j-1}, \quad b_j = r_{j+1,j+1}/r_{j,j}.$$

为什么这条路稳 直接解矩匹配方程（经典 aPC 的做法）等价于求一个高次 Vandermonde 矩阵的逆，次数一高就病态。Hankel + Cholesky 把同样的问题变成对**条件良好的对称正定矩阵**做分解：数值上稳定，而且“矩是否对应合法测度”的判定（Hamburger 正定性）恰好就是分解能否完成的判定，算法与理论合一。

13.3 采样与拟合：平衡测度 + Christoffel 加权

拟合用加权最小二乘：

$$f_N = \arg \min_{p \in P_N} \frac{1}{M} \sum_{m=1}^M w_m (p(z_m) - f(z_m))^2, \quad w_m = \frac{N}{\sum_{j=1}^N \Phi_j^2(z_m)},$$

权重正是 Christoffel 函数。为什么这么加权？来自 Cohen 等的稳定性定理：

定理（Cohen-LS 稳定性） 记 $\kappa(N) = \max_z \sum_{j=1}^N \Phi_j^2(z)$ 。若

$$\kappa(N) \leq \delta \frac{M}{\log M}, \quad \delta = \frac{1 - \log 2}{2 - 2r},$$

则无权最小二乘以概率 $1 - 2M^{-r}$ 稳定。

Legendre 基的 $\kappa(N) \sim N^2$ ，要求 $M \gg N^2$ ，不划算。改用加权基 $\hat{\Phi}_j = \Phi_j / \sqrt{K(z)}$ 后 $\hat{\kappa}(N) = N$ （最优）。严格无偏要求按 $\kappa(z)\rho(z) = \rho(z)/K(z)$ 采样（采样偏向能量大的点），而位势论给出 $\kappa\rho \rightarrow$ 平衡测度（ $N \rightarrow \infty$ ），于是用平衡测度采样：有界域上是张量积 Chebyshev 测度（ $z_m = \cos(u_m)$ ），对任意容许输入密度普

适); 无界域上高斯型用密度 $C(2 - \|z\|^2)^{d/2}$ (球内, Beta 分布采样半径)、指数型用 $C\sqrt{(4 - \sum_i \zeta_i)^d / \prod_i \zeta_i}$ (Dirichlet 向量法)。

这篇的边界条件 三个诚实的局限 (结论节自述): 离散分布情形的稠密性定理仍是开放问题; 样本矩本身带估计误差 (density error) 未量化; 无界域需要假设密度类型 (高斯型还是指数型), 否则只能截断。采样测度与构基解耦换来的稳定性是“准线性” ($M = CN \log N$), 没有 ℓ_1 的欠定能力, 目标真的极稀疏、样本极缺时仍需要下一章的合流版本。

实验覆盖了四组混合分布 (二项、Poisson、均匀、正态的两两组合, 含离散)、直方图原始数据、5 维情形与电阻网络 ($d = 2p$ 个不确定电阻的节点电压), 对数线性采样率 $M = N \log N$ 下条件数基本有界。





图 19 左: 2 维混合分布 (二项 $\times$ Poisson) 下的条件数, 对数线性采样率 (log-linear) 曲线平稳、线性采样率 ($1.5N, 2N$) 随 N 缓慢爬升。右: 电阻网络 ($d = 4$, 各电阻服从不同指数分布), 节点电压的逼近误差随采样率收敛。分布可以任意混合 (包括离散), 这是数据驱动基相对分布假设方法的主要优势。

14 第六篇: 合流 (induced sampling, 2020)

14.1 问题: 两条路线各有半截

到这里有半截 ℓ_1 路线 (样本少、欠定、但采样测度要密度) 和半截 数据驱动路线 (密度无关、但只到超定最小二乘)。Guo-Narayan-Liu-Zhou (2020) 把它们接上: data-driven 基 + 预条件 ℓ_1 + 从 induced 测度采样。这是六篇里集成度最高的一篇。

14.2 诱导测度: 只依赖样本的采样分布

构基与第五篇相同 (加权矩 $\rightarrow$ Hankel $\rightarrow$ Cholesky $\rightarrow$ 三项递推; 多元按坐标边际化逐维构基再张量化, 注意所得基只尊重边际测度)。关键是采样。定义诱导测度 (induced measure): 在经验样本集 $\Xi = \{z^{(1)}, \dots, z^{(Q)}\}$ 上

$$\mu(z) = \sum_{j=1}^Q \tilde{\kappa}_j \delta_{z^{(j)}}, \quad \tilde{\kappa}_j = \frac{\kappa(z^{(j)})}{\sum_{q=1}^Q \kappa(z^{(q)})},$$

其中 $\kappa(z; \Lambda_K^{\text{TD}}) = \frac{1}{N} \sum_{j=1}^N \Phi_j^2(z)$ 是归一化 Christoffel 函数。读法有两层, 方向容易搞反。这篇论文把 κ 定义为 能量的平均 ($1/N \sum \Phi_j^2$), 所以 κ 大的点 (多项式能量高) 被采得更多; 随后每个样本按 $1/\kappa$ 加权, 两个因子相乘恰好还原经验分布, 只差一个全局常数, 被回归问题吸收。这就是原文所说“用 Radon-Nikodym 导数 $1/\kappa$ 保持无偏”的准确含义。偏向高能量点采样的作用: 让 $\sqrt{W}A$ 的最大元有一致界: 对任何点都有 $|\varphi_k(z)|^2 \leq \sum_j \Phi_j^2(z) = N\kappa(z)$, 于是加权后 $|\varphi_k(z)|/\sqrt{\kappa(z)} \leq \sqrt{N}$, 与采样位置无关。支撑就是样本集本身, 有限点上的逆变换采样, 实现只有几行。

预条件权取 $W_j = 1/\kappa(z^{(j)})$ ，基追踪格式 $\min \|c\|_1$ s.t. $\sqrt{W}Ac = \sqrt{W}b$ 。

这个组合为什么自治 压缩感知的恢复误差理论罚项正比于 $\sqrt{W}A$ 的最大元， $1/\kappa$ 加权把最大元压平。加权等效于测度偏置，要保持估计无偏 就必须从“偏置后的测度”采样，而偏置后的测度恰好是 ω/κ 的离散版本，即 induced 测度。采样、加权、无偏三者咬合：**从 μ 采样、按 $1/\kappa$ 加权，等于从原分布做了一次重要性采样。**

与平衡测度的关系需要说清： ω 已知时 induced 测度有唯一极限（加权多位势平衡测度；有界超立方上就是乘积 Chebyshev 测度）。有限 K 时 induced 不是平衡测度，但它只依赖样本，而且样本保证落在数据支撑内，平衡测度或 Chebyshev 采样会把点落在低概率甚至数据集之外的区域。




图 20 两种采样测度的散点对比（论文 2008.10121，数据为 二项 $\times$ Poisson 模拟）。左：CSA 采样（平衡测度的经验版），点撒满了 Chebyshev 网格，大量点落在数据支撑之外；右：induced 采样，点全部落在数据样本上，采样概率按 κ （多项式能量）偏置，再由 $1/\kappa$ 权重补偿，两者配对保持估计无偏。

实验：稀疏恢复（真实密度是均匀、截断正态、截断对数正态的等权混合， $Q = 10^5$ 个经验样本）：低维高次（ $d = 2, K = 20$ ）induced 显著优于 MC 与 CSA；高维低次（ $d = 10, K = 3$ ）induced 与 MC 相当（此时 $\mu \approx \omega$ ，两种采样没有差别，作者如实说明了这一点）。Kirchhoff 板弯曲问题（随机杨氏模量 KL 展开，Morley 非协调有限元 1369 个未知数）上 induced 在 $d = 2$ 显著省样本。




图 21 Kirchhoff 板问题的 ℓ_2 误差 ($d = 2$): induced 采样 (红色) 在全部样本量上都低于 MC 与 CSA, 达到同精度所需样本最少。

14.3 六篇合起来：Christoffel 函数的六副面孔

论文	Christoffel 函数的身份	解决的核心困难
第一篇 (2017)	求积权 + 逐点一致界 (L 因子)	任意分布下的 RIP 样本量
第二篇 (2017)	点列加权 ($1/\sqrt{K}$ 进基)	超定 LS 的确定性选点
第三篇 (2018)	列归一 (P 矩阵)	导数行的各向同性
第四篇 (2018)	(不直接出现)	罚函数与采样正交改进
第五篇 (2018)	LS 权重 + 平衡测度	分布未知时的稳定拟合
第六篇 (2020)	采样概率 + 预条件权	数据支撑上的稀疏恢复

一条线收束：凡是“多项式在某点太活跃”导致的问题(采样噪声、病态、权重失衡)，答案都是按 Christoffel 函数的倒数加权或偏置。

15 第五、六篇补充：数据驱动路线的完整记录与无偏性的推导

15.1 第五篇：矩问题什么时候有解

主章节的 Hankel–Cholesky 构基有一个前提没有展开：什么样的测度能保证正交多项式在 L^2 中稠密(展开式收敛到目标函数)? Ernst 等 (2012) 给了五个充分条件，满足其一即可：

1. 紧支撑: Γ 有界;
2. 矩的增长受控: $\liminf_{k \rightarrow \infty} \sqrt[2k]{\mu_{2k}} / (2k) < \infty$;
3. 指数可积: $E[e^{a|\eta|}] < \infty$ 对某个 $a > 0$;
4. Carleman 条件: $\sum_{k=0}^{\infty} 1 / \sqrt[2k]{\mu_{2k}} = \infty$;
5. Lin 条件: 密度对称正定且 $-xf'(x)/f(x) \rightarrow \infty$ 。

直觉读法：五个条件都在排除“矩增长太快以至于测度不由矩决定”的病态情形（例如对数正态分布在某些参数下矩不唯一）。第五篇的实验刻意包含二项、Poisson 这类离散分布：它们的支撑有限，条件 1 直接满足，这也是数据驱动基对离散分布好用的理论原因。

15.2 第五篇：条件数与精度的完整记录




图 22 左：2 维均匀输入（纯连续分布）的条件数：对数线性采样率（log-linear）平稳。右：直方图原始数据的条件数：数据只有一份经验直方图时，构基与采样照常工作，条件数行为与合成分布一致。




图 23 左：函数 $f_1 = \exp(\sum \xi_k)$ (Poisson 输入) 的离散 ℓ_2 误差。右：电阻网络 ($d = 2$, 均匀分布电阻) 的逼近误差：1000 个样本估矩、构基、加权最小二乘，误差随采样率收敛。

15.3 第六篇：无偏性的完整推导

主章节给了“采样按 κ 、加权按 $1/\kappa$ 、乘积还原经验分布”的读法。这里把这笔账算清楚，因为它是 induced 采样正确性的全部。

命题 (induced 采样的无偏性, 差一个全局常数) 设经验样本集 $\Xi = \{z^{(1)}, \dots, z^{(Q)}\}$, induced 测度 $\mu(z) = \sum_j \tilde{\kappa}_j \delta_{z^{(j)}}$, $\tilde{\kappa}_j = \kappa(z^{(j)}) / \sum_{q=1}^Q \kappa(z^{(q)})$, 权重 $W_j = 1/\kappa(z^{(j)})$ 。对任意函数 h :

$$E_{z \sim \mu}[W(z)h(z)] = \sum_{j=1}^Q \tilde{\kappa}_j \frac{h(z^{(j)})}{\kappa(z^{(j)})} = \frac{1}{\sum_{q=1}^Q \kappa(z^{(q)})} \sum_{j=1}^Q h(z^{(j)}) = \frac{1}{\bar{\kappa}} \cdot \left(\frac{1}{Q} \sum_{j=1}^Q h(z^{(j)}) \right),$$

其中 $\bar{\kappa} = \frac{1}{Q} \sum_q \kappa(z^{(q)})$ 是 κ 在样本集上的均值。

证明. 第一个等号按定义展开期望（有限支撑上求和）；第二个等号把 $\tilde{\kappa}_j$ 的分子 $\kappa(z^{(j)})$ 与权重里的 $1/\kappa(z^{(j)})$ 消去；第三个等号把常数提到求和外，拆成 κ 均值的倒数乘经验均值。□

这笔账在说什么 加权后的估计等于经验平均乘 $1/\bar{\kappa}$ ：形状完全正确，只差一个与 h 无关的常数。回归问题对这个常数不敏感，把 $\sqrt{W}A$ 与 $\sqrt{W}b$ 同乘一个常数，基追踪的解不变（约束与目标同时缩放）。这就是“无偏”在压缩感知语境下的准确含义：不是估计量等于真值，而是偏差与目标无关，被问题的尺度不变性吸收。

与重要性采样的对照也更清楚了：若把 μ 看成提案分布、经验分布看成目标，Radon–Nikodym 导数 $d\omega_{\sim}/d\mu = 1/\kappa$ 乘上一个归一化常数。常数在蒙特卡洛里需要显式除回去，在回归里免费。

15.4 第六篇：稀疏恢复与函数逼近的完整记录




图 24 左：直方图原始数据的恢复率随 M ($d = 2$)：induced 对 CSA 与 MC 的优势在数据完全“无分布信息”时同样成立。右： $f = \exp(\sum z_i)$ （二项 $\times$ Poisson 数据， $K = 20$)：大 M 时 induced 明显占优。




图 25 左：corner-peak 函数（二项 $\times$ Poisson 数据）：induced 的优势在小 M 区最明显。右：Kirchhoff 板问题的 ℓ_2 误差 ($d = 10$, 3 个 KL 模态)：此时 $\mu \approx \omega$ ，induced 与 MC 相当，正是方法自己指出的适用边界。

16 第五篇的实现台：采样测度、实验设置与逐图读数

主章节讲了“构基与采样解耦”这个想法。这一章把它落成可以照着跑的规格：五步流程里哪几步可以离线、两种采样测度的具体抽样算法长什么样、稳定性与精度两类实验各自的度量口径与全部输入设置，最后是把论文九张图里的趋势读成数字。

16.1 五步流程与“可以离线”的准确含义

论文给的流程（第 4.1 节末尾）是五步：

1. 按密度 $\hat{\rho}$ 采样（ $\hat{\rho}$ 是平衡测度，只依赖输入密度 ρ 的类型；无界域时还依赖最高次数 k ，记作 $\hat{\rho}_k$ ）；
2. 在样本 $z^1, \dots, z^M$ 上求模型输出 f ；
3. 组 $M \times N$ 的 Vandermonde 型矩阵 $A = [\Phi_j(z_m)]$ ；
4. 组对角预条件 $W = \text{diag}(w_1, \dots, w_M)$, $w_m = N / \sum_{j=1}^N \Phi_j^2(z_m)$ ；
5. 解 $\min_c \|W^{\frac{1}{2}}Ac - W^{\frac{1}{2}}f\|_2$ 。

“可以离线”指的是第 1 步与第 3、4 步里的基：采样测度不依赖数据驱动的基，基只依赖样本矩，所以采样模式（sampling pattern）与模型求值可以在决定多项式空间之前先做完。与 Ahlfeld–Mauß 的 SAMBA 稀疏配点相比，论文自述的三点差别是：采样不需要对基做矩阵运算、采样与基解耦、最小二乘的样本量对基数呈近似线性。

记号对照 这篇把（缩放）Christoffel 函数定义成 $K(\xi) = N / \sum_{j=1}^N \Phi_j^2(\xi)$ ，也就是第六篇那个 $\kappa(z) = \frac{1}{N} \sum_j \Phi_j^2(z)$ 的倒数乘 N^2 ： $K = N^2 / (N\kappa) = N/\kappa$ 。两篇用同一个字母族指互为倒数数量，读跨篇的公式时先确认这一点。预条件权 w_m 在这篇是 K ，在第六篇是 $1/\kappa$ ，两者只差一个与样本无关的常数 N ，对最小二乘与基追踪都无影响。

16.2 两种采样测度的可执行形式

有界域（不失一般性取 $[-1, 1]^d$ ）：采样测度恒为张量积 Chebyshev 测度

$$\hat{\rho}(\xi) = 1 / \left(\pi^d \prod_{k=1}^d \sqrt{1 - \xi_k^2} \right),$$

与真实输入密度无关。抽样用反函数：取 $u_m \sim \text{Unif}[-1, 1]$ ，令 $z_m = \cos(u_m)$ 。论文的措辞是“平衡测度对有界域的任意容许密度都是 Chebyshev 测度”，即它是普适的，需要的唯一信息是支撑有界。

无界域：论文给出两类，并明确说这些是**猜测**（conjecture），有效性靠数值证据。做法是先用样本估出均值与方差、做线性变换把输入化成标准型，再从下面的密度采样，最后按最高次数 k 展开。

高斯型 ($\mathbb{R}^d$)。目标密度 $\hat{\rho}(\xi) = C(2 - \|\xi\|^2)^{d/2}$ 。具体四步：算出 k ；抽 d 个独立标准正态组成 y ；抽 $\nu \sim \text{Beta}(\alpha = d/2, \beta = d/2 + 1)$ ；令

$$z = y / \|y\| \cdot (2k\nu)^{1/2},$$

即样本落在半径 $\sqrt{2k}$ 的欧氏球内，方向均匀、半径由 Beta 给出。

指数型 ($\mathbb{R}_+^d$)。目标密度 $\hat{\rho}(\xi) = C \sqrt{(4 - \sum_i \xi_i)^d / \prod_i \xi_i}$ 。三步：算 k ；抽 $d+1$ 维 Dirichlet 向量 $y \sim \text{Dir}(1/2, \dots, 1/2, d/2 + 1)$ ；截掉最后一个分量后令 $z = 4ky$ 。

Remark 里补了一句：这两类之外的无界密度，连猜测形式的平衡测度都不知道，只能截断成有界域再做 Chebyshev 采样，代价是引入截断误差。

两处让步 第一，无界域的采样测度是猜的，正确性只有数值证据；第二，即使猜对， $\hat{\mu}, \hat{\sigma}$ 由样本估出，于是又引入一层“密度误差”（density error）。论文把这两点都列进了结论节的开放问题，没有试图掩盖。有界域那半边不需要任何让步，这也是实验里二项、Poisson、均匀这类有界输入表现最干净的原因。

16.3 稳定性实验的口径

度量是设计矩阵的条件数

$$\text{Cond}(\hat{A}) = \lambda_{\max}(\hat{A}) / \lambda_{\min}(\hat{A}), \quad \hat{A} = W^{1/2} A,$$

每个配置重复 100 次，报条件数均值与 20%、80% 分位数（误差棒）。采样率取四种： $M = 1.5N$ 、 $M = 2N$ 、 $M = N \log N$ 、 $M = 1.5N \log N$ ，前两个叫线性、后两个叫对数线性。多项式空间是总次数型，基数 $N = |\Lambda_k^{\text{TD}}| = \frac{(k+d)!}{k!d!}$ ，最高次数记 k 。

输入分布一共五类，论文逐个写了公式：二项 $\text{Bino}(n, p)$ 取值在 $[-1, 1]$ ($\xi = 2k/n - 1$)、Poisson $\text{Pois}(\lambda)$ (同取值范围)、均匀 $U[a, b]$ 、指数 $\text{Exp}(\mu)$ 在 $(0, \infty)$ 、正态 $N(\mu, \sigma)$ 在全直线。二维与五维各四组组合：

编号	二维组合	五维组合
1	$\xi_1 \sim \text{Bino}(20, 1/2)$, $\xi_2 \sim U[-0.6, 0.6]$	$\xi_i \sim U[a_i, b_i]$, $a = (-0.1, -0.5, -0.8, -1, -1.2)$, $b = -a$
2	$\xi_1 \sim U[-0.8, 0.8]$, $\xi_2 \sim U[-1, 1]$	$\xi_i \sim N(\mu_i, \sigma_i)$, μ 源码写作 $[0, 0.1, -0.1, 0.2, -0.2]$, $\sigma = (1, 1.1, 1.2, 1, 0.9)$
3	$\xi_1 \sim \text{Bino}(20, \frac{1}{2})$, $\xi_2 \sim \text{Pois}(10)$	$\xi_{1,2} \sim U[-0.6, 0.6]$, $\xi_{3,4} \sim \text{Bino}(20, \frac{1}{2})$, $\xi_5 \sim \text{Pois}(10)$
4	$\xi_1 \sim U[-0.6, 0.6]$, $\xi_2 \sim N(0.1, 1.2)$	$\xi_{1,2} \sim U[-1, 1]$, $\xi_3 \sim N(0, 1)$, $\xi_4 \sim N(0.1, 1.5)$, $\xi_5 \sim N(0.2, 2)$

第六组输入是纯经验数据：把均匀、正态、对数正态三种分布叠加生成 $M = 10^4$ 个样本，只用样本算矩来构基，与合成分布走同一套流程。




图 26 五维情形的条件数随多项式阶 i 的变化（论文 1805.10893，表 2 的第 1、2 组，100 次重复，误差棒是 20% 与 80% 分位）。左：全均匀输入；右：全正态输入。四条曲线自上而下是 $M = 1.5N$ 、 $2N$ 、 $N \log N$ 、 $1.5N \log N$ 。读数：线性采样率下条件数从 10^0 爬到 10^1 到 10^2 量级且仍在上升；对数线性采样率下曲线在 $i = 7$ 处已经走平甚至微降。右图（无界输入）的对数线性曲线比左图略高，这是论文所说“含无界变量时仍有轻微上升趋势”的形态。

这组实验真正测的是什么 条件数不衡量精度，衡量的是“数据里的一点扰动会被放大多少倍”。把它随 N 的走势与理论对照：无权最小二乘要求 $\kappa(N) \leq \delta M / \log M$ ，而 Legendre 型基的 $\kappa(N) \sim N^2$ ，即 $M \gg N^2$ 才稳。加权后 $\hat{\kappa}(N) = N$ ，于是 $M \sim N \log N$ 就该看到平稳，图里对数线性两条正是平的。换句话说，这组实验是对“Christoffel 加权把样本量需求从平方降到近线性”这句话的直接检验，而不是对逼近精度的检验。

16.4 精度实验的口径

误差是离散 ℓ_2 ：给定 L 个测试样本，

$$\varepsilon = \left(\frac{1}{L} \sum_{l=1}^L |f_N(z_l) - f(z_l)|^2 \right)^{1/2},$$

其中 f_N 是加权最小二乘解。测试函数四个：

$$f_1 = \exp\left(\sum_{k=1}^d \xi_k\right), \quad f_2 = \sum_{k=1}^d 0.3 + \sin\left(\frac{16}{15}(\xi_k - 0.7)\right) + \sin^2\left(\frac{16}{15}(\xi_k - 0.7)\right),$$

$$f_3 = \exp\left(-\sum_{k=1}^d c_k^2(\xi_k - 0.01)^2\right), \quad c_k = \exp(-6k/d), \quad f_4 = \sin\left(\sum_{k=1}^d \xi_k\right),$$

分布沿用上一节的表。电阻网络： $d = 2p$ 个阻值不定的电阻、已知电源 $V_0 = 1$ ，求节点电压 V ；二维时电阻在 $[10, 100]$ 上均匀，四维时四个电阻分别服从 $\text{Exp}(0.9)$ 、 $\text{Exp}(1.1)$ 、 $\text{Exp}(0.8)$ 、 $\text{Exp}(1.0)$ ；矩由 1000 个样本估计。随机椭圆方程：

$$-\nabla \cdot (a(y, \omega) \nabla u) = f(y) \quad \text{in } [0, 1]^2, \quad u = 0 \quad \text{on } \partial[0, 1]^2,$$

载荷确定 $f = \cos(y_1) \sin(y_2)$ ，扩散系数按 Babuška 等的构造取

$$\log(a_N(y, \omega) - 0.5) = 1 + \xi_1 (\sqrt{\pi} L/2)^{1/2} + \sum_{i=2}^5 \zeta_i g_i(y) \xi_i,$$

$$\zeta_i = (\sqrt{\pi} L)^{1/2} \exp(-(|i/2| \pi L)^2 / 8)$$

， g_i 按 i 的奇偶取正弦或余弦（自变量 $[i/2] \pi y_1 / L_p$ ），相关长度 $L_c = 1/12$ 、 $L_p = \max\{1, 2L_c\}$ 、 $L = L_c / L_p$ 。每个样本用有限元在细网格上解一次确定性方程，目标是 $u(0.5, 0.5; \xi)$ 。参数密度分两种情形各跑一组：全二项（ $\xi_1, \xi_2 \sim \text{Bino}(20, 0.5)$ ）与全正态（ $\xi_1 \sim N(0, 1)$ 、 $\xi_2 \sim N(0.1, 1.2)$ ）。




图 27 随机椭圆方程的离散 ℓ_2 误差随多项式阶 i (论文 1805.10893)。左：二项输入， i 到 14；右：正态输入， i 到 19。四条采样率曲线几乎重合地下降，到 $i \approx 8$ 之后进入机器精度附近的地台（二项约 10^{-13} 到 10^{-16} ，正态约 10^{-11} 到 10^{-16} ），对数线性两条的地台更低。这段曲线说明瓶颈已经从采样转到求解器与浮点精度。




图 28 左：电阻网络二维均匀情形 ($\xi_{1,2} \sim U[10, 100]$) 的误差，从 $i=2$ 的 4×10^{-2} 降到 $i=12$ 的 10^{-5} 到 2×10^{-6} ，四条采样率曲线的间距很小。右：五维纯直方图数据上的 f_1 ， $i=1$ 到 7 误差从约 3 降到约 0.1。两图对照很值得看：同一个方法在“有解析结构的低维问题”上是指数级下降，在“只有一张直方图的高维问题”上是缓慢的代数下降，差别来自被逼近函数在给定基下的系数衰减，而不是算法本身。

读 1805.10893 源码时的对表

- 正文只定义了 f_1 到 f_4 ，图文件名与图例里却出现 f_5 (Err_CLS_f5_normal_d2, Error_f5_uninor_d5)。按图注的分布描述， f_5 应是 f_1 到 f_4 之外的第五个测试函数，正文没有给出它的表达式。
- 五维表第 2 组的均值向量写成 $\mu = [0, 0.1, -0.1, 0.2, -0.2]$ ，分量数与 σ 不一致，按上下文应是 0.01。
- g_i 的 sin、cos 两支都带一个多余的负号且少一个右括号，与一维 KL 展开的常规写法对照，自变量应为 $|i/2|\pi y_1/L_p$ 。
- 条件数写成 $\lambda_{\max}/\lambda_{\min}$ ，而 $\hat{A}$ 是长方形矩阵，严格说这是奇异值之比；按实现理解即可。
- Poisson 一节的公式只给了 $\lambda^k \exp(-\lambda)/k!$ ，没有写它在 $[-1, 1]$ 上的取值映射（二项那一行有）。
- 全部实验结果只有图，没有数值表，也没有时间成本。

16.5 这一篇留下的三个口子

结论节自己列了三条：离散型输入的稠密性定理仍开放（定理只覆盖 密度连续的情形，而实验里二项与 Poisson 都工作得很好）；样本矩带来的密度误差没有量化手段；无界域必须假设密度的类型（高斯型还是指数型），参数可未知、类型不可未知。最后一句是预告：这套策略也能用在压缩感知与 ℓ_1 的设定里，留待后续。下一章就是那篇后续。

17 第六篇的实现台：两个算法、三方对照与逐图读数

主章节讲了 induced 测度的定义与无偏性。这一章补齐照着搭需要的东西：输入约定、两个算法的每一步、张量化到底牺牲了什么、三方对照 (induced、CSA、MC) 各自的采样与预条件、恢复与精度两类实验的判据与全部设置，最后是图的读数。

17.1 输入约定与两个算法

输入是 Q 个经验样本与权重： $S = (z^1, \dots, z^Q) \subset \mathbb{R}^d$ ，权重 $(w_1, \dots, w_Q)$ 非负且 $\sum_j w_j = 1$ ；若 S 是从未知密度 ω 独立抽的，取蒙特卡洛权重 $w_j = \frac{1}{Q}$ 。要解决的问题是：只在这 Q 个点里指定 $M \ll Q$ 个点去求值，然后用这 M 次求值做稀疏逼近。

算法 1 (逐维构基)。

1. 用样本算（非中心）矩 $\nu_k = \sum_{j=1}^Q w_j \xi_j^k$ ， $k = 0, 1, \dots$ ；

2. 组 $(K+1) \times (K+1)$ 的 Hankel 矩阵 $\mathbf{H}$ ，要求它在 Hamburger 意义下确定（所有二次型严格正，即 $\det \mathbf{H} > 0$ ）；
3. Cholesky 分解 $\mathbf{H} = \mathbf{R}^T \mathbf{R}$ ，由 Mysovskih 定理 $\mathbf{R}$ 的元素给出一族正交多项式，三项递推系数按 $a_j = r_{j,j+1}/r_{j,j} - r_{j-1,j}/r_{j-1,j-1}$ 、 $b_j = r_{j+1,j+1}/r_{j,j}$ 读出（约定 $r_{0,0} = 1$ 、 $r_{0,1} = 0$ ）；
4. 可选：按三项递推把多项式值算出来。

可行性与数值选择 论文给的充分条件很朴素：边际样本集 Ξ 里至少有 $K+1$ 个不同取值，矩问题就确定，分解就能做。为什么绕道 Hankel：直接解矩匹配线性方程组（对 φ_K 的系数 β_j ）在 K 大时病态，而 Hankel + Cholesky 这条路“经验上病态轻得多”。这是实现层面的取舍，论文没有给出两者的条件数对比。

算法 3（整体流程）。 输入离散分布或数据集 $\{z^j, w_j\}_{j=1}^Q$ 与函数 f ：

1. 逐维跑算法 1，张量化得 $\{\Phi_j(z)\}_{j=1}^N$ ；
2. 从 induced 测度 μ 抽 M 个 iid 样本；
3. 组 $b_i = f(z_i)$ 与 $A_{ij} = \Phi_j(z^i)$ ；
4. 按 κ 算预条件权 W ；
5. 解 $c^* = \arg \min \|c\|_1$ s.t. $\sqrt{W}Ac = \sqrt{W}b$ 。

17.2 张量化牺牲了什么

对每个坐标做边际化， $\Xi_i = \{z_i^1, \dots, z_i^Q\}$ ，配上同样的权重 $1/Q$ ，逐维跑算法 1 得到 d 族一元正交多项式 $\{\varphi_j^i\}_{j=0}^K$ ，再按多指标 $\lambda \in \Lambda_K^{\text{TP}}$ 张量化。所得基的正交性是对张量化的边际测度

$$\nu(z) = \otimes_{i=1}^d \nu_{i(z_i)}, \quad \nu_{i(z_i)} = \frac{1}{Q} \sum_{j=1}^Q \delta_{z_i^j}$$

成立，而不是对经验测度成立。论文写得很直白：这样构造的 Φ_λ 不尊重 S 的矩，只尊重“把 S 逐维边际化再张量回去”的那个测度，由此带来的额外逼近代价“基本等价于把 S 张量化”。

基数核对 总次数空间的基数 $N = |\Lambda_K^{\text{TP}}| = \binom{K+d}{d}$ 。论文报的两个配置都对得上： $d=2, K=20$ 给 $N=231$ ； $d=10, K=3$ 给 $N=286$ 。五维那组（ $d=5, K=7$ ）论文只给了 K 没给 N ，按同一公式是 792，这个数是本笔记算的。

17.3 采样与预条件：三方对照

归一化 Christoffel 函数（这篇的定义与第五篇互为倒数，见上一章的记号对照）

$$\kappa(z; \Lambda_K^{\text{TP}}) = \frac{1}{N} \sum_{j=1}^N \Phi_j^2(z),$$

induced 测度把 κ 当作样本点上的质量：

$$\mu = \sum_{j=1}^Q \tilde{\kappa}_j \delta_{z^j}, \quad \tilde{\kappa}_j = \kappa(z^j) / \sum_{q=1}^Q \kappa(z^q),$$

从 μ 抽 M 个点（支撑有限，逆变换采样即可），预条件权 $W_j = 1/\kappa(z^j)$ 。这样做的两个理由：

其一，一致界。对任何点都有 $|\Phi_k(z)|^2 \leq \sum_j \Phi_j^2(z) = N\kappa(z)$ ，于是 $|\sqrt{W_j}A_{jk}| \leq \sqrt{N}$ ，与样本位置、与 S 无关。压缩感知里 ℓ_1 恢复定理的罚项正比于 $\sqrt{W}A$ 的最大元，压平最大元同时改善理论与实际表现（这条线索可追溯到 Rauhut 的 Legendre 工作）。

其二，无偏。 $\sqrt{W}$ 是对测度的偏置，要保持对 S 上均匀测度的无偏，采样测度必须换成偏置后的那个，恰好就是 μ 。

名称	采样	预条件	需要知道 ω 吗
induced (本篇)	从 μ iid 抽，支撑在 S 上	$W_j = 1/\kappa(z^j)$	不需要
CSA	从 K 渐近平衡测度抽（有界域即乘积 Chebyshev）	同样的 $1/\kappa$	需要（论文里是已知密度的情形）
MC	从 ω iid 抽	无	需要

与平衡测度的关系 ω 已知时，induced 测度在 $K \rightarrow \infty$ 下趋于加权多位势平衡测度（有界超立方上就是乘积 Chebyshev 测度）。论文强调两点差别： μ 的支撑只在 S 上，因此抽出的点一定落在数据里；乘积 Chebyshev 只是极限意义最优，有限 K 时并不最优。二维那组实验（ $K = 20$ ）作者自己说“显然还没进入渐近区”，所以两种采样给出不同结果是预期之内，图 2 的散点对比就是为这句话服务的。

17.4 手算例：16 个样本上的矩、基与诱导测度

定义到此为止，用一个能手工核对的数据集把整条流水线走一遍。数据集取二项分布 $\text{Bino}(4, 1/2)$ 整体平移 -2 后的完整计数：支撑 $\{-2, -1, 0, 1, 2\}$ ，频数 $(1, 4, 6, 4, 1)$ ， $Q = 16$ ，经验权重 $w_p = n_p/16$ 。选它是因为所有数字都停在有限小数上，每一步都能用纸笔复核，而它恰好是论文二维实验数据的同族（离散、有限支撑）。

矩。 $\nu_k = \sum_{p=1}^5 w_p \xi_p^k$ ，奇数阶全零（支撑与权重都关于零对称），偶数阶 $\nu_0 = 1$ 、 $\nu_2 = 1$ 、 $\nu_4 = 2.5$ 、 $\nu_6 = 8.5$ 、 $\nu_8 = 32.5$ 。取 $K = 4$ 需要 $\nu_0, \dots, \nu_8$ ，Hankel 矩阵 5×5 。

可解性与条件数。 $\det \mathbf{H} = 243/32 = 7.59375 > 0$ （五个不同原子，满足“至少 $K + 1$ 个”那条充分条件），Cholesky 可做； $\mathbf{H}$ 的条件数 ≈ 343 。次数只到 $K = 4$ 就已经三位数，这就是正文说“直接解矩匹配方程在 K 大时病态”的量化起点。

三项递推系数。 R 的对角元依次是 $1, 1, \sqrt{1.5}, 1.5, 1.5$ ，按公式读出 $a_1 = \dots = a_4 = 0$ （对称测度必然如此）与 $b_1 = 1$ 、 $b_2 = b_3 = \sqrt{1.5} = 1.2247$ 、 $b_4 = 1$ 。递推 $\xi \varphi_{j-1} = b_{j-1} \varphi_{j-2} + a_j \varphi_{j-1} + b_j \varphi_j$ 给出一族标准正交多项式：

$$\begin{aligned}\varphi_0 &= 1, \quad \varphi_1 = \xi, \quad \varphi_2 = \sqrt{2/3}(\xi^2 - 1), \\ \varphi_3 &= (2\xi^3 - 5\xi)/3, \quad \varphi_4 = (2\xi^4 - 8\xi^2 + 3)/3.\end{aligned}$$

在五个原子上核对正交性： $\sum_p w_p \varphi_i(\xi_p) \varphi_j(\xi_p) = \delta_{ij}$ 成立到 2×10^{-16} 。

Christoffel 函数。取 $N = K + 1 = 5$ 个基函数， $\kappa(\xi_p) = 1/5 \sum_j \varphi_j^2(\xi_p)$ 分别是 $3.2, 0.8, 0.5333, 0.8, 3.2$ 。这里有一个精确关系可以看见：五个基在五个原子上满足完备性关系

$$\sum_{j=0}^4 \varphi_j(\xi_p) \varphi_j(\xi_q) = \delta_{pq}/w_p,$$

左端矩阵的对角元是 $16, 4, 2.667, 4, 16$ （即 $1/w_p$ ），非对角元最大 2.7×10^{-15} 。于是 $\kappa(\xi_p) = 1/(5w_p)$ ，各原子的 induced 质量正比于 $n_p \kappa(\xi_p) = 3.2$ ，与 p 无关：五个原子各得 0.2 ，两个尾部点被抬到和众数同频采样。

预条件与还原。 $W_p = 1/\kappa(\xi_p) = 5w_p$ ，于是 $\mu_p W_p$ 正比于 n_p ，归一化后逐分量回到经验权重 $(0.0625, 0.25, 0.375$ 以及两端对称的值)。之所以精确，是因为 μ 的定义带一个 κ 、 W 的定义带一个 $1/\kappa$ ，两者相乘必然消掉，剩下的就是经验分布。换掉 N 只改变两者如何分工：

基函数个数 N	五个原子上的 κ	induced 质量	μ 乘 W 归一
2	2.500, 1.000, 0.500, 1.000, 2.500	0.156, 0.250, 0.188, 0.250, 0.156	还原, 误差 $< 10^{-16}$
3	3.667, 0.667, 0.556, 0.667, 3.667	0.229, 0.167, 0.208, 0.167, 0.229	同上
4	3.750, 0.750, 0.417, 0.750, 3.750	0.234, 0.188, 0.156, 0.188, 0.234	同上
5	3.200, 0.800, 0.533, 0.800, 3.200	0.200, 0.200, 0.200, 0.200, 0.200	同上

这个小例子极端在哪里 $\kappa(\xi_p) = 1/(Nw_p)$ 成立的前提是 N 恰好等于支撑里的原子数, 此时基空间已经把测度“看穿”, induced 采样退化成在原子上一致采样。论文的配置是 $N = 231$ 对 $Q = 10^5$, 差两个数量级, κ 不再是 $1/(Nw_p)$, induced 测度也不再均匀: 它按多项式能量挑点, 能量在低概率处冲高是有限样本下的常见现象, 两者在定义上没有绑定。恒等式里被保留的是后半截: μ 与 W 相乘还原经验分布, 与 N 无关, 这就是“用 $1/\kappa$ 保持无偏”那句话的全部内容。

一致界也能逐个数字核对。 κ 在 ± 2 处最大 (3.2), 该点上 $|\varphi_4| = 1$, 界 $\sqrt{N\kappa} = 4$; κ 在 0 处最小 (0.533), $|\varphi_4(0)| = 1$, 界 $\sqrt{N\kappa} = 1.63$ 。比值 $|\varphi_k(\xi_p)|^2 / (N\kappa(\xi_p))$ 在 $N = 5$ 时最大 0.375 ($\xi = 0$ 处的 φ_0 , 恰好等于众数的概率), $N = 2$ 时达到 1 ($\xi = 0$ 上除 φ_0 外全为零)。理由很直白: 这个比值就是 $\varphi_k^2 / \sum_j \varphi_j^2$, 等号当且仅当其余基函数在该点全部取零; $N = 5$ 那行的 0.375 则来自饱和情形 $\kappa = 1/(Nw)$ 的代入。界的方向恒真、松紧随基的饱和度变化, 这就是正文那句“加权后最大元与采样位置无关”在这个规模上的样子。整条流水线从矩到 c^* 不过十几行代码: 算矩、组 Hankel、Cholesky、递推多项式、算 κ 、按 κ 抽样并取 $1/\kappa$ 为权重、解基追踪。

17.5 实验协议与全部设置

两类测试共用一套数据生成: S 是从“未知的真密度” ω 抽的 Q 个 iid 样本, ω 是各维同分布的张量积密度, 边际取三种密度的混合: $[-1, 1]$ 上的均匀、 $[-1, 1]$ 上的截断正态 $N(0.2, 1.5)$ 、 $[0, 1]$ 上的截断对数正态。

恢复测试。 右端 b 由一个 s -稀疏向量 c^* 生成 (非零元独立标准正态, 目标函数 $f = \sum_i c_i^* \Phi_i$ 因此是多项式本身), 判据是 $\|c - c^*\|_\infty < 10^{-3}$, 纵轴是成功频率。配置: $d = 2$ 、 $K = 20$ 、 $N = 231$ 、 $s = 8$ 、 $Q = 10^5$; 以及 $d = 10$ 、 $K = 3$ 、 $N = 286$ 、 $s = 8$ 。

精度测试。 纵轴是离散 ℓ_2 误差 $\varepsilon = \left(\frac{1}{E} \sum_{j=1}^E |f_N(z^j) - f(z^j)|^2 \right)^{1/2}$, 测试样本 $E = 10^4$ 个 iid 自 ω 。测试函数是 Genz 型的四个:

$$f_1 = \exp\left(-\sum_i z_i\right), \quad f_2 = \sum_{i=1}^{d-1} (1 - z_i)^2 + 100 \sum_{i=2}^d (z_i - z_{i-1}^2)^2,$$

$$f_3 = \sin\left(\sum_i z_i\right), \quad f_4 = \left(1 + \frac{1}{2d} \sum_{i=1}^d c_i (1 + z_i)\right)^{-d-1}, \quad c_i = \frac{1+i}{4d},$$

数据集两种: 二项 $\times$ Poisson 的张量网格 (24×24 个点, 第一维权重取 Bino(24, 1/2) 的概率质量函数、第二维取 Pois(10) 的前 24 个概率值再归一, 被截掉的质量约 10^{-5}), 以及上面那个混合密度的 iid 样本集。配置: $d = 2$ 用 $K = 20$ 、 $d = 5$ 用 $K = 7$ 。

Kirchhoff 板弯曲。 夹紧板 $-\mathcal{M}_{IJ,IJ}(u) = f$ 在 $\Gamma \times \mathcal{D}$ 、 $u = \partial_n u = 0$ 在边界, $\mathcal{M}_{IJ} = D((1 - \nu)\mathcal{K}_{IJ}(u) + \nu\mathcal{K}_{LL}(u)\delta_{IJ})$ 、 $\mathcal{K}_{IJ}(u) = -\partial_{IJ}u$ 、弯曲刚度 $D = Eh^3/(12(1 - \nu^2))$ 。不确定性加在杨氏模量上: $Y = \log(E - 100)$, $Y = 1 + Z_1(\sqrt{\pi}L/2)^{1/2} + \sum_{i=2}^d \zeta_i g_i(x) Z_i$, $\zeta_i = (\sqrt{\pi}L)^{1/2} \exp(-([i/2]\pi L)^2/8)$, g_i 按

i 奇偶取正弦或余弦、只依赖 x_1 ；核 $K(x_1, x_1') = \exp(-(x_1 - x_1')^2/L_c^2)$, $L_c = 1/2$, $L_p = \max\{1, 2L_c\}$, $L = L_c/L_p$ 。板域 $[0, 1]^2$ 、厚度 $h = 0.02$ 、载荷 $f = \cos(x_1)\sin(x_2)$ ，确定性求解用 Morley 非协调元，648 个三角形、1369 个未知数，目标是 $u(z, (0.5, 0.5))$ ； $Q = 10^4$ 。

17.6 逐图读数




图 29 稀疏恢复成功率随样本数 M (论文 2008.10121 图 3, $s=8$, 判据 $\|c - c^*\|_\infty < 10^{-3}$)。左: $d=2, K=20, N=231$ 。induced 在 $M=50$ 处已达约 0.74, $M=75$ 附近饱和到 1; MC 在 $M=50$ 处仍为 0, $M=64$ 约 0.33, 要到 $M \approx 200$ 才满。换算成“每个未知数需要几个样本”, 大约是 $M/N \approx 0.3$ 对 0.85。右: $d=10, K=3, N=286$ 。两条曲线几乎重合, 都在 $M \approx 100$ 处到 1, 此时 $M/N \approx 0.35$ 。这正是作者声明的适用边界: 低次多项式的 κ 接近常数, μ 与 ω 差不多, induced 没有优势。




图 30 二维函数逼近误差随 M ($K=20$)。左: $f_3 = \sin(\sum z_i)$, 数据为二项 $\times$ Poisson 网格, 三种方法同图。CSA (绿) 从 4×10^{-1} 起、到 $M=400$ 约 8×10^{-4} ; induced (红) 起点最高 (约 2×10^{-1}) 但下降最快, 在 $M \approx 100$ 处越过另两条, $M=400$ 时到 2×10^{-5} 。右: 广义 Rosenbrock f_2 , 混合密度数据, 只有 induced 与 MC。小 M 区 MC 明显更好 ($M=25$ 时 6×10^{-3} 对 2×10^{-2}), M 增大后反转, $M=400$ 时 induced 约 3×10^{-5} 、MC 反而升到 1×10^{-2} 。“小样本 MC 略优、大样本 induced 明显优”这句话在正文与图里是一致的。




图 31 左：五维 ($K = 7$) 混合密度数据上的 f_2 ：induced 从 $M = 25$ 的约 2×10^{-1} 降到 $M = 600$ 的 4×10^{-6} ，MC 同区间从 2 降到 2×10^{-3} ，差距稳定在一个量级以上。右：Kirchhoff 板 ($d = 2$ 、20 次多项式) 的 ℓ_2 误差： $M = 36$ 时两者几乎相同 (约 3×10^{-3})， $M = 80$ 处拉开到 3×10^{-5} 对 3×10^{-4} ， $M = 200$ 处 3×10^{-6} 对 3×10^{-5} ，即同精度下 induced 省下的样本数随精度要求提高而增大。

17.7 这一篇没有给出的东西

缺口清单

- 没有定理。induced 采样 + aPC 基下的样本量界、恢复保证都没有，方法的正当性由“一致界 + 无偏 + 数值”三条支撑。
- 没有成本对比。三种方法的误差曲线同图，但没有一次求值开销或墙钟时间，“省样本”是否等于省算力无法核对 (induced 需要先构基并算全 Q 个点的 κ)。
- 只数值测试了总次数空间。作者声明方法对任意有限多指标集不变，但各向异性、超球、稀疏网格指标集下的表现没有数据。
- 阶数 K 由用户给定，没有自适应准则； κ 在样本上的估计误差 (Q 有限) 也未量化，而它同时决定采样概率与预条件权。
- 全部结果只有图，没有数值表；五维配置没报 N 。
- 源码里两处编号与下标问题：测试函数 f_3 与 f_4 都被写成 f_3 ； f_2 的第一段和式按原文写是 $\sum_{i=1}^d (1 - z_{i-1})^2$ ，出现 z_0 ，实现里应是 $i = 1, \dots, d - 1$ (本笔记的表按此改写)。误差公式的分母写成 $1/M$ ，求和指标却是 $j = 1, \dots, E$ 。

六篇到这里合流完成：第五篇给出“分布未知时怎么造基、怎么稳拟合”，第六篇把同一批基接到压缩感知的轨道上，用基自己诱导出的测度采样、用同一个量的倒数预条件，于是稀疏恢复这条线不再需要已知密度。剩下的短板与第五篇同源，都在理论一侧。

18 工程实践：一个最小算例的走查与常见误区

18.1 算例走查： $d = 2$ 的稀疏恢复从头到尾

把六篇的方法在同一个玩具问题上走一遍，全部步骤只用纸笔加一个 ℓ_1 求解器。设定： $d = 2$ ， y_1, y_2 独立同分布地取均匀分布 $\sim U[-1, 1]$ (Legendre 基)，总次数指标集 Λ_n^T 取 $n = 5$ ，基函数个数 $N = \binom{2+5}{5} = 21$ 。目标函数是一个稀疏组合，例如 $f(y_1, y_2) = 1.5\varphi_{(2,0)}(y) - 0.8\varphi_{(0,3)}(y) + 0.1\varphi_{(1,1)}(y)$ ，真实稀疏度 $s = 3$ 。

第一步：选指标集与网格。 $\Lambda \subset \Lambda_{n-1}^P$ 要求每个维度的单项次数不超过 $n_i - 1$ 。对总次数集 $n = 5$ ，每维取 $n_i = 5$ 个 Gauss-Legendre 节点 (第一篇的构造)，得到 $5 \times 5 = 25$ 个候选网格点。

第二步：采样与测量矩阵。 从 25 个网格点无放回抽 M 个（第一篇主定理的样本量： $M \geq LC_1 s \log^3 s \log N$ ，Legendre 情形 $L = C^d = O(1)$ ，取 $M = 40$ 已留足余量）。组装 $\Psi_{m,j} = \varphi_j(\mathbf{x}_m)$ 与求积权 $\sqrt{n\lambda_n(\mathbf{x}_m)}$ 做行预条件： $\mathbf{D} = \sqrt{\mathbf{W}}\Psi$ 。

第三步：求解与诊断。 用 SPGL1 解基追踪。诊断三件套：恢复误差 $\|c^\sharp - c\|_2$ 、支撑是否正确（非零位置集合一致）、残差范数（应为机器零，无噪情形）。

第四步：换采样测度做对照。 同样的 M ，把采样点换成 原密度 iid 均匀采样（不加权）：恢复率下降但不崩溃；换成 Chebyshev 网格子采样 + Chebyshev 预条件（用 Chebyshev 基）：与 Legendre 网格平行。三组对照合起来验证第一篇的核心主张：**预条件与采样测度必须配套**，混搭（Legendre 基 + Chebyshev 权不匹配的组合）会比不加权更差。

这个走查里没有出现任何新理论；它的用途是把六篇的“测度 $\rightarrow$ 预条件 $\rightarrow$ 求解 $\rightarrow$ 诊断”四步流程落到一个可以亲手复现的规模上。 $d = 10$ 的版本（ $n = 3$ ， $N = 286$ ， $s = 5$ ）是论文原实验的规模，流程完全相同，只有 $\log N$ 项要求 M 变大。

18.2 常见误区

五个反复出现的错误 误区一：混用两种 Christoffel 约定。 $K = N / \sum \varphi^2$ 与 $\kappa = 1/N \sum \varphi^2$ 差一个倒数，采样方向陈述相反（预备章的警告框）。读论文先查定义式。

误区二：跳过空间增广。 最小二乘路线若取 $M = N$ 恰好满秩，条件数通常不可接受；第二篇的实验全部用 $M = 1.05N$ 以上的过采样（实现里按总次数序增广指标集约 5%）。

误区三：无界域不设节点截断。 Gauss–Hermite 节点随 n 外跑，最外侧节点上的多项式值巨大；第一篇的 $n^{2/3}$ 分析正是为它准备的。实务上若目标函数在远尾部非零，考虑换映射变量或截断支撑并接受偏差。

误区四：非凸罚不扫参数。 TL1 的 a 控制稀疏强度，固定 $a = 1$ （接近 ℓ_1 ）等于没享受非凸的好处；固定 $a = 0.05$ （过近 ℓ_0 ）会被 DCA 的局部极小坑。论文的自适应版本（候选集各解一次、保留最稀疏）是标准做法。

误区五：把压缩感知用在弱稀疏目标上。 ℓ_1 的样本复杂度正比于 $\sigma_{s,1}/\sqrt{s}$ ；目标系数长尾缓慢衰减时（如 corner-peak 型函数），稀疏网格或自适应最小二乘往往更省样本。先看系数衰减再选路线，本组方向 B 的神经网络代理是第三条路（样本足够便宜时）。

18.3 软件与可复现性

六篇论文的求解器是 SPGL1（解基追踪与 Lasso 的经典 ℓ_1 求解器，基于谱投影梯度），Legendre/Hermite 基与 Gauss 网格可由 SciPy、Chebfun 或 ChaosPy 生成；数据驱动构基（Hankel–Cholesky）二十行以内可写。六篇的方法两两正交（采样 $\times$ 罚 $\times$ 基），组合着用时按“先采样测度、后罚函数、最后基”的顺序叠加，每一步的判据在对应章节。

19 附录补充：全书的符号对照

主附录的记号表按“六篇各自使用”列出。这里给一张跨篇对照，方便交叉阅读时对照：

概念	第一篇	第二篇	第三篇	第五/六篇
Christoffel 函数	λ_n^i （求积权）	K_Λ （点列加权）	（隐式，经 P ）	κ 或其倒数
采样测度	ν_n （Gauss 网格）	确定性点集	Chebyshev 偏置	平衡测度 / induced μ
预条件	$\sqrt{n\lambda_n}$	$1/\sqrt{K_\Lambda}$ 进基	$\mathbf{W}$ 行 + $\mathbf{P}$ 列	$w_m = K(z_m)$ 或 $1/\kappa$

概念	第一篇	第二篇	第三篇	第五/六篇
优化问题	加权基追踪	加权最小二乘	梯度增强基追踪	加权 LS / 加权基追踪
判据	RIP, L 因子	条件数 = 1	MIC / coherence	Cohen-LS 稳定性

20 案例研究：同一个问题族，六种工具

六篇的 PDE 实验并没有共用一个基准算例。它们问的是同一件事：给一个系数（或载荷、或材料参数）随机的方程，把某个数量对随机参数的依赖 写成一个多项式，然后回答需要多少次求解。但每篇挑的模型、报的误差量、图的横轴各不相同。读这组论文时最容易弄混的就是最后一列，所以先把六个算例摆清楚，再谈可比的部分。

论文	随机方程算例	维数与多项式空间	报告的量与横轴	参照解怎么来
第一篇	稀疏多项式恢复；解析函数；一维随机 ODE；二维随机扩散	$d = 2, n = 21, N = 231$; $d = 10, N = 286$	系数 ℓ_2 误差与恢复概率，横轴样本数 M ，500 次试验平均	恢复实验用已知真系数；PDE 用高阶稀疏网格配点
第二篇	一维随机扩散 $-\frac{d}{dx}x(\kappa u_x) = f, f = 2$ ，两端 Dirichlet	$d = 2, 6$ (TD); $d = 10, 25$ (HC), $M = 1.05N$	QoI $u(0.5, y)$ 的逼近误差，横轴是多项式次数；条件数另图，50 次试验分位数	稠密配点解
第三篇	二维随机扩散 (Babuška–Nobile–Tempone 系数，相关长度 $L_c = \frac{1}{12}$ ，载荷 $\cos(y_1) \sin(y_2)$)	$d = 3, n = 10$; $d = 10, n = 4$	均值与方差的 ℓ_2 误差，横轴样本数	蒙特卡洛 6000 样本给出均值与方差
第四篇	稀疏多项式恢复；解析函数；随机强迫 KdV 方程	$d = 2, k = 20, N = 231$; $d = 10$	恢复概率与误差，横轴 M ；KdV 一例画 gPC 系数幅值图	已知真系数；KdV 与 ℓ_1 对照
第五篇	Genz 型测试函数；电阻网络；二维随机扩散	网络 $d = 2, 4$; PDE $d = 2$ (二项与正态边际)	逼近误差，横轴次数 k ；条件数对照 MC/AFP/CFP	函数用解析值；网络用稠密求解
第六篇	稀疏恢复；Genz 函数；Kirchhoff 板弯曲（随机杨氏模量 KL 展开，Morley 非协调元）	$d = 2$ 配 20 次； $d = 10$ 配 3 次；候选样本 $Q = 10^4$	系数离散 ℓ_2 误差，横轴 M ；恢复判据 $\ \hat{c} - c^*\ _{\text{infty}} < 10^{-3}$	已知真系数；板方程在 648 个三角形、1369 个未知数的网格上解

三处最容易读错的地方。第一，第一篇与第三篇的曲线横轴是样本数，第二篇与第五篇的横轴是多项式次数（样本数固定在 $1.05N$ ），两种曲线不能叠在一张图上比大小。第二，同为 PDE 误差，第一篇量的是均值与标准差各自的 ℓ_2 偏差，第三篇量均值与方差，第二篇量单点 QoI 的逐点误差，第六篇量系数向量的离散 ℓ_2 误差：系数误差小可以对应 QoI 误差大（低阶系数错得少但错在主导项上）。第三，条件数只有第二、五篇报了，第三篇报的是 MIC，第一、四、六篇报恢复概率或恢复判据。这四项诊断彼此独立，一张图只覆盖其中一项，跨篇比较时要先确认对方看的是哪一项。

把方法本身放在一起看，差异集中在两处（换采样还是换罚函数）：

论文	路线	实验维数	样本量级	关键观察
第一篇 (2017)	Gauss 网格子采样 + 加权 ℓ_1	$d = 3$ (Legendre)、 $d = 10$ (Chebyshev 与 Hermite)	$M \sim 85$ ($s \leq 8$)	Legendre 低维高次最占优; Hermite $d = 10$ 时按原密度采样反超
第二篇 (2017)	加权 Fekete 点 + 加权 LS	$d = 2, 6, 10$ (TD); $d = 10, 25$ (HC)	$M = 1.05N$	条件数恒近 1; 误差与 AFP 相当、远好于 MC
第三篇 (2018)	梯度增强加权 ℓ_1	$d = 3, 10$	同标准 ℓ_1 , 信息多 $d + 1$ 倍	伴随梯度免费时全面占优; 部分梯度也受益
第四篇 (2018)	TL1 + DCA	$d = 2, 10$	同 ℓ_1 或更少	解更稀疏; a 需要扫描或自适应
第五篇 (2018)	数据驱动基 + 加权 LS	$d = 2, 5$ (混合分布)	$M = CN \log N$	分布任意 (含离散) 仍稳定
第六篇 (2020)	数据驱动基 + induced 采样 ℓ_1	$d = 2, 10$	$M \sim s \log$ 因子	低维高次显著省样本; 高维低次退化为 MC

20.1 从表里读出的三条选型规则

规则一：先问“分布知不知道”。 已知分布 $\rightarrow$ 第一至四篇的路线（测度可以显式构造）；只有样本 $\rightarrow$ 第五、六篇。第五篇走超定 ($M \geq N$)，第六篇走欠定 ($M \ll N$)，由样本预算决定。

规则二：再问“梯度贵不贵”。 伴随方程可得时，第三篇的梯度增强是纯收益（同样本量信息翻倍），没有已知的代价场景。梯度只能从差分来时，多算 d 倍函数值（standard-double 对照），收益为负。

规则三：最后问“目标多稀疏”。 系数快速衰减（随机场相关长度短，理论章的 c 大） $\rightarrow$ 欠定 ℓ_1 路线（第一、六篇）最省；系数缓慢衰减或目标接近稠密 $\rightarrow$ 超定加权 LS（第二、五篇）更稳，非凸罚（第四篇）介于两者之间。

20.2 把样本量界换算成预算，以及为什么换算不动

三条规则给的是方向。要落成预算，得把定理里的 M 界代进具体参数。以第四篇的显式界为例（它把第一篇的 L 因子写成了 3^P ， P 是多项式的最高次数，其余各篇的界形状相同）：

$$M \gg C\delta^{-2}3^P s \log^3(2s) \log(N),$$

取三个真实的指标集： $s = 20$ ，非凸参数 $a = 0.3$ （第四篇的推荐区间），于是 $\delta < \frac{1}{1+(a+1)/a\sqrt{2}} = 0.140$ ， $\delta^{-2} > 50.8$ 。剩下的因子按指标集算：

指标集	N	$s \log^3(2s) \log N$	3^P	界的量级	超定 LS 的 $1.05N$
$d = 2, P = 20$	231	5464	3.5×10^9	10^{15}	243
$d = 3, P = 10$	286	5678	5.9×10^4	10^{10}	300
$d = 10, P = 4$	1001	6936	81	$10^{7.5}$	1051

三个界落在 $10^{7.5}$ 到 10^{15} ，而论文实际用的 M 是 85 到 $1.05N$ 。差了八个到十二个数量级，所以这些界不能当预算用，它们的用途是同一族问题内部的相对比较。两点相对结论是可靠的：其一， 3^P 是这里唯一能压垮一切的因子，第一个算例比第三个高约七个半数量级，几乎全部来自 $P = 20$ 与 $P = 4$ 的差别；在 Legendre 基加均匀采样这套估计里，次数比维数致命。其二， δ^{-2} 与 a 绑在一起，非凸罚把 a 调小（更靠近 ℓ_0 ）就要付出样本量的代价，这笔账在第四篇的 a 扫描图里是以恢复率的形式出现的，两处说的是同一个折中。

预算该抄哪个数 能直接抄的是论文里的经验标度： $N = 231$ 到 286 的欠定恢复用 $M \approx 85$ ($s \leq 8$)；超定加权 LS 用 $M = 1.05N$ ；数据驱动基上的准线性路线用 $M = CN \log N$ 。这三组数字来自同一批实验设置，量纲一致，可以直接换算成自己的求解次数。

20.3 六篇都没有做的事

把表里所有方法放在同一个 $d = 20$ 、非仿射（对数正态混合）场下比较，在文献里仍然缺失：六篇的实验各自止步于自己的维数区间（最高 $d = 25$ ，那一格只测了条件数，没有做逼近）。第三篇的均值误差与第五篇的次数误差之间也缺一座桥：前者要蒙特卡洛参照，后者要稠密配点参照，两种参照的精度没有对过表。真正的“维数、稀疏度、分布类型”三元相图要靠后续工作补全，读这组论文时值得带着这张未完成的地图。

21 谱系：随机方程的统计量，前人怎么算

在进入本线六篇之前，先把问题域里的三条前人路线按时间排开。本线的每一篇都能在这张地图上找到自己的出发点。

21.1 谱方法线：从随机 Galerkin 到任意分布

- **Wiener (1938)** 提出齐次混沌展开，是“用正交多项式表示随机量”的数学源头。
- **Ghanem-Spanos (1991)** 把多项式混沌做成随机有限元：把展开代入方程、对基做投影，解一个大的确定性方程组。收敛快（谱收敛），但侵入式：必须改求解器内部，且基函数个数随维数指数增长。
- **Xiu-Hesthaven (2005)** 提出随机配点：在随机空间选点、每个点调用原求解器（黑箱）、再用插值或回归拟合系数。非侵入的代价是配点数仍然指数增长，于是有了下一站。
- **稀疏网格**：Smolyak (1963) 的嵌套构造把张量积从 n^d 压到 $n(\log n)^{d-1}$ 量级；Gerstner-Griebel (1998) 做自适应加密（按每个方向的方差贡献增量加点）；Babuška-Nobile-Tempone (2007) 给出随机椭圆方程的收敛分析。稀疏网格今天仍是弱稀疏问题的主力，本线六篇的 PDE 实验全部用它做参考解。
- **任意分布的基**：Wiener-Askey 对应表 (Xiu-Karniadakis 2002) 把经典分布映射到经典多项式；ME-gPC (Wan-Karniadakis 2006) 做多单元自适应；aPC (Oladyshkin-Nowak 2012) 直接做矩匹配，放弃分布假设；SAMBA (Ahlfeld 等 2016) 用 Hankel 矩阵稳定化。本线第五、六篇的 data-driven 基就是从 aPC 与 SAMBA 接力的。

21.2 压缩感知线：从计数到采样测度

- **Candès-Romberg-Tao 与 Donoho (2006)** 确立压缩感知： M 与稀疏度同阶的测量可以恢复稀疏向量，RIP 是标准分析工具。
- **Doostan-Owhadi (2011)** 第一次把它用到随机 PDE：解在 Legendre 基下稀疏，所以欠定的配点系统可以解。同期 Mathelin 等做了类似尝试。
- **理论侧**：Rauhut-Ward (2012 起) 证明 Legendre/Chebyshev 系统在 Chebyshev 偏置采样下满足 RIP，给“采样测度影响样本量”定下基调；Yan-Guo-Xiu (2018) 给原密度采样下的高维恢复率；Peng 等 (2016) 做了 Hermite 情形的梯度增强。
- **采样测度的演化**贯穿本线六篇：原密度采样（信息少、噪声大）→ Chebyshev 偏置（压平多项式能量）→ coherence 最优 (Hampton-Doostan 2015) → 平衡测度 (Jakeman 等 2016 的 CSA) → induced 分布 (Cohen-Migliorati 2017, 密度已知时最优)。本线第一篇与第六篇分别接管了其中“结构化网格”与“只靠样本”两个分支。

21.3 加权最小二乘线：确定性点集

- **Cohen-Davenport-Leviatan (2013)** 分析无权最小二乘的稳定性：均匀随机采样要 $M \sim N^2$ 。
- **Narayan-Jakeman-Zhou (2014 起)** 证明 Christoffel 加权配平衡测度采样可把样本量压到接近最优的 $M \sim N$ 。

- **确定性点集**：Fekete 点 (Sommariva–Vianello 2009 的数值构造)、Leja 点的贪心序列。本线第二篇的加权 Fekete 点在这一支上，贡献是“加权后贪心有全局最优性证明”且摆脱紧支撑假设。
- 一个跨社区的联系：Christoffel 函数在随机数值线性代数里对应 **杠杆分数** (leverage score: 第 i 行对拟合的贡献占比，衡量“这个样本重不重要”的通行度量)，两个社区在互不知情的情况下用了同一个量。

22 坐标：这条线站在哪里

22.1 每篇的最接近替代品

论文	最接近的替代品	差在哪里
Gauss 网格子采样 (2017)	Tang–Zhou (仅均匀分布 + Legendre); Yan–Guo–Xiu 按原密度采样	前者只覆盖一种分布; 后者无结构化网格, L 因子无法显式估计, 高维 Hermite 下样本量失去控制
加权 Fekete 点 (2017)	经典 AFP (Sommariva–Vianello); Leja 点	AFP 需要紧支撑; 两者都没有“贪心 = 全局最优条件数”的证明
梯度增强 ℓ_1 (2018)	Peng 等 2016 (Hermite/高斯专用)	只有一种基一种测度; 无一般预条件框架与 coherence 理论
TL1 (2018)	ℓ_{1-2} (Yan 等 2015)、 ℓ_p (Guo–Liu 2017)	RIP 条件依赖 s 或更紧; 误差常数更繁琐; 无自适应 a
数据驱动加权 LS (2018)	SAMBA (Ahlfeld 等 2016, 稀疏网格后处理); 经典 aPC (矩匹配 Vandermonde)	SAMBA 点数随维数爆炸; 经典 aPC 高次病态、无稳定性理论
induced sampling (2020)	CSA (Jakeman 等 2016, 平衡测度采样 ℓ_1); Cohen–Migliorati induced (密度已知版)	CSA 采样点会落在数据支撑外; Cohen–Migliorati 需要已知密度

22.2 更大坐标系里的位置

相对稀疏网格。 Smolyak/自适应稀疏网格是配点法的传统主力，点集结构化、有收敛理论，但点数随维数增长仍快，且自适应构造串行。压缩感知路线把负担从“选点的结构”转移到“解的稀疏性”上，两者适用区不同（弱稀疏问题稀疏网格仍占优）。

相对随机 Galerkin。 Galerkin 侵入但收敛最快；配点非侵入但点数受限。本线的全部方法都站在配点一侧，为的是与既有确定性求解器即插即用。

相对贝叶斯压缩感知。 sparse Bayesian learning 给出系数后验，适合量化系数级不确定度；代价是超参数与推理开销。本线是频率派点估计，换来的是清晰的样本复杂度。

与现代深度学习代理的关系。 当样本极便宜（模拟可以海量并行）时，神经网络代理（本组方向 B 的 PINN 类方法）是替代路线；样本昂贵（一次 PDE 求解以小时计）时，本线的“用最少样本恢复最多系数”仍然是更合适的选择。两条线在同一位作者的工作里并行，对应“样本贵”与“样本便宜”两种现实。

22.3 逻辑阶梯

级	工作	新加入的概念
1	Doostan–Owhadi; Yan–Guo–Xiu	随机 PDE 解稀疏 $\rightarrow$ CS 可用; 原密度采样
2	Rauhut–Ward; Tang–Zhou	偏置采样 (Chebyshev/Gauss 网格) + 预条件
3	本线第一篇 (2017)	任意 Beta/指数分布的网格子采样; L 因子显式界

级	工作	新加入的概念
4	第二篇 (2017)	确定性贪心点列; 加权 = 全局最优条件数
5	第三篇 (2018)	导数测量; 预条件三件套 W/P
6	第四篇 (2018)	非凸罚 TL1 + DCA; 自适应 a
7	第五篇 (2018)	纯数据驱动的基; 采样与构基解耦
8	第六篇 (2020)	induced 测度: 数据支撑上的稀疏恢复

每一级都在收窄同一个间隙：从“假设分布已知”到“只有样本”，同时保持样本复杂度尽量贴近理论下限。

22.4 谁受影响

- **UQ 工程界**：多物理场、地下水、结构力学的参数化 PDE 前向 UQ，有了“任意分布 + 黑箱求解器 + 样本量有保证”的现成工具箱；
- **压缩感知社区**：Christoffel 加权在“离散正交系统 + 行子采样”框架下 的分析技术被后续采样型 CS 工作反复引用；
- **本组方向 B (深度学习 UQ)**：当输入分布未知、样本有限时，induced sampling 的“从数据定义测度”思想在数据驱动 aPC 基里延续，是方向 B 里 NN-aPC 那篇的直接前身（aPC 正交化思路同源）。

22.5 不该过度宣称的部分

- “任意分布”在无界域仍需假设密度类型（高斯型或指数型），第五篇自己列出的局限；
- L 因子的常数 C 在 Legendre 情形理论上界是 3^d （数值暗示 2^d ），维数指数尾巴没有消除，只是被压小；
- TL1 的 DCA 是局部算法，非凸罚没有全局最优保证；
- induced 采样在高维低次（ $\mu \approx \omega$ ）时与朴素 MC 无差别，集成方法的优势区在低维高次。

23 附录

23.1 A. 记号表

记号	含义
d	随机维数
$y, \mathbf{y}$	随机变量 / 随机向量; Γ 是取值域
ρ^i, ρ	边际密度与联合密度
φ_n^i, φ_n	一元与多元正交多项式基
Λ, N	指标集与基函数个数
s	稀疏度（显著非零系数个数）
M	样本（配点）数
$\Psi, \mathbf{A}, \mathbf{D}$	测量矩阵（ $\mathbf{D}$ 为预条件后）
$\mathbf{W}, \mathbf{P}$	行预条件与列归一矩阵（第三篇）
δ_s	RIP 常数
μ, μ_L, β_L	互不相干常数与逐列上界型 coherence
$K_\Lambda, \kappa, \lambda_n$	Christoffel 函数的三种记法（各篇略异）
$L(n)$	采样测度的分布常数（主定理里的乘积界）
ν_n, μ	Gauss 网格离散测度与 induced 测度

记号	含义
$\sigma_{s,1}$	最佳 s -项逼近的 ℓ_1 尾巴
ρ_a, P_a	TL1 罚与它的总和
a_j, b_j	正交多项式三项递推系数

23.2 B. 关键公式速查

问题格式

- 基追踪: $\arg \min \|c\|_1$ s.t. $\Psi c = f$; 加权版 $\sqrt{W}Ac = \sqrt{W}b$
- 加权最小二乘: $\arg \min \|W^{1/2}Ac - W^{1/2}f\|_2^2$
- 梯度增强: $\tilde{\Phi} = \begin{pmatrix} \Phi \\ \Phi_\theta \end{pmatrix}$, $\arg \min \|c\|_1$ s.t. $W\tilde{\Phi}Pc = W\tilde{f}$
- TL1: $\min P_a(x) = \sum \frac{(a+1)|x_i|}{a+|x_i|}$ s.t. $Ax = b$

恢复保证

- RIP 恢复: $\delta_s < 0.307 \Rightarrow \|c^\dagger - c\|_2 \leq C\sigma_{s,1}(c)/\sqrt{s}$
- 样本量: $M \geq L(n)C_1 s \log^3(s) \log(N)$, $L = \prod_i L_i(n_i)$; Jacobi: $L_i = C$; 指数型: $L_i = Cn^{2/3}$
- MIP 恢复: $\mu < 1/(2s-1)$ 时精确恢复
- TL1: $\delta_{2s} < \frac{1}{1+(a+1)/a\sqrt{2}}$, 误差 $C_0 s^{-1/2} P_a(x - x_s) + C_1 \varepsilon$
- Cohen-LS: $\kappa(N) \leq \delta M / \log M$ 时无权 LS 稳定; Christoffel 加权后 $\hat{\kappa} = N$

三个显式构造

- 求积权多项式: $\psi_{k,n}^i = \sqrt{n\lambda_n^i(x^i)}\varphi_k^i(x^i)$, 在离散测度 ν_n^i 下正交归一
- 加权基: $Q = \text{span}\{\psi_\alpha/\sqrt{K_\Lambda}\}$, 行范数恒为 1
- induced 测度: $\mu = \sum_j \tilde{\kappa}_j \delta_{z^{(j)}}$, $\tilde{\kappa}_j \propto \kappa(z^{(j)})$; 采样从 μ 、权重 $1/\kappa$

23.3 C. 六篇论文信息

- L. Guo, A. Narayan, T. Zhou, Y. Chen. **Stochastic collocation methods via ℓ_1 minimization using randomized quadratures.** SIAM J. Sci. Comput., 2017. arXiv:1602.00995.
- L. Guo, A. Narayan, L. Yan, T. Zhou. **Weighted approximate Fekete points: sampling for least-squares polynomial approximation.** 2017. arXiv:1708.01296.
- L. Guo, A. Narayan, T. Zhou. **A gradient enhanced ℓ_1 -minimization for sparse approximation of polynomial chaos expansions.** 2018. arXiv:1802.08837.
- L. Guo, J. Li, Y. Liu. **Stochastic collocation methods via minimization of transformed ℓ_1 penalty.** 2018. arXiv:1805.05416.
- L. Guo, Y. Liu, T. Zhou. **Data-driven polynomial chaos expansions: a weighted least-square approximation.** 2018. arXiv:1805.10893.
- L. Guo, A. Narayan, Y. Liu, T. Zhou. **Sparse approximation of data-driven polynomial chaos expansions: an induced sampling approach.** 2020. arXiv:2008.10121.

23.3.1 背景文献

- D. Doostan, H. Owhadi. **A non-adapted sparse approximation of PDEs with stochastic inputs.** J. Comput. Phys., 2011. 压缩感知进入 UQ 的最早工作之一。
- L. Yan, L. Guo, D. Xiu. **Stochastic collocation algorithms using ℓ_1 -minimization.** SIAM J. Sci. Comput., 2018. 原密度采样路线的代表。

- H. Rauhut, R. Ward. **Interpolation via weighted ℓ_1 minimization**. Appl. Comput. Harmon. Anal., 2016. Chebyshev 偏置采样的 RIP 理论基础。
- G. Tang, G. Iyengar (Tang-Zhou). **Compressed sensing with structured Gauss quadrature grids**. 2016. 本线第一篇的直接前身（均匀分布情形）。
- A. Cohen, M. A. Davenport, D. Leviatan. **On the stability and accuracy of least squares approximations**. 2013. 无权最小二乘 $M \sim N^2$ 的奠基分析。
- A. Cohen, G. Migliorati. **Optimal weighted least-squares methods**. 2017. induced distribution 概念的来源（密度已知版）。
- J. Hampton, A. Doostan. **Coherence motivated sampling**. 2015. coherence 型采样判据的来源。
- J. Jakeman, A. Narayan, et al. **Generalized compressed sensing statistics**. 2016. CSA（平衡测度采样）的代表。
- O. G. Ernst, et al. **On the convergence of generalized polynomial chaos expansions**. 2012. gPC 收敛与矩问题理论。
- X. Wan, G. E. Karniadakis. **Multi-element generalized polynomial chaos**. 2006. ME-gPC, 任意分布 gPC 的早期替代路线。
- L. Zhang, J. Xin. **TL_1 : transformed ℓ_1 penalty**. 2016. TL1 罚的原始文献。

23.4 D. 自检清单

读完后应该能回答

1. 随机配点法为什么天然欠定？稀疏性假设从哪里来？（第 1 章）
2. RIP 与 MIP 各自衡量什么？为什么梯度增强那篇走 MIP 路线？（第 4 章）
3. Christoffel 函数的分母大意味着什么？为什么“多采 K 大的点”？（第 1 章定义框）
4. Gauss 网格子采样里，求积权为什么恰好等于 Christoffel 权重？离散正交性怎么证？（第 6 章引理）
5. L_i 在有界与无界分布下的界差在哪里？为什么无界情形的 $n^{2/3}$ 无法消除？（第 6 章）
6. 加权 Fekete 点的“贪心 = 全局最优”证明里，Hadamard 不等式用在何处？（第 7 章）
7. 拼接导数行后矩阵为什么变差？ W/P 预条件靠哪条正交恒等式设计？（第 9 章）
8. TL1 的参数 a 怎么插值 ℓ_0 与 ℓ_1 ？自适应版怎么选 a ？（第 10 章）
9. Hankel–Cholesky 构基相对直接解矩匹配方程，稳定在哪里？（第 13 章）
10. induced 测度怎么定义？“从 μ 采样 + 按 $1/\kappa$ 加权”为什么等于一次重要性采样？（第 14 章）

24 附录补充：术语索引、阅读路线与跨界接口

24.1 术语索引（按定义位置）


术语	定义位置	一句话
Christoffel 函数	第 1 章定义框	多项式平方和的倒数（或其倒数版），采样与加权的公共主轴
三项递推 / Jacobi 矩阵	第 2 章	递推系数编码测度；Golub–Welsch 从它读出节点与权
Gauss 求积精度	第 2 章，定理	n 点法则对 $2n - 1$ 次精确，证明一行带余除法
求积权 = Christoffel 函数	第 2 章，引理	Christoffel–Darboux 的直接推论
基追踪	第 1 章	$\min \ c\ _1 \text{ s.t. } \Psi c = f, \ell_0$ 的凸松弛
RIP	第 4 章，定义	矩阵近似保持稀疏向量长度；随机采样高概率成立
MIP / MIC	第 4 章，定义	最坏列对的归一化内积；逐点可验

术语	定义位置	一句话
一致有界系统 / L 因子	第 6 章, 引理	加权多项式逐点界的常数, 决定样本量
加权近似 Fekete 点	第 7 章	$1/\sqrt{K}$ 进基的贪心点列; 加权后贪心全局最优
梯度增强	第 9 章	导数行拼入测量矩阵; W/P 预条件保各向同性
TL1 罚	第 10 章	$\rho_a = (a+1) t /(a+ t)$, a 插值 ℓ_0 与 ℓ_1
Hankel-Cholesky 构基	第 13 章	矩 $\rightarrow$ 对称正定矩阵 $\rightarrow$ 分解 $\rightarrow$ 递推系数
平衡测度	第 14 章与谱系章	$\kappa\rho$ 的位势论极限; 有界域上是 Chebyshev 测度
induced 测度	第 14 章	经验样本按 κ 加权的离散测度; 配 $1/\kappa$ 权无偏
杠杆分数	谱系章	随机数值线性代数里同一思想的另一个名字

24.2 与方向 B 的接口：数据驱动思想进入深度学习

组内方向 B (神经网络解随机方程) 的第一篇 (NN-aPC) 与本线的 第五、六篇共享同一个出发点：**输入分布未知、只有样本时，正交基从数据的矩构造**。差异在下游：本线把基交给多项式逼近，方向 B 把基交给网络的模态结构。两条线对“数据驱动基”的分工也互补：本线的收敛性由逼近论保证（多项式最优逼近率），方向 B 的表达力由网络保证（非线性特征），代价是没有收敛率。一个正在发生的合流：学习式基函数 + 稀疏恢复系数（用方向 B 的网络算基、用本线的 ℓ_1 算系数）在文献里已经出现雏形，本线第六篇的 induced 采样正是这类混合方法需要的采样部件。

24.3 阅读路线



24.4 参考文献补充 (谱系章新增条目)

- N. Wiener. **The homogeneous chaos**. American J. Math., 1938.
- R. Ghanem, P. Spanos. **Stochastic finite elements: a spectral approach**. Springer, 1991.
- S. Smolyak. **Quadrature and interpolation formulas for tensor products of certain classes of functions**. 1963.
- Gerstner, Griebel. **Numerical integration using sparse grids**. 1998.
- I. Babuška, F. Nobile, R. Tempone. **A stochastic collocation method for elliptic PDEs with random input data**. SIAM Review, 2010.
- D. Xiu, G. E. Karniadakis. **The Wiener-Askey polynomial chaos**. 2002.
- X. Wan, G. E. Karniadakis. **Multi-element generalized polynomial chaos**. J. Comput. Phys., 2006.

- R. Ahlfeld, B. Belkharraz, et al. (SAMBAs). 2016.
- A. Cohen, M. A. Davenport, D. Leviatan. **On the stability and accuracy of least squares approximations**. Found. Comput. Math., 2013.
- A. Chkifa, A. Cohen, C. Schwab. **High-dimensional adaptive sparse polynomial interpolation**. 2014.
- A. Cohen, G. Migliorati. **Optimal weighted least-squares methods**. 2017.
- J. Hampton, A. Doostan. **Coherence motivated sampling**. J. Comput. Phys., 2015.
- J. Jakeman, A. Narayan, et al. **Generalized compressed sensing statistics**. SIAM/ASA JUQ, 2016.
- A. Cohen, R. DeVore, C. Schwab. **Analytic regularity and polynomial approximation of parametric stochastic PDEs**. 2010. 稀疏性定理的出处。
- E. Fornberg et al. SPGL1 求解器: M. Friedlander, M. van den Berg. **Probing the Pareto frontier for basis pursuit solutions**. 2008.