

科学机器学习的不确定性量化

从一个综述到一个信息瓶颈框架，再到四个后继

精读对象：Psaros, Meng, Zou, Guo, Karniadakis (SIAM Review 2023);

Guo, Wu, Zhou, Wang, Zhou (2023); Wang, Guo, Wu, Zhou (2024);

Zhang, Guo, Wu (2024); Ma, Guo, Wu, Zhou (2025); Feng, Guo, Wan, Wu, Zhou, Zhou (2025)

上海师范大学 郭玲 · SciML 不确定性量化方向 · arXiv 2201.07766 / 2302.03271 / 2401.02080 / 2408.15981 / 2509.25646 / 2507.22493

神经网络开始替代数值求解器之后，出现一个新问题：网络给出的预测 要不要信、信多少。这份笔记沿这条线索走：先把“不确定性”本身拆开（它有几种来源、怎么度量、怎么校准），再进入方法主线，信息瓶颈如何同时给出预测均值与可信的不确定度，以及它的四个演化方向（采样、降维理论、置换不变算子、物理约束的潜变量模型）。

怎么读这份笔记

- **概念准备** 备齐起点：不确定性从哪来（数据、模型、网络三层的分解），贝叶斯模型平均与 MC 采样怎么把参数不确定性传播成预测分布，以及“校准”这个容易被忽略的维度。
- **综述篇** 到 **评测协议实操** 四章是全景：方法分类、经典方法的逐个精讲、指标体系与大规模比较的结论。读它们建立坐标。
- **方法核心** 与 **IB-UQ 深入** 两章是主线：信息瓶颈怎么被改造成 UQ 工具。变分下界的推导完整保留；它与信息瓶颈谱系（Tishby、VIB）的关系逐条对照。
- **后继一** 到 **后继四** 是四个演化方向：扩散生成器采样 Boltzmann 分布（EDG）、反应坐标的最优降维（FMRC）、置换不变的算子学习 UQ（UQ-SONet）、物理约束的潜变量模型（LVM-GP）。每个后继后面紧跟一章“实验台／实现台”，把论文正文与附录里的算法、数据配置、超参数和全部数值摊开核对。
- **谱系** 与 **坐标** 两章把这条线放回更大的文献网络，并说明它现在停在何处。 **附录** 是符号表与复现清单。

术语地图

aleatoric / epistemic
后验分布
贝叶斯模型平均
校准
过置信
OOD
信息瓶颈

数据噪声带来的不可约不确定性 / 有限知识带来的可约不确定性。
看到数据之后参数（或解）的条件分布；UQ 的中心对象。
按后验加权平均各参数取值下的预测，得到预测分布。
预测的置信区间与真实误差频率一致：95% 区间盖住约 95% 真值。
区间太窄：声称的置信度高于实际覆盖率。深度网络最常见。
分布外（out-of-distribution）：输入落在训练数据没覆盖的区域。
在压缩输入与保留目标信息之间取权衡的表示学习框架。

变分下界	把算不出的量变成可优化的上/下界，深度生成模型的标准工具。
normalizing flow / GIN	可逆变换链；保体积版本（GIN）用来给输入分布“加温”。
配分函数	Boltzmann 分布的归一化常数，积分通常算不出，采样方法必须绕开它。
反应坐标	高维动力系统的少数关键变量，长期行为由它们决定。
置换不变	输入集合换顺序输出不变；处理“变长传感器集合”的性质。
潜变量模型	用隐随机变量解释观测相关性的模型；VAE 是其神经版本。
高斯过程	函数上的高斯先验，由核函数指定任意两点取值的相关性。

目录

第 0 章 预备知识：这本书假设你会什么、补什么	5
0.1 读者起点：已经会的，与不要求的	5
0.2 两种不确定性：为什么模型要输出一个分布	5
0.3 贝叶斯定理：先验、似然、后验	6
0.4 熵、KL 散度、互信息	7
0.5 高斯分布：这本笔记里的三个角色	8
0.6 蒙特卡洛：算不出的积分怎么估	8
0.7 分位数与置信区间：从分布回到一句话的决策	9
0.8 训练一个神经网络：最小必要版	10
0.9 生成模型：只有样本、没有密度公式时怎么办	10
0.10 记号约定	11
0.11 阅读地图与自测	11
1 概念准备：不确定性从哪里来	12
1.1 为什么神经网络需要 UQ	12
1.2 统一的问题设定	13
1.3 贝叶斯模型平均：参数不确定性怎么变成预测不确定性	13
1.4 校准：被忽略的第二个维度	14
2 综述篇：方法地图与比较结论（SIAM Review 2023）	15
2.1 方法分类	15
2.2 指标体系	16
2.3 比较研究的设计与结论	16
3 经典 UQ 方法逐个精讲	17
3.1 HMC：金标准及其代价	17
3.2 朗之万动力学：一步版	17
3.3 MFVI：把采样变成优化	18
3.4 MC dropout：不重新训练的不确定度	19
3.5 拉普拉斯近似：训练后的一次性计算	19
3.6 深度集成与其省钱变体	19
3.7 非贝叶斯三替代（综述列出的未来方向）	19
3.8 指标体系补全	19
4 评测协议实操：指标、校准与成本	20
4.1 三类指标，按你需要什么数据来分	20
4.2 RMSCE 的构造细节，以及为什么要按 x 平均	21
4.3 后校准：三种花小钱的修法	22

4.4	金标准之外：怎么知道模型“知道自己不懂”	22
4.5	成本要按“取样”算，别按“使用”算	22
4.6	同一批数据上的相反结论	23
4.7	这套协议里仍然空的格子	24
5	方法核心：信息瓶颈做 UQ (IB-UQ, 2023)	24
5.1	它要解决的问题	24
5.2	改造一：压缩项换成宽分布版本	24
5.3	改造二：置信度混合编码器	25
5.4	变分下界（推导完整保留）	26
5.5	数据增强的理论保证	27
5.6	DeepONet 版（算子学习）	28
5.7	实验检验	28
6	IB-UQ 深入：率失真视角、算法细节与实验画廊	29
6.1	用率失真的语言重读 IB-UQ	29
6.2	Mixup 与 $\alpha = 0.005$	29
6.3	算子版算法的完整流程	29
6.4	实验画廊	30
7	后继一：Boltzmann 分布的扩散采样器 (EDG, 2024)	32
7.1	问题：没有样本的生成建模	32
7.2	框架与主定理	32
7.3	样本重加权与配分函数	33
8	后继二：反应坐标的最优降维 (FMRC, 2024)	35
8.1	问题：降维有没有“最优”，能不能端到端学	35
8.2	两个准则	35
8.3	Flow matching 损失与主定理	35
9	后继三：置换不变的算子学习 UQ (UQ-SONet, 2025)	36
9.1	问题：变长传感器 + 不确定度	36
9.2	结构	37
9.3	实验：不确定度随传感器数的两种行为	37
10	后继四：物理约束的潜变量模型 (LVM-GP, 2025)	38
10.1	问题：潜变量要不要空间相关	38
10.2	方法：把 IB-UQ 的编码器接上 GP 先验	38
11	EDG 实验台：怎么在没有真样本的问题上比方法	39
11.1	指标：加权 MMD，以及它为什么还能用	39
11.2	六个二维能量函数：MMD 对照表	39
11.3	消融：解码器和编码器各赚了多少钱	40
11.4	两个网络设计细节	40
11.5	贝叶斯逻辑回归与 Coverttype：把采样当后验拟合	41
11.6	分子任务：LJ13 与 LJ55	41
11.7	Ising：把配分函数下界当成绩	42
11.8	时间与内存	43
11.9	这一篇里还没做完的事	43
12	后继方法补充：推导、对照与画廊	44
12.1	EDG 补充一：为什么 subVP 的转移核解析可采样	44
12.2	EDG 补充二：概率流 ODE 与密度计算	45
12.3	FMRC 补充：误差链的完整叙述	46

12.4 UQ-SONet 与 LVM-GP 补充	48
13 FMRC 深处：算子误差、可计算准则与一次验证	49
13.1 设定：允许非平衡的转移算子	49
13.2 两个准则，以及它们为什么成对出现	50
13.3 最优性定理：损失值就是坐标质量	51
13.4 误差链条的四块砖	52
13.5 算法与它没说的事	53
13.6 唯一的实验说明了什么，没说明什么	53
13.7 它站的位置	55
14 UQ-SONet 的实现台：算法、数据、超参与全部数值	55
14.1 算法把编码器和解码器分在了两侧	55
14.2 方差乘 M ：从离散损失到函数空间损失	56
14.3 数据怎么生成，参照解怎么算	57
14.4 超参与成本	58
14.5 数值表	58
14.6 指标口径与没测的东西	60
14.7 源码里几处需要留意的书写	60
15 LVM-GP 的实现台：门控、正则与六个算例的数字	61
15.1 编码器：一个门控，一个带空间相关的先验	61
15.2 解码器：归一化的高斯核积分，以及一条“噪声不求导”的假设	61
15.3 正则项：独立版、相关版，以及一处核对	62
15.4 GP 怎么求导（附录 A 的两条路）	62
15.5 训练协议与两个基线的配置	63
15.6 六个算例的数字	63
15.7 这份源码里没有的东西	66
16 谱系：神经网络的“误差棒”从哪来	66
16.1 贝叶斯深度学习：后验样本的三条获得方式	66
16.2 非贝叶斯的不确定度：三条替代路线	67
16.3 物理约束 + UQ：综述与本组的交接点	67
17 坐标：这条线站在哪里	67
17.1 每篇的最接近替代品	67
17.2 更大坐标系里的位置	67
17.3 逻辑阶梯	68
17.4 谁受影响	68
17.5 不该过度宣称的部分	68
18 附录	69
18.1 A. 记号表	69
18.2 B. 关键公式速查	69
18.3 C. 六篇论文信息	70
18.4 D. 自检清单	71

第 0 章 预备知识：这本书假设你会什么、补什么

这份笔记默认读者修完数学分析、线性代数、概率论与常微分方程。但正文从第 1 章起就要使用信息论（熵、KL 散度、互信息）、贝叶斯统计（先验、后验）与机器学习（训练神经网络、生成模型）的词汇，这些通常在后续课程才出现。这一章把用到的部分从零补齐：每个概念先说它回答什么问题，再算一个具体的数值例子，然后给形式定义，最后用日常语言把定义再读一遍。全部内容控制在十二章正文之前，读完本章即可无障碍进入第 1 章。

0.1 读者起点：已经会的，与不要求的

默认你已经会	不要求会，用到时会就地解释
数学分析：极限、连续、一元微积分、级数；对指数与对数函数熟练。	信息论：熵、KL 散度、互信息（本章 §0.4 从零讲）。
线性代数：矩阵运算、特征值、正定矩阵、二次型。	数理统计中的贝叶斯学派：先验、后验、共轭分布（本章 §0.3 从零讲）。
概率论：随机变量、分布函数与密度、期望、方差、联合分布与条件分布、大数定律的陈述。	机器学习实践：神经网络的结构与训练（本章 §0.8 给最小必要的一版）。
常微分方程：解的存在性、数值积分的初等概念。	测度论、随机过程：全篇只有第 7 章的随机微分方程用到，届时正文把用到的性质直接列出来。
会用科学计算器或脚本算简单表达式。	生成模型：VAE、归一化流、扩散模型（本章 §0.9 给一句版，正文各章展开）。

两个使用说明。第一，遇到陌生符号先查附录 A 的记号表，它按章列出全部记号。第二，本章的每个小节都服务于正文的具体位置：§0.2 对应第 1 章的不确定性分类，§0.3 对应第 1 章的贝叶斯模型平均，§0.4 对应第 5 章的信息瓶颈，§0.5 对应几乎每一章的高斯记号 $\mathcal{N}(\mu, \sigma^2)$ ，§0.6 对应第 1 章的 MC 采样与第 3 章各方法的成本，§0.7 对应第 1 章的校准判据与第 4 章的区间指标，§0.8 对应第 1 章的网络权重后验，§0.9 对应第 2 章起的生成式方法。

0.2 两种不确定性：为什么模型要输出一个分布

先看这本书要回答的问题。训练好的模型对一个输入 x 给出预测，你要据此决定下一步动作：要不要补做实验、要不要停机检修、要不要换一个模型。这些决定依赖的信息量超出一个数：你需要知道预测有多可靠，以及可靠程度里有多少还能补救。

两类不确定性 **偶然不确定性** (aleatoric, 词源是拉丁语 alea, 骰子)：数据生成过程本身的随机性带来的不可约不确定性。 **认知不确定性** (epistemic, 词源是希腊语 episteme, 知识)：数据不够、模型不对带来的可约不确定性，多采数据可以减小。

用一枚硬币把两者分开。第一个场景：一枚硬币，正面朝上的概率**精确已知** $\theta = 0.7$ ，问下一次掷出正面吗。任何模型都答不准：单次结果有真实的随机性，概率 0.7 意味着长期频率是七成，单次该是什么仍然定不下来。再多掷一万次也改变不了这一点，因为这里的不可预测性来自硬币与掷出过程本身，与你知多少无关。

第二个场景：同一枚硬币， θ **未知**，只掷了 4 次、出了 3 次正面。此时对“下一次是否正面”的判断依据不足，因为 4 次数据太少， θ 可能是 0.5，也可能是 0.75。多掷几百次后， θ 能估得相当准，判断的把握随之上升。这一个场景的不可预测性来自数据少，采到足够数据就消失。

两类不确定性的对比到此完成：前者是世界的属性，数据再多也在（不可约）；后者是知识的缺口，数据能填（可约）。区分它们决定下一步动作：面对偶然不确定性，补数据没有意义，能做的是把风险计入决策；

面对认知不确定性，补数据、换模型就是正确反应。第 1 章把这两类记作 σ_a^2 (aleatoric) 与 σ_e^2 (epistemic)，并给出各自的计算公式。

最后一个问题：为什么模型要输出一个**分布**，输出一个数不行吗。设输入 x ，预测目标 u 。若模型只输出一个数 $\hat{u}(x)$ ，两种不确定性都被这个数藏起来了：你看不出 $\hat{u}$ 可信到什么程度，更看不出可信度的损失来自噪声还是来自数据缺口。同一个均值还可以配完全不同的可靠性：两个模型对同一输入都预测 $u = 1.0$ ，模型 A 的预测分布是 $\mathcal{N}(1.0, 0.1^2)$ ，模型 B 是 $\mathcal{N}(1.0, 1.0^2)$ 。均值相同，处境不同：按模型 A，观测 $u = 1.3$ 距均值 3 倍标准差，属于异常，该排查；按模型 B，1.3 在 1 倍标准差之内，完全寻常。区分这两种处境的，只有分布的宽度。若模型输出一个条件分布 $p(u | x)$ ，分布的宽度同时容纳两种来源，而且（第 1 章会证明）总方差可以拆成 aleatoric 与 epistemic 两项的和，各算各的。这本书讨论的全部方法，都是在构造、校准或解释这个 $p(u | x)$ 。

0.3 贝叶斯定理：先验、似然、后验

贝叶斯定理回答的问题：观测到数据之后，如何把对某个未知量的判断从“看数据之前”系统地更新为“看数据之后”。它是全书的核心机制，第 1 章的贝叶斯模型平均、第 3 章的每一个采样方法都建立在它上面。

继续用硬币算一个完整例子。设硬币正面概率 θ 是未知数，我们只考虑三个候选值 $\theta \in \{0.2, 0.5, 0.8\}$ 。看数据之前，先给每个候选值分配信心，分配的依据可以只是对称性：没有理由偏向哪一边，于是取

$$P(\theta = 0.2) = 0.25, \quad P(\theta = 0.5) = 0.5, \quad P(\theta = 0.8) = 0.25.$$

这就是**先验分布**：看到数据之前，对未知参数的判断。名字里的“先”相对“看到数据”而言。

现在掷 4 次，出 3 次正面。记这个观测为 $\mathcal{D}$ 。对每个候选 θ ，算“假如 θ 是真值，出现 $\mathcal{D}$ 的概率”：4 次里出 3 次正面的方式有 $\binom{4}{3} = 4$ 种，每次正面概率 θ 、反面概率 $1 - \theta$ ，于是

$$P(\mathcal{D} | \theta) = \binom{4}{3} \theta^3 (1 - \theta): \quad 0.2 \rightarrow 0.0256, \quad 0.5 \rightarrow 0.2500, \quad 0.8 \rightarrow 0.4096.$$

这就是**似然**：把参数值固定、让数据变化时，数据出现的概率。同一个符号 $P(\mathcal{D} | \theta)$ 在先验一栏里是“数据对参数的条件概率”，在这里读作“这批数据支持这个参数值的程度”。数值上 0.8 的似然最大：一枚偏正面的硬币最容易产出 4 掷 3 正。

把两样东西乘起来，再归一化（除以三个乘积之和，使总概率为 1）：

先验	似然	乘积	归一化后（后验）
0.25	0.0256	0.0064	0.027
0.50	0.2500	0.1250	0.535
0.25	0.4096	0.1024	0.438

读这最后一列：看到数据之后，信心从 0.5 一侧移到了 0.8 一侧，0.2 几乎被排除。这一列就是**后验分布**：看到数据之后对参数的判断，名字里的“后”同样相对“看到数据”而言。整个更新规则写成一行就是贝叶斯定理：

$$\underbrace{p(\theta | \mathcal{D})}_{\text{后验：看数据后对参数的判断}} = \underbrace{p(\mathcal{D} | \theta)}_{\text{似然：参数为真时数据的出现机会}} \cdot \underbrace{p(\theta)}_{\text{先验：看数据前对参数的判断}} / \underbrace{p(\mathcal{D})}_{\text{证据：只作归一化用}}.$$

用日常语言读一遍：后验与“似然乘先验”成比例。先验记录看数据前的判断，似然记录数据在各参数取值下的出现机会，两者相乘、归一化，得到看数据后的判断。分母 $p(\mathcal{D}) = \int p(\mathcal{D} | \theta) p(\theta) d\theta$ 只起归一化作用，它也叫**边际似然或证据** (evidence)，第 3 章的变分推断会再遇到它。

数据分批到来时，贝叶斯更新可以连续做：上一批数据的后验，作为下一批数据的先验。继续硬币例子：再掷 4 次、出 2 次正面，对三个候选值，似然 $P(4 \text{ 掷 } 2 \text{ 正} | \theta) = \binom{4}{2} \theta^2 (1 - \theta)^2$ ：0.2 $\rightarrow$ 0.1536，0.5 $\rightarrow$ 0.3750，0.8 $\rightarrow$ 0.1536。拿上一轮的后验 (0.027, 0.535, 0.438) 当先验，重复“乘、归一化”：乘积为 0.0041, 0.2006, 0.0673，总和 0.2720，归一化后

(0.015, 0.737, 0.247).

读法：第二批数据对 0.5 与 0.8 各给了同样强的支持（两头的似然一样大），于是判断的重心回到 0.5，但 0.8 仍明显高于起点。两批数据合起来（8 掷 5 正）与“一次算总账”的结果完全相同，这是贝叶斯更新的一个基本性质：分批更新与一次更新等价，顺序无关。

这本笔记里，硬币的 θ 换成神经网络的权重 θ （百万维向量）， $\mathcal{D}$ 换成训练数据。贝叶斯定理的形状一个字都不用改： $p(\theta | \mathcal{D}) \propto p(\mathcal{D} | \theta)p(\theta)$ 。改变的是可行性：百万维空间上的后验分布算不出、也存不下，于是第 1 章之后的全部方法都在回答同一个问题：后验拿不到整张分布，能不能拿到它的样本或一个好的近似。

0.4 熵、KL 散度、互信息

这一节补三个信息论量。它们在第 5 章集中出场（信息瓶颈的目标函数由两个互信息组成），在第 2、3 章也会出现。

熵：一个分布有多不确定。我们要一个数 H ，满足两条直觉要求：结果完全确定时它为 0；结果越“平”它越大。对离散分布 p ，取 $H(p) = -\sum_x p(x) \log p(x)$ ，可以证明满足这两条要求加上对称性、可加性的度量只有这一种（差一个常数倍）。先算三个数值例子（对数以 2 为底，单位是比特）：

- 单点分布 $p = (1, 0)$ ： $H = -1 \cdot \log 1 - 0 = 0$ ，完全确定，不确定性为零；
- 均匀两点分布 $p = (0.5, 0.5)$ ： $H = -0.5 \log 0.5 - 0.5 \log 0.5 = 1$ ，两点分布里最大；
- $p = (0.7, 0.3)$ ： $H = -0.7 \log 0.7 - 0.3 \log 0.3 = 0.7 \cdot 0.515 + 0.3 \cdot 1.737 \approx 0.881$ ，介于两者之间：分布越偏，熵越小。

熵

离散分布的熵为 $H(p) = -\sum_x p(x) \log p(x)$ ；连续分布把求和换成积分： $H(p) = -\int p(x) \log p(x) dx$ 。对数以 2 为底时单位是比特，以 e 为底时单位是奈特 (nat)；这份笔记的正文用自然对数。

用日常语言读一遍：熵是“按这个分布抽一个结果，平均携带多少信息”，也等于“按这个分布做最优编码时，平均每个结果需要多长的编码”。越平的分布越难猜，平均编码越长；单点分布不用编码，熵为 0。均匀分布在同样多的取值上熵最大，这个事实第 5 章会直接用到。

KL 散度：两个分布差多远。熵度量一个分布，KL 散度度量一对分布。问题来自实践：我们常用一个方便的分布 q 去近似一个算不出的分布 p （第 3 章的变分推断正是如此），需要一个数来度量近似得好不好。取两个两点分布算一算， $p = (0.5, 0.5)$ ， $q = (0.9, 0.1)$ ，用自然对数：

$$\text{KL}(p \parallel q) = 0.5 \log(0.5/0.9) + 0.5 \log(0.5/0.1) = 0.5 \cdot (-0.588) + 0.5 \cdot 1.609 \approx 0.511,$$

$$\text{KL}(q \parallel p) = 0.9 \log(0.9/0.5) + 0.1 \log(0.1/0.5) = 0.9 \cdot 0.588 + 0.1 \cdot (-1.609) \approx 0.368.$$

两行公式的读法：每一项是“在真实分布 p 下抽到 x 的频率，乘上两个分布在 x 处的密度比的对数”，再对全部 x 求和。两个结果不同，说明 KL 散度**不对称**： p 换成 q 与 q 换成 p 是两个不同的量。它还有三条常用性质：非负 ($\text{KL} \geq 0$)；等于 0 当且仅当两个分布相同；若 q 在某个 p 取正值的点上为 0，KL 为无穷（近似分布漏掉了真实分布支撑的位置，罚到无穷）。

KL 散度

$D_{\text{KL}}(p \parallel q) = \sum_x p(x) \log(p(x)/q(x))$ （连续分布换成积分）。用日常语言读：数据真来自 p 、编码表却按 q 造时，平均每个样本多付出的编码长度。它是两个分布差异的单向度量，方向写在记号里。

方向在这本书里有实际后果。第 3 章的变分推断最小化 $\text{KL}(q \parallel \text{真后验})$ ：近似分布 q 在真后验有峰的地方不能留空，否则罚到无穷；第 7 章的 EDG 控制的是另一个方向 $D_{\text{KL}}(p_D \parallel \pi)$ ：采样分布偏离目标分布的位置被直接惩罚。同一族公式，两个方向，优化的后果不同，读各章时留意方向是哪一边。

互信息：知道一个变量能消掉多少另一个的不确定性。 有了熵，这个问题的答案是一行： $I(X; Y) = H(Y) - H(Y | X)$ ，其中**条件熵** $H(Y | X) = E_{x \sim p(X)}[H(Y | X = x)]$ 是“已知 X 的取值后 Y 还剩多少不确定性”按 X 的分布取的平均。两个极端给出直觉：若 Y 与 X 独立，知道 X 不改变对 Y 的判断， $H(Y|X) = H(Y)$ ， $I(X; Y) = 0$ ；若 Y 的取值由 X 完全决定，知道 X 后 Y 的不确定性清零， $I(X; Y) = H(Y)$ 。中间情形介于 0 与 $H(Y)$ 之间。互信息对称： $I(X; Y) = I(Y; X)$ 。

第 5 章的信息瓶颈目标是 $\max_Z I(Z; Y) - \beta I(Z; X)$ ： Z 是网络的内部表示， Y 是要预测的目标， X 是输入。读法：第一项要求表示 Z 保住与目标有关的信息（知道 Z 后对 Y 的不确定性尽量小）；第二项要求 Z 丢掉输入的冗余细节（知道 Z 后对输入 X 的还原信息尽量少）。 β 调两项的权重。

0.5 高斯分布：这本笔记里的三个角色

翻开正文会反复遇到 $\mathcal{N}(\mu, \sigma^2)$ 这个记号，先把话说清楚。一维高斯分布的密度是

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-(x - \mu)^2 / (2\sigma^2)).$$

读法：密度在 $x = \mu$ 处最高，随 x 偏离 μ 按平方规律衰减， $\frac{1}{\sqrt{2\pi\sigma^2}}$ 保证全轴积分为 1。两个参数各管一件事： μ 是期望，管中心在哪； σ^2 是方差，管散开多宽， σ^2 越大密度越平。数值上， $\mathcal{N}(\mu, \sigma^2)$ 的样本落在 $\mu \pm \sigma$ 内的概率约 68%，落在 $\mu \pm 2\sigma$ 内约 95%。第 1 章实验图里的“2 倍标准差带”用的就是第二个数：若预测分布正确，真值应有约 95% 落在均值上下 2 倍标准差之内。

大家爱用高斯，理由是**可算**，三条：

- **线性变换封闭**： $X \sim \mathcal{N}(\mu, \sigma^2)$ 时， $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$ 。高斯经过放大平移仍然是高斯，参数直接读出。
- **乘积仍是高斯**：两个高斯密度的乘积正比于第三个高斯。数值例子： $\mathcal{N}(0, 1)$ 与 $\mathcal{N}(1, 1)$ 的乘积正比于 $\mathcal{N}(0.5, 0.5)$ （精度相加 $1 + 1 = 2$ ，故方差 $1/2$ ；均值按精度加权 $(0 \cdot 1 + 1 \cdot 1)/2 = 0.5$ ）。这一条是贝叶斯更新在高斯世界里保持高斯的理由：高斯先验配高斯似然，后验自动是高斯，公式可以全部写出。
- **中心极限定理**：大量独立的小扰动相加，和的分布近似高斯，与每个扰动自身长什么样关系不大。测量噪声是许多小误差的总和，所以用 $\mathcal{N}(0, \sigma^2)$ 给噪声建模是标准做法。

这三个理由对应它在本书的三个角色：

1. **噪声模型**（偶然不确定性的化身）。观测写成 $u = f(x) + \varepsilon$ ， $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ：真值 $f(x)$ 加高斯噪声。第 1 章预测方差里的 σ_a^2 就是这个 σ^2 。
2. **先验**。对权重或潜变量的初始判断用高斯表达，最常见的是 $z_0 \sim \mathcal{N}(0, I)$ ：每个坐标独立、均值 0、方差 1。第 5 章编码器的先验噪声、第 13 章的高斯过程先验都是这个用法。
3. **后验近似**。真后验算不出时，用高斯去贴它：第 3 章的拉普拉斯近似把后验在极大值点附近换成高斯，平均场变分推断直接在高斯族里挑最像后验的成员。

多维高斯记作 $\mathcal{N}(\mu, \Sigma)$ ： μ 是均值向量， Σ 是协方差矩阵，第 i 行第 j 列是第 i 、 j 两个坐标的协方差； $\Sigma = I$ 表示各坐标互不相关且方差都是 1。以上一维的三条性质在多维全都成立，记号表见附录 A。

0.6 蒙特卡洛：算不出的积分怎么估

问题：期望 $E[f(X)] = \int f(x)p(x)dx$ 在 p 复杂或维数高时没有解析式，数值积分在维数高时也贵。第 1 章的后验预测分布恰好是这种：对百万维的权重后验求积分。蒙特卡洛（MC (Monte Carlo)）用随机抽样换答案。

先用它估圆周率。在边长为 2 的正方形 $[-1, 1]^2$ 里均匀撒点，一个点落进内切单位圆的概率，等于圆面积与正方形面积之比 $\pi/4$ 。于是向正方形撒 N 个均匀随机点，数出落在圆内的个数 k ，取 $\pi \approx 4k/N$ 。

取 $N = 1000$ 、 $k = 785$ ，得 $\pi \approx 3.140$ 。结果带随机性：换一批点会得到 3.135 或 3.148。随机性不是缺陷，是方法的本体，下面量化它。

蒙特卡洛估计

要估计 $E[f(X)]$ ，从 p 抽独立同分布样本 $X_1, \dots, X_N$ ，取 $\hat{E}[f] = \frac{1}{N} \sum_{i=1}^N f(X_i)$ 。大数定律保证 $N \rightarrow \infty$ 时 $\hat{E}[f] \rightarrow E[f]$ 。用日常语言读：积分算不动，就让 p 自己抽样本，用样本的平均值代替积分值。

误差的量级有一条通用规律：标准误差按 $1/\sqrt{N}$ 下降。这条规律解释两件事。其一，精度提升很贵：误差要减半，样本量要乘 4；要多降一位数字，样本量要乘 100。其二，它不依赖积分的维数，维数高时蒙特卡洛仍按同一速度收敛，这是它在高维问题里成为标准工具的原因。

在这本笔记里的用法（第 1 章反复出现）：从后验分布抽 M 个权重样本 $\hat{\theta}_1, \dots, \hat{\theta}_M$ ，预测分布近似成

$$p(u | x, \mathcal{D}) \approx \frac{1}{M} \sum_{j=1}^M p(u | x, \hat{\theta}_j),$$

读法：对权重的积分算不出，就抽 M 组权重、每组各自做一次预测，把 M 个预测按等权混合。后面各方法的成本差异，多数落在“这 M 个样本怎么抽”上（第 3 章逐个比较）。

留一个尾巴：上面的定义假设样本能从 p 直接抽，而第 1 章的后验 $p(\theta | \mathcal{D})$ 只能算到差一个常数（分母 $p(\mathcal{D})$ 积不出），直接抽没有现成办法。马尔可夫链蒙特卡洛 **MCMC** (Markov chain Monte Carlo) 补上这一块：构造一条随机链，每一步从当前位置出发、按一个只依赖当前位置的随机规则走到下一个位置；把规则设计成链的平稳分布（链走了足够多步之后位置服从的分布）等于目标分布，丢掉链初期还没进入平稳段的样本 **burn-in**（预热：丢弃链初期未平稳的部分），之后链上的位置就可以当目标分布的样本用。链从一片区域挪到另一片区域的速度叫**混合速度**：混合慢的链要很久才能代表整个分布。第 3 章的 HMC 与朗之万动力学是两种设计走法的方式，代价差异取决于每一步走多远、花几次梯度。

还有一种变通办法，第 7 章会用到：想算 $E_p[f]$ 但 p 不好抽、 q 好抽，就从 q 抽样本、按密度比加权。恒等式

$$E_p[f] = E_q[f(X)(p(X)/(q(X)))] \approx \frac{1}{N} \sum_{i=1}^N f(X_i)(p(X_i)/(q(X_i))), \quad X_i \sim q$$

的读法：右端每个样本的贡献乘上权重 $p(X_i)/q(X_i)$ ，样本落在 p 相对 q 更常出现的地方权重就大，加权平均修正了抽样分布的偏差。条件是 q 在 p 取正值的每点都取正值，否则权重会无界。权重参差不齐时估计的有效样本量小于 N ，所以第 7 章报告重加权质量时用“有效样本量占比”这个数。

0.7 分位数与置信区间：从分布回到一句话的决策

预测分布 $p(u | x)$ 信息完整，但汇报与决策需要更小的载体：区间。构造区间靠分位数，而“区间盖住了多少真值”的频率解读就是第 1 章“校准”的全部内容，这里把地基打好。

分位数 对连续分布，它的 p 分位数 ($p \in (0, 1)$) 指满足 $P(U \leq z_p) = p$ 的值 z_p ，也就是把分布函数 $F(z) = P(U \leq z)$ 反解到水平 p 。用日常语言读： p 分位数是“有 p 的概率不出这个值”的门槛。

数值例子。设预测分布为 $\mathcal{N}(1.0, 0.5^2)$ ，均值 1.0、标准差 0.5。它的 0.025 分位数是 $1.0 - 1.96 \cdot 0.5 \approx 0.02$ ，0.975 分位数是 $1.0 + 1.96 \cdot 0.5 \approx 1.98$ （常数 1.96 是标准高斯 $\mathcal{N}(0, 1)$ 的 0.975 分位数，查表即得，高斯平移缩放后分位数按同样方式平移缩放）。于是区间 $[0.02, 1.98]$ 两端各留出 2.5% 的概率，中间盖住 95%：这就是“95% 置信区间”的来历。§0.5 说过 $\mu \pm 2\sigma$ 盖住约 95%，与这里的 1.96 是同一件事。

区间的价值要靠频率检验：如果模型对 100 个不同输入各给一个 95% 区间，其中真值落进区间的大约应有 95 个。多一个少一个是随机波动，明显少于 95 个说明模型**过置信**：报出的把握高于实际覆盖的频

率。第 1 章把这条频率判据正式化（校准与 RMSCE 指标），第 4 章补上它的另一半：覆盖率达标还不够，区间同时要尽量窄（指标 PIW），宽到荒谬的区间总能覆盖，却没有信息量。

0.8 训练一个神经网络：最小必要版

这本书处处说“训练网络”，这里交代训练在做什么、随机性从哪来。两点就够读完全书：网络是带参数的函数，训练是最小化一个损失。

网络是带参数的函数。输入 x （比如一个物理场的传感器读数向量），输出预测 $f_{\theta(x)}$ ， θ 是网络中全部可调参数的总称，现代网络从几个到十亿个不等。网络的主体是一层层叠起来的线性变换与非线性函数（例如把负数压向 0 的函数）；非线性必不可少，没有它多层叠加仍等价于一层线性变换，表达能力不会增加。

训练是最小化损失。给定训练数据 $\{(x_i, y_i)\}_{i=1}^N$ ，定义损失，最常用的是均方误差

$$\text{MSE}(\theta) = \frac{1}{N} \sum_{i=1}^N \|f_{\theta}(x_i) - y_i\|^2,$$

读法：每个数据点上预测与真值的差距平方，再取平均；平方使误差非负、可导，并且罚大误差比罚小误差重。让 MSE 变小的算法是梯度下降：沿负梯度方向更新参数 $\theta \leftarrow \theta - \eta \nabla_{\text{MSE}}(\theta)$ ，步长 η 叫学习率。 N 大时每步只用随机抽的一小批（mini-batch）数据估计梯度，这叫随机梯度下降 SGD（stochastic gradient descent）。

同一批数据训练两次，结果为什么不同。三个随机来源：

- 参数起点随机： θ 的初值是随机抽的；
- 优化路径随机：每个 mini-batch 是随机抽的，梯度本身是随机量，更新路径每一步都带随机性；
- 部分方法在训练中还开着随机的内部开关（如 dropout，第 3 章讲）。

损失关于 θ 的曲面有很多局部极小。不同的随机起点与随机路径停在哪个极小、停在极小附近的哪个位置，都不相同。于是两个网络在同一输入上给出两个不同的预测。这个现象就是第 1 章定义的 epistemic 不确定性的直接来源：对权重的判断不确定，预测随之摆动。第 2 章的深度集成把这件事反过来用：故意用不同随机起点训练 M 个网络，把它们预测的分歧当作认知不确定性的度量。

一个后面会用到的细节：可以让网络输出两个数，一个作预测均值，一个取平方后作预测方差，让数据自己决定每个点噪声多大。第 1 章的异方差版本（heteroscedastic：噪声水平随输入 x 变化）就是这么做的。

0.9 生成模型：只有样本、没有密度公式时怎么办

前面各节的分布都带着解析式。很多场合没有解析式：你手里只有一批样本（图像、传感器记录、分子构象），想知道两件事：造出像训练数据的新样本（**采样**），以及评一个新样本出现的机会有多大（**密度求值**）。生成模型就是同时瞄准这两件事的模型家族，第 2 章起大量出场。按“密度能不能直接算”分几类，各用一句话认识名字：

- **归一化流**（normalizing flow）：用一串可逆变换把一个简单分布（标准高斯）逐步变换成目标分布。可逆性保证密度可算：概率在变换下按雅可比行列式换算，链式法则给出显式公式。第 5 章的 GIN 是它的保体积特例。
- **扩散模型**：把数据逐步加噪声直至变成纯噪声，再训练一个网络把加噪过程倒着走一遍，从噪声还原出样本。采样是迭代式的。第 7 章的 EDG 在潜空间用它做采样器。
- **变分自编码器 VAE**（variational autoencoder）：引入潜变量 z ， z 从先验抽出、 x 由解码器网络从 z 生成；真后验 $p(z|x)$ 算不出，用编码器网络近似它，训练目标是第 3 章完整推导的 ELBO。
- **生成对抗网络 GAN**（generative adversarial network）：生成器网络直接输出样本，判别器网络分辨真假，训练是两者的对抗；采样方便，密度不好算。第 2 章的函数先验方法（GAN-FP）用它当预训练生成器。

一个一维小例子说明归一化流为什么两头都能做。取 $z \sim \mathcal{N}(0, 1)$ ，定义变换： $z < 0$ 时 $x = 2z$ ， $z \geq 0$ 时 $x = z$ 。变换可逆（负半轴拉宽两倍，正半轴不动），于是两件事同时解决。采样：抽 z 、按规则算 x ，得到的新样本来自一个左半边被拉宽的分布。密度：概率密度在可逆变换下按 $p(x) = p_{z(z)} |dz/dx|$ 换算，得 $p(x) = 0.5\varphi(x/2)$ ($x < 0$) 与 $p(x) = \varphi(x)$ ($x \geq 0$)，其中 φ 是标准高斯密度；代数值： $p(-1) = 0.5\varphi(0.5) \approx 0.176$ ， $p(1) = \varphi(1) \approx 0.242$ 。要点：变换可逆时，采样与密度求值是同一套机制的两面，这是归一化流在需要密度值的场合（第 5 章的加温分布、第 7 章的重加权）被选中的原因。

0.10 记号约定

正文还有一些记号在本科课程里出现得少，集中列在这里，读到具体章节时回来查。先给每个记号配一个数值例子。

- **期望与方差**： $E[X]$ 是期望， $\text{Var}[X]$ 是方差， $E[X | Y]$ 是条件期望：已知 Y 的取值后 X 的平均。数值：投一个均匀骰子， $E[X] = 3.5$ ；已知点数大于 4， $E[X | X > 4] = (5 + 6)/2 = 5.5$ 。
- **成比例记号**： $\propto$ ： $p(\theta | \mathcal{D}) \propto p(\mathcal{D} | \theta)p(\theta)$ 表示两边差一个乘法常数（使左边积分为 1 的那个）。§0.3 硬币表格里“乘起来再归一化”两步，就是这个记号的展开。
- **独立同分布**，缩写 iid (independent and identically distributed)：一组样本互不相关、且都来自同一个分布。蒙特卡洛的收敛依据（大数定律）要求这个条件。
- **向量与矩阵**：粗体字母表示向量或矩阵，向量默认是列向量； $\mathbf{x}^T$ 是转置； $\mathbf{I}$ 是单位矩阵； $\text{diag}(\mathbf{v})$ 是以向量 $\mathbf{v}$ 为对角线的对角矩阵； $\mathbf{1}$ 是分量全为 1 的向量。数值： $\mathbf{x} = (1, 2)^T$ 时 $\text{diag}(\mathbf{x}) = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ 。第 5 章编码器的 $m(\mathbf{x}) \in [0, 1]^d$ 表示“每个分量都在 0 与 1 之间的 d 维向量”。
- **范数**： $\|\mathbf{x}\|$ 指各分量平方和的平方根： $\|(1, 2)^T\| = \sqrt{5}$ 。第 4 章 RL2E 公式里的 $\|\cdot\|_2^2$ 是它的平方，下标 2 标明用的是这一种范数。
- **对数**：正文 $\log$ 一律是自然对数， $\log_2$ 明确标出以 2 为底（熵的比特数）。
- **花体字母**： $\mathcal{D}$ 全书固定表示数据集， $\mathcal{N}$ 表示高斯分布， $\mathcal{H}$ 表示熵， $\mathcal{L}$ 表示损失或似然，具体看上下文。

0.11 阅读地图与自测

主线怎么走。第 1 章建立词汇（两类不确定性、贝叶斯模型平均、MC 采样、校准），第 2 章给方法地图与比较结论，第 3 章逐个讲经典方法（读之前先过本章 §0.6），第 4 章讲评测协议，第 5、6 章是方法主体（信息瓶颈与变分下界，读之前先过 §0.3 与 §0.4）。

按章给出建议的预备材料，供跳读时对照：

章	内容	建议先读
第 1 章	两类不确定性、BMA、MC 采样、校准	本章 §0.2、§0.3、§0.6、§0.7、§0.8
第 2 章	方法分类、指标体系、比较结论	第 1 章
第 3 章	HMC、朗之万、MFVI、dropout、集成、拉普拉斯	本章 §0.6（MC 与 MCMC）、§0.8
第 4 章	评测指标、后校准、成本核算	本章 §0.7
第 5、6 章	信息瓶颈做 UQ、变分下界推导	本章 §0.3、§0.4、§0.5
第 7 章	后继一：Boltzmann 分布的扩散采样器	本章 §0.6、§0.9；随机过程超出本章范围，正文自足
第 8 章	后继二：反应坐标的最优降维	第 5 章、本章 §0.9
第 9、10 章	后继三、四：算子学习 UQ、潜变量模型	第 5 章、本章 §0.5
第 11 至 15 章	各后继的实验台、实现台与推导补充	与对应的后继章配对读
第 16 至 18 章	谱系、坐标、附录（记号表与自检清单）	任意时刻可查

哪些可以跳读。 第 4 章可以先跳过，读到具体实验数字再回来查。第 7 章起的四个后继方向及其实验台彼此独立，按兴趣选读。其中第 7 章用到随机微分方程，超出本章范围；正文把用到的性质直接列出来，不熟悉随机过程的读者可以只读它的小节“问题”与各实验节，跳过证明。

遇到陌生符号去哪里查。 记号约定回本章 §0.10，更全的清单查附录 A 的记号表；熵、KL 散度、互信息的公式回本章 §0.4；先验、后验、贝叶斯定理回 §0.3；蒙特卡洛与 MCMC 回 §0.6；高斯记号回 §0.5；分位数、置信区间、覆盖率回 §0.7；网络的损失、训练随机性回 §0.8。

自测八题。 都能在本章找到答案，答得上来就具备阅读条件：

1. 一枚正面概率精确为 0.7 的硬币，与一枚只掷过 4 次、出了 3 次正面的硬币：各自的不确定性属于哪一类？多采数据能减掉哪一个？
2. 写出贝叶斯定理，指出先验、似然、后验、证据各是哪一项，“先”与“后”相对什么而言。
3. $p = (0.5, 0.5)$, $q = (0.9, 0.1)$ ： $KL(p \parallel q)$ 与 $KL(q \parallel p)$ 哪个大？这说明 KL 的什么性质？
4. 高斯分布的两个参数各管什么？说出一条“大家都用高斯”的可算性理由。
5. 蒙特卡洛的标准误差按 $1/\sqrt{N}$ 下降：要让误差减半，样本量要乘几？
6. 同一批数据训练同一个网络两次，结果不同。列出两个随机性来源，并说明这个现象对应哪一类不确定性。
7. 生成模型要解决哪两件事？归一化流凭什么同时做到？
8. 一个只输出单点预测值的模型，为什么表达不了偶然不确定性？

1 概念准备：不确定性从哪里来

1.1 为什么神经网络需要 UQ

神经网络正在进入计算科学的内核：替代数值求解器解 PDE（物理信息网络）、学算子（DeepONet（神经算子：两个网络的内积，branch 网络吃输入函数的离散表示，trunk 网络吃查询点坐标）、参数化随机过程。随之而来的问题是：这些网络的预测误差怎么量化？传统数值分析有成熟的误差理论（离散误差、收敛阶），神经网络没有对应物，它的误差来源更多：

- **数据**：观测有噪声、有缺失；
- **物理模型**：方程本身是对现实的近似（模型误设）；
- **网络结构**：超参数选择、过参数化；
- **优化**：非凸目标只找到局部极小，采样有随机性。

SciML 的 UQ 框架 (Psaros 等, SIAM Review 2023) 把不确定性分成两大类，这个区分贯穿全部后续方法：

- **aleatoric（偶然不确定性）**：数据噪声带来的，**不可约**，数据再多也在；
- **epistemic（认知不确定性）**：有限数据与模型选择带来的，**可约**，数据越多越小。

两者的区分决定下游动作：传感器读数的抖动（aleatoric）不该激励你去补实验；网络在外推区的大幅波动（epistemic）应该。




图 1 总不确定性的来源分解 (综述 2201.07766 的饼图): 数据 (噪声、缺失)、物理模型 (误设、随机性)、网络 (结构、超参数、过参数化)、后验推断误差。其中模型误设一项是该框架没有显式建模的, 也是后续多篇工作 (如模型修正方向) 要补的缺口。

1.2 统一的问题设定

综述给出一个覆盖四类问题的统一格式:

$$\mathcal{F}_{\lambda, \xi}[u(x; \xi)] = f(x; \xi), \quad x \in \Omega, \quad \xi \in \Xi, \quad \mathcal{B}_{\lambda, \xi}[u(x; \xi)] = b(x; \xi), \quad x \in \Gamma.$$

四类场景由“谁未知”区分:

1. **正向确定性**: 算子与参数已知, 求 u ;
2. **混合确定性**: $\lambda(x)$ 与 $u(x)$ 都部分未知, 共同重构;
3. **混合随机**: 算子随机, 求 u 与 λ 的统计量;
4. **算子学习**: $\mathcal{F}, \mathcal{B}$ 本身未知, 先预训练再处理有限含噪推断数据。

1.3 贝叶斯模型平均: 参数不确定性怎么变成预测不确定性

设网络权重为 θ , 数据为 $\mathcal{D}$ 。贝叶斯框架下权重有后验分布 $p(\theta | \mathcal{D}) \propto p(\mathcal{D} | \theta)p(\theta)$: 先验 $p(\theta)$ 是看数据之前对权重的假设, 似然 $p(\mathcal{D} | \theta)$ 是给定权重时数据出现的机会, 后验是两者按贝叶斯定理合成、看数据之后的更新 (硬币版完整数值例见第 0 章 §0.3)。预测的分布由 **BMA** (贝叶斯模型平均) 给出:

$$p(u | x, \mathcal{D}) = \int p(u | x, \theta)p(\theta | \mathcal{D})d\theta, \quad p(\mathcal{D}) = \int p(\mathcal{D} | \theta)p(\theta)d\theta.$$

这个积分算不出来 (θ 维数是百万级), 实践用 **MC** (Monte Carlo, 蒙特卡洛: 从分布抽样本、用样本平均代替积分, 第 0 章 §0.6) 近似: 从后验抽 M 个样本 $\hat{\theta}_1, \dots, \hat{\theta}_M$, 预测分布近似为混合

$$p(u | x, \mathcal{D}) \approx \bar{p}(u | x) = \frac{1}{M} \sum_{j=1}^M p(u | x, \hat{\theta}_j).$$

预测均值与总方差有显式公式（方差的分解定律）：

$$\hat{u}(x) \approx \bar{\mu}(x) = \frac{1}{M} \sum_{j=1}^M u_{\hat{\theta}_j}(x),$$

$$\text{Var}(u | x, \mathcal{D}) \approx \bar{\sigma}^2(x) = \underbrace{\Sigma_u^2}_{\bar{\sigma}_a^2(x)} + \underbrace{\frac{1}{M} \sum_{j=1}^M (u_{\hat{\theta}_j}(x) - \bar{\mu}(x))^2}_{\bar{\sigma}_e^2(x)}.$$

逐项读：总方差 = aleatoric 项（噪声水平 Σ_u^2 ，各成员共享）加 epistemic 项（各成员预测在均值附近的散度）。**两类不确定性从此有了可计算的化身**：网络组内分歧就是 epistemic 的度量。异方差（heteroscedastic：噪声水平随输入 x 变化）版本把 $\Sigma_{u,\theta}^2(x)$ 也作为网络的额外输出（每点一个噪声水平）， $\bar{\sigma}_a^2$ 改为对各成员噪声输出的平均。




图 2 从 BMA 到预测分布的四步（综述 2201.07766）：参数后验 → MC 采样 → 各成员预测叠加噪声 → 混合出总预测分布。图中两个预测成员的散度 给出 epistemic 项，噪声宽度给出 aleatoric 项。

各种 UQ 方法的差别，只在于“怎么得到后验样本”这一步：HMC 与朗之万做 **MCMC**（马尔可夫链蒙特卡洛：构造平稳分布等于后验的随机链，链上位置当样本，第 0 章 §0.6）；变分推断（MFVI、MC dropout）用可优化分布近似；深度集成直接训练多个网络取它们的极小值点；拉普拉斯近似在训练终点 局部展开。综述把这些统一进一个“模型 + 物理 + 后验推断”的框架（第 2 章的图），下一节展开。

1.4 校准：被忽略的第二个维度

有了不确定度还不够，它必须**诚实**。**校准**（calibration）的定义：

什么叫“校准” 理想的概率校准满足：真实值落在预测分布 p 分位数以内的频率等于 p 。实用判据：对每个分位水平 $p \in [0, 1]$,

$$P(U_X \leq \bar{P}_X^{-1}(p)) = p,$$

校准误差在分位水平上取均方根（RMSCE）：

$$\text{RMSCE} = \sqrt{E_{p \in [0,1]} (p - \hat{p}(p))^2} \approx \sqrt{\frac{1}{N_p} \sum_{j=1}^{N_p} \left[p_j - \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} \mathbf{1}\{u_i \leq \hat{u}(x_i)_{p_j}\} \right]^2}.$$




图 3 过置信与欠置信 (综述 2201.07766)。左：过置信模型的预测区间比数据生成分布窄，校准曲线在低位就达到 1；右：欠置信相反。中间的对角线是理想校准。深度网络的常态是过置信，尤其在 OOD (out-of-distribution, 分布外：输入落在训练数据没有覆盖的区域) 区域。

事后校准有三条标准路线，都只需要一小块留出数据：方差缩放 (Levi 等：找一个最优常数 s ，用 $\mathcal{N}(\bar{\mu}(x), s^2 \bar{\sigma}^2(x))$ 替换预测分布，只改方差)；CDF 校准 (Kuleshov 等：拟合失准函数 $Q(p) = P(U_X \leq \bar{P}_X^{-1}(p))$ 并把它作用到所有预测 CDF 上，均值方差都改)；CRUDE (Zelikman 等：对标准化残差 $(u - \bar{\mu})/\bar{\sigma}$ 拟合经验分布并回代)。这三条在第 2 章的比较实验里都会出场。

2 综述篇：方法地图与比较结论 (SIAM Review 2023)

2.1 方法分类

综述把获取后验样本 $\{\hat{\theta}_j\}$ 的方法分两大族。

贝叶斯方法族 (显式或隐式近似后验 $p(\theta | \mathcal{D})$):

- **HMC**: 两步 MCMC，模拟虚构粒子的哈密顿动力学 (leapfrog 积分 + 拒绝采样)，高维下混合效率最高的金标准，也最贵；
- **LD (朗之万动力学)**: 一步 MCMC，可以理解为“带噪声的随机梯度下降”；
- **MFVI (平均场变分推断)**: 用对角高斯变分分布 $q_w(\theta)$ 近似后验，最大化边际似然的下界 **ELBO** (evidence lower bound, 证据下界: $\log p(\mathcal{D})$ 的可优化下界，第 3 章完整推导)，训练即推断；
- **MC dropout**: 标准训练带 **dropout** (训练时按比例随机把一部分神经元的输出置零的正则化手段)、推断时随机丢弃，是 MFVI 的特例 (Gal 与 Ghahramani 的等价性)；
- **LA (拉普拉斯近似)**: 标准训练后在极值点 $\hat{\theta}$ 处用训练误差 Hessian 定宽的高斯拟合，训练后一次性计算。

集成方法族 (目标是捕捉后验的多个模式，跳过对后验本身的近似):

- **DEns**: 不同初始化独立训练 M 次 (Lakshminarayanan 等 2017)；
- **SEns**: 单次优化轨迹上用学习率调度取 M 个局部最优快照；
- **SWAG**: SEns 的快照再拟合高斯并采样。

两类之外的三个扩展：**函数先验** (FP: 用历史数据预训练一个生成器， θ 变成低维生成器输入；GAN-FP 用预训练 **GAN** (生成对抗网络: 生成器网络直接输出样本、判别器网络分辨真假，第 0 章 §0.9)，推断便宜、所需数据少)；**随机 PDE 方法** (U-PI-GAN 用 GAN 表示随机场再推断；U-NNPC 用 PINN 拟合多

项式混沌的随机模态)；以及第 5 章的信息瓶颈路线（综述在结论里把它与 conformal、evidential 并列为未来方向）。




图 4 统一框架（综述 2201.07766）：所有方法都是“模型 M （贝叶斯网络 / GAN 生成器 / 无）+ 物理约束（PDE 或预训练 DeepONet）

1. 后验推断”的组合特例。横轴是模型形式，纵轴是推断方式。

2.2 指标体系

综述把指标按数据需求分三类（需测试集 / 需金标准参考解 / 两者皆不需）。核心的三个：

指标	公式	衡量什么
精度 RL2E	$\sqrt{\sum_i (\bar{\mu}(x_i) - u_i)^2 / \sum_i u_i^2}$	均值预测的相对误差
预测能力 MPL	$\frac{1}{N} \sum_i \mathcal{N}(\bar{\mu}(x_i), \bar{\sigma}^2(x_i))[u_i]$	测试数据在预测分布下的平均对数似然
校准 RMSCE	$\sqrt{E_p(p - \hat{p}(p))^2}$	区间覆盖率与名义置信度的偏差

单一指标会误导 这是综述最重要的方法论结论之一（与机器学习社区的已知教训一致）：某些指标上 MC dropout 大幅优于 HMC，但在 OOD 数据上 dropout 会过置信。每个指标都从某一个侧面看“预测分布好不好”，侧面之间不互相保证。实用建议：**多指标 + 多方法**，任何单指标上的排名都不足以选型。

2.3 比较研究的设计与结论

五个算例：不连续函数逼近（10 多种方法）、混合扩散反应方程、混合随机椭圆方程、前向 PDE、算子学习加 OOD 检测。结论按可信度排列：

- 1. **便宜方法可以够用。** MFVI、LA 这类低成本方法配上学好的先验（用留出数据调超参数），性能可与 HMC、深度集成相当；
- 2. **事后校准显著有效。** 用小规模留出数据做方差缩放或 CDF 校准，校准误差大幅下降，成本几乎为零；

3. **集成方法有盲区**。深度集成给出的 epistemic 不确定性 在混合随机 PDE 场景下可能无法覆盖一、二阶统计量的预测误差；
4. **OOD 检测可行**。算子学习场景下，U-DeepONet 的 epistemic 不确定性 在 OOD 输入上系统性增大，三个检测指标与误差同向变化，可当“红旗”用；
5. **精度与成本的权衡有明确赢家**。函数逼近算例的 CPU 时间：HMC 131.5 s、LD 44.4 s、MFVI 19.5 s、MCD 41.7 s、LA 60.3 s、DEns 359.8 s（10 个串行）、SEns 31.9 s、SWAG 36.6 s。LA、MFVI、SEns 是性能成本曲线上的最优折中。

这份综述的定位要说清楚：它代表“贝叶斯/集成”主流范式，并把信息瓶颈、conformal prediction、evidential deep learning 列为 尚未展开的替代路线。接下来四篇正是这些路线的具体落地，其中第一篇（IB-UQ）就是信息瓶颈路线的落地，也是本笔记方法部分的主体。

3 经典 UQ 方法逐个精讲

综述把方法分成两族各五六种，主章节只给了一句话版。这一章逐个展开：每种方法的机制、代价、失效模式。它们是后续所有方法的对照基线，也是读综述比较实验的解码表。

3.1 HMC：金标准及其代价

HMC（混合蒙特卡洛）把后验采样想象成一个物理系统：权重 θ 是粒子位置，引入动量 p ，在“负对数后验”构成的 势能面上滚动。每步先按哈密顿动力学用 leapfrog 积分走 L 步（可逆、保体积），再按 Metropolis 准则（按新旧位置的密度比决定接受概率）接受或拒绝。

它解决随机游走采样的大问题：哈密顿轨迹一次可以横穿后验的 大范围，混合效率在高维远超逐坐标采样。代价同样清楚：每个 leapfrog 步要算一次完整梯度（对百万级参数的网络，一次前向 + 反向）， L 步 $\times$ 5000 样本 $\times$ burn-in（预热：丢弃链初期还没进入平稳段的样本），综述算例里 131.5 秒（函数逼近这种小网络），PDE 场景要乘几个量级。另一个实践坑：步长与 L 要调（NUTS 是自动调步长与 L 的 HMC 变体），调不好要么拒绝率爆炸要么轨迹折返。

3.2 朗之万动力学：一步版

朗之万（LD）可以读成“带各向同性噪声的梯度下降”：每步 $\theta_{t+1} = \theta_t + \eta \nabla \log p(\theta_t | \mathcal{D}) + \sqrt{2\eta} z_t$ 。步长 η 趋零时马尔可夫链的不变分布（链跑久之后位置服从的 平稳分布，第 0 章 §0.6）恰好是后验。为什么是后验：后验的对数梯度 $\nabla \log p$ 指向密度高处，噪声项按扩散方程 把概率从密度高处向低处搬运；对精确的连续时间过程，这两股流在密度恰好等于 $p(\theta | \mathcal{D})$ 时互相抵消，分布不再变化，所以后验是平稳解。它比 HMC 便宜（每样本一次梯度），混合慢；综述里 44.4 秒。常数步长版本不精确（不变分布有偏），有偏性在 η 小时可以忽略但永不严格为零，这也是它常被当成“便宜的近似”而不是“正确的方法”的原因。

“常数步长有偏”这句话可以用一维高斯目标算到底，看清偏差从哪来、有多大。取目标 $\mathcal{N}(0, 1)$ ：此时 $\log p(\theta) = -\theta^2/2$ ，梯度是 $-\theta$ ，一步更新为 $\theta' = (1 - \eta)\theta + \sqrt{2\eta} \cdot z$ ， $z \sim \mathcal{N}(0, 1)$ 。

证明. 设链已进入平稳状态， $\theta \sim \mathcal{N}(0, \sigma^2)$ ，求 σ^2 。

第一步：算一步之后 θ' 的分布。 θ' 等于 θ 的 线性变换加一项独立高斯噪声。由第 0 章 §0.5 的线性变换封闭性， $(1 - \eta)\theta \sim \mathcal{N}(0, (1 - \eta)^2 \sigma^2)$ ；两个独立高斯之和仍是高斯，方差相加（协方差为零，交叉项在期望中消失），所以 $\theta' \sim \mathcal{N}(0, (1 - \eta)^2 \sigma^2 + 2\eta)$ 。

第二步：解不变条件。平稳意味着 θ' 与 θ 同分布： $\sigma^2 = (1 - \eta)^2 \sigma^2 + 2\eta$ 。把含 σ^2 的项移到左边，提出 σ^2 ： $\sigma^2[1 - (1 - \eta)^2] = 2\eta$ 。括号展开 $1 - (1 - 2\eta + \eta^2) = \eta(2 - \eta)$ ，两边除以 $\eta(2 - \eta)$ ：

$$\sigma^2 = \frac{2}{2 - \eta} = \frac{1}{1 - \eta/2} \approx 1 + \eta/2.$$

读法：链最终停留的分布方差比目标方差 1 大。 $\eta = 0.1$ 时 $\sigma^2 \approx 1.053$ ；步长减半，偏差也约减半。

用日常语言读一遍：偏差从哪来 每一步都拿常数近似连续变化的漂移与噪声，这个线性化误差 每步一点点积累，最后凝成不变分布里那份约 $\eta/2$ 的方差膨胀。高维情形结论同形：偏差是 η 的一阶小量，所以实践里靠调小步长压制，或者像 MALA 那样在每步后面加一次 Metropolis 接受拒绝（按新旧位置的密度比决定接受概率），把偏差精确修掉，代价是每步多算一次密度。

3.3 MFVI：把采样变成优化

平均场变分推断用对角高斯 $q_\omega(\theta) = \mathcal{N}(\mu, \text{diag } \sigma^2)$ 近似后验，目标是最大化证据下界（ELBO；证据是边际似然 $p(\mathcal{D})$ 的别名）。推导值得完整写出，因为它是后面 VIB（IB-UQ）下界的骨架：

证明. 对任意分布 q ，逐步展开 $\log p(\mathcal{D})$ 。

第一步：把常数写成积分。 $\log p(\mathcal{D})$ 不含 θ ，是常数；任何分布满足 $\int q(\theta)d\theta = 1$ 。于是 $\log p(\mathcal{D}) = \log p(\mathcal{D}) \cdot \int q(\theta)d\theta = \int q(\theta) \log p(\mathcal{D})d\theta$ ：常数乘 1 不变，而常数可以自由移进积分号（对 θ 的积分不改变它）。

第二步：插入贝叶斯恒等式。 由乘法公式 $p(\mathcal{D}, \theta) = p(\theta | \mathcal{D})p(\mathcal{D})$ （第 0 章 §0.3）得 $\log p(\mathcal{D}) = \log p(\mathcal{D}, \theta) - \log p(\theta | \mathcal{D})$ 。再同时加减 $\log q(\theta)$ ：

$$\log p(\mathcal{D}) = \log(p(\mathcal{D}, \theta)/q(\theta)) + \log(q(\theta)/p(\theta | \mathcal{D})).$$

读法：右端两项相加时 $\log q(\theta)$ 一负一正抵消，剩下的正是上式的 $\log p(\mathcal{D}, \theta) - \log p(\theta | \mathcal{D})$ 。

第三步：两边对 q 取期望。 第一步的积分形式两边替换成第二步的右端：

$$\begin{aligned} \log p(\mathcal{D}) &= \int q(\theta) \log(p(\mathcal{D}, \theta)/q(\theta))d\theta \\ &\quad + \int q(\theta) \log(q(\theta)/p(\theta | \mathcal{D}))d\theta \\ &= \text{ELBO}(q) + \text{KL}(q \parallel p(\theta | \mathcal{D})). \end{aligned}$$

第二个积分与第 0 章 §0.4 的 KL 定义逐字相同，它是 q 与真后验的 KL；第一个积分按定义记作 ELBO。KL 非负（第 0 章 §0.4 的性质二），所以 $\log p(\mathcal{D}) \geq \text{ELBO}(q)$ 。

第四步：从界到优化问题。 $\log p(\mathcal{D})$ 由数据决定，是固定常数（算不出它的值，但它不随 q 变）。于是 $\max_q \text{ELBO}(q)$ 与 $\min_q \text{KL}(q \parallel p(\theta | \mathcal{D}))$ 是同一个问题：两者之和恒等于这个常数，ELBO 每升一分，KL 就降一分。

第五步：把 ELBO 拆成重构项与先验惩罚项。 对第一个积分用 $p(\mathcal{D}, \theta) = p(\mathcal{D} | \theta)p(\theta)$ 拆开对数，第三个积分按熵的定义（第 0 章 §0.4， $\mathcal{H}(q) = -\int q \log q$ ）改写：

$$\begin{aligned} \text{ELBO}(q) &= \int q(\theta) \log p(\mathcal{D} | \theta)d\theta + \int q(\theta) \log p(\theta)d\theta - \int q(\theta) \log q(\theta)d\theta \\ &= \underbrace{E_{q(\theta)}[\log p(\mathcal{D} | \theta)]}_{\text{重构项：采样出的参数解释数据多好}} - \underbrace{\text{KL}(q(\theta) \parallel p(\theta))}_{\text{变分分布偏离先验的惩罚}}. \end{aligned}$$

前一行到后一行的中间代数：后两个积分合并为 $\int q(\theta) \log(p(\theta)/q(\theta))d\theta$ ，它按定义就是 $\text{KL}(q \parallel p(\theta))$ 。读法：优化 ELBO 就是在“拟合数据”与“不偏离先验”之间取加权。第 5 章的 VIB 目标与这一行同构。

第六步：为什么整个目标能反向传播。 目标里有采样 $\theta \sim q_\omega$ ，而“采样”这个操作对参数 μ, σ 没有导数。重参数化 $\theta = \mu + \sigma \cdot \varepsilon$ ， $\varepsilon \sim \mathcal{N}(0, 1)$ 把随机性转移到与参数无关的 ε 上（两者同分布由第 0 章 §0.5 的线性变换封闭性保证）。于是目标写成 $E_\varepsilon[g(\mu, \sigma, \varepsilon)]$ ，是可导函数的期望；期望与求导交换需要的条件（被积函数对参数连续可微、且被可积函数控制）在高斯族与常见网络下成立，梯度就能用 ε 的样本平均来估计。□

用日常语言读一遍：这六步合起来干了什么 它把算不出的证据 $\log p(\mathcal{D})$ 换成了一个能算的下界：前四步证明 $\log p(\mathcal{D})$ 永远压着 ELBO，两者的差距恰好是 q 与真后验的距离；第五步把 ELBO 改写成“数据拟合减去先验惩罚”，这才是可以直接写进代码的形式；第六步解决“目标里有采样、怎么求梯度”。代价在平均场假设里： q 的族太窄时，最优的 q 只能贴住后验的一个峰。

失效模式来自平均场假设：对角高斯表达不了权重之间的后验相关，不确定性往往被低估；深度网络的 ELBO 优化本身非凸， q 可能塌到后验的某一个峰（多峰后验的模式坍塌）。综述里 19.5 秒，全表最便宜。

3.4 MC dropout：不重新训练的不确定度

标准训练（带 dropout），推断时也开着 dropout 采样 T 次，统计预测均值与方差。Gal-Ghahramani 的等价性定理说这近似于对网络权重做变分推断（Bernoulli 掩码的变分分布）。它的吸引力是零额外训练成本；代价是“不确定度的质量”依赖 dropout 率这个超参数，且 OOD 区域经常过置信（综述实验的直接观察）。41.7 秒。

3.5 拉普拉斯近似：训练后的一次性计算

在训练终点 $\hat{\theta}$ 对负对数后验做二阶泰勒展开： $-\log p(\theta|\mathcal{D}) \approx \text{常数} + \frac{1}{2}(\theta - \hat{\theta})^T \mathbf{H}(\theta - \hat{\theta})$ ，后验近似为 $\mathcal{N}(\hat{\theta}, \mathbf{H}^{-1})$ 。Hessian（损失对参数的二阶偏导数矩阵）太大（百万量级参数的平方规模），实际用对角近似、Kronecker 分解（K-FAC）或 Gauss-Newton 结构。60.3 秒，精度常与 MFVI 相当。失效模式：单模态假设（多峰后验只取一个峰）。

3.6 深度集成与其省钱变体

深度集成（DEns）训练 M 个不同初始化的网络。它的“贝叶斯解读”至今有争议：多初始化捕到的是损失面的多个局部极小，与后验多峰有对应关系但没有等价定理。实证上它是最强的便宜基线之一（359.8 秒，即 M 个训练串行跑完）。两个省钱变体：快照集成 SEns（31.9 秒，单轨迹取多个极小）与 SWAG（36.6 秒，快照再拟合高斯采样）。

综述比较实验的三个可迁移结论 一，便宜方法 + 学好先验 可以打平昂贵方法：用留出数据调噪声水平与先验强度后，MFVI/LA 的校准与精度接近 HMC。二，深度集成的不确定度在 OOD 处经常不涨：各成员在训练分布外的行为趋于一致（都外推得差不多差），散度不再标记误差。三，单指标排名不可信：dropout 在某些指标上大幅领先 HMC、在 OOD 校准上大幅落后，论文结论依赖指标选择。

3.7 非贝叶斯三替代（综述列出的未来方向）

Conformal prediction：不需要分布假设。拿一个留出集，计算“真实值相对预测分位的偏差”的经验分位数 q ，新预测的区间宽度乘上 q 。有限样本覆盖保证 $(P(u \in \text{区间}) \geq 1 - \alpha)$ 是分布自由的，代价是区间只有宽度没有形状、且要求数据可交换（把样本顺序打乱，联合分布不变；比独立同分布略弱的假设）。

Evidential deep learning：网络直接输出一个证据分布的参数（回归用 Normal-Inverse-Gamma：一次前向同时给出均值、aleatoric、epistemic 与总方差），推断最便宜；训练需要精心设计的损失（对错配的证据重罚），校准难做。

神经过程（NP）：函数空间的潜变量模型：给一组“输入-输出”对，推断潜变量 z 的后验，再预测新点的条件分布。UQ-SONet（第 9 章）的 cVAE 解码器与它同族，差别在后者把 PDE 物理损失接了进来。

3.8 指标体系补全

主章节给了 RL2E / MPL / RMSCE 三个一级指标。补两个常被引用的：

CRPS（连续排序概率得分）：预测分布 F 对真值 u 的得分

$$\text{CRPS}(F, u) = \int (F(x) - \mathbf{1}\{x \geq u\})^2 dx$$

，它度量“预测 CDF 与以真值为中心的阶跃函数”的距离，有解析式（对高斯预测），是气象学几十年的标准得分，综合了校准与锐度。

覆盖率与区间宽度 (PIW)：名义 95% 区间的实际覆盖率与平均宽度。覆盖率达标只是底线（宽到荒谬也能达标），覆盖率与宽度的联合才是质量，RMSCE 与 PIW 要成对报告的原因就在这里。




图 5 评价指标全景 (综述 2201.07766)：按数据需求分三类。蓝色需要测试集 (RL2E、MPL、RMSCE)，橙色需要金标准参考解 (NIP-G、KL-G)，绿色两者都不需要 (区间宽度、离散度)。实践建议是三类各取至少一个。

4 评测协议实操：指标、校准与成本

前面把方法讲完，这一章处理另一个问题：拿一个具体问题做完 UQ 之后，凭什么说它做得好。综述在这一点上比一般方法论文更啰嗦，而这份啰嗦正是它最有用的部分：同一批实验里，不同的指标会把不同方法推到第一，所以“哪个方法最好”这个问题必须拆成“在哪个指标上、花多少代价、用什么当参照”三个问题。

4.1 三类指标，按你需要什么数据来分

综述把指标按“算它要不要额外数据”分三类。这个分法比按公式分更有用，因为它直接对应你手头的资源。

第一类只要测试集。三个量：

- RL2E (相对 L_2 误差)：

$$\text{RL2E} = \sqrt{E_{(x,u) \in \mathcal{D}_{\text{test}}} \|E_{\theta | \mathcal{D}} u_{\theta}(x) - u\|_2^2 / \|u\|_2^2} \approx \sqrt{\sum_i (\bar{\mu}(x_i) - u_i)^2 / \sum_i u_i^2},$$

分子里的期望用后验样本平均 $\bar{\mu}(x) = \frac{1}{M} \sum_j u_{\hat{\theta}_j}(x)$ 近似。它只管均值准不准，对不确定度带完全无感。

- MPL (平均对数似然型指标, mean probabilistic likelihood)：

$$\text{MPL} = E_{(x,u) \in \mathcal{D}_{\text{test}}} E_{\theta | \mathcal{D}} p(u | x, \theta) \approx \frac{1}{N_{\text{test}}} \sum_i \mathcal{N}(u_i | \bar{\mu}(x_i), \bar{\sigma}^2(x_i)),$$

注意它把每个点的预测分布换成了一个高斯 (用逐点的总均值与总方差)，所以多峰后验会被“压平”。

MPL 高说明测试点在预测分布下概率大，它对带宽度的惩罚比对形状更敏感。

- RMSCE (均方校准误差)：下节单独讲。

第二类要金标准。需要先有一个贵但准的参照解（综述明说：HMC 或精确解），然后：

$$\text{NIP-G} = \angle(\sigma_G^2, \text{Var}(U | X, \mathcal{D})) / \sqrt{\angle(\sigma_G^2, \sigma_G^2) \angle(\text{Var}, \text{Var})},$$

即预测方差场与真条件方差场的余弦相似度，取值在 0 到 1 之间。它不问“区间盖住没有”，只问“该宽的地方宽了没有、该窄的地方窄了没有”。配合 KL-G：

$$\text{KL-G} = \text{KL}(p_G(u | x) \parallel E_{\theta|\mathcal{D}}[p(u | x, \theta, \mathcal{D})]),$$

把参照分布 p_G 当基准，量预测分布与它的偏离。这两个指标在纯 ML 里几乎用不了，因为很少有人能拿到“真条件方差”；SciML 里可以，这正是综述强调的学科优势。

第三类什么额外数据都不要：PIW（区间宽度）与 SDCV（方差离散度）。

$$\text{PIW} = E_{x \in \mathcal{D}_{\text{test}}} [\hat{u}(x)_p^h - \hat{u}(x)_p^l], \quad \text{SDCV} = \sigma_{\text{sigma}} / \mu_{\text{mu}},$$

PIW 是名义置信水平（综述用 95%）下区间宽度的平均，量“锐度”；SDCV 是预测标准差在测试点上的变异系数，量“模型知道哪里该宽、哪里该窄”。综述给的使用规则很硬：这两个都不能单独当指标用，只在 RMSCE 相同的前提下比较，**同校准下偏好更小的 PIW 与更大的 SDCV。**




图 6 积分式校准（综述 2201.07766 附录）：名义概率 p 与经验覆盖率的关系曲线，对角线是理想校准。曲线整体在对角线上方表示过置信（声称 95% 实际只盖住更少），下方表示欠置信。

4.2 RMSCE 的构造细节，以及为什么要按 x 平均

概率校准的要求是：对每个名义概率 p ， p 分位数以下应当恰好有比例 p 的观测。写成条件是 $P(U_X \leq \bar{P}_X^{-1}(p)) = p$ 对所有 $p \in [0, 1]$ ，其中 $\bar{P}_X$ 是预测分布。

困难在数据：回归问题里同一输入通常只有一个观测值，没法在一个 x 上算经验 CDF。综述的做法是反过来平均：在输入空间取一批 p_j (N_p 个名义概率)，每个 p_j 用整个测试集算覆盖率，

$$\text{RMSCE} \approx \sqrt{\frac{1}{N_p} \sum_{j=1}^{N_p} \left[p_j - \frac{1}{N_{\text{test}}} \sum_i \mathbf{1}\{u_i \leq \hat{u}(x_i)_{p_j}\} \right]^2},$$

其中 $\hat{u}(x)_p \approx \mathcal{N}(\bar{\mu}(x), \bar{\sigma}^2(x))$ 的 p 分位。这个式子解释了两件事。第一，过置信（区间太窄）表现为内层覆盖率低于 p_j ，RMSCE 把它记成正的偏差；第二，一个把区间放到荒谬宽度的模型也能把 RMSCE 压小（覆盖率超过 1 之后被截断），所以它必须与 PIW 成对报告。




图 7 同一个深度集成在同一个问题上的两次报告（综述 2201.07766 附录）：左为训练后直接给出的预测带，右为用 14 个留出点做后校准之后的结果。均值曲线没变，变的是带宽。这个对照是后校准的标准形态：它修的是“信任度”，不是“预测值”。

4.3 后校准：三种花小钱的修法

如果训练完发现 RMSCE 大，综述列了三条不需要重训的补救，都只用一份留出的校准集 $\mathcal{D}_r$ （实验里 2 到 14 个点）。

方差重标定。给总方差乘一个常数 s^2 ， s^2 由校准集上的一维搜索定出，使 RMSCE 最小。均值不动，形状不动，只把带子整体拉宽或收窄。它修的是“整体过置信”，修不了“该宽的地方不宽”。

CDF 修正。在校准集上把每个点的经验概率 $\bar{P}(u_i | x_i)$ 与该概率的经验覆盖率配对，用保序回归 (isotonic regression) 拟合一个单调映射 Q ，新预测用 $Q \circ \bar{P}$ 。单调性保证还是一个合法 CDF。它会同时改变预测的分位数与方差，均值也可能移动。

CRUDE。不假设修正函数的形状，直接学残差的分布：把校准集上的预测标准化成 $\mathbf{1}\{(u_i - \bar{\mu}(x_i))/\bar{\sigma}(x_i)\}$ 排序后的经验分布，其均值 μ_ϵ 与方差 σ_ϵ^2 用来平移和缩放新预测，即 $\bar{\mu}_{\text{new}} = \bar{\mu} + \bar{\sigma}\mu_\epsilon$ ， $\bar{\sigma}_{\text{new}}^2 = \bar{\sigma}^2\sigma_\epsilon^2$ 。比前两条多一点：它能纠正系统性偏置 ($\mu_\epsilon \neq 0$ 时平移均值)。

综述给这三条的批语是同一句：它们校准的是**平均意义**。它随后用一个具体后果说明这一点：SWAG 在校准集上做了 ID 校准之后，在分布外区域 (OOD) 的 RMSCE 从 22.0 变成 27.0，即**校准让 OOD 更差了**。所以任何后校准都要同时在 ID 与 OOD 两份测试集上报告，否则你修的是自己留出集的形状。

4.4 金标准之外：怎么知道模型“知道自己不懂”

算子学习场景里综述专门做了一组 OOD 检测实验 (Darcy 流，训练用相关长度 $l = 0.25$ 的渗透率场，测试换成 $l = 0.15$)。它用三个不需要真解就能算的量：

- GAN MSE: $\sum_i \|\lambda_i - \lambda_\theta(x_i, y_i)\|^2 / \sum_i \|\lambda_i\|^2$ ，即把网络的隐变量当优化变量、以物理残差为目标做一轮优化后的终值。拟合不下去 (值大) 说明输入不像训练数据。
- GAN NLL: $\|\hat{\theta}\|_2^2 + \frac{1}{2}K \log 2\pi$ ，隐变量在标准高斯先验下的对数密度，量“隐编码本身有多反常”。
- DEns std: 成员间的 epistemic 标准差在测试集上的平均。

三者换相关长度后相对 ID 的变化是 +60%、+37%、+57%，方向与真实误差的变化 (RL2E 从约 4% 升到约 19%) 一致。这是“集成散度可以当 OOD 探测器”的一个干净证据，但注意它是在算子学习的设定下得到的：一次推理能拿到上百个输出点的散度，比逐点回归更容易看出异常。

4.5 成本要按“取样”算，别按“使用”算

综述的成本表只统计**拿到样本的时间**，不统计之后用这些样本做推断的时间。这个口径决定了哪些方法看起来便宜。函数逼近问题的实测 (秒，CPU 为两颗四核八线程 Xeon E-2643 @ 3.30 GHz，GPU 为 Titan Xp)：

方法	CPU	GPU
HMC	131.5	322.7
朗之万动力学	44.4	269.7
平均场变分推断	19.5	31.2
MC dropout	41.7	55.4
拉普拉斯近似	60.3	77.6
深度集成（10 成员串行）	359.8	494.7
单体重标定集成	31.9	56.1
SWAG	36.6	61.5

表里有两个反直觉的地方，综述解释了原因。第一，GPU 上 HMC 与朗之万反而更慢：动量采样要在设备上产生随机数、Metropolis 接受步的 if/else 造成同步，而这类小数据问题的计算量小到让 PCIe 3.0 (8 GT/s) 的传输延迟占了主导。作者明确说这张表不能用来比较 CPU 与 GPU 的优劣。第二，深度集成的 359.8 秒是十个成员**串行**训练的时间；它贵得合理，但表里的 SE_{ns} (31.9 秒) 给出了同族替代：只训一个网，事后在权重上做扰动再重标定。

Gan 型函数先验 (GAN-FP) 的成本不在表里：预训练生成器要约一小时 (单卡)，好处是之后每次推断都便宜，而且性能在算子实验里最好。综述的判断是把这类方法看成“用一次性预训练换长期推理成本”。

4.6 同一批数据上的相反结论

指标之间会打架，综述自己给的最典型例子是 MC dropout 对比 HMC：

在若干噪声水平与数据集规模下，按评测指标 MC dropout 比 HMC 更好；但 MC dropout 不像 HMC 那样随噪声增大或数据减少而一致地给出更大的认知不确定性。

数字上更直观：已知同方差噪声的设定里，MPL 这一列 MC dropout 在全部六个（数据量，噪声）组合里都是第一，而 HMC 因为诚实的欠置信被这条指标惩罚。综述因此把它写成选型的第一个教训：**必须同时报告多个指标**。它给的完整建议是四条：把手头问题上的几种方法都跑一遍；用多个指标；用验证数据学或调先验与超参数；训练后用一份小的留出集做校准。并补了一句按代价的选择：拉普拉斯近似、平均场变分推断、单体重标定集成 是性能与代价的折中点。




图 8 从样本到校准判据的一步（综述 2201.07766 附录）：后验样本给出预测 PDF，积分成 CDF，再按名义概率读分位数与覆盖率。RMSCE 就是在最后这一步上量“名义概率与经验覆盖率的差”。

4.7 这套协议里仍然空的格子

按综述自己的说法，以下几项没被回答：所有方法的成本效益还没有系统研究，尤其是校准本身要花多少数据；主动学习与校准的代价关系没人做；多保真数据与数据增强如何进 UQ 只做了一点；输入含噪的算子学习（DeepONet 的输入本身有不确定度）仍是空白；证据深度学习、变分信息瓶颈、共形预测这些替代路线只在展望里出现，其中“变分信息瓶颈”一条正是本组 IB-UQ 那条线接上去的位置。

5 方法核心：信息瓶颈做 UQ (IB-UQ, 2023)

5.1 它要解决的问题

综述的框架给出预测分布的构造方式（后验样本 + 混合），但构造方式本身没回答一个关键问题：**网络在 OOD 输入上的不确定度可信吗？** 贝叶斯方法与集成方法的参数分歧在训练数据附近有意义，在外推区未必变大（综述自己的实验显示深度集成的 OOD 不确定度经常不涨）。

Guo-Wu-Zhou-Wang-Zhou (CMAME 2023) 从信息瓶颈 (IB) 出发构造 UQ，出发点是一个观察：IB 的目标天然包含“表示要简单”这一项，而“简单表示对没见过的输入无话可说”，这恰好是 OOD 不确定度想要的形状。

先回顾 IB 的目标。经典 IB (Tishby 1999) 寻找一个表示 Z ，最大化

$$I(Z; Y) - \beta I(Z; X),$$

即“保留关于目标 Y 的信息，压缩关于输入 X 的信息”， β 是权衡系数。Alemi 等 (2017) 的 VIB 用变分下界把它变成可训练的损失。IB 谱系与本文的关系逐条对照：

- Tishby-Pereira-Bialek (1999)：IB 原始定义；Tishby-Zaslavsky (2015) 用 IB 分析深度网络的逐层表示；
- Alemi 等 (2017)：VIB 变分近似，本文的下界推导直接沿用其技术；
- Alemi 等 (2018)：指出 VIB 天然蕴含不确定性、可改善校准与 OOD 检测，这是本文的动机文献；
- 本文的改造有两处，见下文（压缩项换成宽分布版本；编码器换成置信度混合）。

5.2 改造一：压缩项换成宽分布版本

原始 IB 压缩 $I(Z; X)$ ：惩罚表示对输入的依赖。但“对输入的依赖”在 OOD 处应该是消失的，惩罚总量做不到这一点。本文的数据增强版目标：

$$\mathcal{L}_{\text{IB}} = I(Z; Y) - \beta I(\tilde{Z}; \tilde{X}),$$

其中 $\tilde{X} \sim \tilde{p}(x)$, 而 $\tilde{p}(x) \propto p(x)^{1/\tau}$ ($\tau > 1$) 是比训练分布更宽的分佈 (加温: τ 越大越平)。

为什么宽分布压缩就是 OOD 保险 在 $\tilde{p}$ 下做压缩, 等于要求“在训练分布及其周边 (含外推区) 都不能依赖输入的具体取值”。最优解会在低密度区自动放弃编码, 于是 OOD 输入的代表退化无信息的先验样本, 预测分布退化为先验, 不确定度自动增大。本节末尾的命题把这个论证变成不等式。

“加温分布”如何实现? 用 **GIN** (General Incompressible-flow Networks, 保体积的 normalizing flow): 它类似 RealNVP 但雅可比行列式恒为 1, 于是变换不改变密度值, 只改变密度的位置。把可训练参数 W 缩放为 $\sqrt{\tau}W$, 就得到密度 $p_V(v)^{1/\tau}$ 的精确采样器。“ $1/\tau$ 次幂”从哪来, 三步说清:

1. **密度换算没有雅可比因子。** 设 $v = g(x)$ 是 GIN 的变换。一般的 flow 换密度要乘 $|\det \partial g / \partial x|$; GIN 的行列式恒为 1, 所以 $p(x) = p_V(g(x))$: 密度值沿着变换原样搬运 (第 0 章 §0.9 的换算公式取雅可比因子为 1 的特例)。
2. **取幂等于除指数。** 若基分布是高斯, $p_V(u) \propto \exp(-\|u\|^2/2)$, 则 $p_V(u)^{1/\tau} \propto \exp(-\|u\|^2/(2\tau))$: 密度取 $1/\tau$ 次幂, 就是把指数上的能量除以 τ 。
3. **除以 τ 等于放大方差。** $\exp(-\|u\|^2/(2\tau))$ 作为 u 的函数正比于 $\mathcal{N}(0, \tau I)$ 的密度。所以采样程序是: 抽 $v \sim \mathcal{N}(0, \tau I)$ (等价于抽标准高斯再乘 $\sqrt{\tau}$, 第 0 章 §0.5 的线性变换封闭性), 令 $x = g^{-1}(v)$ 。换回 x 的密度时本应再乘雅可比因子, 但它是 1, 于是 x 的密度恰为 $\exp(-\|g(x)\|^2/(2\tau)) \propto p(x)^{1/\tau}$ 。

第三步里“再乘雅可比因子”这一处正是普通 flow 做不到的地方: 行列式不是 1 时会多出一个无法吸收的因子, 加温就不再精确。

5.3 改造二: 置信度混合编码器

编码器显式地把“离训练数据多远”编码成一个逐维的门控:

$$z = \text{diag}(m(x))\bar{z}(x) + \text{diag}(\mathbf{1} - m(x))z_0, \quad z_0 \sim \mathcal{N}(0, I),$$

$m(x), \bar{z}(x)$ 都是神经网络, $m(x) \in [0, 1]^d$ 是逐维置信度。这两个量为什么能当“门”用, 看一下 $z | x$ 的分佈: 固定 x 后 $m(x)$ 与 $\bar{z}(x)$ 是确定的数与向量, z 是先验噪声 z_0 的仿射变换, 由第 0 章 §0.5 的线性变换封闭性, $z | x$ 仍是高斯: 均值是 $m(x)\bar{z}(x)$ (噪声项均值为 0), 协方差是 $\text{diag}(\mathbf{1} - m(x)) \cdot \text{diag}(\mathbf{1} - m(x)) = \text{diag}((1 - m(x))^2)$ (对角矩阵相乘就是对角元相乘)。于是 $\text{Var}(z_i | x) = (1 - m_i(x))^2$: 门控的每个分量直接就是该维潜变量的方差参数。两个极端: $m = \mathbf{1}$ (训练数据附近) 时 z 是确定性特征 $\bar{z}(x)$; $m = \mathbf{0}$ (OOD) 时 z 退化为纯噪声 z_0 , 编码器不再携带任何输入信息。解码器是条件高斯 $q_D(y | z) = \mathcal{N}(\mu_D(z), \Sigma_D(z))$, 均值与对角协方差都由网络输出。推断时的预测分佈 $\hat{p}(y | x) = \int q_E(z | x) q_D(y | z) dz$ 用 MC 采样计算。




图 9 IB-UQ 回归框架总图（论文 2302.03271）。GIN 从训练分布生成 加温样本 $\tilde{x}$ ；编码器输出确定性特征 $\tilde{z}$ 与置信门 m ，与先验噪声 z_0 混合成 z ；高斯解码器输出预测均值与方差；变分损失 $\mathcal{L}_{\text{VIB}}$ 由似然项与 KL 型压缩项组成。

5.4 变分下界（推导完整保留）

IB 目标里的两个互信息都算不出，各用一个变分量替换。记号： $q_E(z|x)$ 是编码器， $q_D(y|z)$ 是解码器， $e(z)$ 是任取的边际密度代理（实现里用一个 RealNVP flow）。

第一项： $I(Z; Y)$ 的下界。 记号先说清：联合分布由模型与数据分布给出， $p(y, z) = \int p(y|x)q_E(z|x)p(x)dx$ （从数据分布抽 x 、编码得 z 、解码出 y ，三步合成的联合），推导只用到它的两个边缘 $p(y)$ 与 $p(z)$ ，以及条件分布 $p(y|z)$ 。从互信息的定义 $I(Z; Y) = E_{p(y,z)}[\log(p(y,z)/(p(y)p(z)))]$ 出发（第 0 章 §0.4 的定义式按连续情形积分改写）：

第一步：拆成两个条件对数。 分子分母同除 $p(z)$ ， $p(y,z)/(p(y)p(z)) = p(y|z)/p(y)$ ，于是

$$I(Z; Y) = E_{p(y,z)}[\log p(y|z)] - E_{p(y,z)}[\log p(y)].$$

第二步：把第二个期望里的 z 积掉。 $\log p(y)$ 不含 z ，对联合分布取期望可以先对 z 积分： $E_{p(y,z)}[\log p(y)] = E_{p(y)}[\log p(y)]$ ，按熵的定义（第 0 章 §0.4）它等于 $-\mathcal{H}(Y)$ 。

第三步：把 $\log p(y|z)$ 拆成解码器加比值。 $\log p(y|z) = \log q_D(y|z) + \log(p(y|z)/q_D(y|z))$ （右端展开时 $\log q_D$ 一正一负抵消）。取期望时第二项在固定 z 下对 y 的平均恰是 $\text{KL}(p(y|z) \parallel q_D(y|z))$ （KL 的定义），再对 z 取平均：

$$I(Z; Y) = E_{p(y,z)}[\log q_D(y|z)] + E_{p(z)}[\text{KL}(p(y|z) \parallel q_D(y|z))] + \mathcal{H}(Y).$$

第四步：取下界。 中间一项是 KL 的期望，KL 非负（第 0 章 §0.4 的性质二），扔掉它不等号朝“低估相关性”的方向走：

$$I(Z; Y) - \mathcal{H}(Y) \geq \widehat{I(\tilde{Z}; \tilde{Y})} = E_{p(y,z)}[\log q_D(y|z)],$$

等号当且仅当每个 z 处 $q_D(y | z) = p(y | z)$ (KL 为零当且仅当两个分布相同)。**最大化解码似然就是在最大化相关性的下界。**

第二项： $I(\tilde{Z}; \tilde{X})$ 的上界。 这里的联合分布由编码器自己定义： $\tilde{p}(\tilde{x}, \tilde{z}) = \tilde{p}(\tilde{x})q_E(\tilde{z} | \tilde{x})$ (抽一个加温输入，编码器给它一个随机表示)，所以条件分布 $\tilde{p}(\tilde{z} | \tilde{x})$ 就是 q_E 本身。互信息为

$$I(\tilde{Z}; \tilde{X}) = E_{\tilde{p}(\tilde{x}, \tilde{z})}[\log q_E(\tilde{z} | \tilde{x})] - E_{\tilde{p}(\tilde{z})}[\log \tilde{p}(\tilde{z})],$$

第一项与上一项的第一步同形；第二项里的边缘 $\tilde{p}(\tilde{z})$ 是编码器输出在加温分布上的真实边缘，要对 $\tilde{x}$ 积分，算不出。

第一步：插入代理边缘。 把 $\log \tilde{p}(\tilde{z})$ 拆成 $\log e(\tilde{z}) + \log(\tilde{p}(\tilde{z})/e(\tilde{z}))$ (展开时 $\log e$ 一正一负抵消)，代入：

$$I(\tilde{Z}; \tilde{X}) = E[\log q_E] - E_{\tilde{p}(\tilde{z})}[\log e(\tilde{z})] - E_{\tilde{p}(\tilde{z})}[\log(\tilde{p}(\tilde{z})/e(\tilde{z}))].$$

第二步：认出 KL 并取上界。 第三个期望按定义是 $\text{KL}(\tilde{p}(\tilde{z}) \parallel e(\tilde{z}))$ ，KL 非负，扔掉它不等号朝“高估压缩项”的方向走：

$$I(\tilde{Z}; \tilde{X}) \leq \widehat{I(\tilde{Z}; \tilde{X})} = E_{\tilde{p}}[\log q_E(\tilde{z} | \tilde{x}) - \log e(\tilde{z})],$$

等号当且仅当 $e(\tilde{z}) = \tilde{p}(\tilde{z})$ (KL 为零)。**最小化“编码器对宽分布样本的 编码长度减去代理边际的编码长度”就是在最小化压缩项的上界。**

合并。 两个界都朝安全方向偏 (相关性项低估、压缩项高估)，得到可训练的 VIB 目标：

$$\mathcal{L}_{\text{VIB}} = E_{x,y,z}[\log q_D(y | z)] - \beta E_{\tilde{x}, \tilde{z}}[\log q_E(\tilde{z} | \tilde{x})/e(\tilde{z})] \leq \mathcal{L}_{\text{IB}} - \mathcal{H}(Y).$$

为什么 $\mathcal{H}(Y)$ 不再出现：它只由数据的边缘分布决定，不含 q_D, q_E, e 的任何参数，对优化而言是常数，从目标里去掉不改变极小值点。

训练算法 (每步)：抽 mini-batch；可选 Mixup 平滑 ($\lambda \sim \text{Beta}(\alpha, \alpha)$, $\alpha = 0.005$ 取得极小，只起平滑经验分布的作用)；GIN 抽 $\tilde{x}$ ；编码得 $z, \tilde{z}$ ；用样本平均估计上式；梯度上升更新 q_D, q_E, e 的全部参数。

用日常语言读一遍：这两条界合起来干了什么 互信息的两个项都要求知道真实的条件分布与真实的边缘分布，都算不出。推导把每一项拆成“一个能算的期望”加“一个非负的 KL”：第一项扔掉 KL 得到相关性的下界，第二项扔掉 KL 得到压缩的上界，两个“扔掉”的方向都让目标变得保守，所以最大化这个替代目标 不会把模型引向高估自己的方向。训练时唯一要算的是 三个网络的输出对数，样本平均即可估计，这就是整个框架可以端到端训练的原因。

5.5 数据增强的理论保证

命题(OOD 处的编码退化) 记 $\mathcal{M} = (q_E, q_D, e)$ ，最优模型 $\mathcal{M}^*$ 。若存在常数 $C > 1$ 使 $p(y)^{-1}p(y | x) \leq C$ 对所有 x, y ，则对满足 $p(x) \leq \varepsilon \tilde{p}(x)$ 的 x 与 ε ：

$$\text{KL}(q_E^*(\cdot | x) \parallel e^*(\cdot)) \leq \varepsilon \beta^{-1} \log C.$$

读法： $\text{KL}(q_E^* \parallel e^*)$ 衡量“编码器输出与代理边际的偏离”，也就是编码器还在多大程度上“依赖这个输入”。不等式说：在训练密度比加温密度低 ε 倍的位置 (外推区)，最优编码器的输出与输入几乎独立， z 落回先验 z_0 ，预测分布退化为先验，不确定度由解码器在纯噪声输入下的行为决定 (自动变大)。这个命题是“宽分布压缩”设计的数据理论保证。




图 10 信息平面分析 (论文 2302.03271): 不同 β 下相关性下界 $\widehat{I(\tilde{Z}; \tilde{Y})}$ 与压缩上界 $\widehat{I(\tilde{Z}; \tilde{X})}$ 的轨迹。 β 小时压缩不足 (点右上), β 大时过度压缩 (点左下), 实验里的最优区间是 $\beta \in [0.2, 0.3]$ 。

5.6 DeepONet 版 (算子学习)

算子学习的 UQ 把瓶颈放在 branch 网络 (处理传感器测量的一侧)。编码器同构: $z(o) = \text{diag}(m(o))\bar{z}(o) + \text{diag}(\mathbf{1} - m(o))z_0$, o 是传感器读数向量。解码器用确定性 DeepONet 同时输出均值与对数标准差:

$$\mathcal{F}_\theta(u)(y) = \sum_{i=1}^n b_i(o)t_i(y), \quad (\mu_D(y, z), \log \sigma_D(y, z))^T = \sum_{i=1}^n b_i(z)t_i(y),$$

IB 目标变为 $\mathcal{L}_{\text{IBONet}} = I((Y, Z); s(Y)) - \beta I(\tilde{Z}; \tilde{O})$, 变分下界与回归版逐字平行 (把 x 换成 o 、 y 换成采样点处的 $s(y)$)。两个 remark: 只做单点 y 的 UQ (多点联合预测是开放问题); trunk 网络也可以加瓶颈, 本文选择只在 branch。

5.7 实验检验

四个场景, 每个都把 IB-UQ 与 GP、HMC、深度集成对照:

- **不连续函数** (32 个含噪样本): IB-UQ 与 GP/HMC 一样在外推区 不确定度显著增大; 深度集成的 OOD 不确定度不明显增大, 印证了综述的“集成盲区”;
- **算子学习** (扩散反应方程与对流方程, OOD 输入取不同的相关长度): 误差被 2 倍标准差覆盖, 输入越粗糙误差越大且不确定度越大;
- **California housing**: 用 LOF (Local Outlier Factor, 局部离群因子: 按每个点的邻居密度给它打异常分) 划分 ID/OOD, 误差随 LOF 降低 (越异常) 增大, 不确定度同步覆盖;
- **气候模型** (温度场到气压场, 删掉部分季度数据做 OOD): IB-UQ 的不确定度在缺失区域增大, 而普通 DeepONet 不输出任何置信度。

IB-UQ 的边界 三点。第一，GIN 加温与 Mixup 都引入新超参数 (τ, α) ，虽然实验显示结果对它们不敏感，但理论没有给出选择准则。第二， $e(z)$ 的表达力决定压缩上界的紧度，表达不足时上界松。第三，OOD 命题的常数条件 $(p(y)^{-1}p(y|x) \leq C)$ 在重尾目标下可能不成立。这些都是后续工作（第 9、10 章）继续改造的入口。

6 IB-UQ 深入：率失真视角、算法细节与实验画廊

6.1 用率失真的语言重读 IB-UQ

第 5 章的推导可以再用一遍信息论的经典对照来读。经典率失真问题：给定源 X 与失真度量，求“失真不超过 D 时最少要多少码率”的曲线 $R(D)$ 。IB 的变体：失真不是平方误差，而是“丢掉了多少关于 Y 的信息” $I(X; Y|Z)$ ，码率是 $I(X; Z)$ 。第 5 章第四步的改写 $\mathcal{L}_{\text{IB}} = I(X; Z) + \beta I(X; Y|Z) - \beta I(X; Y)$ 正是“码率 + $\beta \times$ 失真（差常数）”， β 是两条曲线的兑换率。

IB-UQ 在这个框架上换了两样东西，对照如下：

成分	经典 IB	IB-UQ
码率	$I(X; Z)$	$I(\tilde{Z}; \tilde{X})$ ，在加温分布上算
失真	$I(X; Y Z)$	同（经变分下界近似）
兑换率	β ，扫参定	β ，实验最优 [0.2, 0.3]
无失真极限	Z 保留全部 X 的信息	Z 只保留训练分布内的信息；OOD 处 Z 与 X 独立

最后一行是关键差别：经典 IB 的“最优编码”会把 X 的全部信息（包括噪声）都录进 Z ，遇到分布外的 X 就瞎编；IB-UQ 的最优编码被训练成“只在训练分布内依赖输入”，OOD 输入自动落到先验。这就是“宽分布压缩”在率失真语言里的样子：**把失真的定义域扩大到了训练分布的邻域。**

6.2 Mixup 与 $\alpha = 0.005$

算法里 Mixup 的系数 $\alpha = 0.005$ 远小于原论文的 0.1 到 0.4，值得解释。原 Mixup 用大 α 做数据增强（标签平滑）；这里 $\lambda \sim \text{Beta}(\alpha, \alpha)$ 在 α 很小时几乎总是取 0 或 1（分布集中在两端），Mixup 退化为“偶尔把两个样本连线中间的点加入训练”。它扮演的角色不是增强而是**平滑经验分布**：数据少时 $q_D(y|z)$ 会过拟合到有限个点，偶尔的插值样本把解码器的条件高斯拉宽。这是防 q_D 过拟合的轻量手段，与换更强的密度模型（normalizing flow 解码器，论文留作选项）是两条互补的路。

6.3 算子版算法的完整流程

DeepONet 版（IB-ONet）每个训练步：

1. 抽 mini-batch 的输入函数-解对 (o_b, s_b) ；
2. (可选) Mixup；
3. GIN 抽加温输入 $\tilde{o}_b$ ；
4. 编码 $z_b = \text{diag}(m(o_b))\bar{z}(o_b) + \text{diag}(1 - m(o_b))z_{0,b}$ ；
5. 对每个 o_b 另抽 B_M 个查询点 y_j^b (trunk 网络输入)；
6. 估计 $\hat{\mathcal{L}} = \frac{1}{BB_M} \sum_{b,j} \log q_D(s(y_j^b) | y_j^b, z_b) - \frac{\beta}{B} \sum_b [\log q_E(\tilde{z}_b | \tilde{o}_b) - \log e(\tilde{z}_b)]$ ；
7. 梯度上升更新 q_D, q_E, e (全部网络)。

与回归版唯一的结构差异在第 5 步：解码器的输入是 (查询点，潜变量) 二元组，所以每个样本要配多个查询点才能约束整个函数。 B_M 的选择是精度与代价的折中。

第 6 步的估计量为什么长这样，逐项对。VIB 目标是两个期望之差（第 5 章的 $\mathcal{L}_{\text{VIB}}$ ，把 x 换成 o 、 y 换成 $s(y)$)：

- 似然项 $E_{o,y,z}[\log q_D(s(y) | y, z)]$ 是对“输入函数-查询点”联合分布的期望。第 1 步抽的每个 o_b 与第 5 步另抽的每个查询点 y_j^b 互相独立，于是每个对 (o_b, y_j^b) 都是这条联合分布的一个独立样本； $B \times B_M$ 个样本的算术平均估计期望，正是第 0 章 §0.6 的蒙特卡洛估计。这解释了分母为什么是 BB_M ：似然项的样本有这么。潜变量 z_b 在同一 o_b 的 B_M 个查询点之间共享，不影响无偏性：先对 j 平均、再对 b 平均，只是交换了求和的顺序，期望的嵌套结构没变。
- 压缩项 $E_{\tilde{o}, \tilde{z}}[\log q_E/e]$ 只对加温输入分布取期望，查询点不出现，样本只有 B 个、分母是 B ； β 是原目标的权衡系数，原样乘上来。

6.4 实验画廊




图 11 不连续函数的四种方法对比（论文 2302.03271）：GP、HMC、深度集成、IB-UQ。预测均值（线）与 2 倍标准差带（阴影）。GP/HMC/IB-UQ 在外推区（两端与中间断点附近）不确定性都增大；深度集成的带在外推区没有张开，印证综述的“集成盲区”。




图 12 算子版结构 (论文 2302.03271): 瓶颈加在 DeepONet 的 branch 网络 (传感器测量一侧), 置信门 $m(o)$ 决定每个维度 走确定性特征还是先验噪声; trunk 网络保持确定性。




图 13 反应扩散与对流方程的算子学习 UQ (论文 2302.03271)。左: 一维反应扩散在 OOD 输入 (不同相关长度) 下的预测与不确定带; 右: 二维情形的代表样本。误差大的区域与不确定度大的区域重合。




图 14 气候模型实验（温度场到气压场）：删除部分季度数据做 OOD。上：完整数据；中、下：分别删除第二季度与二、三季度。IB-UQ 的不确定度在数据缺失的区域增大，而普通 DeepONet 不输出任何置信度信息，误差无人报告。

7 后继一：Boltzmann 分布的扩散采样器（EDG，2024）

7.1 问题：没有样本的生成建模

统计力学里的标准对象是 Boltzmann 分布

$$\pi(x) = \frac{1}{Z} \exp(-U(x)), \quad Z = \int e^{-U(x)} dx,$$

配分函数 Z 是高维积分，通常算不出。难点与普通生成模型不同：**没有训练数据**，拿到 π 的样本正是任务本身。于是 JSD、MMD、Wasserstein 这些“真样本对假样本”的分布差异度量（分别是 Jensen-Shannon 散度、最大均值差异、最优传输距离）全部不可用，只剩 KL 可选；MCMC（HMC、朗之万）渐近无偏但混合慢；变分路线（Boltzmann Generator）用 normalizing flow 最小化 $D_{\text{KL}}(p_D \parallel \pi)$ ，但 flow 的双射性限制表达力；扩散采样（PIS 等）训练中要反复数值积分 SDE，昂贵。

Wang-Guo-Wu-Zhou (2024) 的 EDG (energy based diffusion generator)：**VAE 框架装一个潜空间扩散编码器**。解码过程不需要迭代采样，编码过程（score 网络）训练时不需要数值积分 SDE (simulation-free)，两头都省。

7.2 框架与主定理

解码过程（生成方向）： $z_0 \sim p_D(z_0) = \mathcal{N}(0, I)$, $x | z_0 \sim p_D(x | z_0; \varphi)$ （可训练解码器），然后潜变量沿一个 SDE 扩散：

$$dz_t = f(z_t, t)dt + g(t)dW_t, \quad t \in [0, T].$$

两个设计条件：(a) $p_D(z_t | z_0)$ 可解析采样（选 subVP 型 SDE，即分数方差保持型，score-based 模型的标准选型，好处是转移核解析可采样）；(b) T 足够大使得 z_T 近似与 z_0 独立（信息耗尽）。

编码过程（推断方向）：条件 score 网络 $s(z_t, x, t; \theta) \approx \nabla_{z_t} \log p_D(z_t | x)$ ，沿逆时 SDE 从 (x, z_T) 走回 (x, z_0) 。

定理（VAE 型 KL 上界，主定理）

$$D_{\text{KL}}(p_D(x) \parallel \pi(x)) \leq D_{\text{KL}}(p_D(x, z_{[\cdot]}) \parallel p_E(x, z_{[\cdot]})) \\ = \mathcal{L}(\theta, \varphi) + \int_0^T \frac{g(t)^2}{2} E_{p_D} [\|\nabla_{z_t} \log p_D(z_t)\|^2] dt + \log Z,$$

$$\mathcal{L}(\theta, \varphi) = E_{p_D} [\log p_D(x | z_0; \varphi) + U(x)] + \int_0^T \frac{g(t)^2}{2} E_{p_D} [\|s(z_t, x, t; \theta)\|^2 + 2\nabla_{z_t} \cdot s(z_t, x, t; \theta)] dt,$$

且等号成立当且仅当三条同时满足：解码过程中 z_0 与 z_T 独立，编码过程在 T 时刻的边缘与解码过程重合 ($p_E(z_T) = p_D(z_T)$)，且 s 恰为条件 score $\nabla_{z_t} \log p_D(z_t | x)$ 。

证明分两段，各用一条工具。这里把工具用在哪、靠什么假设成立交代清楚。

第一段：VAE 型上界。 联合分布的 KL 按链式法则拆成“边缘的 KL + 条件的 KL”，条件的 KL 非负（第 0 章 §0.4），扔掉它就把对 x 的 KL 控制在联合的 KL 之下；附录单独证明 $x \perp z_T$ （条件 (b) 的信息耗尽），独立时含 z_T 的项退化成两个先验之间的 KL，可以显式算。

第二段：用 Girsanov 定理（随机分析中处理 SDE 漂移项变化的测度变换定理，给出两个漂移对应的分布之间的密度比）处理逆时 SDE。 这一步回答的问题：编码过程沿逆时 SDE 走出的路径分布与解码过程的路径分布，两者的密度比是多少。Girsanov 定理给答案时用到两条假设，缺一结论就不成立：一是两条 SDE 的扩散系数相同（解码与逆时编码共用同一个 $g(t)dW_t$ ，只允许漂移不同），二是漂移差平方可积。在假设下，两条路径测度之间的 KL 等于漂移差平方除以 $2g(t)^2$ 后对时间积分的期望。把两条 SDE 的漂移代进去（一条含 score 网络 s ，一条含真实条件 score $\nabla_{z_t} \log p_D(z_t | x)$ ），出现 $E[\|s\|^2]$ 与交叉项 $E[s^T \nabla \log p]$ 。

分部积分恒等式。 交叉项里的真实 score 未知，要换成散度。逐行推导（记 p 为出现 s 的那个密度，维数记为 d ）：

$$E_{p[s^T \nabla \log p]} = \int s^T (\nabla p / p) \cdot p dz = \int s^T \nabla p dz \\ = \int \nabla \cdot (ps) dz - \int p \nabla \cdot s dz = -E_{p[\nabla \cdot s]}.$$

第一行把 $\nabla \log p$ 写成 $\nabla p / p$ ， p 与约掉；第二行用乘积法则 $\nabla \cdot (ps) = s^T \nabla p + p \nabla \cdot s$ 移项；第三行第一项是全散度的积分，由散度定理化为边界通量，它在“ p 在无穷远处的衰减快于 s 的增长”时为零（这是分部积分合法性的条件，常见网络的输出满足）。合并成一句： $E[\|s\|^2 + 2\nabla \cdot s] = E[\|s - \nabla \log p\|^2] - E[\|\nabla \log p\|^2]$ ，展开完全平方并代入恒等式即得。左端是损失里出现的形状，右端说明它在度量 score 离真实 score 有多远。最后把各项按参数分拣：含 θ 的只剩 $\mathcal{L}(\theta, \varphi)$ ， $E[\|\nabla \log p_D(z_t)\|^2]$ 与 $\log Z$ 两块不含 θ ，对优化是常数，所以训练损失就是 $\mathcal{L}(\theta, \varphi)$ 。

训练用 Hutchinson 估计器（用随机向量的期望估计矩阵的迹或算子的散度，代价远低于显式求和）估计散度项（Rademacher 随机向量 ε ）。无偏性三行可得： $\varepsilon^T (\partial s / \partial z_t) \varepsilon$ 是标量，标量等于自己的迹，由迹的循环性质它等于 $\text{tr}((\partial s / \partial z_t) \cdot \varepsilon \varepsilon^T)$ ； ε 的分量独立取 ± 1 ，故 $E[\varepsilon \varepsilon^T] = \mathbf{I}$ ；期望与迹交换，得 $E[\varepsilon^T (\partial s / \partial z_t) \varepsilon] = \text{tr}(\partial s / \partial z_t) = \nabla \cdot s$ 。计算代价只是一次雅可比向量积：

$$\mathcal{L}_t = \frac{Tg(t)^2}{2} \left(\|s\|^2 + 2 \frac{\partial [\varepsilon^T s]}{\partial z_t} \varepsilon \right),$$

时间 t 均匀采样，整个训练过程只从 $p_D(z_t | z_0)$ 精确采样，不需要数值积分任何 SDE。与 PIS 的差别就在这一句。

7.3 样本重加权与配分函数

训练分布 p_D 与目标 π 有偏离，用重要性采样去偏：以 $p_D(x, z_0)$ 为提案，未归一化权重

$$w(x, z_0) = \frac{\exp(-U(x))p_E(z_0 | x)}{p_D(z_0)p_D(x | z_0)},$$

$p_E(z_0 | x)$ 用概率流 ODE 与散度估计计算。副产品是一个配分函数下界 $\log Z \geq E_{p_D}[\log w]$ ，它同时充当训练质量的指示器（越大越好）。

网络设计有两个针对物理问题的细节：score 模型把 $t = 0, T$ 两端的已知边界 score 显式嵌入参数化（两端误差为零）；解码器用广义哈密顿动力学（GHD）：从 $z_0 = (\zeta, v_1, \dots, v_K)$ 出发做可训练步长的 leapfrog 式更新，末端加一步布朗动力学输出 x ，解码密度可解析求值并与 score 网络联合训练。




图 15 EDG 的解码/编码结构（论文 2401.02080）。实线是解码依赖链（ $z_0 \rightarrow \text{GHD 解码} \rightarrow x \rightarrow \text{潜空间 SDE 扩散}$ ），虚线是编码依赖（score 网络逆时回到 z_0 ）。联合损失 $\mathcal{L}(\theta, \varphi)$ 同时训练两支。

实验：2D 能量函数的六个分布（MoG2、MoG2(i)、MoG6、MoG9、Ring、Ring5）上，EDG 的加权 MMD 在五列并列最低，Ring5 一列以 0.02 对 L2HMC 的 0.01 排第二；贝叶斯逻辑回归四个数据集精度与 AUC 全部第一；Lennard-Jones 原子簇（LJ13 维数 39、LJ55 维数 165）的原子间距分布最贴合参考数据，重加权有效样本比 rESS（

$$\frac{(\sum_i w_i)^2}{N \sum_i w_i^2}$$

，衡量重要性权重的均匀程度，1 为完美、趋 0 为退化）比 Boltzmann Generator 与 PIS 高一个量级；Ising 模型（连续松弛）的 $\log Z$ 估计在多数温度下最优。




图 16 LJ13 与 LJ55 的原子间距分布 (论文 2401.02080): Boltzmann Generator (左列) 与 EDG (右列) 对比参考数据 (灰)。维数 165 时 EDG 仍贴合双峰结构。

8 后继二：反应坐标的最优降维 (FMRC, 2024)

8.1 问题：降维有没有“最优”，能不能端到端学

高维动力系统的长期行为由少数 **反应坐标** (reaction coordinate) 刻画 (分子动力学里构象变化的主轴)。基于转移算子谱分解的方法 (**TICA** 与 **VAMPnets** (分子动力学里用转移算子的特征函数做降维的方法族, 前者线性、后者用两个网络)) 给出线性降阶模型, 转移密度位于非线性低维流形上时失效; 深度方法 (time-lagged 自编码器、信息瓶颈式反应坐标、normalizing flow) 缺少“损失函数与降维引起的算子误差”之间的定量联系。Bittracher 等 (2023) 给了两个评估准则 (见下), 但数值实现 需要估计与积分转移密度, 难以扩展。

Zhang-Guo-Wu (2024) 把两个准则等价改写为两个条件概率模型的可计算损失, 用 flow matching 端到端优化, 并证明损失值直接控制算子误差。

8.2 两个准则

数据是 Markov 过程 X_t 的转移对, lag 为 τ , 转移密度 $p_\tau(x, y)$, 经验联合密度 $\rho(x, y) = \rho_0(x)p_\tau(x, y)$ (不假设平衡)。两个算子: Perron-Frobenius 算子 $\mathcal{T}_\tau u_t(y) = E[u_t(X_t) | X_{t+\tau} = y]$ (密度前传), Koopman 算子 $\mathcal{K}_\tau f(x) = E[f(X_{t+\tau}) | X_t = x]$ (观测量前传)。

两个准则 Lumpability (可归并性): $p_\tau(x, y) = p_\tau^L(r(x), y)$ 对所有 x, y 。即“ x 的转移密度只依赖 $r(x)$ ”: 反应坐标是预测未来的充分统计量。

Decomposability (可分解性): $p_\tau(x, y) = p_\tau^D(x, r(y))p_{\text{local}}(r(y), y)$ 。即“两步采样”: 先由 p_τ^D 定未来落在哪个水平集, 再由与 x 无关的 p_{local} 在集合内定位。反向等价刻画 (第 13 章的引理): decomposable 当且仅当反向转移密度 $p_{-\tau}(y, x) = \rho_0(x)p_\tau(x, y)/\rho_1(y)$ 满足 $p_{-\tau}(y, x) = p_{-\tau}^D(r(y), x)$ 。

直觉: lumpability 管“过去的哪些信息对未来必要” (正向充分性), decomposability 管“未来的状态能不能由反应坐标加局部噪声解释” (反向充分性)。两者合起来才是“这个反应坐标无损”。

8.3 Flow matching 损失与主定理

Flow matching 的元素: 路径 $Y^s = (1-s)Y^0 + sY^1$, 目标速度场 $v^*(s, y) = E[Y^1 - Y^0 | Y^s = y]$, 训练损失 $\int_0^1 E[\|v(s, Y^s) - (Y^1 - Y^0)\|^2] ds$ 。FMRC 同时恢复 p_τ 与 $p_{-\tau}$ (两个方向的速度场 v_0, v_1), 然后在速度场的第三个参数处塞进瓶颈:

$$\min_{\theta} \mathcal{L}^{\text{FMRC}} = \mathcal{L}_0[v_0^{\text{RC}}(\cdot, *, r(\cdot))] + \mathcal{L}_1[v_1^{\text{RC}}(\cdot, *, r(\cdot))],$$

即速度场只能看到 $r(X_t)$ 或 $r(X_{t+\tau})$, 看不到完整状态。

定理 (主定理) 对给定反应坐标 r :

$$\min_{v_0^{\text{RC}}, v_1^{\text{RC}}} \mathcal{L}^{\text{FMRC}} \geq \min_{v_0, v_1} \mathcal{L},$$

且等号成立当且仅当 lumpability 与 decomposability 同时满足。

证明要点：等号方向，最优瓶颈速度场等于全场，其诱导的流恰好给出 lumpability 的 p_τ^L 与反向的 p_τ^D ；反方向，在两个准则下 条件期望允许把 X_t 换成 $r(X_t)$ ，瓶颈不损失信息。

于是 $\mathcal{L}^{\text{FMRC}}$ 的数值就是反应坐标质量的度量，联合最小化 $\min_\theta \mathcal{L}^{\text{FMRC}}[v_{0,\theta}^{\text{RC}}, v_{1,\theta}^{\text{RC}}, r_\theta]$ 端到端学最优 RC。误差的定量版 (定理 5.7)：速度场误差 ε 经 Lipschitz 常数指数放大成联合分布的 W_2 误差，再用 Benamou–Brenier 线性化 (W_2 与 $\dot{H}^{-1}$ 范数的比较) 转成算子的弱范数误差：

$$\|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_H \leq \sqrt{\beta} \varepsilon e^{\int_0^1 L_s ds}.$$

实验（七井圆形势，再经 Swiss roll 映射（把二维平面卷成三维流形的经典非线性测试变换）扭曲的数据构造）：一维 RC 清晰区分七个亚稳井，PCCA+（把转移算子的特征向量聚类成亚稳态的谱聚类方法）聚类的簇内 RC 值一致、簇间有清晰间隙，与理论刻画 (lumpable $\Rightarrow$ 簇内转移同质) 一致。




图 17 学到的反应坐标 (论文 2408.15981)： $r(x)$ 投影在二维 Swiss roll 数据上，颜色区分七个亚稳井。同一井内的点 RC 值连续，井与井之间有清晰分界，这正是 lumpability 的几何形态。

9 后继三：置换不变的算子学习 UQ (UQ-SONet, 2025)

9.1 问题：变长传感器 + 不确定度

DeepONet 的两个限制：传感器数量与位置必须训练测试一致；没有内置 UQ。VIDON (Prasthofer 等) 用 Deep Sets + set transformer 把 branch 换成对变长集合的置换不变编码，但它是确定性映射，不处理稀疏、噪声或算子本身的随机性。

Ma-Guo-Wu-Zhou (2025) 的 UQ-SONet 组合两样东西：set transformer (处理集合输入的网络：逐元素编码后用注意力做置换不变的汇合，源自 Deep Sets) 嵌入与条件 VAE。

9.2 结构

嵌入：每个传感器读数先嵌入 $\Lambda_i = \Lambda_x(x_i) + \Lambda_\kappa(\kappa(x_i))$ ，然后注意力池化成固定维表示（ H 个头）：

$$h^l(\mathcal{O}) = \sum_{i=1}^m \frac{\exp(w_l(\Lambda_i)/\sqrt{d_{\text{emb}}})}{\sum_{k=1}^m \exp(w_l(\Lambda_k)/\sqrt{d_{\text{emb}}})} \cdot v_l(\Lambda_i),$$

$h(\mathcal{O})$ 是各头输出的拼接。**置换不变性**来自求和：传感器换顺序，注意力权重的集合不变，和不变。

条件 VAE：潜变量 $z \sim \mathcal{N}(0, I)$ 承载“观测不完备 + 算子固有随机性”两层信息；解码器是 DeepONet 型 $\hat{\mathcal{G}}(h(\mathcal{O}), z)(y) = \sum_{n=1}^p b^n(h, z)t^n(y)$ ，输出各点条件独立的乘积高斯 $p_D(\bar{u} | \mathcal{O}, z) = \prod_i \mathcal{N}(u(y_i) | \hat{\mathcal{G}}(y_i), M\sigma_u^2)$ 。**人工噪声方差乘 M 是刻意的：**它保证 $M \rightarrow \infty$ 时离散损失收敛到 **函数空间 cVAE** 的损失（基于 Seidman 等的 functional VAE 理论，附录严格推导）。编码器 $q_E(z | \mathcal{O}, \bar{u})$ 是对角高斯。损失是负 ELBO：

$$\mathcal{L} = E[D_{\text{KL}}(q_E(z | \bar{u}, \mathcal{O}) \| p(z)) - E_{q_E}[\log p_D(\bar{u} | \mathcal{O}, z)]],$$

展开后 KL 项有解析式（对角高斯对标准高斯，逐项展开见第 14 章），似然项用重参数化采样。推断时多次采 z 、前向、统计条件分布。




图 18 UQ-SONet 总结构（论文 2509.25646）。上半：set transformer 把变长传感器集合编码成置换不变表示 $h(\mathcal{O})$ ；下半：条件 VAE 的编码器（训练时）与先验采样（推断时），DeepONet 型解码器输出均值场。不确定度来自潜变量 z 的多次采样。

9.3 实验：不确定度随传感器数的两种行为

一维扩散方程 (10^4 训练对)：传感器数 m 从 1 增到 10 时 **不确定度带随 m 收缩**，均值误差全面优于 VIDON（如 $m = 1$ ：4.47 对 5.35, $\times 10^{-2}$ ）；乘性噪声下误差几乎不变。二维 Navier-Stokes（涡量-速度形式， $\nu = 0.001$ ）：均值误差 1.89 到 2.69 对 VIDON 的 5.98 到 8.74 ($\times 10^{-2}$)，优势最明显。

第四个实验是**随机椭圆方程**（系数与源项都由 GP 抽样，算子本身随机）：即使传感器很密，不确定度也不消失。这里要说清模型的立场：UQ-SONet 没有把 aleatoric 与 epistemic 写成两项分解，两类来源都塞进同一个潜变量 z ；能分开的是**观测行为**，即随 m 增大而收缩的那部分来自观测不完备，收缩不到零的剩余部分对应算子的内在随机性。比较的基准是条件 GP 后验（每套观测采 1000 个后验样本），指标是均值与标准差的相对 L_2 误差，不是覆盖率类指标。




图 19 不同传感器数下的条件预测（论文 2509.25646）： $m = 2, 4, 7, 10$ 的代表样本，参考解（灰）、预测均值（蓝）与不确定性带。带宽度随 m 增大系统性收缩，收缩行为本身就是“网络知道数据在变多”的证据。附录还有一个对照：给 VIDON 加深度集成，均值准，但不确定性带**系统性偏窄**（低估条件不确定性），再次呼应综述与 IB-UQ 里“集成低估 OOD/条件不确定性”的发现。

10 后继四：物理约束的潜变量模型（LVM-GP, 2025）

10.1 问题：潜变量要不要空间相关

LVM-GP (Feng-Guo-Wan-Wu-Zhou-Zhou, 2025) 处理含噪数据下的 PDE 正反问题。动机来自一个一维观察： $\lambda u_{xx} = f$ 中 u 是 f 的二重积分，因此

$$\text{Var}(u(x)) \sim \int \int_{\Omega_x} \text{Var}(f(\xi)) d\xi,$$

u 的不确定性是源项不确定性的全域能量聚合，带空间相关结构。常规潜变量模型（VAE 类）用低维标准高斯潜变量，表达不了函数级的空间相关性；B-PINN-HMC 精确但极贵；深度集成在高噪与数据稀疏下不可靠（产生伪振荡）。

10.2 方法：把 IB-UQ 的编码器接上 GP 先验

编码器与 IB-UQ 的置信度混合同构，差别只在一处：先验 z_0 从标准高斯换成**高斯过程**：

$$z(x; \theta_E) = \text{diag}(m(x))\bar{z}(x) + \text{diag}(1 - m(x))z_0, \quad z_0 \sim \text{GP}(0, K(x, x')),$$

$K = \sigma_K^2 \exp(-\|x - x'\|^2 / (2l^2)) \mathbf{I}_{d_z}$ 。 $m \rightarrow 1$ 时 z 退化为确定性特征； $m \rightarrow 0$ （远离数据）时 z 落入 GP 先验，它带着空间相关性。对固定 x ， $\text{Var}(z(x)) = (1 - m(x))^2$ ，置信函数因此是“非平稳核 GP 的另一种参数化”。

解码器是神经算子型的深层积分算子（位置变换核），条件高斯输出 $u(x) = z_L(x) + \sigma_u(x)\omega_D$ 。物理约束体现在三处： f 与 b 的均值由 PDE 诱导（ $\mu_f = \mathcal{N}_{x[\mu_u]}$ ）；GP 的导数有解析处理（KL 展开逐项求导）；反问题里 λ 与 u 共享同一个编码器（一致潜空间）。

损失 = 数据负对数似然 + IB 式正则。正则有两个版本：基本版是 $ED_{\text{KL}}(q_E \parallel e_1)$ （ e_1 为标准高斯），防止编码器把 m 全推到 1（潜 GP 塌缩成确定性映射）；改进版对一批随机点取联合 GP 边际 $e_2 = \mathcal{N}(0, \mathbf{K})$ ，KL 有解析式，同时优化 m 与 GP 核超参数（实验中长度尺度从 1.0 自适应收敛到 0.58，先验自己学到了数据的相关长度）。

LVM-GP for forward problem




图 20 LVM-GP 正问题全流程 (论文 2507.22493): 置信度编码器把数据 映到潜随机场 (GP 先验兜底), 深层积分算子解码出 u 与 f , 两者的均值由 PDE 耦合, 损失由三份数据似然加 IB 正则组成。

实验 (对照 B-PINN-HMC 与 20 个深度集成): 一维 Poisson 噪声 $\sigma = 0.1$ 时深度集成的 f 不确定度失效, LVM-GP 比 HMC 均值更准、带更紧; 一维非线性 Poisson 反问题识别 $\lambda = 0.7$, 深度集成的解出现明显伪振荡而 LVM-GP 平滑; 二维扩散反应 $\sigma = 0.1$ 时 LVM-GP 的标准差 5.70×10^{-3} 对 HMC 的 4.98×10^{-2} , 预测标准差紧一个量级且均值更准; 六维污染源反演定位三个高斯源, 三个定位均值都接近真值, 但 LVM-GP 报告的标准差比 HMC 大一个量级 (10^{-2} 对 10^{-3}), 带宽的取舍在下一节按偏差与标准差之比逐项看。训练策略有一条实用经验: 先 5000 步只训均值、再加 std 微调, 分阶段训练是稳定性的关键。

11 EDG 实验台: 怎么在没有真样本的问题上比方法

EDG 的实验部分值得单独一章, 因为它的评测协议本身就是一个设计: 没有 π 的样本当训练数据, 也没有当测试数据, 所有“分布距离”都要想办法绕开这个限制。下面按论文的实验顺序走, 每处都给出可以直接抄走的配置数字。

11.1 指标: 加权 MMD, 以及它为什么还能用

JSD、MMD、Wasserstein 这类度量都要真样本, 作者的做法是把 MMD 换成带重要性权重的版本: 从提案分布 p_D 采 N 个样本 $\{x_i, z_0^i\}$, 用重加权公式里那个未归一化权重 $w(x, z_0)$ 把它们折算成对 π 的无偏估计, 再与参考样本算核距离。实验中核函数取 RBF, 带宽用参考样本两两距离的中位数, 每格报 10 次独立运行、每次 5000 个生成样本对 5000 个参考样本, 标准差小到不印。

这个改动有一个副作用要看清: 加权 MMD 里同时含生成质量误差与权重估计误差, 所以“EDG 的 MMD 高”可能来自提案分布偏离目标、也可能来自权重方差太大。论文用 rESS 把后者单独量出来 (见下)。

11.2 六个二维能量函数: MMD 对照表

表 1 全部是 MMD (越小越好), 基线是变分 HMC (V-HMC, 1000 步预热)、L2HMC (三层全连接、leapfrog 10 步)、Boltzmann Generator (BG, RealNVP、三个 affine 块、每块三层 256 单元)、PIS (用 torchsde.sdeint 的 SRK 求解器)。

能量函数	V-HMC	L2HMC	BG	PIS	EDG
MoG2	0.01	0.04	1.90	0.01	0.01
MoG2(i)	1.56	0.94	1.63	1.66	0.50

能量函数	V-HMC	L2HMC	BG	PIS	EDG
MoG6	0.02	0.01	2.64	0.01	0.01
MoG9	0.04	0.03	0.07	0.42	0.02
Ring	0.01	0.02	0.05	0.01	0.01
Ring5	0.01	0.01	0.18	0.78	0.02

能量函数的构造很简单：MoG2 是两个各向同性高斯，方差都是 $\sigma^2 = 0.5$ ，中心相距 10；MoG2(i) 把两个峰改成 $\sigma^2 = 1.5$ 与 0.3 (i 表示 inhomogeneous)；MoG6 用 $\sigma^2 = 0.1$ ，MoG9 用 0.3 ；Ring 与 Ring5 的能量取自 ANICE-MC 的原式。

真正有信息量的是 MoG2(i) 这一行。所有方法在这里都掉到 0.5 以上，而其它五列普遍在 0.05 以下。原因在权重：一峰宽一峰窄时， π 在两峰之间的极低密度区给出极端权重比值，任何提案分布都要花大量样本去覆盖窄峰。EDG 的 0.50 是表内最好，但离“合格”还有距离，这正是后面重加权要解决的例子（未加权 0.50，重加权后 0.09）。




图 21 最难那一列的直方图对照（论文 2401.02080 图 2 的两格）：左为 Boltzmann Generator，右为 EDG，都在 MoG2(i) 能量上，灰线是 Metropolis 参考。两峰宽度不同，窄峰是全部方法的难点。

11.3 消融：解码器和编码器各赚了多少

论文的消融表把“用不用 GHD 解码器”和“编码器是不是扩散”两个开关分开，同一个 MMD 指标，六个能量函数的列序同上：

配置	MoG2	MoG2(i)	MoG6	MoG9	Ring	Ring5
VAE, 解码器不用 GHD	1.86	1.62	2.57	2.10	0.12	0.23
VAE, 解码器用 GHD	0.01	2.43	0.15	0.59	1.68	0.63
EDG, 解码器不用 GHD	0.06	1.01	0.04	0.05	0.02	0.04
完整 EDG	0.01	0.50	0.01	0.02	0.01	0.02

这张表读出来的东西比“EDG 最好”多三条。第一，把 GHD 放进普通 VAE（第二行）在 MoG2 上确实拿到 0.01，但在 Ring 上退到 1.68：物理结构正确的解码器不等于全局更好，它对多流形目标不稳固。第二，EDG 去掉 GHD（第三行）在六列里赢下五列，只有 MoG2 一列的 0.06 不敌“VAE + GHD”的 0.01，其余各列都优于两个 VAE 变体，说明主要收益来自潜空间的扩散编码结构。第三，MoG2(i) 这一列在四行里分别是 1.62、2.43、1.01、0.50：只有“扩散编码 + GHD 解码”同时到位才把它压下来。

11.4 两个网络设计细节

边界条件引导的 score 参数化。条件 score 网络写成

$$s(z, x, t; \theta) = \left(1 - \frac{t}{T}\right) \nabla_z [\log p_D(x | z_0 = z) + \log p_D(z_0 = z)] \\ + \left(\frac{t}{T}\right) \nabla_z \log p_D(z_T = z) + \left(\frac{t}{T}\right) \left(1 - \frac{t}{T}\right) s'(z, x, t; \theta),$$

前两项是已知的两端 score，第三项才是学出来的，并被系数 $(\frac{t}{T})(1 - \frac{t}{T})$ 夹成在 $t = 0$ 与 $t = T$ 处为零。“前两项已知”的依据是 Bayes 公式： $\log p_D(x | z_0) + \log p_D(z_0) = \log p_D(z_0 | x) + \log p_D(x)$ ，对 z 求梯度时右端第二项（只含 x ）消失，所以第一项的组合给出 $\nabla_z \log p_D(z_0 = z | x)$ ，第二项给出 $\nabla_z \log p_D(z_T = z)$ ，两者都不含可训练参数，可以精确写出。于是网络在两个端点不可能犯错，中间区域才承担误差。这是一类通用的“把边界条件编进参数化”的做法，在训练数据稀缺的高维问题上是实打实的正则。

GHD 解码器。潜变量拆成 $z_0 = (\zeta, v_1, \dots, v_K)$ ，先由一个小网络把 ζ 映到中间变量

$$y := a(\zeta; \varphi), \quad y = \mu_0(\zeta_0; \varphi) + \Sigma_0(\zeta_0; \varphi) \cdot \zeta_1,$$

然后做 M 轮外循环，每轮 J 步 leapfrog，步长与动量变换都由三层 MLP (Q_v, T_v, Q_y, T_y) 给出、可训练，每轮结束把速度 v_k 翻转，最后加一步布朗动力学输出

$$x \sim \mathcal{N}(y - \varepsilon_0 e^{\varepsilon_0 \eta} \nabla U(y), 2\varepsilon_0 e^{\varepsilon_0 \eta} I).$$

配置数字：内层步长 J 固定为 5；外层 M 按问题取 2（二维能量函数）、10（贝叶斯逻辑回归与 Ising）、100（Lennard-Jones）；末端布朗步的 ε_0 在 0.005 到 0.1 之间扫（步长 0.005），各任务的最佳值分别是二维问题 0.1、Ring 0.03、贝叶斯回归 0.05、Covertime 0.005、LJ13 0.03、LJ55 0.015、Ising 0.1。 ε_0 同时出现在均值与方差里，它的作用就是把解码密度 $\mathcal{V}_{p_D}(x | z_0)$ 变成一个能解析求值的表达式，从而能和 score 网络一起放进 $\mathcal{L}(\theta, \varphi)$ 训练。

11.5 贝叶斯逻辑回归与 Covertime：把采样当后验拟合

这组实验的任务是给定数据集的权重后验，看采样器给出的样本能不能支撑好的分类性能。AU（15 维协变量）、GE（25 维）、HE（14 维）按 4:1 划分并标准化，HMC 的步长取 0.01，每格 32 次运行报 Acc 与 AUC 的均值加减标准差。

方法	AU Acc	AU AUC	GE Acc	GE AUC	HE Acc	HE AUC
V-HMC	82.97 ± 1.94	90.88 ± 0.83	78.52 ± 0.48	77.67 ± 0.28	86.75 ± 1.63	93.35 ± 0.76
L2HMC	73.26 ± 1.56	79.69 ± 3.65	62.02 ± 4.19	60.23 ± 5.10	82.23 ± 2.81	90.48 ± 0.51
BG	82.99 ± 1.18	91.23 ± 0.67	78.14 ± 1.44	77.59 ± 0.73	86.75 ± 1.99	93.44 ± 0.39
PIS	81.64 ± 2.63	91.23 ± 0.67	71.90 ± 3.17	71.67 ± 4.52	83.24 ± 3.95	91.68 ± 2.78
EDG	84.96 ± 1.67	92.82 ± 0.69	79.40 ± 1.74	82.79 ± 1.46	88.02 ± 3.90	95.10 ± 1.23

三个数据集的名称是 Australian、German、Heart。六格里 EDG 全部最高，但优势大小差别很大：AU 上比第二名高 1.97 个百分点，HE 的 Acc 上比两个 HMC 类基线高 1.27 到 5.78 个百分点，而 GE 的 AUC 上比 BG 高 5.20 个百分点、比 V-HMC 高 5.12 个百分点。L2HMC 在 GE 上塌得最厉害（62.02），标准差也最大（± 4.19），说明它在这个后验上不稳定。

Covertime（581012 条、54 个特征，层级先验 $\alpha \sim \text{Gamma}(1, 0.01)$ ）是这组里差距最大的一格：EDG 的 Acc 是 70.13 ± 2.13，其余四种方法全部落在 49.88 到 51.51 之间。作者把这格归功于 minibatch 下无偏的 $\log \pi$ 估计，也就是把能量项按小批量拆分后仍能写进训练损失；HMC 一类的梯度方法在小批量下做不到这一点。

11.6 分子任务：LJ13 与 LJ55

势能取非周期形式加谐波约束，源码写作

$$U = \frac{1}{2} \sum_{i \neq j} \left[\left(\frac{1}{d_{i,j}} \right)^6 - \left(\frac{1}{d_{i,j}} \right)^{12} \right] + \frac{1}{2} \sum_i \|x_i - x_{\text{COM}}\|^2,$$

LJ13 维数 39、LJ55 维数 165。参考数据来自一条 1000 链、每链 10000 步、预热 200000 步的 MCMC。评价指标不是能量而是 **原子间距的密度曲线**，因为它直接反映构型是否物理。




图 22 LJ 任务上两个基线的偏离（论文 2401.02080 附录图）：L2HMC 与 PIS 生成的原子间距分布在双峰位置上都与参考数据有可见偏移，这是把“能量拟合得好”与“构型分布对”分开看的一个对照。

这一格的具体 MMD 数值在源码里是一张被注释掉的表（LJ13: L2HMC 1.34、BG 0.25、PIS 4.25、EDG 0.19；LJ55: 1.36、0.09、4.20、0.02），正文只保留了间距分布图。笔记按正文引用图，但把注释里的数字原样列出，读者应当知道它们没有进入正稿的比较结论。

重加权是否有效用 rESS 检查：

$$\text{rESS} = \left(\sum_i w_i \right)^2 / \left(N \sum_i w_i^2 \right),$$

这个量为什么能衡量权重的均匀程度，两步说清。Cauchy-Schwarz 不等式给 $\left(\sum_i w_i \right)^2 = \left(\sum_i w_i \cdot 1 \right)^2 \leq \left(\sum_i w_i^2 \right) \left(\sum_i 1 \right) = N \sum_i w_i^2$ ，所以 $0 < \text{rESS} \leq 1$ ，等号成立当且仅当所有 w_i 相等（完全均匀）；权重集中到少数样本时分子几乎不涨、分母照常累加，rESS 趋零。它同时给出“等效均匀样本数”的读法： $N \cdot \text{rESS}$ 。

256 个样本、10 个随机种子的结果：LJ13 上 BG 0.006 ± 0.002 、PIS 0.005 ± 0.001 、EDG 0.132 ± 0.048 ；LJ55 上 0.004、0.004、0.098。两个高维格子里 EDG 高出二十倍量级，但它仍然只有 0.1 上下，说明权重集中在少数样本上，重加权是可用而不富裕的手段。这里的 $p_E(z_0 | x)$ 由概率流 ODE 积分得到，求解器是 RK45，绝对与相对容差都是 10^{-5} 。

11.7 Ising：把配分函数下界当成绩

二维 16×16 自旋系统（ $d = 256$ ）走的是连续松弛：

$$\pi(x) \propto \exp \left(-\frac{1}{2} x^T (K + \alpha I)^{-1} x \right) \prod_i \cosh(x_i),$$

再从连续样本抽离散构型， $\pi(s | x) = \prod_i (1 + e^{-2s_i x_i})^{-1}$ 。这样做的用处是 $\log Z$ 有闭式分解， $\log Z = \log Z_{\text{Ising}} + \frac{1}{2} \ln \det(K + \alpha I) - \frac{N}{2} \left[\ln \left(\frac{2}{\pi} \right) - \alpha \right]$ ，于是可以拿“变分下界 $E[\log w]$ ”与别的估计器比大小。每个温度用 $n = 256$ 的一批样本估下界，误差按 $1/\sqrt{n}$ 折算：

温度 T	NeuralRG	PIS	EDG
2.0	260.24 ± 0.13	210.17 ± 0.43	270.32 ± 0.18
2.1	250.57	208.48	260.34
2.2	239.43	210.57	252.11
2.3	231.25	214.64	233.46
2.4	225.69	212.43	225.02

温度 T	NeuralRG	PIS	EDG
2.5	219.26	202.92	220.03
2.6	216.69	181.83	214.78
2.7	212.42	189.16	212.57

下界越高越好（它离真值更近）。EDG 在八个温度里六个更高， $T = 2.4$ 与 2.6 由 NeuralRG 拿到最好值；PIS 在整套温度上都低得多。论文另外给了一张层级结构对普通 MLP 的对照图：把 score 网络换成 MERA 式的层级网络（作者说它与 NeuralRG 同族，但不堆双射层）之后， $\log Z$ 下界随训练的曲线整体上移，这正是高维自旋系统里局部相关结构被网络表达出来的效果。




图 23 左：固定同一个潜变量 z_0 ，从 $T = 2.0$ 生成到 $T = 2.7$ 的自旋状态序列（论文 2401.02080 图 4），相变附近的磁化翻转出现在连续样本里。右：层级 score 网络与普通 MLP 的 $\log Z$ 下界曲线对照（ $T = 2.0$ ，附录图）。

11.8 时间与内存

训练时间上有两个方向的结论，作者没有把它们合并成一个“更快”的说法。比较在 MoG2 任务、批量 128、单卡 RTX 2080 Ti (11 GB) 上做：每轮迭代 EDG 比 BG 慢，但达到同样 MMD 所需的累计训练时间更短（左图的对数每轮时间、右图的 MMD 随累计时间曲线，评测时间不计入）。同一张表的内存占用列在这版源码里同样是被注释掉的，数字是 L2HMC 17.19 MB、BG 22.41 MB、PIS 55.83 MB、EDG 16.75 MB，参数量 9.2k、402.5k、37.8k、24.0k。PIS 的内存最高，与它训练时要解 SDE、存下整条轨迹的用法一致。重加权的成本是另一个量级：它要解 ODE 并估散度，所以 EDG 的采样加校准时间与 PIS 同量级、比 PIS 略慢，BG 因为 affine coupling 的 Jacobi 行列式解析，重加权几乎不增加计算量。这张“快在哪、慢在哪”的表在选型时比单看 MMD 更接近实际使用。




图 24 左：每轮时间与 MMD 随墙钟时间的变化（论文 2401.02080 附录图），EDG 起点慢、终点早。右：重加权阶段的耗时对照，需要解概率流 ODE 的方法在这里付出代价。

11.9 这一篇里还没做完的事

作者自己在结论里写了两条：LJ 这类分子系统里等变性被暂时忽略（下一步打算在 GHD 里换 EGNN、并把 score 网络做成等变的）；理论界的成立依赖训练时间无限与模型容量无限，作者说有限情形下的收敛保证“可以加强”。把这两条与前面 MoG2(i) 与 rESS 的数字放在一起看，EDG 的可靠边界比较清楚：中等

维数（几十到两百维）、能量面不太病态时它给出可用的样本与可观的 $\log Z$ 下界，再往上（真实蛋白质）还没有证据。




图 25 重加权的完整效果图（论文 2401.02080 图 6）：MoG2(i) 上能量直方图未加权（偏）与加权（贴合参考）的对照，以及加权 MMD 随样本数的下降曲线。正文报告的单个数字是 0.50 降到 0.09。

12 后继方法补充：推导、对照与画廊

12.1 EDG 补充一：为什么 subVP 的转移核解析可采样

解码过程要求 $p_D(z_t | z_0)$ 可直接采样（否则每步要数值积分 Fokker-Planck 方程，simulation-free 就不成立）。subVP 型 SDE

$$dz_t = -\frac{1}{2}\beta(t)z_t dt + \sqrt{\beta(t)}dW_t$$

是线性 SDE，条件转移是高斯：

$$z_t | z_0 \sim \mathcal{N}\left(e^{-\frac{1}{2}\int_0^t \beta(s) ds} z_0, \left(1 - e^{-\int_0^t \beta(s) ds}\right) \mathbf{I}\right).$$

推导完整写出。记 $\Lambda(t) = \int_0^t \beta(s) ds$ （累积系数，下面反复出现）。线性 SDE 的解有显式公式：对两边从 0 到 t 积分，套用一维线性 ODE 的常数变易法并补上噪声项，

$$z_t = e^{-\Lambda(t)/2} z_0 + \int_0^t e^{-(\Lambda(t)-\Lambda(s))/2} \sqrt{\beta(s)} dW_s,$$

读法：第一项是确定性部分的衰减，第二项把每个时刻的噪声 乘上“从它发生到 t 的衰减因子”后累加。这个公式直接给出后面要用的两条性质：随机积分的期望为零（被积函数与 W 适应且平方可积，随机积分的定义性质）；随机积分的二阶矩公式 $E\left[\left(\int h dW\right)^2\right] = \int \|h\|^2 ds$ 。

第一步：均值。 对解取期望，第二项期望为零：

$$E[z_t] = e^{-\Lambda(t)/2} z_0,$$

读法：均值按指数衰减，速度由 β 的累积量决定。

第二步：方差。 $\text{Var}[z_t] = E[z_t^2] - (E[z_t])^2$ 。 z_0 与随机积分独立（后者只含 $t > 0$ 的噪声增量），平方展开后的交叉项期望为零；对第二项用二阶矩公式（这里 $\|h\|^2 = e^{-(\Lambda(t)-\Lambda(s))} \beta(s)$ ）：

$$\text{Var}[z_t] = \int_0^t e^{-(\Lambda(t)-\Lambda(s))} \beta(s) ds.$$

第三步：算出这个积分。 链式法则给出 $d/ds[-(\Lambda(t) - \Lambda(s))] = \beta(s)$ ，所以被积函数可以收进一个导数： $e^{-(\Lambda(t)-\Lambda(s))} \beta(s) = d/ds e^{-(\Lambda(t)-\Lambda(s))}$ ，积分值等于原函数在两端的差： $e^0 - e^{-\Lambda(t)} = 1 - e^{-\Lambda(t)}$ 。于是

$$z_t | z_0 \sim \mathcal{N}\left(e^{-\frac{1}{2}\int_0^t \beta(s) ds} z_0, \left(1 - e^{-\int_0^t \beta(s) ds}\right) \mathbf{I}\right).$$

“方差保持”名字的来历在公式里直接可见： $t \rightarrow \infty$ 时 $e^{-\int_0^t \beta(s) ds} \rightarrow 0$ ，方差趋于 1，与先验 $\mathcal{N}(0, \mathbf{I})$ 一致。两个矩都解析，采样直接按公式来。 $\beta_{\min} = 0.1$ 、 $\beta_{\max} = 20$ 是标准配置。

用日常语言读一遍：这三步合起来干了什么 解码器每走一步都需要“从 z_0 出发 t 时刻后在哪里”的答案。这三步把答案从“解一个随机微分方程”降为“查一个高斯公式”：线性结构让解可以整条写出，期望和方差各自只剩一个能精确积分的式子。于是训练与采样全程不碰数值积分，这是 subVP 型 SDE 被选中的原因。

12.2 EDG 补充二：概率流 ODE 与密度计算

重加权需要算 $p_E(z_0 | x)$ ：编码过程的密度。score 网络除了定义逆时 SDE，还定义了一个**概率流 ODE**（同一密度的确定性表示）：

$$dz_t = \left(f(z_t, t) - \frac{1}{2}g(t)^2 s(z_t, x, t; \theta) \right) dt.$$

命题（概率流 ODE 的密度公式） 沿 ODE 的流映射 $z_T \mapsto z_0$ 改变密度的规则是连续性方程：

$$\log p_E(z_0 | x) = \log p_E(z_T | x) - \int_0^T \nabla \cdot F_\theta(z_t, t) dt,$$

$F_\theta = f - \frac{1}{2}g^2 s$ 是 ODE 的速度场。散度用 Hutchinson 估计器估计（随机向量 ε , $\nabla \cdot F \approx \varepsilon^T (\partial F / \partial z) \varepsilon$ ）。

证明. 第一步：连续性方程从质量守恒来。 取任意区域 Ω ，它里面的概率质量是 $\int_\Omega p(z, t) dz$ 。质量随时间变化的唯一途径是穿过边界流动：流出边界 $\partial\Omega$ 的总流量是 $\int_{\partial\Omega} pF \cdot n dA$ （ n 是单位外法向， $F \cdot n$ 是垂直于边界的速度分量）。于是 $d/dt \int_\Omega p dz = - \int_{\partial\Omega} pF \cdot n dA$ 。右端由散度定理换成体积分 $- \int_\Omega \nabla \cdot (pF) dz$ ，移项：

$$\frac{d}{dt} \int_\Omega p dz + \int_\Omega \nabla \cdot (pF) dz = 0.$$

这个等式对**每个**区域 Ω 成立，被积函数不逐点为零就能造出反例区域，所以 $\partial_t p + \nabla \cdot (pF) = 0$ 。这就是连续性方程，它的全部内容就是“概率质量既不凭空产生也不凭空消失”。

第二步：展开并除以 p 。 乘积法则给出 $\nabla \cdot (pF) = F \cdot \nabla p + p \nabla \cdot F$ ，方程变成 $\partial_t p + F \cdot \nabla p + p \nabla \cdot F = 0$ 。在密度为正处两边除以 p ： $\partial_t \log p + F \cdot \nabla \log p = -\nabla \cdot F$ 。

第三步：左端是沿轨迹的全导数。 ODE 的轨迹满足 $dz_t/dt = F(z_t, t)$ ，多元链式法则给出

$$\frac{d}{dt} \log p(z_t, t) = \partial_t \log p + (dz_t/dt) \cdot \nabla \log p = \partial_t \log p + F \cdot \nabla \log p,$$

正是第二步方程的左端。所以沿轨迹 $d \log p / dt = -\nabla \cdot F_\theta(z_t, t)$ ：密度的对数变化率等于速度场散度的负值。

第四步：沿轨迹积分。 从 T 积到 0（时间倒行）：

$$\log p_E(z_0 | x) - \log p_E(z_T | x) = \int_T^0 (-\nabla \cdot F) dt = - \int_0^T \nabla \cdot F_\theta(z_t, t) dt.$$

端点 $p_E(z_T)$ 已知：条件 (b) 说它与 $p_D(z_T)$ 重合，而 $p_D(z_T)$ 由转移核解析可得。□

散度项没法逐维求偏导再求和（维数高时代价是每步 d 次反向传播），实际用 Hutchinson 估计器。它为什么无偏，两步算完。记 $A = \partial F / \partial z$ ， ε 的分量独立地以等概率取 ± 1 （Rademacher 随机向量）：

$$E_{\varepsilon[\varepsilon^T A \varepsilon]} = E_{\varepsilon[\text{tr}(A \cdot \varepsilon \varepsilon^T)]} = \text{tr}(A \cdot E_{\varepsilon[\varepsilon \varepsilon^T]}) = \text{tr}(A) = \nabla \cdot F.$$

第一步：标量等于自己的迹，再用迹的循环性质把 ε 挪到一起；第二步：期望与迹都是线性运算，可以交换； $E[\varepsilon \varepsilon^T]$ 的第 i, j 元是 $E[\varepsilon_i \varepsilon_j] = \mathbf{1}\{i = j\}$ ，即单位矩阵。所以期望恰是 $\text{tr}(A) = \nabla \cdot F$ ，估计无偏，代价从 d 次偏导数降为一次雅可比向量积。

这套“采样走 SDE、密度走 ODE”的双表示是扩散模型的标准结构，EDG 把它用在潜空间而不是数据空间，于是数据空间的高维性（LJ55 的 165 维）不直接冲击散度估计的成本。




图 26 Ising 模型的连续松弛采样（论文 2401.02080）：固定潜变量 z_0 ，从温度 $T = 2.0$ 生成到 $T = 2.7$ 的状态序列。相变附近（磁化翻转）被自然捕捉；离散构型按 $\pi(s | x) = \prod_i (1 + e^{-2s_i x_i})^{-1}$ 从连续样本抽取。




图 27 左：重加权的效果（MoG2(i)）：能量直方图从未加权（偏差）修正到贴合目标，加权 MMD 从 0.50 降到 0.09。右：训练时间与 MMD 的对比：EDG 用更少时间达到更低 MMD。

12.3 FMRC 补充：误差链的完整叙述

主定理把 $\mathcal{L}^{\text{FMRC}}$ 与算子误差连起来，中间的链条值得完整走一遍：

$$\text{速度场误差 } \varepsilon^2 = \int_0^1 E[\|v_i^* - v_{i,\theta}\|^2] ds \Rightarrow W_2(\text{联合分布}) \leq \varepsilon e^{\int L_s ds} \Rightarrow \|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_H \leq \sqrt{\beta} \varepsilon e^{\int L_s ds}.$$

链条有两个箭头。第一个箭头在笔记内拆成三步走完；第二个箭头的两半各引一条已给出的引理（下一章砖一与砖四）。

第一个箭头：速度场误差到分布误差。 输入两条：训练收敛使速度场误差的平方平均不超过 ε^2 ；速度场对状态 L_s -Lipschitz。

1. **耦合两条轨迹。** 让全速度场与瓶颈速度场从同一个起点出发；把 X 分量的速度补一个零块， X 在两条轨迹里走成同一条线，偏差全部集中在 X_1 分量。记 $e(s) = \|Y^s - \hat{Y}^s\|$ ，求导、用三角不等式、再对速度差用 Lipschitz 条件：

$$\begin{aligned} de/ds &\leq \|v(s, Y^s) - v_{\theta}(s, \hat{Y}^s)\| \\ &= \|v(s, Y^s) - v_{\theta}(s, Y^s)\| + \|v_{\theta}(s, Y^s) - v_{\theta}(s, \hat{Y}^s)\| \\ &\leq \Delta_s + L_s e(s), \end{aligned}$$

第一行是三角不等式拆成“同一点的速度差”与“同一场里的状态差”两段；第二行第一段记作 Δ_s （两个速度场在同一点的差，平方沿时间的平均被 ε^2 控制，这是训练误差假设），第二段用 v_{θ} 的 Lipschitz 条件。

2. **解微分不等式（Gronwall）。** $e' \leq L_s e + \Delta_s$ 两边乘积分因子 $e^{-\int_0^s L_r dr}$ ，左边变成一个函数的导数；从 0 积到 1，再对起点取期望并沿 Δ 用 Cauchy-Schwarz：

$$\left(E[\|(X, X_1) - (X, \hat{X}_1)\|^2] \right)^{\frac{1}{2}} \leq \varepsilon \cdot e^{\int_0^1 L_s ds}.$$

读法：指数因子是 Lipschitz 常数沿路径的累积放大，流走得越远、对状态越敏感，同样的速度场误差被放得越大。

3. 认出 W_2 。左端是一条具体耦合的 L^2 代价； W_2 的定义是对一切耦合取下确界（下一章砖一给出定义式），下确界不超过任何一条具体的值，于是 $W_2((X, X_1), (X, \hat{X}_1)) \leq \varepsilon e^{\int L_s ds}$ 。

第二个箭头： W_2 到算子范数。 分两半。前半是 W_2 与 $\dot{H}^{-1}$ 范数的比较（Benamou–Brenier 线性化加 Loeper 型引理，即下一章砖一：密度有 β 倍体积支配时 $\|\mu - \nu\|_{\dot{H}^{-1}} \leq \sqrt{\beta} W_2(\mu, \nu)$ ； β 在这里进场，多峰分布峰间的低密度沟谷正是它可能失效的位置）。后半是“弱形式算子范数被联合密度的 $\dot{H}^{-1}$ 误差控制”，依据是算子范数的上确界只遍历 $g(x)h(y)$ 形状的测试函数，而 $\dot{H}^{-1}$ 范数遍历全部测试函数；逐步展开见下一章砖四。两个箭头接起来就是主定理的右端。

用日常语言读一遍：这条链保证了什么 它把“网络训练得好不好”翻译成“降维有没有丢信息”：速度场误差先被流的敏感性指数放大成两个联合分布的搬运距离，再被密度支配条件折算成算子的弱范数误差。每一环的方向都朝保守一侧，所以损失收敛就能保证算子误差收敛；代价全在常数里（指数因子与 $\sqrt{\beta}$ ），见下面的两个折扣。

读这条链时打两个折扣 一， $e^{\int L_s}$ 里的 Lipschitz 常数没有实用上界，理论意义是“形状正确”（误差确实随速度场误差消失）多于“数值精确”。二，第二段的密度上下界 β 在多峰分布处可能不成立（峰间密度低）。论文正稿只保留 H 范数结果，谱误差分析在源码里被注释掉，原因是论证不完备，这本身是值得学习的诚实处理。




图 28 FMRC 的数据构造与聚类检查（论文 2408.15981）。左：Swiss roll 映射把二维七井势的轨迹卷进三维（观测空间是非线性流形）。右：PCCA+ 聚类结果与各簇的 RC 值分布：簇内直方图窄、簇间间隙清晰。

12.4 UQ-SONet 与 LVM-GP 补充




图 29 VIDON + 深度集成的对照实验 (论文 2509.25646 附录): 均值预测准确, 但不确定度带系统性偏差: 多次独立训练的分歧没有覆盖真实的条件波动。这是“集成低估条件不确定度”在算子学习里的又一次出现。




图 30 左: 二维 Navier-Stokes (涡量-速度形式, $\nu = 0.001$): UQ-SONet 的均值误差 1.89 到 2.69 对 VIDON 的 5.98 到 8.74 ($\times 10^{-2}$), 置换不变嵌入在高维问题上的优势最明显。右: 随机椭圆方程 (算子本身随机) 在传感器数不同时的条件预测: 不确定度不随传感器加密消失: 算子内在随机性被潜变量保留。




图 31 LVM-GP 的编码器结构与先验自适应 (论文 2507.22493)。左: 确定性特征 $\bar{z}$ 、置信门 m 与 GP 先验 z_0 的插值结构 (与 IB-UQ 同构, 先验换成带空间相关的 GP)。右: GP 核长度尺度的训练曲线: 从初始 1.0 自适应收敛到 0.58, 先验自己学到了数据的相关长度。




图 32 左: 一维非线性 Poisson 反问题 (识别 $\lambda = 0.7$): 深度集成的解出现明显伪振荡, LVM-GP 与 HMC 平滑且贴近真值。右: 多孔介质流动问题三种方法的对照: LVM-GP 与 HMC 的不确定度带接近, 深度集成在高噪声下失效。

13 FMRC 深处: 算子误差、可计算准则与一次验证

FMRC 这一篇在四篇后继里最“数学”, 也最短。它把一个降维问题 写成两个条件密度模型的拟合问题, 再证明拟合损失控制算子误差; 实验只有一个七井势。这个配比决定了读法: 定理链条要逐步走完, 实验部分则要清楚它到底验证到了哪一步。

13.1 设定: 允许非平衡的转移算子

相空间 $\mathcal{X} \subset \mathbb{R}^D$ 带 Lebesgue 测度 λ 。给定 lag τ , 转移概率与转移密度

$$P_\tau(x, B) = \text{Prob}\{X_{t+\tau} \in B \mid X_t = x\}, \quad P_\tau(x, dy) = p_\tau(x, y)dy,$$

手上的数据是 lag- τ 的对 $\{(x_n, y_n)\}_{n=1}^N$, 其联合密度写成

$$\rho(x, y) = \rho_0(x)p_\tau(x, y), \quad \rho_1(y) = \int \rho_0(x)p_\tau(x, y)dx.$$

这里 ρ_0 与 ρ_1 允许不同, 也就是不假设过程处于平衡态。平衡是特例 $\rho_0 = \rho_1 = \pi$ 。为什么要费这个力气: 采样数据往往来自一段有限轨迹, 起点的分布并不等于不变测度, 按平衡假设写的理论在这样的数据上不成立。

两个算子分别按密度前传与观测量前传:

$$(\mathcal{T}_\tau u_t)(y) = \int \rho_0(x)/\rho_1(y)p_\tau(x,y)u_t(x)dx = E[u_t(X_t) | X_{t+\tau} = y],$$

$$(\mathcal{K}_\tau f)(x) = \int p_\tau(x,y)f(y)dy = E[f(X_{t+\tau}) | X_t = x],$$

前者是 Perron–Frobenius 算子，作用在 $L^1_{\rho_0} \rightarrow L^1_{\rho_1}$ ；后者是 Koopman 算子，在 L^∞ 上。作者特别指出与 Bittracher 等的定义差别：那里 Perron–Frobenius 是相对不变测度写的，这里相对经验初值测度 ρ_0 写。这一个改动决定了后面所有范数里出现的权重是 ρ_0, ρ_1 。

反应坐标 $r: \mathcal{X} \rightarrow \mathbb{R}^d$ ($d \ll D$, C^1)，水平集 $\Sigma_r(z)$ 是 $D-d$ 维子流形。

13.2 两个准则，以及它们为什么成对出现

lumpability (可归并) 存在 $p_\tau^L: \mathcal{Z} \times \mathcal{X} \rightarrow \mathbb{R}^+$ 使 $p_\tau(x,y) = p_\tau^L(r(x),y)$ 对所有 x,y 。同一个水平集 $r^{-1}(r(x))$ 里的所有点有完全相同的未来分布。

decomposability (可分解) 存在 $p_\tau^D: \mathcal{X} \times \mathcal{Z} \rightarrow \mathbb{R}^+$ 与 $p_{\text{local}}: \mathcal{Z} \times \mathcal{X} \rightarrow \mathbb{R}^+$ 使 $p_\tau(x,y) = p_\tau^D(x, r(y)) \cdot p_{\text{local}}(r(y), y)$ 。转移分两步：先用 p_τ^D 决定未来落在哪个水平集，再用只依赖目标集与目标点的 p_{local} 在集内定位。

两条不是同个性质的正反说法，它们各自管一半信息。lumpability 说“把过去压缩到 $r(x)$ 不丢预测未来的能力”；decomposability 说“未来状态可以由 $r(y)$ 加一层与过去无关的局部噪声生成”。只有两条同时成立， r 才是对动力学无损的坐标。

反向密度是 $p_{-\tau}(y,x) = \rho_0(x)p_\tau(x,y)/\rho_1(y)$ ，它是 Bayes 反演意义下的“从 y 回到 x ”的转移密度。论文用一条引理把 decomposability 换成反向的陈述：

引理（反向等价） p_τ 关于 r decomposable 当且仅当存在 $p_{-\tau}^D: \mathcal{Z} \times \mathcal{X} \rightarrow \mathbb{R}^+$ 使 $p_{-\tau}(y,x) = p_{-\tau}^D(r(y),x)$ 。

证明。必要性，分三步。 **第一步：代入反向密度的定义。** 反向密度是 Bayes 反演： $p_{-\tau}(y,x) = \rho_0(x)p_\tau(x,y)/\rho_1(y)$ （联合密度 $\rho(x,y) = \rho_0(x)p_\tau(x,y)$ 除以 y 的边缘）。代入 decomposability 的分解式：

$$p_{-\tau}(y,x) = (\rho_0(x)p_\tau^D(x, r(y))p_{\text{local}}(r(y), y))/\rho_1(y).$$

第二步：把分母算开。 按 ρ_1 的定义对 x 积分：

$$\rho_1(y) = \int \rho_0(x)p_\tau^D(x, r(y))p_{\text{local}}(r(y), y)dx = p_{\text{local}}(r(y), y) \cdot \int \rho_0(x)p_\tau^D(x, r(y))dx,$$

第二个等号的依据： $p_{\text{local}}(r(y), y)$ 不含积分变量 x ，提出积分号。这就是后文“分子里的 p_{local} 与归一化里的它相消”中 归一化里的那一份。

第三步：约分。 把第二步代回第一步， p_{local} 上下消去：

$$p_{-\tau}(y,x) = (\rho_0(x)p_\tau^D(x, r(y)))/\left(\int \rho_0(x)p_\tau^D(x, r(y))dx\right),$$

右端只通过 $r(y)$ 依赖 y ，把它取作 $p_{-\tau}^D(r(y),x)$ 即为所求（若分母还差一个只依赖 $r(y)$ 的常数因子，并进 $p_{-\tau}^D$ 的定义即可）。

充分性： 由 $p_{-\tau}^D(r(y),x)$ 反解 $p_\tau(x,y) = p_{-\tau}(y,x)\rho_1(y)/\rho_0(x) = [p_{-\tau}^D(r(y),x)/\int \rho_1(y)p_{-\tau}^D(r(y),x)dy]\rho_1(y)$ ，其中分母用了 $\int \rho_1(y)p_{-\tau}^D(r(y),x)dy = \rho_0(x)$ （把

$p_{-\tau}(y, x) = \rho_0(x)p_\tau(x, y)/\rho_1(y)$ 乘 $\rho_1(y)$ 后对 y 积分, 右端 $\rho_0(x) \int p_\tau(x, y)dy = \rho_0(x)$, 转移密度对 y 归一)。方括号里第一项只依赖 $(x, r(y))$, 取它为 $p_\tau^D(x, r(y))$; 剩下的 $\rho_1(y)$ 取为 p_{local} (p_{local} 的定义本就允许任意依赖目标点 y), 正好是 $p_\tau^D \cdot p_{\text{local}}$ 的形状。□

这条引理的用处是工程性的: 它说明做反向拟合时, 只要把反向速度场也瓶颈到 $r(y)$ 上, 就是在检验 decomposability。下一节的损失函数正是这样构造的。

把两个准则翻译成算子语言, 是论文给出的第二个等价:

降阶算子 $\hat{\mathcal{K}}_L h(x) = E[h(X_{t+\tau}) | r(X_t) = r(x)]$, $\hat{\mathcal{T}}_D h(x) = E[h(X_t) | r(X_{t+\tau}) = r(x)]$ 。

于是“无损”有第三种说法: $\hat{\mathcal{K}}_L = \mathcal{K}_\tau$ 等价于 lumpability, $\hat{\mathcal{T}}_D = \mathcal{T}_\tau$ 等价于 decomposability。这三种说法 (密度等式、反向密度等式、算子等式) 在论文里互为引理, 它们把“评价一个反应坐标”这件事变成“比较两个算子”。

13.3 最优性定理: 损失值就是坐标质量

flow matching 的部分按 rectified flow 写。虚拟时间 $s \in [0, 1]$, 插值路径 $Y^s = (1-s)Y^0 + sY^1$, 最优速度场是条件期望 $v^*(s, y) = E[Y^1 - Y^0 | Y^s = y]$, 生成靠解 ODE $dY^s/ds = v(s, Y^s)$, 训练损失是 $\int_0^1 E[\|v(s, Y^s) - (Y^1 - Y^0)\|^2] ds$ 。

论文同时拟合正向与反向两个条件密度。记 $X \sim \rho_0$ 、 $X_1 \sim p_\tau(X, \cdot)$ 、 $X' \sim \mathcal{N}(0, I)$ (用于反向传播的辅助高斯), 两个全速度场 $v_0, v_1: \mathbb{R} \times \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}^D$ 的最小化目标是 $\mathcal{L} = \mathcal{L}_0 + \mathcal{L}_1$, 其中

$$\mathcal{L}_0[v] = E[\|v(s, X_1^s, X) - (X_1 - X')\|^2],$$

$$\mathcal{L}_1[v] = E[\|v(s, X^s, X_1) - (X - X')\|^2],$$

第一项把第三个参数当“过去”, 拟合 $p_\tau(\cdot | X)$; 第二项把第三个参数当“未来”, 拟合反向密度。

瓶颈就是在第三个参数上做的: 把 X 换成 $r(X)$ 、 X_1 换成 $r(X_1)$, 得到 $\mathcal{L}^{\text{FMRC}}[v_0, v_1, r] = \mathcal{L}_0[v_0^{\text{RC}}(\cdot, \cdot, r(\cdot))] + \mathcal{L}_1[v_1^{\text{RC}}(\cdot, \cdot, r(\cdot))]$, 然后对 (r, v_0, v_1) 共享参数 θ 联合最小化。

定理 (最优性) 对给定的反应坐标 r ,

$$\min_{v_0^{\text{RC}}, v_1^{\text{RC}}} \mathcal{L}^{\text{FMRC}} \geq \min_{v_0, v_1} \mathcal{L}$$

, 且等号成立当且仅当 p_τ 关于 r 同时 lumpable 与 decomposable。

证明. 左边的可行集是右边可行集的子集 (任何只读 r 的速度场也是全速度场), 所以不等式平凡。

等号 $\Rightarrow$ 两准则成立: 取右端最优场 v_0^*, v_1^* 与左端瓶颈最优场 $v_0^{\text{RC},*}, v_1^{\text{RC},*}$ 。等号意味着两者几乎处处相等, 于是正向流 $dY^s/ds = v_0^*(s, \cdot, X)$ 的起点只通过 $r(X)$ 进入方程, 它诱导的密度可写成 $p_\tau^L(r(x), \cdot)$, 这正是 lumpability; 反向流同理给出 $p_{-\tau}^D(r(y), \cdot)$, 按上一条引理换成 decomposability。

两准则成立 $\Rightarrow$ 等号: lumpable 时 $E[X_1 - X' | X_1^s = y, X = x]$ 在固定 $r(x)$ 的水平集上是常数, 所以 $v_0^*(s, y, x) = v_0^*(s, y, r(x))$, 最优场本身就已经瓶颈化; decomposable 时对反向场做同样的论证。两者合起来, 瓶颈问题的最优值不小于全问题的最优值 (平凡方向) 又不大于它 (取到同一个场), 故相等。□

这个定理的实际含义是把“验证一个反应坐标”变成一次前向计算: 在固定的 r 上训到底, $\mathcal{L}^{\text{FMRC}}$ 的收敛值与全模型的收敛值之差 就是这个坐标的代价。它不需要真样本, 也不需要预先知道亚稳态划分。

13.4 误差链条的四块砖

最优性是定性的(等号何时成立), 定量版本要说“差一点等于损失值多大”。链条有四块, 每块都是一个引理。

砖一： W_2 与齐次 Sobolev 范数的比较。 在 Riemannian 流形 M 上 $W_2(\mu, \nu) = \inf_{\gamma \in \Pi(\mu, \nu)} [\int d(x, y)^2 d\gamma]^{1/2}$, 半范数 $\|f\|_{\dot{H}^1(m)} = (\int |\nabla f|^2 dm)^{1/2}$, 其对偶定义 $\|\nu\|_{\dot{H}^{-1}(m)} = \sup\{|\angle(f, \nu)| : \|g\|_{\dot{H}^1(m)} \leq 1\}$ 。Benamou–Brenier 线性化说 $W_2(\mu, \mu + d\mu) = \text{norm}(d\mu) \mid (H^{-1})(\mu) + o(d\mu)$ 。需要的引理 (Loeper 型): 若 $\mu, \nu \leq \beta \cdot \lambda$ (两个测度的密度都被 β 倍体积测度控制), 则

$$\|\mu - \nu\|_{\dot{H}^{-1}} \leq \sqrt{\beta} W_2(\mu, \nu).$$

方向要说清: 是 W_2 控制 $\dot{H}^{-1}$ 范数, 不是反过来。直觉是 $\dot{H}^{-1}$ 是“最粗的”输运度量之一, 把质量搬动一点点的代价在它下面被低估, 而 W_2 按距离计价。

砖二：速度场误差到分布误差。 若 $\int_0^1 E[\|v_0^{\text{RC},*}(s, X_1^s, X) - v_{0,\theta}^{\text{RC}}(s, X_1^s, X)\|^2] ds \leq \varepsilon^2$ 且 $v_{0,\theta}^{\text{RC}}$ 对 (y^s, x) 是 L_s -Lipschitz, 则联合律 (X, X_1) 与 $(X, \hat{X}_1)$ 之间的 W_2 不超过 $\varepsilon \cdot e^{\int_0^1 L_s ds}$ 。证明的做法是把速度场补一个零块, 让 X 分量不动, 然后套用 Benton–Deligiannidis–Doucet 的 flow matching 稳定性结果 (Gronwall 型: 路径误差随速度误差指数放大)。

砖三：镜像的一支。 对反向那半有同样的结论, 误差记 $\tilde{\varepsilon}$ 、Lipschitz 常数记 $\tilde{L}_s$, 控制 $(\hat{X}, X_1)$ 与 (X, X_1) 的 W_2 。论文对这一支只写了一句“证明同前, 略”。

砖四：密度误差到算子误差。 弱算子范数定义为

$$\|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_H = \sup \left\{ \angle(g, \mathcal{K}_\tau h - \hat{\mathcal{K}}_L h)_{\rho_0} : \|g\|_{H^1(\rho_0)} \leq 1, \|h\|_{H^1(\rho_1)} \leq 1 \right\},$$

把联合密度的 $\dot{H}^{-1}$ 误差限制在形如 $g(x)h(y)$ 的张量测试函数上, 正好就是上式。这个“正好”拆成三步:

1. **把算子作用写成对联合密度的配对。** Koopman 算子按密度前传: $(\mathcal{K}_\tau h)(x) = \int p_\tau(x, y)h(y)dy$ 。代入内积的定义:

$$\angle(g, \mathcal{K}_\tau h)_{\rho_0} = \int g(x) \left[\int p_\tau(x, y)h(y)dy \right] \rho_0(x)dx = \int \int g(x)h(y)\rho_0(x)p_\tau(x, y)dydx,$$

读法: 末端的被积对象是联合密度 $\rho(x, y) = \rho_0(x)p_\tau(x, y)$ 与测试函数 $g(x)h(y)$ 的乘积。

2. **两个算子相减, 认出密度差。** $\hat{\mathcal{K}}_L$ 同样按某个联合密度前传 (水平集内的平均, 对应密度 $\hat{\rho}$)。两个配对相减时 测试函数 gh 不变, 剩下的全部差别在被积的密度里: $\angle(g, (\mathcal{K}_\tau - \hat{\mathcal{K}}_L)h)_{\rho_0} = \angle(gh, \rho - \hat{\rho})$, 右端是联合密度差 $\delta\rho$ 对测试函数 gh 的作用。
3. **部分上确界不超过全上确界。** 算子范数的上确界只遍历 能写成 $g(x)h(y)$ 乘积形状的测试函数; $\dot{H}^{-1}$ 范数的上确界 遍历全部单位球测试函数, 张量积是其中的子集。子集上的最大读数不超过全集上的最大读数, 于是 $\|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_H \leq \|\rho - \hat{\rho}\|_{\dot{H}^{-1}}$ 。

于是主定理:

定理 (主定理) 在砖二、砖三成立且砖一的密度支配条件以常数 $\beta, \tilde{\beta}$ 成立时,

$$\|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_H \leq \sqrt{\beta} \cdot \varepsilon \cdot e^{\int_0^1 L_s ds},$$

$$\|\mathcal{T}_\tau - \hat{\mathcal{T}}_D\|_H \leq \sqrt{\tilde{\beta}} \cdot \tilde{\varepsilon} \cdot e^{\int_0^1 \tilde{L}_s ds}.$$

(源码里这一条的第二式在定理陈述处把 $\hat{\mathcal{T}}_D$ 写成了 $\hat{\mathcal{T}}_L$, 附录证明里用的是 D 。这是笔误, 不影响结论。)

这条链上真正强的与真正弱的部分 强的是形状：损失值（砖二的左端）确实直接进了算子误差的右端，中间没有“存在某常数使得”之类的非构造环节。弱的是常数： $e^{\int L_s}$ 里的 Lipschitz 常数在实践中拿不到上界；密度支配 β 要求联合密度不出现极低的沟谷，多峰系统里峰间的低密度区正是要跨的东西。所以这条链给的是“误差随损失消失”的定性保证，不能拿来给具体数值定界。

论文里还有第五块砖被整段注释掉了：平衡情形 ($\rho_0 = \rho_1 = \mu$) 下的 L_μ^2 误差界。它的思路是用连续性方程展开 $\delta f = f - \hat{f}$ ，把 $\text{norm } \delta v \leq \varepsilon_1^2$ 与 $\text{norm } \nabla \cdot \delta v \leq \varepsilon_2^2$ 代进 $u' \leq \alpha u + \beta$ 型微分不等式，再走 Gronwall，目标是 $\|\mathcal{K}_\tau - \hat{\mathcal{K}}_L\|_{\text{op}} \leq \text{norm} \cdot \text{HS}$ ，接上谱误差（引 Bittracher 等的引理 3.5）。附录里这段推导停在一个未完成的不等式 $\int_{\Omega_Y} \mu \nabla \cdot (v_X \delta f) dy \leq$ 上。正稿的取舍是：保留 H 范数那条完整链条，把没写完的谱误差留在注释里。

13.5 算法与它没说的事

训练循环六步，写得很具体：取小批量 $\{(x_b, y_b)\}_{b=1}^B$ ；抽 $x'_b, y'_b \sim \mathcal{N}(0, I)$ 与 $s \sim \mathcal{U}(0, 1)$ ；构造插值 $x_b^s = I(s, x'_b, x_b)$ 、 $y_b^s = I(s, y'_b, y_b)$ ；算

$$\hat{L} = \frac{1}{B} \sum_b \|v_0^{\text{RC}}(s, y_b^s, r_\theta(x_b)) - (y_b - y'_b)\|^2 + \frac{1}{B} \sum_b \|v_1^{\text{RC}}(s, x_b^s, r_\theta(y_b)) - (x_b - x'_b)\|^2$$

；随机梯度步 $\theta \leftarrow \theta - \eta \cdot \partial \hat{L} / \partial \theta$ ；重复到收敛。

有三处“没说”要如实记下。一，网络只写成多层感知机，没有层数、宽度、批量、迭代次数、学习率、求解器容差。二，推断阶段要生成样本就得解那两个 flow ODE，论文把它列为可行但没有实验。三，源码里瓶颈速度场的类型写成 $v_0^{\text{RC}}, v_1^{\text{RC}} : \mathbb{R} \times \mathbb{R}^D \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，值域应当是 $\mathbb{R}^D$ （要输出下一状态），是笔误。另外损失里没有散度项，也没有 Hutchinson 估计器；散度只出现在被注释掉的 L^2 推导里。

13.6 唯一的实验说明了什么，没说明什么

数据构造： $\mathbb{R}^3$ 上的过阻尼 Langevin $dX_t = -\nabla V(X_t)dt + \sqrt{2\beta^{-1}}dW_t$ ，势能

$$V(x_1, x_2, x_3) = V'(x_1, x_2) + 10x_3^2,$$

$$V'(x_1, x_2) = \cos(7 \cdot \arctan(x_2, x_1)) + 10\left(\sqrt{x_1^2 + x_2^2} - 1\right)^2,$$

也就是圆周上七个井，外加一个把 x_3 牢牢按在 0 附近的强约束，其平衡分布是 $\mathcal{N}(0, 0.05)$ ，混合时间远小于 (x_1, x_2) 方向。用 Euler-Maruyama 模拟，步长 $\Delta t = 0.001$ ，再套一个把平面卷成三维流形的 Swiss roll 映射，使观测空间中的线性降维注定失败。反应坐标维度取 $d = 1$ 。

验证方式是把学到的 $r(x)$ 投回二维平面看颜色分层，再用 PCCA+ 在投影数据上做亚稳态聚类，检查两件事：每个 PCCA+ 簇内的 RC 值分布是否窄，簇之间是否有间隙。




图 33 数据构造（论文 2408.15981 图 1 的两格）：左为圆周上七个井的势能面，右为加上 x_3 方向强约束后的三维采样点。真实动力学本身是二维的，三维只是被刻意“搅浑”的观测。




图 34 三步验证（论文 2408.15981）：左为平面投影上的聚类真值；中为学到的 $r(x)$ 着色在同一投影上，七口井各自连续成段；右为 PCCA+ 各簇内 RC 值的直方图，簇内窄、簇间有间隙。这正是 lumpability 的可视图证：同一簇（近似同一水平集）里的点有相似的未来，不同簇被 r 分开。

这篇没有的东西同样要说清：没有数值表格，没有与 TICA、VAMPnets、time-lagged 自编码器的定量对照，没有 alanine dipeptide 之类的真实分子数据，没有训练超参数，引用的补充材料文件不在源码包里。它给出的是一件结构性的事（损失与算子误差的可微联系）加一个演示。所以合理的使用方式是：把 $\mathcal{L}^{\text{FMRC}}$ 当成可优化的目标与可比较的坐标质量分数，把它的双向瓶颈结构当成设计模板，而不是把它的图示当成性能基准。




图 35 PCCA+ 亚稳态与 RC 的并置图 (论文 2408.15981 图 2b): 簇的边界与 RC 的间隙对齐。作者用的 PCCA+ 是事后聚类工具 (Roblitz-Schütte 版本), 不是模型的一部分。

13.7 它站的位置

往回看, Bittracher–Mollenhauer–Koltai–Schütte (2023) 给出了这两个准则 以及“满足准则即无损”的理论, 但他们的数值流程要估计并积分转移密度, 在高维上跑不动。FMRC 的贡献不在提出准则, 而在把准则改写成两个条件密度模型的拟合损失, 于是可以用 flow matching 的现成工具箱端到端训练, 顺手把“优化时也在评价”这两件事合成了一个目标。往前看, 它留下的空格也很清楚: 多峰低密度沟谷下的密度支配、 L^2 与谱误差那一支、以及任何意义上的定量基线比较。

14 UQ-SONet 的实现台: 算法、数据、超参与全部数值

主章节讲了结构和一个结论。这一章补齐复现需要的部分: 训练与推理各自用到网络的哪一半、解码器的方差为什么要乘 M 、数据与参照解怎么生成、超参与时间成本, 以及五个算例的全部数值表。最后一节记下源码里几处需要读者自己判断的书写问题。

14.1 算法把编码器和解码器分在了两侧

训练输入是 N 对 $\{(\kappa_i, u_i)\}$ 、允许的传感器数集合 $\mathcal{M} \subset \mathbb{Z}^+$ 、输出函数在固定网格 $\{y_j\}_{j=1}^M$ 上的取值 $\bar{u}_i = \{u_i(y_j)\}_{j=1}^M$, 以及批大小 B 。八个网络部件同时初始化: 嵌入用的 Λ_x 、 Λ_κ 与 H 个头的 w_l 、 v_l , 解码器的 p 对 b^n 、 t^n , 编码器的 μ_z 、 Σ_z 。

每一步训练做的事: 采一个批; 在批内随机选一个 $m \in \mathcal{M}$, 为批内每个样本随机采 m 个传感器位置并读出 κ 的值; 过嵌入得 $h(\mathcal{O}_i)$; 从编码器采 $z_i \sim q_E(z \mid \mathcal{O}_i, \bar{u}_i)$ (重参数化); 算损失估计

$$\hat{\mathcal{L}} = \frac{1}{2B} \sum_{i=1}^B \left[-\log |\Sigma_z| + \text{tr}(\Sigma_z) + \|\mu_z\|^2 - d_z \right] + \frac{1}{2BM\sigma_u^2} \sum_{i=1}^B \sum_{j=1}^M \left(\hat{g}(h(\mathcal{O}_i), z_i)(y_j) - u(y_j) \right)^2,$$

第一项为什么是这个形状: 方括号内是 $\text{KL}(q_E(z \mid \cdot) \parallel \mathcal{N}(0, \mathbf{I}))$ 一对角高斯的解析式。按 KL 的定义写对数密度差, 逐步算:

$$\begin{aligned}\text{KL} &= E_{q[\log q(z) - \log p(z)]} = E_q[-\frac{1}{2} \log |\Sigma| - \frac{1}{2} (z - \mu)^T \Sigma^{-1} (z - \mu) + \frac{1}{2} z^T z] - d_z/2 \\ &= \frac{1}{2} [\text{tr}(\Sigma) + \|\mu\|^2 - d_z - \log |\Sigma|],\end{aligned}$$

三块的出处：第一个期望里的二次型用期望的线性拆开， $E[(z - \mu)^T \Sigma^{-1} (z - \mu)] = \text{tr}(\Sigma^{-1} \cdot E[(z - \mu)(z - \mu)^T]) = \text{tr}(I) = d_z$ （协方差的定义加迹的循环性质）； $E[z^T z] = \text{tr}(\Sigma) + \|\mu\|^2$ （ $E[z z^T] = \Sigma + \mu \mu^T$ ，分解成方差加均值的平方）； $-d_z/2$ 与 $-\frac{1}{2} \log |\Sigma|$ 是两个归一化常数相减的残余（ $\frac{1}{2} \log(2\pi)$ 的项相消）。期望与积分交换的合法性由高斯密度平方可积保证。除以 $2B$ 是批平均， z_i 用重参数化采样。其中 μ_z 、 Σ_z 都带自变量 $(h(\mathcal{O}_i), \bar{u}_i)$ 。之后 Adam 更新全部参数。

推断只有四步：算 $h(\mathcal{O})$ ，从先验 $z \sim \mathcal{N}(0, I)$ 采样，前向 $\hat{g}(h(\mathcal{O}), z)$ ，重复多次后统计条件分布的量。编码器在测试时完全不出现。这个分工值得说清：模型给出的条件分布不是某个后验的样本，而是“先验驱动、训练时被 KL 项塑形”的生成器。 $D_{\text{KL}}(q_E \parallel p(z))$ 把每个观测下的后验压向标准高斯，压得越紧，先验采样覆盖到的范围就越接近后验覆盖的范围；压得太紧则 z 失去表达力，条件分布退化。 σ_u^2 与 d_z 是这条权衡上的两个旋钮。




图 36 潜变量维度、训练样本数与传感器数的影响（论文 2509.25646 图 2）。(a) W_2 距离随潜变量维度： $m=3$ 与 $m=5$ 两条，维度到 10 之后趋于平稳，后续实验因此固定 $d_z=10$ 。(b) 相对 L_2 误差随训练样本数， $m=3$ 、 $m=5$ 分开，样本越多误差越小，取 10^4 作为折中。(c) 预测标准差的均值随传感器数 m 下降并逼近参照值（图中逐点标注 0.070、0.070、0.069、0.064、0.058、0.048、0.047），这就是主章节说的“带随 m 收缩”。五个独立实验的平均，误差棒为跨实验波动。

14.2 方差乘 M ：从离散损失到函数空间损失

解码器写成 M 个网格点上条件独立的高斯乘积，每点方差取 $M\sigma_u^2$ ：

$$p_D(\bar{u} \mid \mathcal{O}, z) = \prod_{i=1}^M \mathcal{N}(u(y_i) \mid \hat{g}(y_i), M\sigma_u^2).$$

“代进 ELBO 后”这一步补出中间行。ELBO 的似然项取对网格点的求和，逐点写出对数密度再合并：

$$\sum_{i=1}^M \log \mathcal{N}(u(y_i) \mid \hat{g}(y_i), M\sigma_u^2) = -\frac{M}{2} \log(2\pi M\sigma_u^2) - \frac{1}{2M\sigma_u^2} \sum_{i=1}^M (\hat{g}(y_i) - u(y_i))^2.$$

第二步把平方项重排： $\frac{1}{2M\sigma_u^2}\Sigma = \frac{1}{2\sigma_u^2} \cdot (\frac{1}{M})\Sigma$ ，网格点的平均恰好消掉分母里的 M ，于是含预测值 $\hat{\mathcal{G}}$ 的数据项与网格数无关；第一项不含任何网络输出，对优化是常数（ σ_u^2 在实验里按表固定）。乘 M 是为了让 $M \rightarrow \infty$ 时损失不塌不爆，它换来的是一条与离散化无关的解释。附录 A.3 把这件事做严：按 Seidman 等的函数空间 VAE（其定理 4.1 与式 (9)），在 $\Omega_u \subset \mathbb{R}^{d_y}$ 上定义解码输出 $u_\sigma = \frac{u}{\sigma} = \frac{\widehat{\mathcal{G}(h,z)}}{\sigma} + \eta$ ， $\eta \sim \mathbb{V}$ 是 Ω_u 上的高斯测度，编码器为 $z \mid \mathcal{O}, u \sim \mathcal{N}(\mu_z(h, u), \Sigma_z(h, u))$ ，则

$$\mathcal{L}_f = E[\text{KL}(Q_{z|u} \parallel \mathcal{N}(0, I))] + \frac{1}{2\sigma^2} E\left[\left\|\widehat{\mathcal{G}(h, z)} - u\right\|_{L^2}^2\right] + \text{const},$$

网格均匀且 M 足够大时 $(\frac{1}{M})\sum_i (\hat{\mathcal{G}}(y_i) - u(y_i))^2 \approx \frac{\|\hat{\mathcal{G}} - u\|_{L^2}^2}{|\Omega_u|}$ ，与上式逐项比对，取

$$\sigma = \sqrt{|\Omega_u|}\sigma_u$$

就得到“ $\mathcal{L}$ 是 $\mathcal{L}_f$ 的离散近似”。结论是 σ_u^2 的身份：它不是观测噪声方差，而是函数空间高斯测度的尺度参数，数值上等于把 L^2 误差换算成逐点似然时的换算系数。 $\frac{1}{2\sigma_u^2}$ 因此同时充当“数据项对 KL 项的权重”，它与 β 类正则系数是同一个角色，只是藏在高斯密度里。

14.3 数据怎么生成，参照解怎么算

一维扩散方程 $-\frac{1}{10}(ku_x)_x = f$ 在 $[-1, 1]$ 、 $u(+1) = 0$ ， $f = 2\sin(2\pi x)$ ，要学的算子是 $k \mapsto u$ 。为保证 $k > 0$ ，抽样对象是 $\log k$ ：

$$\log k \sim \text{GP}(\mu(x), \sigma^2 \exp(-(x - x')^2/l^2)),$$

$\mu(x) = \sin(2\pi x)$ ， $\sigma = 0.5$ ， $l = 0.1$ 。每条实现记在 401 个等距点上，二阶有限差分解出 u ，共 $N = 10^4$ 对；训练时输出只取 101 个均匀点。

参照解（附录 A.2）走的是另一条路：把 $\log k$ 当高斯场，对给定的 m 个观测做 GP 后验条件化（无噪时 $K(x_{\text{obs}}, x_{\text{obs}})^{-1}$ ，有噪时换成加 $\sigma^2 I$ 的版本），每套观测采 1000 个后验样本，逐个解有限差分，得到参照均值场与参照标准差场。附录里明确写了：模型吃的是 k 的观测，参照解条件在 $\log k$ 上。这也让乘性噪声实验自治：观测取 $k(x) \cdot e^{\varepsilon(x)}$ ， $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 空间独立，取对数后就是 $\log k$ 上的加性噪声，正好落进加噪后验公式，参照解仍是精确的那个分布，而不是近似。

二维与 Navier-Stokes 算例的生成细节：

项	二维 Poisson	二维随机椭圆	Navier-Stokes
方程	$-\frac{1}{10}\Delta u = f$, $[0, 1]^2$	$-\nabla \cdot (k\nabla u) = f$, $[0, 1]^2$	涡量-速度形式，周期边界
输入场先验	$f \sim \text{GP}$, $\mu = 4(\sin 2\pi x + \sin 2\pi y)$, $l_1 = l_2 = 0.1$	$\log k$ 零均值、 f 均值同上， $l_1 = l_2 = 0.1$	$w_0 = x^{\frac{1}{3}}(1-x)^{\frac{1}{3}}y^{\frac{1}{3}}(1-y)^{\frac{1}{3}}h$, h 零均值 GP, $l = 0.1$
训练对数	8×10^4	同二维 Poisson	$4 \times 2 \times 10^4$ （四批）
求解	二阶有限差分， 101×101	中心差分， 101×101	流函数 + 伪谱， 100×100
训练观测网格	51×51	51×51	50×50
预测网格	101×101	101×101	100×100
传感器位置	正则空间聚类	同左	同左
$\mathcal{M}$	1, 2, 3, 4	1, 2, 3, 4	1, 2, 3, 4
迭代数	2×10^4	5×10^4	5×10^4

二维算例的传感器放置值得单独说：它不是均匀随机撒点，而是对 $[0.1, 0.9]^2$ 内的 81×81 均匀网格随机置换后用 PyEMMA 的 `coordinates.cluster_regspace` 做正则空间聚类，强制最小间距 $d_{\min} = 0.8$ （两个传感器时）与 0.5（三或四个时）。这样采出的集合覆盖均匀又不会两点重叠， $\mathcal{M}$ 只到 4，是“极少观测下还

能不能给出合理条件分布”的压力测试。一维算例的 $\mathcal{M} = \{1, \dots, 10\}$ ，训练集均分成 10 批、每批 1000 个样本，每批绑定一个 m ，预生成 10 批后每次迭代随机挑一批。

所有算例都套了硬边界条件（Lu 等的构造）：一维 $u(x) = (1-x)(1+x)u_\theta(x)$ ，二维 $u(x,y) = x(1-x)y(1-y)u_\theta(x,y)$ ， u_θ 是网络的无约束输出。齐次 Dirichlet 条件因此不是学出来的，是构造时焊死的。评估时看到的误差里不含边界违反。

14.4 超参与成本

算例	嵌入网络	注意力	branch / trunk / encoder	截断维 p	d_z	d_{emb}	σ_u^2	学习率
一维 PDE	2×40	4×32	4×64	100	10	2	10^{-3}	10^{-4}
一维 SDE	2×40	4×32	4×64	100	10	2	10^{-4}	10^{-4}
二维 PDE/SDE/NS	4×40	4×64	4×128	100	100	3	10^{-4}	10^{-4}

表里 2×40 表示两层、每层 40 个神经元，激活函数全用 tanh。三处细节。第一， d_{emb} 只有 2（一维）和 3（二维），注意力 softmax 是在 2 到 3 维的嵌入上算的，嵌入维度比 Deep Sets 类工作里常见的 64、128 小两个量级。第二， d_z 从一维的 10 跳到二维的 100，而图 2(a) 只说明一维问题 10 够用，二维没有做同样的扫描。第三，VIDON 基线用的是同一套网络结构与超参（附录 A.1 明说），所以下面的对比不含“我们调过参、对手没调”的成分。

	4.1 VIDON	4.1 UQ-SONet	4.2 VIDON	4.2 UQ-SONet	4.3	4.4	4.5
训练（小时）	5.24	6.03	4.04	4.37	6.01	11.34	10.32
推断（秒）	0.025	0.030	0.012	0.028	0.031	0.029	0.026

全部计时在 NVIDIA GeForce RTX 3090 上完成。训练侧多出的 0.33 到 0.79 小时是编码器的开销；推断侧 4.1 从 0.025 到 0.030 秒、4.2 从 0.012 到 0.028 秒，差值来自潜变量采样与统计量计算，单次前向本身几乎等价。4.4（二维随机）与 4.5（Navier-Stokes）的训练时间 11.34 与 10.32 小时是这套框架的成本上限，且没有 VIDON 的对照列。

14.5 数值表

一维扩散，固定 m 变位置（表 2，五个独立实验，数值 $\times 10^{-2}$ ）：

m	VIDON 均值	UQ-SONet 均值	UQ-SONet 标准差	m	VIDON 均值	UQ-SONet 标准差
1	5.35 ± 0.15	4.47 ± 0.83	8.77 ± 0.86	6	7.14 ± 0.40	8.74 ± 0.58
2	5.64 ± 0.99	4.62 ± 0.54	8.73 ± 0.49	7	8.73 ± 1.03	8.95 ± 0.52
3	6.17 ± 0.91	4.81 ± 0.37	8.57 ± 0.53	8	6.36 ± 0.59	7.68 ± 0.55
4	6.98 ± 0.80	5.52 ± 0.80	7.79 ± 0.85	9	7.92 ± 0.61	8.09 ± 0.44
5	5.41 ± 0.79	5.40 ± 0.26	8.48 ± 0.45	10	7.10 ± 1.16	8.35 ± 0.38

（源码这张表的 UQ-SONet 两列表头都写成 $\text{err}_{E[u]}$ ，按数据顺序第二列应是 $\text{err}_{\sigma[u]}$ ，这里按修正后的读法列出。）

两个读出。均值误差随 m 缓慢上升：UQ-SONet 从 4.47 到 5.97，VIDON 从 5.35 到 7.10，两列同向。这与图 2(c) 的“带随 m 收缩”不矛盾：表里量的是预测矩与参照矩的相对偏差，图里量的是带宽本身。传感器变多让预测更锐，锐化的同时并不自动让均值更贴近参照均值。标准差误差 7.68 到 8.95，没有随 m 改善的趋势，说明模型学到的带宽形状与参照带宽仍有约 8% 的系统性相对偏差。

乘性观测噪声下的鲁棒性（表 3， $\times 10^{-2}$ ）：

σ	$m = 3$ 均值	$m = 3$ 标准差	$m = 7$ 均值	$m = 7$ 标准差
----------	------------	-------------	------------	-------------

0.1	6.77 ± 1.17	9.43 ± 0.48	7.49 ± 0.95	9.67 ± 0.32
0.3	7.06 ± 1.73	9.46 ± 0.46	7.08 ± 1.71	9.31 ± 0.75
0.5	6.69 ± 0.65	9.07 ± 0.47	6.04 ± 0.67	9.02 ± 0.42
0.7	7.16 ± 0.45	8.90 ± 0.71	7.11 ± 1.48	9.35 ± 0.80
1.0	6.58 ± 1.03	9.20 ± 1.07	6.50 ± 0.69	7.52 ± 0.35

十个噪声级到 $\sigma = 1.0$ （观测被 e^ε 污染， ε 的标准差与信号同量级）为止，误差曲线是平的：均值列在 6.0 到 7.5 之间无趋势，标准差列在 7.5 到 9.7 之间。这张表是“观测被污染时条件分布仍然诚实”的最直接证据，因为参照解在 $\log$ 域是精确后验。

二维 Poisson（表 4，三个独立实验， $\times 10^{-2}$ ）：

m	VIDON 无噪	无噪均值	无噪标准差	$\sigma = 0.5$ 均值	$\sigma = 0.5$ 标准差	$\sigma = 1.0$ 均值	$\sigma = 1.0$ 标准差
1	3.26 ± 0.19	4.00 ± 0.35	9.46 ± 0.28	3.40 ± 0.60	9.22 ± 0.60	3.40 ± 0.52	8.66 ± 0.37
2	4.67 ± 0.24	4.83 ± 0.01	8.75 ± 0.43	3.86 ± 0.30	8.30 ± 0.81	3.40 ± 0.17	8.79 ± 0.26
3	5.99 ± 0.88	5.92 ± 0.30	9.18 ± 0.05	4.53 ± 0.22	8.61 ± 0.22	4.16 ± 0.41	7.49 ± 0.03
4	7.01 ± 1.15	5.48 ± 0.16	9.37 ± 0.01	5.03 ± 0.15	8.01 ± 0.26	5.54 ± 0.53	7.27 ± 0.21

加噪列不比无噪列差， $m = 1, 2, 3$ 时甚至更好（ $m = 1$ ：4.00 对 3.40）。合理解释是噪声相当于对极少传感器观测做了随机正则，而参照解在加噪时也用了对应的加噪后验，两边口径一致。 $m = 4$ 时反过来（5.48 对 5.54），差距在标准差范围内。这张表只有 10 个测试函数对、三次重复，读趋势可以，读小数点后一位不行。

随机算子的两个算例：

m	1	2	3	4	5	6	7	8	9	10
一维 SDE 均值	1.76	1.79	2.29	2.04	2.37	2.16	2.38	2.45	2.34	2.40
一维 SDE 标准差	3.94	3.90	4.54	3.61	5.12	4.58	5.54	4.61	5.66	4.58

（表 5 的 $\pm$ 值在 0.12 到 0.75 之间，这里只列均值， $\times 10^{-2}$ ，五个独立实验。）一维随机算例的误差比确定性版本低一档（均值 1.76 到 2.45 对 4.47 到 5.97）。原因是分母：随机算例的参照场本身带大面积不确定度， $|E[u]|$ 的范数更大，相对误差自然被压低。跨算例比较这两个数没有意义，算例内比较 m 才有。

二维随机算例按四个物理位置分别报告（表 6， $\times 10^{-2}$ ，三次实验）：

m	$x = 0.5$ 均值	$x = 0.5$ 标准差	$y = 0.5$ 均值	$y = 0.5$ 标准差	$x = 0.7$ 均值	$x = 0.7$ 标准差	$y = 0.7$ 均值	$y = 0.7$ 标准差
1	4.23	8.09	3.91	6.92	3.23	8.11	3.23	7.61
2	7.57	8.13	5.98	7.83	4.85	8.25	4.44	6.95
3	6.92	7.26	7.45	7.57	4.72	6.52	4.25	6.96
4	7.13	8.50	6.47	8.13	4.51	7.02	4.21	7.48

$x = 0.7$ 与 $y = 0.7$ 两列稳定低于 $x = 0.5$ 、 $y = 0.5$ 两列（4.2 到 4.9 对 3.2 到 7.6）。源项均值 $4(\sin 2\pi x + \sin 2\pi y)$ 在 0.5 处过零、在 0.7 处接近极值，参照场的相对结构在这两处不同，误差的差别大概率来自这里，论文没有给解释。

Navier–Stokes（表 7， $\times 10^{-2}$ ，三次实验）是差距最大的算例：

m	VIDON 均值	UQ-SONet 均值	UQ-SONet 标准差
-----	----------	-------------	--------------

1	6.01 ± 0.64	2.35 ± 1.03	7.32 ± 1.08
2	5.98 ± 0.36	1.89 ± 0.60	7.02 ± 0.78
3	8.74 ± 0.78	2.55 ± 0.46	6.25 ± 0.54
4	8.08 ± 0.75	2.69 ± 0.38	6.52 ± 0.25

$T = 10$ 的涡量场预测上 UQ-SONet 的均值误差是 VIDON 的三分之一到四分之一，且随 m 增大没有恶化。时间依赖算子把置换不变嵌入的价值放大得最明显：初值场在 100×100 上，观测只有 1 到 4 个点，此时“把观测集合当集合处理”与“把观测插值到固定网格”是两种不同的偏置。




图 37 左：乘性噪声下的条件预测（论文 2509.25646 图 3），上排 3 个传感器、下排 7 个，左列 $\epsilon \sim \mathcal{N}(0, 0.5^2)$ 、右列 1.0^2 ；红点是污染后的观测。右：二维 Poisson 的六联图（图 4），四个传感器加 $\mathcal{N}(0, 1.0^2)$ 噪声，上排参照均值、预测均值、绝对误差，下排对应的标准差。

14.6 指标口径与没测的东西

W_2 按标准定义写在 Polish 空间 (M, d) 上：

$$W_2(\mu, \nu) = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x_1, x_2)^2 d\gamma \right)^{\frac{1}{2}},$$

另外两个是均值与标准差的相对 L_2 误差 $\text{err}_{E[u]} = \frac{\|E[u] - E_{\theta[u]}\|_2}{\|E[u]\|_2}$ ， $\text{err}_{\sigma[u]}$ 同形，参照量由条件 GP 后验给出。注意 W_2 只在图 2(a) 里用来选 d_x ，五个算例的表全部是相对 L_2 。

没测的东西和测了的同样重要：

- 没有覆盖率、PICP、ACE 或 NLL 一类的校准指标。表里的“标准差误差”是带宽的相对偏差，不是校准质量：一个整体偏窄 8% 的带与一个偏宽 8% 的带在这张表里同分。
- 测试集只有 10 个输入-输出函数对（一维与二维都是），五个或三次重复平均的是训练随机性，不是测试集抽样随机性。
- 没有“未见传感器数”的泛化测试：训练与测试都从同一个 $\mathcal{M}$ 里取 m ，置换不变带来的变长能力只被“批间切换 m ”用到，没有检验模型在 $m \cap \in \mathcal{M}$ 上的行为。
- 没有噪声水平外推：训练与测试用同一个噪声级。
- 深度集成基线（附录 A.4）的结论是均值准、带系统性偏窄，但没有给数值表，只有图。

14.7 源码里几处需要留意的书写

读 2509.25646 源码时的对表

- 表 2 的表头把 UQ-SONet 的两列都标成 $\text{err}_{E[u]}$ ，按数据排布第二列是 $\text{err}_{\sigma[u]}$ 。表 4、表 6、表 7 的表头没有这个问题。
- 二维 GP 的协方差写作 $\exp\left[-\frac{x-x'}{2l_1^2} + -(y-y')^2/(2l_2^2)\right]$ ：第一项缺平方、两项用加号连接。按上下文与一维式对照，应是可分离核 $\exp\left(-\frac{(x-x')^2}{2l_1^2}\right) \cdot \exp\left(-\frac{(y-y')^2}{2l_2^2}\right)$ 。

- 附录 A.3 的推导里有一句 “where can be interpreted as a generalization of the inner product”，被解释的对象（带波浪号的配对记号）在源码中丢失了。
- 正文把 p_D 的方差说成“人工噪声”， σ_u^2 又出现在损失里当数据项权重，两处是同一个符号；Remark 3.1 与附录 A.3 才交代它的函数空间身份。
- 表 A.5（成本）只给 4.1、4.2 两个算例的 VIDON 时间，4.3 到 4.5 没有基线列。

15 LVM-GP 的实现台：门控、正则与六个算例的数字

主章节讲了“把 IB-UQ 的先验换成高斯过程”这一句。这一章把它展开成可以照着搭的规格：编码器的两个部件各自约束什么、解码器的积分核怎么归一、正则项从独立版改到相关版时解析式长什么样（以及一处需要读者自己判断的地方）、GP 求导的两条路、全部超参与基线配置，最后是六个算例的完整数字。

15.1 编码器：一个门控，一个带空间相关的先验

$$z(x; \theta_E) = \text{diag}(m(x; \theta_m)) \bar{z}(x; \theta_z) + \text{diag}(1 - m(x; \theta_m)) z_0,$$

$$z_0 \sim \text{GP}(0, K(x, x'))$$

， $K(x, x') = \sigma_K^2 \exp(-\|x - x'\|^2 / (2l^2)) \mathbf{I}_{d_x}$ ，各分量独立、共用同一个标量核， σ_K 固定为 1。 m 的每个分量取值在 $[0, 1]$ 。对固定 x 求出的边际是

$$q_E(z | x) \sim \mathcal{N}(m(x) \bar{z}(x), \text{diag}((1 - m(x))^2)),$$

所以 $\text{Var}(z(x)) = (1 - m(x))^2$ ，门控本身就是方差参数。 $m \rightarrow 1$ 时潜变量退化成确定性特征， $m \rightarrow 0$ 时完全由 GP 先验给出，而 GP 先验带空间相关，这正是标准高斯潜变量给不了的。

源码里 m 的两种说法 式 (6) 后面一句写“ $m(x; \theta_m)$ 是可解释为 x 远离训练数据分布的概率”，紧接着的下一句写“ $m(x) = 1$ 意味着 x 靠近某个训练数据、 z 成为确定性潜表示”。两句话对 m 的取向是反的。方差式 $(1 - m)^2$ 与后一句一致，与图里的行为（数据密集处带窄、边界与外推处带宽）也一致，本笔记按后一句读。

15.2 解码器：归一化的高斯核积分，以及一条“噪声不求导”的假设

潜随机场先由 L 层积分算子处理（ z_1 就是上面的 z ， $\omega_E \sim \mathcal{N}(0, \mathbf{I}_M)$ 提供 GP 的实现抽样）：

$$z_i(x, \omega_E) = \sigma \left(W_i z_{i-1} + b_i + \int_{\Omega} k_i(x, x') z_{i-1}(x', \omega_E) dx' \right), \quad i = 2, \dots, L-1,$$

$$z_L(x, \omega_E) = W_L z_{L-1}(x, \omega_E) + b_L,$$

核取位置变换核（Positional Transformer kernel）

$$k_i(x, x') = \exp(-\alpha_i \|x - x'\|^2) / \int_{\Omega} \exp(-\alpha_i \|x - y\|^2) dy \cdot V_i,$$

分母把核在 Ω 上归一，于是积分项是上一层特征的加权平均而不是加权求和，尺度不随域的大小漂移； $\alpha_i > 0$ 由 $\alpha_i = \tan(\tilde{\alpha}_i)$ 、 $0 < \tilde{\alpha}_i < \pi/2$ 参数化。输出 $\mu_u := z_L$ ，解本身写成条件高斯 $u(x, \omega_u) = \mu_u + \sigma_u(x) \omega_D$ 。

三处设计要单独记。

第一，噪声不参与求导。 论文假设 $\sigma_u(x; \theta_\sigma)$ 不对 x 微分，于是 PDE 残差 $\mathcal{N}_{\text{bold}}(x)[u] = \mathcal{N}_{\text{bold}}(x)[\mu_u]$ ，自动微分只作用在均值上。好处是残差项不必穿过随机变量；代价是残差对噪声场的空间结构完全没有梯度， σ_u 只能靠数据似然项去学。

第二, f 与 b 的均值不是独立网络。 $\mu_f = \mathcal{N}_{\text{bold}}(x)[\mu_u]$ 、 $\mu_b = \mathcal{B}_{\text{bold}}(x)[\mu_u]$, 再各加自己的 aleatoric 项。物理一致性焊在均值表达式里, 不是罚在损失里, 所以“ f 的预测与 u 的预测是否满足方程”这个问题在这个架构下恒成立。三份数据似然共享同一次前向。

第三, 积分算子可换。Remark 1 给出 DeepONet 型替代: $\mu_u = \text{Branch}(z(\mathbf{x}_{\text{grid},1}), \dots, z(\mathbf{x}_p)) \cdot \text{Trunk}(z(\mathbf{x}))$, Branch 输入维 $p \times d_z$, d_z 与 p 都大时会撑爆; FNO 型的积分是 $O(N^2)$, FFT 降到 $O(N \log N)$ 。附录 B 用与算子型完全相同的配置跑了 DeepONet 型, 均值与不确定度都可用, 没有给出谁更好的数字。

15.3 正则项: 独立版、相关版, 以及一处核对

只用数据似然时, 编码器会把观测点处的 $m(\mathbf{x}_i)$ 推到 1, 潜 GP 在整个域上塌成确定性映射。正则项按 IB-UQ 的思路加:

$$\mathcal{L}_{\text{reg}}(Z, X) = E_{\mathbf{x} \sim \mathcal{U}(\Omega)} D_{\text{KL}}[q_E(\mathbf{z} | \mathbf{x}) \| e_1(\mathbf{z})],$$

e_1 取标准高斯 $\mathcal{N}(0, \mathbf{I}_{d_z})$, 经验式是 $\frac{1}{N} \sum_i [\log q_E(\mathbf{z}_i | \mathbf{x}_i) - \log e_1(\mathbf{z}_i)]$, 其中 $\mathbf{z}_i \sim q_E(\cdot | \mathbf{x}_i)$ 、 $\mathbf{x}_i \sim \mathcal{U}(\Omega)$ 。总目标是 $\mathcal{L} = \mathcal{L}_{\text{data}} - \beta \mathcal{L}_{\text{reg}}$, $\mathcal{L}_{\text{data}}$ 写成 $\log q_D$ 的平均, 所以要最大化, 算法第 3 步的更新式 $W \leftarrow W + \text{lr} \cdot \partial \mathcal{L} / \partial W$ 与此一致 (源码把 $\mathcal{L}_{\text{data}}$ 称作 negative log-likelihood, 与它自己的符号相反, 按式子读)。

Remark 3 的相关版把一批 B 个点的边际换成联合 GP: $e_2(\mathbf{z}_{1:B} | \mathbf{x}_{1:B}) \sim \mathcal{N}(0, \mathbf{K})$, $\mathbf{K} = (K(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1..B}$, 解析式 (源码式 14) 为

$$\tilde{\mathcal{L}}_{\text{reg}} = E_{\mathbf{x}_{1:B}} \frac{1}{2B} [-2 \log \det(\mathbf{D}_m) - B + \text{tr}(\mathbf{K}^{-1} \mathbf{D}_m \mathbf{K} \mathbf{D}_m) + (\mathbf{m} \bar{\mathbf{z}})^{\text{op}}(\mathbf{T}) \mathbf{K}^{-1} (\mathbf{m} \bar{\mathbf{z}})],$$

$\mathbf{D}_m = \text{diag}(1 - m(\mathbf{x}_1), \dots, 1 - m(\mathbf{x}_B))$ 。它的用处是让 m 与 GP 核的超参数 (长度尺度 L_c) 能同时被优化。

对这一项的核对 两个均值不同、协方差不同的高斯之间的标准式是 $D_{\text{KL}}(\mathcal{N}(\mu, \Sigma) \| \mathcal{N}(0, K)) = \frac{1}{2} [\text{tr}(\mathbf{K}^{-1} \Sigma) - B + \log \det K - \log \det \Sigma + \mu^{\text{op}}(\mathbf{T}) \mathbf{K}^{-1} \mu]$ 。代入 $\Sigma = \mathbf{D}_m^2$ 、 $\mu = \mathbf{m} \bar{\mathbf{z}}$: $-\log \det \Sigma = -2 \log \det \mathbf{D}_m$ 与源码一致, 末两项的形式也一致。差别在迹项: 标准式给 $\text{tr}(\mathbf{K}^{-1} \mathbf{D}_m^2)$, 源码写的是 $\text{tr}(\mathbf{K}^{-1} \mathbf{D}_m \mathbf{K} \mathbf{D}_m)$, 只有 K 与 $\mathbf{D}_m$ 可交换时两者才相等; 另外 $\log \det K$ 被略去, 若 L_c 真的要跟着一起优化, 这一项不是常数。这一条是本笔记的核对, 不是论文的结论; 论文自己声明了 $B \rightarrow \infty$ 的统计性质与该项的数学适定性都留待分析。

15.4 GP 怎么求导 (附录 A 的两条路)

Mercer / Karhunen–Loève 展开。 $k(\mathbf{x}, \mathbf{x}') = \sum_n \lambda_n \varphi_n(\mathbf{x}) \varphi_n(\mathbf{x}')$, $z_0(\mathbf{x}) = \sum_n \sqrt{\lambda_n} \xi_n \varphi_n(\mathbf{x})$, ξ_n 独立标准高斯; 特征函数足够光滑时可逐项求导, $\mathcal{N}_{\text{bold}}(x)[z_0] = \sum_n \sqrt{\lambda_n} \xi_n \mathcal{N}_{\text{bold}}(x)[\varphi_n]$ 仍是零均值高斯过程, 数值上截断到 N 项。

一维情形源码给了显式展开 (L_c 是物理相关长度, $L_p = \max\{1, 2L_c\}$ 、 $L = L_c/L_p$):

$$z_{0,i}(x, \omega_i) = \omega_{i,1} (\sqrt{\pi} L / 2)^{\frac{1}{2}} + \sum_{j=2}^N \zeta_j q_j(x) \omega_{i,j},$$

$$\zeta_j = (\sqrt{\pi} L)^{\frac{1}{2}} \exp\left(-\left(\left\lfloor \frac{j}{2} \right\rfloor \pi L\right)^2 / 8\right), \quad q_j(x) = \begin{cases} \sin\left(\left\lfloor \frac{j}{2} \right\rfloor \pi x / L_p\right) & \text{if } j \text{ even} \\ \cos\left(\left\lfloor \frac{j}{2} \right\rfloor \pi x / L_p\right) & \text{if } j \text{ odd} \end{cases}$$

ζ_1 那一项被单独写成常数项, 展开式里的 q_j 分支条件源码写的是 “if i even/odd”, 按上下文应为 j 。二维不写展开, 改用乘积核 $k((x_1, x_2), (x_1', x_2')) = \tilde{k}(x_1, x_1') \tilde{k}(x_2, x_2')$ 。

函数值与导数值联合抽样。一维、单输出、平方指数核时

$$\begin{pmatrix} z_0(X_u) \\ z_0(X_f) \\ z_0'(X_f) \\ z_0''(X_f) \end{pmatrix} \sim \mathcal{N}(0, \mathbf{K}),$$

$\mathbf{K}$ 的 16 个分块全由核的混合偏导解析给出 ($k_x, k_y, k_{xy}, k_{xx}, k_{yy}, k_{xxyy}$ 等, 约定 $k_x(x, x') = \partial/\partial x' k(x, x')$)。于是非线性算子 $\mathcal{N}_{x[z_0]}(x) = F(z_0, z_0', z_0'')$ 可以在每个实现上逐点算, 输出一般不再是高斯, 按样本统计。

15.5 训练协议与两个基线的配置

项	取值	出处 / 备注
默认网络	3 层全连接、每隐层 64、Mish	编码器 m 、 $\bar{z}$ 与解码器同规格
潜变量维 d_z	20	全部算例
β	0.01; 外推算例 0.1	β 只在这两处不同
优化	Adam, 初始学习率 0.001, 10000 步, 每 1000 步乘 0.7	默认协议
两阶段	前 5000 步只优化均值, 后 5000 步同时优化标准差并微调均值	默认协议
多孔介质	3 层 $\times$ 20; 两阶段为 2000 / 8000 步	三种方法用同一尺寸网络
二维反应扩散	3 层 $\times$ 128	其余同默认
六维反演	编解码 3 层 $\times$ 128; λ 网络 2 层 $\times$ 128、tanh; 20000 步 (10000 / 10000), 学习率恒 0.001	σ_u 初始化 0.1
一维反问题的 λ 网络	单神经元隐层 + tanh	其余算例未用
噪声参数	σ_u, σ_f 取可学标量, 初始化为 2 倍经验噪声	$\varepsilon \sim \mathcal{N}(0, 0.01^2)$ 时 $\sigma_u = 0.02$
核参数化	$\alpha_i = \tan(\tilde{\alpha}_i)$, $\tilde{\alpha}_i \in (0, \pi/2)$	保证正

两个基线的配置要按论文写的复现, 不能凭印象: **B-PINN-HMC** 用两层、每层 50 个神经元, 权重与偏置的先验是各分量独立标准高斯, 质量矩阵 $M = \mathbf{I}$, leapfrog 步数 $L = 50$, 步长 $\delta_t = 0.1$, burn-in 2000 步、总样本 5000。**深度集成** 用与 HMC 同尺寸的网络、权重衰减 4e-6、独立训练 20 次后取集成统计量。除多孔介质一例明确写了“HMC 与深度集成采用与 LVM-GP 相同的网络结构”, 其余算例里三者的网络尺寸并不一致 (LVM-GP 默认 3×64 , 基线 2×50)。

15.6 六个算例的数字

一维 Poisson (正问题)。 $\lambda \partial_x^2 u = f$ 在 $[-0.7, 0.7]$, $\lambda = 0.01$, 精确解 $u(x) = [\sin(6x)]^3$, f 由方程给出; f 有 32 个等距传感器, u 在两端各一个传感器给 Dirichlet 条件; 噪声两档 $\varepsilon \sim \mathcal{N}(0, 0.01^2)$ 与 $\mathcal{N}(0, 0.1^2)$ 。低噪时三种方法都合格; 高噪时深度集成对 f 的不确定度失效, LVM-GP 的均值比 HMC 更准、带更紧。把核长度尺度 L_c 也放进优化后, 它从初值约 1.0 单调下降, 约 8000 步后稳定在 0.58 附近。

一维多孔介质。 $-\nu_e/\varphi \partial_x^2 u + \nu u/K = g$ 在 $[0, 1]$, $\nu_e = \nu = 10^{-3}$ 、 $\varphi = 0.4$ 、 $K = 10^{-3}$ 、 $g = 1$, 解析解 $u = gK/\nu[1 - \cosh(r(x - H/2))/\cosh(rH/2)]$ 、 $r = \sqrt{\nu\varphi/(\nu_e K)}$; g 有 16 个等距传感器、 u 两端各一个, 噪声两档。边界层解, $rH/2$ 不小, 两端陡。LVM-GP 与 HMC 相当, 深度集成在高噪下不可靠。

一维非线性 Poisson (反问题), 识别 λ 。 $k \partial_x^2 u + \lambda \tanh(u) = f$, $k = 0.01$, $u = [\sin(6x)]^3$, λ 真值 0.7; 32 个 f 传感器、2 个边界 u 传感器, 另有 6 个内部 u 传感器专门用来定 λ 。

噪声		LVM-GP	B-PINN-HMC	深度集成
0.01	均值	0.6976	0.6967	0.6966

0.01	标准差	9.816×10^{-3}	4.225×10^{-3}	2.493×10^{-4}
0.01	偏差 / 标准差	0.24	0.79	13.6
0.1	均值	0.6965	0.6787	0.6959
0.1	标准差	6.954×10^{-2}	4.166×10^{-2}	3.691×10^{-2}
0.1	偏差 / 标准差	0.05	0.51	0.11

最后一行是本笔记加的：把 $|\text{均值} - 0.7|$ 除以该方法的预测标准差，得到一个粗糙的 z 值。低噪档里深度集成的标准差小到 2.5×10^{-4} ，偏差是它的 13.6 倍，这是“集成在数据少时给出假精确”的数字形态；高噪档三者的 z 都落在 ± 1 左右，此时集成不再离谱。这个换算只在“预测分布是单峰且标准差是其主要宽度参数”时才有意义，它不是覆盖率检验。

外推。 只用 $x \leq 0$ 一侧的 4 个 u 观测，配 40 个均匀 f 观测，噪声标准差 0.01，靠 PDE 约束把 u 外推到 $x > 0$ 。论文报的参数预测均值 0.7040、标准差 1.361×10^{-2} ，与 0.7 相符。这一段源码把待估参数写成 k ，而该方程里 $k = 0.01$ 是已知的扩散系数、0.7 是上一例的 λ ，属符号混用；按数值读它估的是 λ 。

二维非线性扩散反应（反问题），识别 λ 。 $k(\partial_{x_1}^2 + \partial_{x_2}^2)u + \lambda u^2 = f$ 在 $[-1, 1]^2$ ， $k = 0.01$ ， $u = \sin(\pi x_1) \sin(\pi x_2)$ ， λ 真值 1； u 有 100 个域内传感器、 f 有 484 个，每条边界 25 个 u 传感器。

噪声		LVM-GP	B-PINN-HMC	深度集成
0.01	均值	1.0003	1.0005	1.0047
0.01	标准差	4.58×10^{-3}	5.75×10^{-3}	4.12×10^{-3}
0.01	偏差 / 标准差	0.07	0.46	1.14
0.1	均值	0.9916	0.9781	0.9302
0.1	标准差	5.70×10^{-3}	4.98×10^{-2}	2.60×10^{-2}
0.1	偏差 / 标准差	1.47	0.44	2.68

高噪档里 LVM-GP 的标准差比 HMC 小一个量级，偏差与自己的标准差同量级（1.47），而 HMC 的标准差比自己的偏差大两倍（0.44）。一个偏紧、一个偏松；深度集成的偏差 0.0698 是其标准差的 2.68 倍，是三家里唯一明显失准的。




图 38 二维非线性扩散反应算例的场级结果 (论文 2507.22493): 左为预测误差场 (色标 0 到 0.149), 右为预测标准差场 (色标 0.103 到 0.111)。右图值得多看一眼: 标准差场几乎是平的, 误差场却有明显的团块结构: 带宽反映了观测噪声的水平, 没有跟上误差实际集中的位置。

六维污染源反演。 $-\lambda(\partial_{x_1}^2 + \partial_{x_2}^2)u - f_2 = f_1$ 在 $[0, 1]^2$ 、零边界, $\lambda = 0.02$, 已知源 $f_1 = 0.1 \sin(\pi x_1) \sin(\pi x_2)$, 未知源 $f_2 = \sum_{i=1}^3 k_i \exp[-0.5\|x - x_{c,i}\|^2/0.15^2]$, 幅度 $\mathbf{k} = (2, -3, 0.5)$ 已知、三个中心 $x_{c,i}$ 待估; 观测为 u 的 1000 个点 ($\varepsilon_u \sim \mathcal{N}(0, 0.1^2)$) 与 f_1 的 200 个点 ($\varepsilon_{f_1} \sim \mathcal{N}(0, 0.01^2)$); 参照解由 FEniCS 有限元给出 (源码此处写作 “finite method method”)。真值中心 $(0.3, 0.3)$ 、 $(0.75, 0.75)$ 、 $(0.2, 0.7)$ 。

		$x_{c,1}$	$x_{c,2}$
$x_{c,3}$	LVM-GP	均值	(0.2927, 0.3022)
(0.7433, 0.7542)	(0.2065, 0.7569)	LVM-GP	标准差 ($\times 10^{-2}$)
(2.79, 6.25)	(2.87, 2.36)	(5.49, 6.34)	LVM-GP
偏差 / 标准差	(0.26, 0.04)	(0.23, 0.18)	(0.12, 0.90)
B-PINN-HMC	均值	(0.3014, 0.2883)	(0.7473, 0.7496)
(0.2268, 0.6519)	B-PINN-HMC	标准差 ($\times 10^{-3}$)	(3.08, 3.45)
(3.51, 2.52)	(18.97, 11.47)	B-PINN-HMC	偏差 / 标准差
(0.45, 0.34)	(0.73, 0.16)	(1.41, 4.19)	

两个标准差列的标度不同 (LVM-GP 是 10^{-2} 量级, HMC 是 10^{-3} 量级), 表头分别写了 $\times 10^2$ 与 $\times 10^3$, 读的时候要换算。差别最大的是第三个中心的 y 分量: LVM-GP 给 0.7569, 偏 $+0.057$, 自己的带宽 0.0634, 偏差落在带内 (0.90); HMC 给 0.6519, 偏 -0.048 , 带宽 0.0115, 偏差是其 4.2 倍。这个算例的结论不是“谁更准”, 而是带宽相差一个量级时同一份数据能被解释成 “在带内”与“显著偏离”两种说法。

LVM-GP for inverse problem





图 39 左: LVM-GP 反问题的结构图 (论文 2507.22493), u 、 f 、 λ 三个解码支路共享同一个潜随机场与同一个 ω_E , 总损失写成 $\mathcal{L}_{\text{data}} + \beta \mathcal{L}_{\text{reg}}$ 。右: 外推算例的 f 面板, 蓝圈是 40 个均匀观测、黑线精确解、红虚线预测均值; 图例里的 2 倍标准差带在这个纵轴尺度上几乎看不见。

15.7 这份源码里没有的东西

缺口清单

- 没有定理。稳定性、逼近阶、正则项的适定性都在结论一节被列为待做。
- 没有成本对比。HMC 要跑 2000 次 burn-in 加 5000 个样本、集成要训 20 次, 论文没有报任何一侧的时间, 效率主张无法核对。
- 没有校准指标。表里只有预测均值与标准差, 没有覆盖率、NLL 或区间宽度, 上一节的 z 值是本笔记用现成数字做的粗算。
- 没有时间相关问题, 作者自己列为待扩展。
- 不是算子学习设定: 每个算例是单一 PDE 实例的求解, 与 UQ-SONet、IB-UQ 的算子版本不在同一比较口径上。
- 附录 B 的图里还留着被注释掉的“PI-IB”图例, 说明曾与 IB-UQ 的物理信息版本同图对比, 正稿删掉了这一列, 因此 LVM-GP 相对 IB-UQ 的增益没有可读的数字。

16 谱系: 神经网络的“误差棒”从哪来

本方向的方法全部长在两个既有谱系上: 贝叶斯深度学习与信息瓶颈。这里把两个谱系以及周边替代路线排开。

16.1 贝叶斯深度学习: 后验样本的三条获得方式

- **贝叶斯框架:** MacKay (1992) 与 Neal (1996) 确立了权重视为随机变量、用后验分布做预测的框架; 推断是瓶颈。
- **MCMC 路线:** HMC (Duane 等 1987; Neal 2011 的综述手册) 借哈密顿 动力学提高高维混合效率, 是金标准也是最贵的选项。
- **变分路线:** Bayes-by-Backprop (Blundell 等 2015) 把后验近似做成可反向传播的优化; **MC dropout** (Gal-Ghahramani 2016) 证明 标准 dropout 训练加推断期丢弃等价于变分高斯过程近似, 让“不加额外训练成本的不确定度”普及; 拉普拉斯近似 (Daxberger 等 2021) 在训练终点做二阶局部展开。
- **集成路线:** 深度集成 (Lakshminarayanan 等 2017) 以极简设计成为 强基线; 快照集成 (Huang 等 2017) 与 SWAG (Maddox 等 2019) 从单条优化轨迹里取样本, 把成本再压一档。综述 (第 2 章) 的比较实验对象全部来自这一节。

16.2 非贝叶斯的不确定度：三条替代路线

- **conformal prediction** (Vovk 2005; Angelopoulos–Bates 2021 的入门综述)：用留出数据的分位数给预测区间做分布自由的覆盖保证，不需要任何分布假设，代价是区间宽度没有形状信息。
- **evidential deep learning** (Sensoy 等 2018 分类; Amini 等 2020 回归)：网络直接输出证据分布（如 Dirichlet）的参数，一次前向就给出不确定度，推断最便宜、校准最难。
- **neural processes** (Garnelo 等 2018)：函数空间上的潜变量模型，UQ-SONet 的 cVAE 与它同族；区别是后者带 PDE 物理损失。
- 软件生态：NeuralUQ (Zou 等 2024) 等工具包把综述的指标体系 实现成可复用的库。

16.3 物理约束 + UQ：综述与本组的交接点

- 贝叶斯侧：B-PINN (Yang 等 2021) 把 HMC 接进 PINN；集成侧：深度集成 PINN 的多个变体；先验侧：GAN-FP (Meng 等 2021) 用历史数据预训练生成器，把后验推断搬进低维 生成器输入空间，综述据此提出 PA-BNN-FP / PA-GAN-FP。
- 信息瓶颈侧：Tishby–Pereira–Bialek (1999) 的 IB、VIB (Alemi 等 2017) 的变分下界、“VIB 蕴含不确定性” (Alemi 等 2018) 构成 IB-UQ 的直接前置；信息瓶颈在时间序列上的平行发展 (time-lagged IB, Federici 等 ICLR 2024) 说明这条思想在动力系统里同样活跃。本方向第 5 章的 IB-UQ 是这条谱系在 SciML 里的落地。

17 坐标：这条线站在哪里

17.1 每篇的最接近替代品

论文	最接近的替代品	差在哪里
综述 (2023)	各类 UQ 教程与软件包 (UQpy、NeuralUQ)	综述给出的是面向 SciML 的方法学比较与指标体系，不是工具箱文档
IB-UQ (2023)	贝叶斯神经网络 + HMC；深度集成；evidential DL	HMC 精确但贵一个量级；集成在 OOD 处过置信；evidential 缺物理场景验证
EDG (2024)	Boltzmann Generator (RealNVP VAE)；PIS；L2HMC	flow 表达力受限；PIS 训练要反复积分 SDE；L2HMC 混合慢
FMRC (2024)	TICA/VAMPnets (线性)；time-lagged 自编码器；信息瓶颈式反应坐标	谱方法限于线性流形；深度方法没有“损失 ↔ 算子误差”的定量联系
UQ-SONet (2025)	VIDON；BNN 算子；深度集成算子	VIDON 确定性且不处理算子内在随机；集成不确定带系统性偏窄
LVM-GP (2025)	B-PINN-HMC；深度集成；PI-VAE；IB-UQ	HMC 太贵；集成高噪下振荡；VAE 潜变量无空间相关；IB-UQ 的先验不带空间结构

17.2 更大坐标系里的位置

相对贝叶斯深度学习主流。 综述代表的“后验样本 + 混合”范式与本组的方法论文是互补关系：贝叶斯方法给参数级后验，IB 系方法给“表示级”的不确定度（编码器自己知道哪些输入不可信）。两者在“参数不确定度”这一层是竞争的，在“OOD 警报”这一层是合作的。

相对信息瓶颈谱系。 这条线的 IB 与 Tishby/Alemi 的关系是“继承 + 改造”：继承变分下界的技术与“压缩换鲁棒”的哲学；改造压缩项 ($I(Z; X) \rightarrow I(\tilde{Z}; \tilde{X})$) 与编码器（确定性 → 置信度混合）。**压缩导致鲁棒**这一因果在分类任务里是经验观察，在 IB-UQ 里变成了有不等式支撑的命题。

相对本组另外两条线。方向 A（稀疏逼近）处理“样本昂贵”的正向 UQ；方向 B（PINN/生成模型）处理“方程已知、解怎么算”；本方向处理“预测本身不可信”。三者在真实工作流里是串联的：A 给便宜的前向代理，B 给方程约束下的解，C 给误差棒。

相对神经算子社区。FMRC 与 UQ-SONet 都在回答神经算子的开放问题（误差界、OOD），前者给“降维引起的算子误差”的定量界，后者给变长输入与内置 UQ。这条线的工作正在被算子学习社区吸收。

17.3 逻辑阶梯

级	工作	新加入的概念
1	Tishby 1999; Alemi 2017	IB 目标; VIB 变分下界
2	综述 2201.07766	SciML 的不确定性来源分解; 指标体系; 比较结论
3	IB-UQ 2302.03271	宽分布压缩; 置信度混合编码器; OOD 退化命题
4	EDG 2401.02080	潜空间扩散编码器; simulation-free 训练; 重加权
5	FMRC 2408.15981	两个降维准则的可计算化; flow matching 瓶颈; 算子误差界
6	UQ-SONet 2509.25646	置换不变嵌入; 函数空间 cVAE; 潜变量统一承载两类不确定来源
7	LVM-GP 2507.22493	GP 先验潜变量; 可学习核超参; 物理诱导的耦合

第 1 级给工具，第 2 级给地图，第 3 级把工具改造成 UQ 专用，第 4 到 7 级把“编码器 + 潜变量”的骨架带进四个相邻领域：采样（EDG）、降维理论（FMRC）、算子学习（UQ-SONet）、物理约束求解（LVM-GP）。置信度混合编码器 $z = \text{diag}(m)\bar{z} + \text{diag}(1-m)z_0$ 是第 3 级发明、第 7 级仍在使用的构件，它在这条线里的地位相当于残差连接在 PINN 谱系里的地位。

17.4 谁受影响

- **把 UQ 接进 SciML 工具链的人：**指标体系（RL2E/MPL/RMSCE）与“事后校准”流程已成事实标准，后续论文的实验设计普遍沿用它；
- **信息瓶颈社区：**IB-UQ 证明了 IB 在回归与算子学习里的可用性，把 IB 谱系从分类任务扩展到物理问题；
- **分子动力学与采样社区：**EDG 的 simulation-free 训练与 FMRC 的可计算降维准则给了 VAMPnets 谱系一个深度学习升级包；
- **本组方向 B：**B 方向的 PINN 系列与本方向的 UQ 系列共享“物理损失 + 生成模型”的骨架，sPI-GeM 与 EDG 的组合（物理约束 + 无样本生成）是两条线的自然交汇点。

17.5 不该过度宣称的部分

- 综述的比较结论来自特定算例族（一维、二维为主），外推到三维 PDE 与真实物理数据集需要谨慎；
- IB-UQ 的 OOD 命题依赖“似然有界”假设与 e 的表达力，理论保证是渐近的（最优模型处）；
- FMRC 的误差界经由 W_2 线性化，常数随 Lipschitz 常数指数增长，实际意义是“形状正确”多于“数值精确”；
- LVM-GP 的联合 KL 正则的统计性质（ $B \rightarrow \infty$ ）是开放问题；UQ-SONet 的多点联合 UQ 同样开放。

18 附录

18.1 A. 记号表

记号	含义
θ	网络权重
$\mathcal{D}$	训练数据
$p(\theta \mathcal{D})$	权重后验
$\hat{\theta}_j$	后验的第 j 个样本（集成成员 / MCMC 样本）
$\bar{\mu}(x), \bar{\sigma}^2(x)$	预测均值与总方差
Σ_u^2	噪声方差（aleatoric）
$\mathcal{F}, \mathcal{B}$	PDE 算子与边界算子
Z, X, Y	IB 的表示变量、输入、目标
$\tilde{X}, \tilde{p}$	加温输入与其分布 ($\propto p^{1/\tau}$)
q_E, q_D, e	编码器、解码器、边际密度代理（flow）
$m(x), \bar{z}(x)$	置信度门控与确定性特征
β, τ	IB 权衡系数与加温温度
$U(x), Z$	Boltzmann 势能与配分函数（第 7 章语境）
$p_\tau, p_{-\tau}$	正向与反向转移密度
$\mathcal{K}_\tau, \mathcal{T}_\tau$	Koopman 算子与 Perron–Frobenius 算子
$r(x)$	反应坐标
$h(\mathcal{O})$	传感器集合的置换不变表示
z	cVAE / LVM 的潜变量
$K(x, x')$	GP 核函数

18.2 B. 关键公式速查

基础

- BMA: $p(u|x, \mathcal{D}) = \int p(u|x, \theta)p(\theta|\mathcal{D})d\theta$
- MC 近似: $\bar{p}(u|x) = \frac{1}{M} \sum_j p(u|x, \hat{\theta}_j)$
- 方差分解: $\sigma^2 = \sigma_a^2 + \sigma_e^2$ （噪声项 + 成员散度项）
- 校准: $P(U_X \leq \bar{P}_X^{-1}(p)) = p$ 对所有 p ; 误差 $\text{RMSCE} = \sqrt{E_p(p - \hat{p}(p))^2}$

IB-UQ

- 目标: $\mathcal{L}_{\text{IB}} = I(Z; Y) - \beta I(\tilde{Z}; \tilde{X})$, $\tilde{p} \propto p^{1/\tau}$
- 编码器: $z = \text{diag}(m(x))\bar{z}(x) + \text{diag}(1 - m(x))z_0$
- 下界: $I(Z; Y) - \mathcal{H}(Y) \geq E[\log q_D(y|z)]$
- 上界: $I(\tilde{Z}; \tilde{X}) \leq E[\log q_E(\tilde{z}|\tilde{x}) - \log e(\tilde{z})]$
- OOD 命题: $p(x) \leq \varepsilon \tilde{p}(x) \implies \text{KL}(q_E^*(\cdot|x) \parallel e^*) \leq \varepsilon \beta^{-1} \log C$
- 算子版: 瓶颈在 branch, $\mathcal{L}_{\text{IBONet}} = I((Y, Z); s(Y)) - \beta I(\tilde{Z}; \tilde{O})$

四个后继的核心量

- **EDG**: $\mathcal{L} = E[\log p_D(x|z_0) + U(x)] + \int g^2/2E[\|s\|^2 + 2 \div s]$, 训练不需要积分 SDE; 权重 $w = e^{-U} p_E(z_0|x)/(p_D(z_0)p_D(x|z_0))$
- **FMRC**: lumpability $p_\tau(x, y) = p_\tau^L(r(x), y)$; decomposability $p_\tau(x, y) = p_\tau^D(x, r(y))p_{\text{local}}(r(y), y)$; $\mathcal{L}^{\text{FMRC}}$ 取等 $\iff$ 两准则成立
- **UQ-SONet**: 注意力池化 $h^l = \sum_i \text{softmax}(w_l(\Lambda_i)/\sqrt{d})v_l(\Lambda_i)$; 噪声方差乘 M 使损失收敛到函数空间 cVAE
- **LVM-GP**: $z = \text{diag}(m)\bar{z} + \text{diag}(1-m)z_0$, $z_0 \sim \text{GP}(0, K)$; $\text{Var}(z(x)) = (1-m(x))^2$

18.3 C. 六篇论文信息

- K. Psaros, X. Meng, Z. Zou, L. Guo, G. E. Karniadakis. **Uncertainty quantification in scientific machine learning: methods, metrics, and comparisons**. SIAM Review, 65(2), 2023. arXiv:2201.07766.
- L. Guo, H. Wu, W. Zhou, Y. Wang, T. Zhou. **Information bottleneck based uncertainty quantification for neural function regression and operator learning**. J. Comput. Phys., 510:113089, 2024. arXiv:2302.03271.
- Y. Wang, L. Guo, H. Wu, T. Zhou. **Energy based diffusion generator for efficient sampling of Boltzmann distributions**. J. Comput. Phys., 2024. arXiv:2401.02080.
- Z. Zhang, L. Guo, H. Wu. **Optimal low-dimensional approximation of transfer operators via flow matching: computation and error analysis**. 2024. arXiv:2408.15981.
- L. Ma, L. Guo, H. Wu, T. Zhou. **Deep set based operator learning with uncertainty quantification**. 2025. arXiv:2509.25646.
- X. Feng, L. Guo, X. Wan, H. Wu, T. Zhou, W. Zhou. **LVM-GP: Uncertainty-aware PDE solver via coupling latent variable model and Gaussian process**. 2025. arXiv:2507.22493.

本笔记读到的版本 笔记里的公式、定理编号与数值一律按 arXiv TeX 源码抄，源码与期刊正稿有几处差别，涉及结论时以源码为准并在此说明：

- 2201.07766 的源码是投 Elsevier 的 preprint 版 (elsarticle 模板)。它定义的指标是 RL2E、MPL、RMSCE、PIW、SDCV 与两个金标准指标 NIP-G、KL-G；正式发表版里常见的 CRPS、PICP、ACE 在这一版源码中没有出现，笔记提到它们时会说明出处不在此处。
- 2401.02080 的源码是 2025 年改投 Neural Networks 的重投稿，管线图的日期戳是 2025-09-09。该版只有一个编号定理 (KL 上界)，正文里没有 MMD 收敛速率界；JCP 正稿中的相应内容在这份源码中找不到，笔记只引用这份源码里存在的结果。
- 2408.15981 的源码是 SIAM 会议短文格式，只有一个实验、没有数值表格，引用的补充材料文件不在源码包内； L_μ^2 误差与谱误差的一节被整段注释掉。
- 2509.25646 与 2507.22493 的源码都是 elsarticle preprint，两者都没有编号定理（前者只有 Jensen 型 ELBO 与函数空间损失的推导，后者只定义了 theorem 环境却未使用）。

18.3.1 背景文献

- N. Tishby, F. C. Pereira, W. Bialek. **The information bottleneck method**. 1999. IB 的原始论文。
- A. Alemi, I. Fischer, J. Dillon, K. Murphy. **Deep variational information bottleneck**. ICLR, 2017. VIB 变分下界的来源。

- A. Alemi, I. Fischer, J. Gilmer. **Deep variational information bottleneck and uncertainty**. 2018. “VIB 蕴含不确定性”的动机文献。
- M. Raissi, P. Perdikaris, G. E. Karniadakis. **Physics-informed neural networks**. J. Comput. Phys., 2019. PINN。
- L. Lu, P. Jin, G. E. Karniadakis. **DeepONet: Learning nonlinear operators**. 2021. 算子学习基座。
- L. Dinh, J. Sohl-Dickstein, S. Bengio. **Density estimation using RealNVP**. arXiv:1605.08803, 2016; 与 P. Sorrenson, C. Rother, U. Köthe. **Disentanglement by nonlinear ICA with general incompressible-flow networks (GIN)**. ICLR, 2020 (保体积 flow, IB-UQ 用它给输入分布“加温”)。
- J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli. **Deep unsupervised learning using nonequilibrium thermodynamics**. 2015; 与 J. Ho, A. Jain, P. Abbeel. **Denoising diffusion probabilistic models**. 2020. 扩散模型基础。
- M. R. Prasthofer, T. De Ryck, S. Mishra. **Variable-input DeepONet (VIDON)**. 2022. 置换不变算子学习的前身。
- J. H. Seidman, G. Kissas, G. J. Pappas, P. Perdikaris. **Variational autoencoding neural operators**. ICML, PMLR 202 (2023). 函数空间 VAE 理论依据 (UQ-SONet 附录用它的定理 4.1 推离散无关的泛函损失)。
- F. Noé, S. Olsson, C. Köhler, H. Wu. **Boltzmann generators**. Science, 2019. 采样对照基线。

18.4 D. 自检清单

读完后应该能回答

1. aleatoric 与 epistemic 的区分标准是什么？方差分解定律怎么把两者算出来？（第 1 章）
2. “过置信”的定义？为什么单指标选型会误导？（第 1、2 章）
3. BMA 的 MC 近似里，成员散度对应哪一类不确定性？（第 1 章）
4. IB-UQ 把经典 IB 的压缩项换成了什么？为什么宽分布压缩能带来 OOD 鲁棒？（第 5 章）
5. 置信度混合编码器的两个极端 ($m = 1$ 与 $m = 0$) 各对应什么行为？（第 5 章）
6. OOD 退化命题的条件与结论分别是什么？（第 5 章）
7. EDG 为什么不能沿用普通生成模型的损失？simulation-free 训练省掉了什么？（第 7 章）
8. lumpability 与 decomposability 各自刻画反应坐标的什么性质？FMRC 的损失为什么能同时检验两者？（第 8 章）
9. UQ-SONet 里“乘 M 的噪声方差”解决什么问题？（第 9 章）
10. LVM-GP 相对 IB-UQ 把先验换成了什么？动机来自哪个一维观察？（第 10 章）