

信息如何塑造 Koopman 表示

Information Shapes Koopman Representation

Xiaoyuan Cheng, Wenxuan Yuan, Yiming Yang, Yuanzhao Zhang,
Sibo Cheng, Yi He, Zhuo Sun

ICLR 2026 · arXiv:2510.13025

一份面向“有机器学习基础、但从未接触过 *Koopman* 算子或信息瓶颈”的读者的
自足讲解。目标不是复述论文，而是把论文的推理链拆开、补全，
让读者读完能自己判断这篇工作在做什么、站在哪里、下一步该往哪走。

怎么读这份笔记 这份笔记刻意不按“摘要—引言—方法—实验—结论”的顺序走。论文的论证主线是一条 **信息在潜在空间中如何流动、流失、被塑造** 的线索，笔记就沿着这条线索走：

- **第 0 章** 预备知识。默认读者只学过数学分析、线性代数、概率论与常微分方程；信息论、动力系统、自编码器这些工具在第 0 章按同一套路补齐（先讲它回答什么问题，再给数值例子，再给定义）。已学过对应内容的读者可以跳过，只读末尾的阅读地图与自测。
- **第一部分 (§1–§2)** 两条线索的谱系。先把问题立起来：为什么需要 Koopman 线性化，为什么它天然困难，深度学习接手后具体坏在哪里；再把信息瓶颈这条线的工具备齐。读完你会知道这不是一个工程调参问题。
- **第二部分 (§3–§5)** 是核心。沿着论文自己的提问链「信息会丢吗？→ 丢多少？→ 丢的是什么？→ 怎么优化？→ 怎么防止副作用？」逐步证明五个命题。每个命题都给完整的推导，不跳步。
- **第三部分 (§6)** 把理论翻译成可运行的损失函数与两份算法。
- **第四部分 (§7)** 实验如何反过来验证理论。
- **第五部分 (§8)** 横向坐标：这条线索相对于 Koopman 谱系和 IB 谱系的位置。
- **第六部分 (§9–§10)** 局限、下一步，以及记号速查与参考文献。

数学密度较高，但每一个符号第一次出现时都会先解释**它为什么存在**。遇到 **黄色框** 时，那是最需要记住的一句话；遇到 **绿色框** 是直觉总结；**红色框** 是容易出错的细节。

术语地图（第一次遇到不懂的词，先回来查这里） 下面这些词在正文里第一次出现时都会展开解释，这里先给一句最简版，方便随时回查。

可观测量	状态的函数，比如“温度场”“某个区域的平均速度”。Koopman 理论作用在它们上面。
谱 / 特征值	线性算子“各个方向上的缩放倍数”。特征值模长 < 1 就衰减， $= 1$ 就持续， > 1 就爆炸。

不变子空间	一个函数集合，被算子作用之后仍然留在自己里面。只有在这种集合上，算子才能写成有限矩阵。
潜变量 / 潜在空间	把高维状态压缩之后得到的低维向量，以及它所在的空间。
互信息	两个变量“共享了多少信息”。用它可以量化“ z 里还留着多少关于未来 x 的线索”。
率失真	“码率”与“误差”之间的最优兑换关系。这里用来把“信息量”换算成“误差有多大”。
注水	一种资源分配方式：水（方差预算）先流向门槛最低的容器（增益最大的方向）。低增益方向一滴都拿不到。
密度矩阵	半正定、迹为 1 的矩阵。它的特征值构成一个概率分布，可以理解成“方差在各方向的占比”。
von Neumann 熵	上面那个特征值分布的香农熵。它只关心“分布铺得开不开”，不关心总量。
有效维度	$\exp(\text{熵})$ 。回答“这些方差实际上用到了几个方向”，取值在 1 到 d 之间。
拉格朗日乘子	把带约束的优化改写成无约束优化的辅助变量，负责“守住约束”。
变分界 / ELBO	真实目标算不出来时，用一个能算的量从上方或下方夹住它。深度生成模型的标准工具。

目录

第 0 章 预备知识：这本书假设你会什么、补什么	4
0.1 你会什么、不用会什么	4
0.2 动力系统：状态怎么随时间走	4
0.3 特征值复习：矩阵幂的行为由特征值决定	6
0.4 Koopman 思想：跟踪观测函数，不跟踪状态本身	6
0.5 信息论三件套：熵、条件熵、互信息	8
0.6 变分下界：算不动，就构造一个能算的量	9
0.7 自编码器：压缩、展开，以及“塌掉”的担心	10
0.8 阅读地图与自测	11
1 第一根线索：Koopman 谱系，从“线性化的梦”到“学一个不变子空间”	12
1.1 一个古老的两难：非线性动力学	12
1.2 Koopman 算子：换一个空间，把非线性搬进函数里	12
1.3 价格：无限维、可能没有特征值、而且非正规	13
1.4 从数据里估计这个子空间：DMD 与 EDMD	14
1.5 有限维不变子空间的根本困难	15
1.6 让神经网络来选字典：从 Takeishi 到 Koopman 自编码器	15
1.7 在 LRA 之上的六个分支	16
1.8 六条分支的共同盲点	20
1.9 论文的重新定位	21
2 第二根线索：信息瓶颈谱系，从“压缩与相关性”到可训练的损失	22
2.1 信息瓶颈：一个被写对了四十年的目标函数	22
2.2 深度变分信息瓶颈：让 IB 可以训练	26
2.3 InfoNCE：当相关性无法写出密度时怎么估计它	27
2.4 修补 IB 漏洞的工具：von Neumann 熵与有效维度	29
2.5 小结：五个工具，各自补什么	30
3 论文的论证链（上）：信息会丢吗？丢多少？	31

3.1	先把信息流的结构写清楚	31
3.2	命题 1: 信息会丢吗?	32
3.3	命题 2: 丢多少?	33
4	论文的论证链 (中): 丢的是哪一类信息?	38
4.1	第一步: 潜在互信息的闭式	38
4.2	第二步: 把 $I(z_t; x_t)$ 拆成三块	40
4.3	第三步: 后两块的闭式	41
4.4	命题 3 全貌与它给出的图像	43
4.5	一个关键的转折: 最大化它会出问题	44
5	论文的论证链 (下): 优化的陷阱与解药	45
5.1	命题 4: 为什么“更好的信息保留”反而会失败	45
5.2	命题 5: 用谱熵把有效维度买回来	47
5.3	到这里, 三个目标已经齐了	50
6	从拉格朗日量到可运行的算法	51
6.1	统一拉格朗日量	51
6.2	可训练损失	51
6.3	两份算法	53
6.4	架构细节	54
7	实验: 理论预测能被验证吗?	56
7.1	任务与基线	56
7.2	问题 (1): 潜在互信息真的决定预测极限吗? (验证命题 2)	56
7.3	问题 (2): 保留的信息如何塑造动力学相关的流形? (验证命题 4、5)	57
7.4	问题 (3): 信息论正则相比 VAE 与 Koopman 自编码器捕捉到了什么? (验证命题 4、5)	58
7.5	问题 (4): 噪声、长时程、大规模下稳健吗? (验证命题 1、2)	58
7.6	问题 (5): 拉格朗日量能推广到不同架构与下游任务吗? (验证命题 1-5)	59
7.7	实验部分的三条总结	60
8	坐标: 这篇论文站在哪里	62
8.1	一次视角比较: Koopman 谱系与 IB 谱系的错位	62
8.2	如果这篇论文不存在, 最接近的替代品	62
8.3	这篇论文出现后, 谁会被直接影响到	64
8.4	逻辑阶梯: 从最原始的想法到最复杂的理论	64
8.5	一句总结	65
9	往前走: 局限、开放问题与可行的下一步	66
9.1	论文自己承认的两条	66
9.2	从脉络看出去的四个问题	66
9.3	三条具体可行的下一步	67
9.4	读完之后应该能回答的问题	68
10	附录	69
10.1	A. 记号表	69
10.2	B. 关键公式速查	69
10.3	C. 补充: 命题 2 的率失真下界	70
10.4	D. 补充: 结构一致性的两个效应	71
10.5	E. 参考文献与阅读顺序	71

第 0 章 预备知识：这本书假设你会什么、补什么

后面各章在推导上不跳步，但会默认你认识一批术语：互信息、变分界、自编码器、协方差谱。这一章按固定的套路把这些术语补齐：每个概念先说它回答什么问题（它为什么存在），再给一个能动手算的数值例子，然后给定义，最后用日常语言把定义读一遍。全章不引入测度论和算子谱理论，需要的只是数学分析、线性代数、概率论和常微分方程。

三条全书通用的记号约定，先在这里说定。**第一**， $\log$ 一律指自然对数（底为 e ），需要以 2 为底时会显式写成 $\log_2$ ；对应的单位见 0.5 节。**第二**， E 表示期望， $|\lambda|$ 表示复数的模长（实数时就是绝对值）。**第三**，排版上加粗的词是当段关键词；黄框是最需要记住的结论，绿框是直觉总结，红框是容易出错的细节，这个约定与后面各章一致。

0.1 你会什么、不用会什么

类别	具体内容	本笔记在哪里用到
默认已会	数学分析：极限、级数、Taylor 展开、凸函数与 Jensen 不等式的说法	证明里的放缩与取极限；第 0.6 节的变分下界
默认已会	线性代数：矩阵乘法、特征值与特征向量、对角化、半正定矩阵	第 1 章的 EDMD；第 3 至 5 章的协方差与谱分解
默认已会	概率论：随机变量、联合分布、条件分布、期望、方差、协方差	第 0.5 节起的全部信息量计算
默认已会	常微分方程： $\dot{x} = f(x)$ 的含义、数值积分的直观	第 1 章动力系统的设定
不要求	信息论（熵、互信息、率失真）	第 0.5 节从零补齐
不要求	动力系统与遍历理论（不变测度、混合性、吸引子）	用到时正文就地解释
不要求	泛函分析（希尔伯特空间、算子谱理论）	第 1 章只给有限维类比，无限维的严格细节不在需要范围内
不要求	机器学习实践（训练网络、调参、写过 VAE 代码）	第 0.7 节给概念最小包；第 6 章的算法只读不跑

怎么用这一章 如果你修过信息论或动力系统的课，可以只扫 0.3 节的命名约定（爆炸区、时间相干区、快速混合区）和 0.8 节的自测，然后直接进第 1 章。如果没有，建议按顺序读完，全章大约十页，后面的每一章都会回到这里的概念。

0.2 动力系统：状态怎么随时间走

先回答一个问题：“预测一个系统”到底是什么意思。

离散时间动力系统 一个状态空间 M （可以当成 $\mathbb{R}^n$ 的一个子集）和一个映射 $T: M \rightarrow M$ 。状态按

$$x_{n+1} = T(x_n)$$

演化：第 $n + 1$ 步的状态由第 n 步的状态完全决定。

为什么要有这个抽象：流体、天气、振子、种群数量，只要“下一步由当前一步决定”，就都写成这一个式子，后面的全部讨论对它们同时成立。**知道这个系统**，指的是知道 T ：给定初始状态 x_0 ，反复代入就得到整条轨迹 $x_0, x_1, x_2, \dots$ 。

连续时间的模型 $\dot{x} = f(x)$ (第 1 章的出发点) 通过离散化也能写成这个形式: 取定步长 h , 欧拉格式 $x_{n+1} = x_n + hf(x_n)$ 就是一个离散动力系统。本笔记两种情形都出现, 但推导全部在离散情形做; 离散与连续的换算 (特征值与增长率的对应) 会在出现处注明。

用一个具体映射做贯穿例子, 本笔记后面会多次回到它。

贯穿例子: logistic 映射

$$x_{n+1} = 4x_n(1 - x_n), \quad x_n \in [0, 1].$$

右边的 $4x(1 - x)$ 读作: 下一时刻的值由当前值乘上一个“增长因子 $4(1 - x)$ ”决定, x 越接近 1 增长因子越小。这是种群模型里最简单的非线性修正项, 这里只把它当 计算对象。对任何 $x \in [0, 1]$ 都有 $4x(1 - x) \in [0, 1]$, 所以状态永远留在 $[0, 1]$ 里。

从三个不同的初值各迭代八步 (保留四位小数):

步数 n	从 $x_0 = 0.2$ 出发	从 $x_0 = 0.25$ 出发	从 $x_0 = 0.2501$ 出发
1	0.6400	0.7500	0.7502
2	0.9216	0.7500	0.7496
3	0.2890	0.7500	0.7508
4	0.8219	0.7500	0.7484
5	0.5854	0.7500	0.7532
6	0.9708	0.7500	0.7436
7	0.1133	0.7500	0.7627
8	0.4020	0.7500	0.7240

同一个 T , 三种完全不同的长期行为。中间一列停在 0.75 (代回验证: $4 \times 0.75 \times 0.25 = 0.75$); 左列看不出任何收敛或周期的迹象; 右列在 0.75 附近来回振荡, 而且振幅一步一步变大。给这三种行为起名字:

不动点、极限环、混沌 **不动点**: 满足 $T(x^*) = x^*$ 的状态 x^* , 到了就不动, 如上面的 0.75。不动点可以是稳定的 (附近初值被拉回来), 也可以是不稳定的 (附近初值被推开, 如 0.2501 那一列, 每步偏离 0.75 越来越远)。

极限环: 每隔 p 步回到原值的状态序列 $x^*, T(x^*), \dots, T^{p-1}(x^*)$, 系统在一个有限圈上循环。

混沌: 初值的微小误差随步数**指数放大**。定量地说, 相邻两条轨迹的差距按 $e^{\lambda n}$ 增长, λ 叫 **Lyapunov 指数** (刻画初值误差平均放大速率的数)。 $\lambda > 0$ 就是混沌。logistic 映射在参数取 4 时 $\lambda = \ln 2$, 误差每步翻倍。

后面还会用到**吸引子**这个词: 指轨迹从大片初值出发、时间足够长之后都 靠近的那部分状态集合。稳定的不动点是吸引子, 极限环也是。logistic 映射 (参数取 4) 的轨迹不收敛到任何不动点或极限环, 长期在整个 $[0, 1]$ 里游走。

翻译: **预测这个系统** 等于知道 T 加上初值。但 logistic 的表说明, 即使 T 完全已知, 初值只能测到有限精度, 混沌系统的长期预测仍然会失效。第 1 章的诉求由此而来: 既然逐点预测靠不住, 就想办法理解系统的**结构**。

0.3 特征值复习：矩阵幂的行为由特征值决定

这一节复习线性代数里已经学过的内容，并给它接上动力学。全篇最重要的一个技术事实是：**矩阵的长期行为由特征值决定**。第4章“谱三分”（爆炸区、时间相干区、快速混合区）是本节内容在 Koopman 算子上的版本。

特征值与特征向量（复习） 方阵 A 的特征值 λ 与特征向量 $v \neq 0$ 满足

$$Av = \lambda v.$$

读法： v 这个方向在 A 作用下只被缩放 λ 倍，方向不变（ $\lambda < 0$ 时反向）。特征方向是矩阵“只做缩放”的方向，这就是它们能决定长期行为的原因。

数值例子。 取对角矩阵

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}, \quad x_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

对角矩阵的特征值就在对角线上： $\lambda_1 = 2$, $\lambda_2 = 1/2$ 。迭代 t 步：

$$x_t = A^t x_0 = \begin{pmatrix} 2^t \\ 2^{-t} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 2^{-t} \end{pmatrix}^t \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad A^t = \begin{pmatrix} 2^t & 0 \\ 0 & 2^{-t} \end{pmatrix}.$$

用日常语言读：第一个坐标每步乘 2， t 步后是 2^t ，爆炸；第二个坐标每步乘 $1/2$ ， t 步后是 2^{-t} ，消失。**模长大于 1 的特征值方向爆炸，模长小于 1 的消失，模长等于 1 的保持**。三档对应三个名字，第4章直接沿用： $|\lambda| > 1$ 叫**爆炸区**， $|\lambda| = 1$ 叫**时间相干区**， $|\lambda| < 1$ 叫**快速混合区**。

复特征值补一个例子。取

$$R = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad R^2 = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}, \quad R^4 = I.$$

R 的特征值是 $\pm i$ ，模长都是 1。 R 作用在平面上是旋转 90 度：幅度不增不减，每四步转回原处。这是“时间相干”的原型：模长为 1 的特征值给出**持续的周期振荡**。

一般情形（可对角化）：若 $A = PDP^{-1}$ ， D 是特征值排成的对角矩阵，则

$$A^t = PD^tP^{-1}.$$

读法：把 x_0 拆到各个特征方向上（乘 P^{-1} ），每个方向独立地按自己的 λ^t 缩放（ D^t ），再拼回来（乘 P ）。矩阵幂的全部长期行为都读得出来，这就是“谱是描述线性系统最有力的语言”的含义。

为什么是特征值决定长期行为 矩阵有 $d \times d$ 个元素，为什么长期行为只由 d 个特征值决定？把 A 换成 PDP^{-1} 之后， t 次迭代就是 t 次独立缩放的拼接，决定增长与衰减的量只有各个 λ^t 。特征向量（矩阵 P ）影响短时间的行为（第1章会看到非正规矩阵在短时间上出的问题，根源就在 P ）；**长时间的行为只看 λ 的模长**。本笔记讨论的信息随时间的保留与丢失都属于长期行为，所以特征值反复出场。

连续时间补充（对应第1章的 $\dot{x} = f(x)$ ）。线性化之后得到 $\dot{x} = Ax$ ，解是 $x(t) = e^{At}x_0$ ，特征值还是那些 λ ，但行为按 $e^{\lambda t}$ 读： λ 的**实部**大于 0 爆炸、小于 0 消失、等于 0 持续振荡。离散与连续之间只差一个换算：每步缩放因子 $\mu = e^{\lambda h}$ ，即 $\lambda = \ln(\mu)/h$ ，模长大于 1 的 μ 对应实部为正的 λ 。第4章说“特征值在单位圆上、圆内、圆外”，在连续时间的语言里对应“实部为零、为负、为正”，两种说法会交替出现。

0.4 Koopman 思想：跟踪观测函数，不跟踪状态本身

上一节结尾说，混沌系统的逐点预测注定困难。Koopman (1931) 换了一个观察角度：**不跟踪状态本身，跟踪状态的函数随时间怎么变**。

可观测量 可观测量是任何把状态映成实数的函数 $\varphi: M \rightarrow \mathbb{R}$ ，例如温度、总能量、某个坐标分量。实验里我们读到的都是 $\varphi(x_n)$ 的数值序列，很少直接拿到 x_n 本身。

Koopman 算子 对映射 $T: M \rightarrow M$ ，Koopman 算子 $\mathcal{K}$ 作用在观测量 φ 上，定义为

$$(\mathcal{K}\varphi)(x) = \varphi(T(x)).$$

读法： $\mathcal{K}\varphi$ 仍是一个函数，它在旧状态 x 处的取值，等于 φ 在推进一步之后的状态 $T(x)$ 处的取值。于是“读数序列”满足 $\varphi(x_{n+1}) = (\mathcal{K}\varphi)(x_n)$ ：想知道一个量随时间怎么变，就反复对它施加 $\mathcal{K}$ 。

$\mathcal{K}$ 对 φ 是线性的，一行就能验证：

$$\mathcal{K}(a\varphi_1 + b\varphi_2)(x) = (a\varphi_1 + b\varphi_2)(T(x)) = a\varphi_1(T(x)) + b\varphi_2(T(x)) = (a\mathcal{K}\varphi_1 + b\mathcal{K}\varphi_2)(x).$$

翻译：两个观测量的加权和推一步，等于各自推一步再加权。 T 本身可以是非线性的，但“复合后取值”这个操作对函数是线性的。这就是 Koopman 视角最大的收益：**非线性系统的演化被装进了一个线性算子**，于是上一节的全部结论（特征值决定长期行为）都可以搬过来。

有限维数值例子 (T 线性)。取 $T(x) = 2x$ ， $\varphi_{k(x)} = x^k$ ：

$$(\mathcal{K}\varphi_k)(x) = \varphi_{k(2x)} = (2x)^k = 2^k x^k = 2^k \varphi_k(x).$$

读法： φ_k 推一步等于自己放大 2^k 倍。 φ_k 是 $\mathcal{K}$ 的**特征函数**，特征值 2^k 。再看两个函数张成的空间：若 $\varphi(x) = ax + bx^2$ ，则

$$\mathcal{K}\varphi = 2ax + 4bx^2,$$

结果仍然落在 $\text{span}(x, x^2)$ 里，所以 $\mathcal{K}$ 限制在这个二维空间上就是矩阵 $\text{diag}(2, 4)$ 。系数向量 (a, b) 每步变成 $(2a, 4b)$ ，与上一节的矩阵幂例子同构。“Koopman 算子写成矩阵”指的就是这种情形：选好一组函数， $\mathcal{K}$ 在这组函数的系数上就是一个普通矩阵。

有限维数值例子 (T 非线性)。取 $T(x) = x^3$ ($x \geq 0$)，猜 $\varphi(x) = \ln x$ ：

$$(\mathcal{K}\varphi)(x) = \varphi(x^3) = \ln(x^3) = 3 \ln x = 3\varphi(x).$$

读法：一个非线性映射的 Koopman 算子照样有特征函数，特征值 3，观测量 $\ln x$ 每步乘 3。这个例子里特征值直接读出状态的增长速度： $x_{n+1} = x_n^3$ 时 $\ln x_n = 3^n \ln x_0$ 。

代价，用贯穿例子看。取 logistic 映射 $T(x) = 4x(1-x)$ ：

$$\mathcal{K}x = 4x - 4x^2, \quad \mathcal{K}x^2 = (4x(1-x))^2 = 16x^2 - 32x^3 + 16x^4, \quad \mathcal{K}x^4 = 256x^4 - 1024x^5 + \dots$$

读法：想留下观测函数 x ，就必须添上 x^2 ； x^2 又逼出 x^3 和 x^4 ；每一步都需要新的更高次函数，任何有限个函数的集合都无法在 $\mathcal{K}$ 下保持不变。结论：**非线性系统的 Koopman 算子一般是无穷维的**。实际计算必须先选定有限个观测函数（第 1 章称之为“字典”），在这个有限集合上做的一切都是近似，得到的特征值也只有近似的意义。

初学时常见的两个疑问，先在这里回答。**疑问一：既然 $\mathcal{K}\varphi = \varphi \circ T$ ， T 的非线性没有被消掉？**是的，非线性一点都没有消失，它被搬进了算子作用的那个空间：状态空间里的非线性映射 T ，换成了函数空间里的**线性算子** $\mathcal{K}$ 。换来的收益是 0.3 节的全部工具（特征值决定长期行为）对 $\mathcal{K}$ 可用，而对一般的非线性 T 不可用。**疑问二：想同时跟踪多个观测量怎么办？**取函数组 $\varphi = (\varphi_1, \dots, \varphi_m)^T$ ，每个分量各自按 $\mathcal{K}\varphi_i = \varphi_i \circ T$ 演化，向量情形就是逐分量作用。第 1 章的“字典”与第 6 章的潜在表示，都是这里的一组函数。

全篇会反复用到的对应关系 κ 的特征值承担上一节矩阵特征值的角色： $|\lambda|$ 是对应特征函数的 **每步放大倍数**。 $|\lambda| > 1$ 的模式爆炸， $|\lambda| = 1$ 的模式持续振荡， $|\lambda| < 1$ 的模式衰减。第 4 章将把这三档与“哪些信息被保留、哪些被丢弃”一一对应起来。

0.5 信息论三件套：熵、条件熵、互信息

论文把“表示有多简单”和“表示有多有用”各用一个数来刻画，这两个数都由本节的量构成。对数底取 e 时单位叫 **nat**（以 e 为底的对数算出的信息单位），底取 2 时单位叫 **bit**；正文用自然对数，两种单位只差一个常数因子 $\ln 2$ 。

0.5.1 熵：这个分布有多不确定

问题：给一个离散分布 $p_1, \dots, p_m$ ，用一个数描述“从它里面抽一个结果，有多难猜”。

熵

$$H(X) = - \sum_{i=1}^m p_i \log p_i.$$

读法：对每个结果取“ $-\log$ 出现概率”（概率越小， $-\log p_i$ 越大，即这个结果出现时带来的意外越多），再按概率加权平均。

数值。 均匀硬币 $p = (0.5, 0.5)$ ： $H = -\log 0.5 = 0.693$ nat（即 1 bit）。有偏硬币 $p = (0.9, 0.1)$ ： $H = -0.9 \log 0.9 - 0.1 \log 0.1 = 0.325$ nat (0.469 bit)。必然事件 $p = (1, 0)$ ： $H = 0$ 。性质：**均匀分布时熵最大，全部概率压在一个点上时熵为零**。翻译：熵衡量的就是“猜”的难度。

0.5.2 条件熵：知道一部分之后还剩多少不确定

问题：已知 X 的取值之后， Y 还剩多少不确定。

条件熵

$$H(Y | X) = \sum_x p(x) H(Y | X = x),$$

即对每个 $X = x$ 的情形算一遍 Y 的熵，再按 x 出现的概率加权平均。

0.5.3 互信息：知道 X 能削掉多少关于 Y 的不确定

问题： X 和 Y 有关联，但关联有多强。

互信息

$$I(X; Y) = H(Y) - H(Y | X).$$

读法： Y 原来的不确定度，减去知道 X 之后剩下的不确定度，差值就是 X 提供的关于 Y 的信息量。它永远非负，且 $I(X; Y) = 0$ 当且仅当 X, Y 独立。

记号读法： $I(X; Y)$ 里的分号把两个变量分开，两边的地位对称（ $I(X; Y) = I(Y; X)$ ）；条件互信息 $I(X; Y | Z)$ 竖线后面是“已经知道”的变量。后文出现的 $I(x_{n-1}; x_n)$ 读作“上一步的状态关于下一步的状态提供了多少信息”。

手算例子。 取 $X, Y \in \{0, 1\}$ ，联合分布

	$Y = 0$	$Y = 1$
$X = 0$	0.4	0.1

	$Y = 0$	$Y = 1$
$X = 1$	0.1	0.4

边缘分布都是 $(0.5, 0.5)$ ，所以 $H(X) = H(Y) = 1$ bit。给定 $X = 0$ ： Y 的分布是 $(0.8, 0.2)$ ，熵为 $-0.8 \log_2 0.8 - 0.2 \log_2 0.2 = 0.722$ bit；给定 $X = 1$ 时对称，也是 0.722 bit。于是

$$H(Y|X) = 0.722, \quad I(X; Y) = 1 - 0.722 = 0.278 \text{ bit}.$$

翻译： X 与 Y 同号的概率是 0.8，有关联但远没有完全确定对方，所以互信息介于 0 与 1 bit 之间。两个极端可以校准：若联合分布是四个格子各 0.25（独立），则 $H(Y|X) = 1$ ， $I = 0$ ；若只有对角线两个格子各 0.5 ($Y = X$)，则 $H(Y|X) = 0$ ， $I = H(Y) = 1$ bit，知道 X 就完全知道 Y 。

连续情形一句话。连续变量的熵可以依赖坐标系的选择（做非线性变换后熵会变），但互信息在两个变量各自做可逆变换时保持不变，所以它才是可以放心优化的量。联合高斯的情形有闭式结果，后面几章会直接代入：设 X, Y 联合高斯、相关系数 ρ ，则

$$I(X; Y) = -1/2 \log(1 - \rho^2).$$

读法： $\rho = 0$ （不相关）时互信息为零； $\rho \rightarrow \pm 1$ （一个几乎决定另一个）时趋于无穷。例如 $\rho = 0.9$ 时 $I = 0.83$ nat。这个公式只给结果，够用了。

0.5.4 两条后面证明反复用的事实

链式法则与数据处理不等式 链式法则：对任意三个变量，

$$I((x, z); y) = I(x; y) + I(z; y | x).$$

读法： (x, z) 合起来提供的关于 y 的信息，等于先由 x 提供的部分，加上知道 x 之后 z 额外提供的部分。调换 x, z 的顺序结果不变，第 2 章的推导正是利用这一点。

数据处理不等式：若 z 只由 x 生成（信息链 $x \rightarrow z \rightarrow y$ ），则

$$I(z; y) \leq I(x; y).$$

读法：加工过的数据不会比原料含更多关于 y 的信息，任何加工最多保持、通常会损失信息。第 2、3 章的各个“界”都源于这一条。

把本节用到论文的核心量上 论文的目标函数（第 1 章末与第 3 章）由两个互信息构成：

$$I(x_{n-1}; z_{n-1}) \text{ 要小}, \quad I(z_{n-1}; x_n) \text{ 要大}.$$

现在可以完全读懂它：第一项是“把状态 x_{n-1} 压成潜在表示 z_{n-1} 花掉了多少信息”，它对应“表示要简单”；第二项是“潜在表示里还留着多少关于下一步状态 x_n 的信息”，它对应“表示要有用”。用 0.5.3 节的手算方法，这两个量对任何给定的联合分布都能算出一个具体的数。剩下的困难是：论文里的变量是连续的、分布是未知的，这时两个互信息都算不出来。第 2 章的全部内容，就是把它们变成可以优化的量。

0.6 变分下界：算不动，就构造一个能算的量

问题： $I(z; y) = H(y) - H(y|z)$ 里的 $H(y|z)$ 需要对真实的条件分布 $p(y|z)$ 求期望，而 $p(y|z)$ 通常不知道，手里只有一个带参数、可以采样和求梯度的模型 $q(y|z)$ 。变分下界就是这时使用的标准构造。

需要的工具只有一条不等式。对任何两个分布 p, q ，定义 **KL 散度**（衡量两个分布差多远的量：用 q 当作 p 的编码方案，平均每个样本多付的代价；它不对称，但永远非负） $D_{\text{KL}}(p \parallel q) = E_{p[\log(\frac{p}{q})]}$ 。它的非负性来自 Jensen 不等式（ $\log$ 是凹函数，所以平均之后取 $\log$ 不超过先取 $\log$ 再平均）：

$$D_{\text{KL}(p \parallel q)} = E_p \left[\log \left(\frac{p}{q} \right) \right] \geq -\log E_p \left[\frac{q}{p} \right] = -\log 1 = 0.$$

由 $D_{\text{KL}(p \parallel q)} \geq 0$ 立刻得到 $E_p[-\log q] \geq E_p[-\log p] = H(p)$: 用任何别的分布 q 去编码 p 的样本, 平均代价不会低于用 p 自己。把它用在 $H(y|z)$ 上, 取 p 为真实分布、 q 为模型:

$$H(y|z) \leq E[-\log q(y|z)] \implies I(z; y) = H(y) - H(y|z) \geq H(y) + E[\log q(y|z)].$$

读法: 右边两项都能用样本估计 ($H(y)$ 与模型无关, 是常数; 第二项是对 $\log q(y|z)$ 求平均), 左边算不动。于是优化目标换成右边这个 **永远不超过 $I(z; y)$ 、又对参数可微** 的量。这种构造叫 **变分下界** (一个总不超过目标量、但可以计算的替代量), 它把“直接最大化一个算不出的量”换成“最大化一个能算的下界”。深度生成模型里同型的构造有一个通用名字: ELBO (证据下界), 第 2 章展开; 码率那一侧同样存在一个上界版本。第 6 章损失函数里的每一项都是这两种界的成员。

一个能完全手算的例子。 取 $y \in \{0, 1\}$ 均匀分布 ($H(y) = \ln 2$), z 也取两个值, 真实条件分布为 $P(y=0|z=0) = P(y=1|z=1) = 0.8$ 。按 0.5.3 节的手算, 真实的 $I(z; y) = 1 - 0.722 = 0.278$ bit。再看下界: 若模型输出常数 $q(y|z) = (0.5, 0.5)$, 则

$$H(y) + E[\log q(y|z)] = \ln 2 + \ln 0.5 = 0,$$

即什么都不懂的模型给出的下界是 0, 确实不超过真实的 0.278 bit。若模型把 q 调到与真实条件分布一致, 则 $E[\log q(y|z)] = -H(y|z)$, 下界恰好取等。整个优化过程就是把下界一步步抬高, 直到贴住真实的互信息; 由于下界永远不超过目标, 抬高它的过程中不会高估。

0.7 自编码器: 压缩、展开, 以及“塌掉”的担心

问题: 论文模型骨架 (第 1 章的 Koopman 自编码器、第 6 章的算法) 建立在这个结构上。

自编码器最小包 两个神经网络: **编码器** f_θ 把高维数据 $x \in \mathbb{R}^N$ (例如一张流场图) 压成低维向量 $z \in \mathbb{R}^d$ ($d \ll N$, 例如 $d=8$); **解码器** g_ω 把 z 展开回同维度的 $\hat{x}$ 。训练目标是

$$\mathcal{L} = \|x - g_\omega(f_\theta(x))\|^2 \quad \text{尽量小},$$

即“展开回去要和原来差不多”。没有人工标注, 输入自己当目标, 这叫自监督训练。

z 叫**潜在表示**, $\mathbb{R}^d$ 叫**潜在空间**。“潜在”指它不由数据直接给出, 是模型自己学出来的内部坐标。Koopman 版本在此之上多一条要求: 潜在表示按线性规律推进, $z_{n+1} = \mathcal{K}z_n$, $\mathcal{K}$ 是一个 $d \times d$ 矩阵 (第 1 章的 LRA 架构)。

后面各章还会反复出现 VAE (变分自编码器) 这个词。它与自编码器的差别只有一点: 编码器输出的 z 加了随机性, z 从一个以 $f_\theta(x)$ 的输出为中心的高斯分布里抽样, 训练目标随之换成 0.6 节的变分下界。为什么要加随机性: 确定性编码器会让“压缩了多少信息”这个量失去测量意义 (第 2 章会看到原因), 随机化之后 压缩程度才成为一个可以调节的旋钮。本笔记不需要 VAE 的任何实现细节, 只需要记住它是“带随机编码的自编码器”。

为什么大家担心潜在空间“塌掉”。 训练目标只约束“展开后像原来”, 完全不约束 d 个坐标都被用到。当解码器足够强时, 全部信息可以挤进一个坐标, 其余坐标对任何输入都输出近似同一个常数, 重构损失照样可以很小。这时名义上是 d 维表示, 实际只用了 1 维。

诊断它需要的量是**协方差谱**。取一批训练好的 z 样本, 算协方差矩阵

$$C_{ij} = E[(z_i - Ez_i)(z_j - Ez_j)],$$

读法： C 的对角线是各坐标的方差，非对角线是坐标之间的联合波动。协方差矩阵的特征值回答“方差分布在几个方向上”：若全部信息挤在一个方向，则归一化后 C 的特征值一个接近 1、其余接近 0；若 d 个方向都被均匀使用，则特征值全接近 $1/d$ 。

数值。 两个坐标的例子：归一化后 C 的特征值为 $(0.99, 0.01)$ ，方差几乎全在一个方向，对应“挤在一个坐标”；特征值为 $(0.5, 0.5)$ ，两个方向都被均匀使用。第 2 章将定义的“有效维度” $\exp(S)$ 对这两种情形分别给出约 1.06 与 2，即“名义二维的表示，实际分别用了约一个方向和两个方向”。第 2 章的“有效维度”（定义 11）把“实际用了几个方向”压缩成一个数，第 5 章的命题 5 用 von Neumann 熵正则对抗塌掉。这一节是那两处推导的全部背景。

0.8 阅读地图与自测

怎么读后面的章节。

- 第 1 章讲 Koopman 谱系，比较长。第一次读可以只读前四节（动力系统设定、Koopman 算子、三个代价、DMD/EDMD）和“六条分支的共同盲点”一节，分支二到分支六的细节可以回头再补。
- 第 2 章讲信息瓶颈。主线是定义 6 到 VIB 一节；高斯 IB 的闭式第一次可以跳过，只读每个黄色框里的结论。
- 第 3 至 5 章是论文的五条命题，是全文核心，建议顺序读。每个命题先读蓝色框，再看是否需要进入证明。
- 第 6 章算法与第 7 章实验，第一次读抓住损失函数总表即可。
- 第 8 章的横向比较与第 9 章的展望互相独立，读完第 5 章后可以任意选读；第 10 章附录的记号表与公式速查适合当工具随时翻。
- 任何时刻遇到不认识的符号：先查卷首的术语地图，再回本章对应小节。

符号速查（本章引入的、后文反复出现的）。

符号	含义	定义位置
T, x_n	动力系统的演化映射与状态	0.2 节
λ	特征值（矩阵或 Koopman 算子）	0.3 节
$\varphi, \mathcal{K}$	观测量与 Koopman 算子	0.4 节
H, I	熵与互信息	0.5 节
q, D_{KL}	变分模型与 KL 散度	0.6 节
z, f_θ, g_ω, C	潜在表示、编码器、解码器、协方差矩阵	0.7 节

自测。 能答上来就具备阅读条件；答不上来就回到对应小节。

- logistic 映射从 $x_0 = 0.25$ 出发永远停在 0.75，从 $x_0 = 0.2501$ 出发却慢慢离开 0.75。这组数字分别对应什么概念？（0.2 节：不动点、不稳定性。）
- 矩阵 A 的特征值模长分别为 0.8 与 1.1。 A^t 的长期行为如何？三档各叫什么名字？（0.3 节。）
- Koopman 算子作用在什么对象上？“它对 φ 是线性的”如何用一行验证？（0.4 节。）
- 对映射 $T(x) = x^3$ ，哪个函数是 Koopman 算子的特征函数？特征值是多少？（0.4 节： $\ln x$ ，特征值 3。）
- 熵在什么分布下最大、什么分布下最小？（0.5 节。）
- 手算： $P(X=0, Y=0) = P(X=1, Y=1) = 0.4$ ，其余两个格子各 0.1。 $I(X; Y)$ 等于多少 bit？（0.5 节：0.278。）
- 为什么“最大化互信息”这个目标防不住潜在空间塌掉？用哪个量能诊断出塌掉？（0.7 节：互信息只管总量；协方差谱或有效维度。）
- 变分下界由哪两样东西构成：一个什么样的目标，和一个什么样的替代量？（0.6 节。）

1 第一根线索：Koopman 谱系，从“线性化的梦”到“学一个不变子空间”

1.1 一个古老的两难：非线性动力学

假设你面对一个物理系统，流体绕过圆柱、天气演化、摆锤、软体机器人。如果它是连续时间的，你写下的通常是

$$\dot{x} = f(x), \quad x \in M \subseteq \mathbb{R}^n,$$

这里 $x \in \mathbb{R}^n$ 是系统的**状态**（一组能完全描述当前情况的数，比如位置和速度）， M 是状态所在的集合（一个 n 维流形，这里可以粗略理解成 $\mathbb{R}^n$ 的一个子集）， f 是一个把状态映到“该往哪个方向变”的非线性函数。离散时间版本写成 $x_t = T(x_{t-1})$ ， $T: M \rightarrow M$ 是相邻两步之间的映射。

线性系统“好”在哪里，值得具体说三点。叠加原理成立， $T(ax + by) = aT(x) + bT(y)$ ，所以把两个解加起来还是一个解；解可以写成矩阵幂 $x_t = A^t x_0$ ，一步到位的公式；把 A 做特征分解之后，长期行为就从特征值的模长直接读出来， $|\lambda| < 1$ 的模式衰减， $|\lambda| = 1$ 的模式振荡， $|\lambda| > 1$ 的模式发散。控制理论里的 LQR、Kalman 滤波、极点配置，全都依赖这三条。

非线性把这一切拿走。 T 不能对角化，没有叠加，长期行为由混沌、极限环、多吸引子（吸引子指系统长期被吸过去的那部分状态集合）支配；在正 Lyapunov 指数下，逐点轨迹预测的误差随时间指数发散。

传统出路两条，都不令人满意。**数值积分**（Runge-Kutta）能算出轨迹，但你始终只有一条轨迹，没有关于系统结构的理解，而且每步都要跑一遍 f 。**局部线性化**（在不动点，即满足 $T(x) = x$ 、系统停在那里就不再变化的状态附近做 Taylor 展开）在混沌系统里很脆弱，因为轨迹会离开任何固定邻域。

Koopman 理论提供的是第三条路，思路出人意料地简单。

1.2 Koopman 算子：换一个空间，把非线性搬进函数里

Koopman 算子的基本思路 不要试图让状态 x 线性演化；让状态的函数线性演化。

在写公式之前，先把“可观测量”这个词说清楚，因为后面所有推导都建立在它上面。

什么叫“可观测量” 系统的状态 x 是一个 n 维向量，理论上是完整的，但它本身往往是抽象的，甚至根本不可测量（比如“某流体微元的速度”）。

可观测量（observable，也叫观测函数）指的是任何一个把状态映成实数的函数

$$\varphi: M \rightarrow \mathbb{R}.$$

它可以是状态的一个分量（例如“ x 方向的速度 x_1 ”），也可以是从状态算出来的任何量（例如“某个区域的平均温度”“系统的总动能”“某一点的涡量”）。凡是你真能从系统里读出数值的東西，都是一个可观测量。

之所以要区分状态和可观测量，是因为实验上我们**只能拿到读数**，拿不到状态本身。而 Koopman 理论的全部技巧，就是不去追踪状态 x ，转而追踪这些读数随时间怎么变。

形式化。设 μ 是状态空间 M 上的一个测度（可以理解成“系统长期待在哪里”的分布），令

$$H = L^2(M, \mu)$$

表示所有**平方可积**的可观测量构成的希尔伯特空间（希尔伯特空间就是完备的内积空间，可以当作有限维欧氏空间在函数上的推广）。所谓平方可积，是指 $\int |\varphi(x)|^2 d\mu(x) < \infty$ 。这个条件让空间有内积 $\langle \varphi, \psi \rangle = \int \varphi(x)\psi(x)d\mu(x)$ ，从而可以谈“两个观测量的夹角”“相互正交”这类几何概念。

这里为什么需要测度 μ , 而不是普通的积分 如果不指定 μ , “平方可积”就没有意义(对哪个权重积分?). 更重要的是, μ 决定了哪些函数被当作“同一个函数”: 两个只在零测集上不同的 φ 在 $L^2(M, \mu)$ 里是同一个元素。

具体到动力学, 取 μ 为系统的**不变测度**(系统长期停留的分布)最自然, 因为这时候“重要与否”是按系统的实际行为来衡量的。

定义 1 (Koopman 算子, Koopman 1931) 对离散映射 $T: M \rightarrow M$, Koopman 算子 $\mathcal{K}: H \rightarrow H$ 定义为

$$(\mathcal{K}\varphi)(x) = \varphi(T(x)), \quad \forall \varphi \in H, x \in M.$$

$\mathcal{K}$ 的作用是让 φ 在演化后的新位置上重新取值, φ 本身的形状不变。

关键在它是**对函数**作用的, 而且对 φ 是线性的。把两个函数加起来再推一步, 等于各自推一步再相加:

$$\mathcal{K}(a\varphi_1 + b\varphi_2)(x) = (a\varphi_1 + b\varphi_2)(T(x)) = a(\mathcal{K}\varphi_1)(x) + b(\mathcal{K}\varphi_2)(x).$$

左边是“把 φ_1 与 φ_2 的混合”整体推一步, 右边是先各自推一步再按同样比例混合。两者相等, 这就是线性。

复合映射 T 本身是非线性的, 但对 φ 而言“复合”这个操作是线性的。Koopman 理论的全部技巧都在这一点上: 非线性被移入观测函数, 剩下的是线性算子。

连续时间下对应 Koopman 半群 $\mathcal{K}_t\varphi = \varphi \circ F_t$ (F_t 是流), 其无穷小生成元是沿向量场的李导数

$$\mathcal{L}\varphi = \lim_{t \rightarrow 0} \frac{\mathcal{K}_t\varphi - \varphi}{t} = \nabla\varphi \cdot f.$$

$\mathcal{L}$ 是无界线性算子, 定义域是光滑函数。它把“演化的瞬时速率”写成了一个线性作用。

这个定义带来什么 解非线性 ODE 被换成了研究一个线性算子。线性的好处全都回来了: 叠加、谱分解、以及 $\varphi_{j(x_t)} = \lambda_j^t \varphi_{j(x_0)}$ 这样的闭式解。非线性没有消失, 它被编码进 φ_j 里了。

1.3 价格: 无限维、可能没有特征值、而且非正规

代价有三个层次, 越往后越隐蔽。

(1) **无限维**。只要 M 不是有限集, H 就是无限维的。你不能把 $\mathcal{K}$ 写成矩阵, 不能用数值线性代数。实践中只能把它投影到有限维子空间, 而投影本身是近似。

(2) **谱可以是连续的**。这里先解释“谱”是什么。

什么叫“谱” 对一个方阵 (更一般地, 对一个线性算子), **谱**就是它全部特征值构成的集合, 在复平面上的若干点。而“谱分解”指的是: 把任意向量拆成各个特征方向上的分量之和, 每个分量随时间是按自己的特征值增长、衰减或旋转的。

线性系统理论里几乎所有结论 (稳定性、振荡频率、长期行为) 都是从谱读出来的。所以说“谱”是描述线性系统最有力的语言并不夸张。

矩阵的谱总是一些离散的点。但 Koopman 算子是无限维的, 它的谱不一定还长这样。Koopman 与 von Neumann 1932 年指出: 对**混合性**系统 (粗略说, 就是时间足够长之后 任何初始状态都会被混合、不再留下影响的系统), $\mathcal{K}$ 的谱可以是**纯连续的**, 像一整段区间那样铺在复平面上, **根本没有特征值**。

这时候“找几个主导模式来概括系统”这件事就在数学上落空了。这一点在混沌系统里很常见, 也是后来 PFNN 这类工作必须特殊处理连续谱的原因。

(3) **非正规性**。对“好”的矩阵（对称矩阵，或更一般地满足 $AA^* = A^*A$ 的所谓正规矩阵），特征值就完全决定了系统怎么演化：各模式互不干扰，谁衰减谁增长一目了然。

$\mathcal{K}$ 一般不满足 $\mathcal{K}\mathcal{K}^* = \mathcal{K}^*\mathcal{K}$ ，也就是**非正规**。非正规的后果是：**特征值不再能预测瞬态行为**。某些模式会先把能量窜得很高，然后才衰减下去，尽管光看特征值，它“应该在衰减”。剪切流里这非常常见，也是深度 Koopman 模型在长时预测中不稳定的一个隐藏来源。

还有一层更隐蔽的困难：**即使你找到了有限维子空间**，它很可能根本不被 $\mathcal{K}$ 保持。

定义 2 (Koopman 不变子空间) 子空间 $\mathcal{S} \subseteq H$ 称为 $\mathcal{K}$ 的不变子空间，如果 $\mathcal{K}\mathcal{S} \subseteq \mathcal{S}$ 。若 $\mathcal{S} = \text{span}(\psi_1, \dots, \psi_d)$ ，则不变性等价于存在矩阵 $K \in \mathbb{R}^{d \times d}$ 使得

$$\mathcal{K}\psi_i = \sum_{j=1}^d K_{ij}\psi_j, \quad i = 1, \dots, d,$$

即 $\mathcal{K}\Psi(x) = K^T \Psi(x)$ ，其中 $\Psi(x) = (\psi_1(x), \dots, \psi_d(x))^T$ 。

公式里那个 K^T 就是我们要找的“有限维线性表示”。它存在当且仅当子空间不变。

1.4 从数据里估计这个子空间：DMD 与 EDMD

最朴素的做法：固定一组观测函数（“字典”） $\psi_1, \dots, \psi_d$ ，假设它们的演化落在这个集合张成的空间里。这样 K 就可以用数据拟合出来，退化成最普通的线性回归。

给定 m 个样本对，令

$$\hat{X} = \begin{pmatrix} \Psi(x_1)^T \\ \vdots \\ \Psi(x_m)^T \end{pmatrix}, \quad \hat{Y} = \begin{pmatrix} \Psi(x_2)^T \\ \vdots \\ \Psi(x_{m+1})^T \end{pmatrix},$$

最小二乘解是

$$K^T = \hat{Y}^T \hat{X} (\hat{X}^T \hat{X})^\dagger, \quad \text{即} \quad K = \hat{Y}^T \hat{X} (\hat{X}^T \hat{X})^\dagger,$$

其中 $A^\dagger$ 表示 Moore–Penrose 伪逆（不可逆情形下的“最小二乘求逆”，这里只需知道它给出上面回归问题的闭式解）。这就是 **EDMD**（扩展动态模式分解）。当字典取恒等映射 $\psi_{i(x)} = x_i$ （直接观测状态）时，它退化成 **DMD**（动态模式分解），Schmid 在流体力学里提出的方法，2015 年 Williams 等人给出了它与 Koopman 算子的理论联系（**A data-driven approximation of the Koopman operator: extending DMD**；同脉络的后续工作还有把这一近似做成算子学习框架的 Koopman neural operator 一线）。

这套骨架后来几乎没变过，值得记住：

1. 字典 Ψ 把状态“抬升”到高维特征空间；
2. 在那个空间里，动力学**近似**线性，由矩阵 K 描述；
3. K 的特征值/特征向量给出 Koopman 谱，可以直接解读系统行为。

EDMD 的两个问题 第一，字典是人选的。多项式、RBF、时间延迟坐标……选错了就捕捉不到非线性。更糟的是加得越多越容易过拟合。Otto & Rowley (2019) 给过一个尖锐的例子：在一个本质只有两个模式、用两个观测就能精确描述的系统里，多加一个“多余”的观测函数，即使拟合残差小到 10^{-15} ，也会凭空冒出 $\{1.0413, 0, 0.3515\}$ 这样的伪特征值。

第二，它假设状态本身落在学到的不变子空间里（因为要从 Koopman 模式线性重构）。对多不动点系统，这一点无法满足，见下一节。

1.5 有限维不变子空间的根本困难

Brunton et al. (2016) 的结论 若一个有限维 Koopman 不变子空间包含状态映射 $x \mapsto x$ (即状态向量本身是观测的线性组合), 则原系统 $x^+ = T(x)$ 必然与某个有限维线性系统**拓扑共轭**。

而拓扑共轭于线性系统的动力学最多只有一个孤立不动点。因此**任何有多个不动点、或有复杂吸引子的系统, 都不可能**被一个包含状态的有限维线性 Koopman 子空间精确表示。

什么叫“拓扑共轭” 两个动力学系统“拓扑共轭”, 意思是存在一个**连续且可逆**的坐标变换, 把其中一个系统一一对应地变成另一个, 并且保持时间顺序 (“ t 时刻的状态”仍被映到“ t 时刻的状态”)。

通俗说: 两个系统**样子不同, 但就是同一个系统**, 只是换了套坐标去描述。所以“ T 拓扑共轭于一个线性系统”等于说: T 实际上是线性的, 它在线性坐标下就是同一件事。

直觉: 有限维线性系统 $x^+ = Ax$ 的不动点只能落在原点 (A 可逆) 或一个子空间上 (A 退化)。若 T 有两个孤立不动点, A 也得有两个, 不可能。

两条数学上的逃逸路线, 它们解释了后面所有方法的设计动机:

1. **放弃包含状态**。只用非线性观测构造子空间, 让状态作为观测的线性组合“近似”重构。几乎所有深度 Koopman 方法都走这条路, 这解释了为什么它们的解码器通常是非线性的。
2. **允许不连续** (Koopman 本人提出)。不动点附近的特征函数在不同吸引盆上取不同值。代价是收敛性无保证, 而且这类函数极难学。

这个结论意味着什么 深度 Koopman 学到的实际上是 Koopman 算子的一个**有损投影**。既然有损, 就必然存在信息丢失。“丢了多少”“丢的是什么”于是成了必须回答的问题。这也预告了后面为什么要把表示学习而不是算子逼近作为出发点。

1.6 让神经网络来选字典: 从 Takeishi 到 Koopman 自编码器

1.6.1 Takeishi et al. (2017): 第一次用神经网络学观测函数

EDMD 的困难归根结底是“字典是人选的”。而神经网络最擅长的正是**学一个映射**。Takeishi 等人 (NeurIPS 2017, **Learning Koopman Invariant Subspaces for DMD**) 第一次把这件事做成了端到端的: 用神经网络参数化观测函数 Ψ_θ , 同时拟合 K , 目标是让学到的子空间尽量不变。损失写成

$$\mathcal{L} = \underbrace{\|Y_1 - AY_0\|_F^2}_{\text{线性前瞻}} + \gamma \underbrace{\mathcal{L}_{\text{rec}}}_{\text{重构}}, \quad A = Y_1 Y_0^+,$$

其中 Y_0, Y_1 是观测矩阵。他们证明 (Theorem 1): **残差为零当且仅当学到的子空间是不变的**。这是很深的一条观察, 它把“学不变子空间”变成了“把残差压到零”。但同时它也暴露了一个问题: 残差为零是一个**太容易满足的目标** ($\Psi \equiv \text{常数}$ 就让残差为零), 所以必须有重构项把解钉住, 而两者之间如何平衡是一个自由参数。

1.6.2 Otto & Rowley (2019): Koopman 自编码器 (LRA)

真正被广泛采用的骨架是 Otto & Rowley 的 **LRAN** (线性递归自编码器网络)。架构如下:

$$x_t \xrightarrow{f_\theta \text{ 编码器}} z_t \in \mathbb{R}^d \xrightarrow{\mathcal{K}_\psi \text{ 线性推进}} z_{t+1} \xrightarrow{g_\omega \text{ 解码器}} \hat{x}_{t+1}.$$

三个部件的分工必须说清楚, 否则很容易误解:

- **编码器 f_θ 和解码器 g_ω** 都是深的非线性网络 (原文用 ELU, 一种常用的神经网络激活函数);
- **线性性只发生在潜在动力学里**: $z_{t+1} = \mathcal{K} z_t$, $\mathcal{K}$ 是一个 $d \times d$ 矩阵;

- 瓶颈是**维度** d 小，不是“线性层”。这一点常被误读，线性性来自 Koopman 算子的定义，不是来自某种架构选择。

损失函数（原文 Eq. 25）是**多步一致性**：

$$\mathcal{L} = \mathbb{E} \left[\frac{1}{1 + \beta} \left(\sum_{\tau=0}^{T-1} \frac{\delta^\tau}{N_1} (\delta) \frac{\|x_{t+\tau} - \hat{x}_{t+\tau}\|^2}{\|x_{t+\tau}\|^2 + \varepsilon_1} + \beta \sum_{\tau=1}^{T-1} \frac{\delta^{\tau-1}}{N_2} (\delta) \frac{\|z_{t+\tau} - \hat{z}_{t+\tau}\|^2}{\|\hat{z}_{t+\tau}\|^2 + \varepsilon_2} \right) \right] + \Omega,$$

其中第一项是多步解码重构误差，第二项是**潜在一致性**误差，它比较“由 $\mathcal{K}^\tau z_t$ 滚出来的潜在表示”与“把真实未来状态 $x_{t+\tau}$ 编码得到的潜在表示”（记 $\hat{z}_{t+\tau} = f_{\theta}(x_{t+\tau})$ ）。 $\delta \in (0, 1]$ 对远期步骤打折。

为什么要多步，而不是一步 因为非正规系统里，一些小振幅但“高度可观测”的特征会在若干步之后把能量注入大模式。如果只在相邻快照上训练（一对一对地拟合），这些特征会被当作噪声丢弃，但它们在多步预测里会显形。多步一致性强行把它们保留进字典。

LRA 留下的问题很明确，而且它们全都不是“调参问题”：

1. $\mathcal{K}$ 没有**稳定性约束**。轻微不稳定的模式 ($|\lambda| > 1$) 短期可容忍，长期是灾难。
2. d, δ, β, T 都没有**原则性依据**。
3. 没有任何东西防止**潜在冗余或坍塌**。所有 d 个模式都被同等训练，即使只有少数几个是真的。

后两条正是本文要处理的问题。第一条由后续工作从不同角度处理，下面按时间顺序展开这棵树的所有主要分支。

1.7 在 LRA 之上的六个分支




图 1 Koopman 学习的谱系。每条分支都是对 LRA 留下的某个问题的一个回答，但它们全都把正则项建立在一个具体的领域先验上，而不是一个可迁移的原则。

1.7.1 分支一：把稳定性写进参数化 (Pan & Duraisamy 2020)

Pan & Duraisamy 处理的是 LRA 的第 1 个问题。他们不在损失里加稳定性惩罚，而是**改参数化**：把 $\mathcal{K}$ 限制成三对角形式

$$\mathcal{K}_{\text{stable}} = \begin{pmatrix} -\sigma_1^2 \zeta_1 & & \\ -\zeta_1 - \sigma_2^2 & \zeta_2 & \\ & -\zeta_2 & -\sigma_3^2 \\ & & \ddots \end{pmatrix}, \quad \sigma_i \in \mathbb{R}, \zeta_i \in \mathbb{R}.$$

对角元 $-\sigma_i^2 \leq 0$ ，非对角元反对称。这样的矩阵特征值实部必定非正，**任何一组参数值都是稳定的**。他们进一步证明：任何实特征值非正的可对角化矩阵，在实数域上都相似于某个这样的 $\mathcal{K}_{\text{stable}}$ ，所以表达力没有损失。

此外他们把 SVD-DMD 嵌入自编码器作为“线性先验”，只学残差； $\mathcal{K}$ 初始化为 DMD 估计。动机是：纯非线性参数化会产生“过度复杂”的伪特征函数（例如 $\varphi_j = y_j^{2n_j+1}$ 会带来特征值 $(2n_j+1)\lambda_j$ ，这在 Koopman 理论里是已知的非唯一性问题）。

这一分支的局限 它假设特征值实部非正，因此**排除了确实不稳定的系统**，也排除了瞬态增长。更关键的是它自己承认：**不处理连续谱**，而连续谱恰恰是混沌系统拥有的东西。

而且它仍然只控制谱的位置，不控制潜在表示里有多少信息、分布在几个方向上。

1.7.2 分支二：一致性约束 (Azencot et al. 2020)

Azencot 等人的 CKA（一致 Koopman 自编码器）处理的是“前向模型无法反向预测”的问题。架构上有两个无偏置线性层：前向 C 与后向 D ，即

$$\hat{f}_{k+1} = \chi_d \circ C \circ \chi_e(f_k), \quad \tilde{f}_{k-1} = \chi_d \circ D \circ \chi_e(f_k).$$

他们的核心贡献是一条**一致性损失**（原文 Eq. 12）：

$$\mathcal{E}_{\text{con}} = \sum_{k=1}^{\kappa} \left[\frac{1}{2k} \|D_{k*} C_{*k} - I_k\|_F^2 + \frac{1}{2k} \|C_{k*} D_{*k} - I_k\|_F^2 \right],$$

其中 D_{k*} 是 D 的前 k 行， C_{*k} 是 C 的前 k 列。

为什么是“分级的”前主子矩阵，而不是简单的 $\|DC - I\|_F^2$ 因为后向损失只更新 D ，不会更新 C ，所以不加约束时 C 和 D 完全解耦。而连续时间下可逆性等价于 $DC = I$ ；但在**离散采样**的设定下，正确的条件是一串嵌套的主子矩阵等式，所以损失是对 $k = 1, \dots, \kappa$ 的求和。

效果是把 $\mathcal{K}$ 的特征值**推向单位圆**（“准稳定”），而不是像 Pan 那样硬性限制在左半平面。

这一分支的局限 要求后向映射存在，扩散系统就满足不了（他们自己的负结果：给 Euler 流加入扩散后 CKA 变差）。一致性只在潜在空间的前 $k \times k$ 块上强制。权重 λ_* 手调。**同样地：没有任何东西控制潜在内容。**

1.7.3 分支三：变分分支，不要解码器，用一个谱分数 (VAMPnets)

上面两条分支都在 LRA 的框架内打补丁。VAMPnets (Mardt et al. 2018, Nature Communications) 走的是另一条路线，而且和本文的关系最密切。

VAMPnets 的动机 它来自分子动力学，原本的流水线是“手工特征 $\rightarrow$ 降维 $\rightarrow$ 聚类 $\rightarrow$ 估计 Markov 状态模型 (MSM)”。每一步错了都会污染后面（误差传播）。问题是：能不能端到端地学？

架构是两个“叶”(lobe) χ_0, χ_1 ，分别作用在 x_t 和 $x_{t+\tau}$ 上，并假设线性传播假设 $\mathbb{E}[\chi_1(x_{t+\tau})] \approx K^T \mathbb{E}[\chi_0(x_t)]$ 。

最小二乘目标本身是病态的 因为常数特征 $\chi \equiv 1$ 给出零误差，但它不携带任何动力学信息。（这和 Takeishi 的“残差为零太容易满足”是同一个病。）

修法就是 **VAMP-2**（变分方法 for Markov 过程的二范数分数）分数：

$$\hat{R}_2[\chi_0, \chi_1] = \left\| C_{00}^{-1/2} C_{01} C_{11}^{-1/2} \right\|_F^2, \quad C_{00} = \mathbb{E}[\chi_0 \chi_0^T], C_{01} = \mathbb{E}[\chi_0 \chi_1^T].$$

其中各个 C 是协方差矩阵（一批向量的各坐标之间的联合波动，对角线是各坐标的方差；第 0 章末节有最小包）。

这个量的意义是：**它是两个特征集之间典型相关系数（canonical correlations）的平方和，等价于被这两个子空间捕捉到的 Koopman 奇异值的平方和 $\sum_i \sigma_i^2$ 。**变分定理保证它是 Koopman 算子谱内容的一个下界，最大化它就会把子空间推向主导奇异函数。

VAMPnets 与 Koopman 自编码器的三点区别

1. 没有解码器，也没有重构项。训练信号是一个谱下界，直接作用于算子本身。
2. 输出层用 Softmax（把任意实数向量变成满足 $\chi_i \geq 0, \sum_i \chi_i = 1$ 的概率表），激活值读作“隶属概率”， K 成为模糊 MSM 的转移矩阵，传播概率密度。这带来了一个额外的好处：模型的统计性质直接可解释（implied timescales $t_i = -\tau / \ln|\lambda_i|$ 、Chapman–Kolmogorov 检验 $K(n\tau) = K^{n(\tau)}$ ）。
3. 潜在空间的目标是**最大化对 Koopman 奇异值的捕捉**，而不是重构输入。

它的问题在于：**VAMP-2 是一个标量分数，对“信息分布在几个方向上”不敏感。**一个只捕捉到一个极强的奇异值的子空间，和一个均匀捕捉到十个中等奇异值的子空间，在这个分数上可能一样好。本文用 von Neumann 熵解决的就是这个问题。

1.7.4 分支四：变分 Koopman 模型（Wu et al. 2017）

同一时期还有一支把“变分”推广到非平衡数据的工作。问题背景是：VAC/TICA 这类方法用对称的协方差估计 $C(0), C(\tau)$ ，这要求采样点服从平衡分布。而实际上 MD 轨迹常常从非平衡起点出发，此时变分下界不再成立。

关键洞察是： $K = C(0)^{-1}C(\tau)$ 恰好就是 Koopman 算子的有限维近似，而 K 可以从非平衡数据一致地估计出来，因为

$$\mathbb{E}[\chi_{i(x_{t+\tau})} | x_t] \approx k_i^T \chi(x_t)$$

是关于采样分布 ρ 的回归，最小二乘解 $\arg \min_K \|XK - Y\|^2 = \hat{C}(0)^{-1}\hat{C}(\tau)$ 最小化了 ρ 加权的误差。随后用一个重权向量 u 把非平衡样本“重加权”成平衡样本，再解广义特征值问题 $C(\tau)B = C(0)BA$ ，读出特征值 $\lambda_i = e^{-\tau/t_i}$ 与慢变量。

这一支与已有方法的关系 MSM = 示性基，TICA = 线性基，线性变分方法 = EDMD，它们是这个框架的特例。它把“Koopman 矩阵”同时当成**动力学模型、密度传播器、以及把非平衡数据转成平衡谱估计的重加权装置**。代价是它专注在谱估计的正确性上，同样不控制潜在表示的容量分配。

1.7.5 分支五：统计学习理论视角（KORR 与 KKR）

前四条分支都在改进估计，但没有人问“这个估计的统计风险是什么”。Kostic 等人（2022, NeurIPS）把 Koopman 学习放进统计学习理论。

先解释两个词。

什么叫 RKHS 与风险 RKHS (再生核希尔伯特空间)：一个函数组成的希尔伯特空间，但它有个特殊性质，在某点 x 取值这个操作是连续的，因此可以用内积写出来： $f(x) = \langle f, k(x) \rangle$ 。这里 k 叫核函数。好处是：你不需要显式写出特征是什么，只要给出核 k ，空间就被确定了。这是核方法 (SVM、核回归、KRR/KKR) 能工作的技术基础。

风险 (risk)：在统计学习里，“风险”就是期望损失。这里特指“把算子 G 用在特征上之后，一步预测的期望平方误差”。最小化风险就是找最好的 G 。

设定：马尔可夫链（下一时刻的分布只依赖当前时刻的随机过程），不变测度 π （即系统长期停留的概率分布），转移算子 A_π 作用在 L_π^2 上。限制到 RKHS $\mathcal{H}$ （特征映射 φ ，核 k ），定义风险

$$\mathcal{R}(G) = \sum_i \mathbb{E}_{x \sim \pi} \mathbb{E} \left[\left| h_i(X_{t+1}) - (Gh_i)(X_t) \right|^2 \mid X_t = x \right],$$

即在 $\mathcal{H}$ 的一组标准正交基上的累积一步预测误差。它分解为

$$\mathcal{R}(G) = \mathcal{R}_0 + \mathcal{E}(G), \quad \mathcal{R}_0 = \|S_\pi\|_{\text{HS}}^2 - \|Z_\pi\|_{\text{HS}}^2, \quad \mathcal{E}(G) = \|Z_\pi - S_\pi G\|_{\text{HS}}^2.$$

于是 Koopman 算子回归就是 $\min_{G \in \text{HS}(\mathcal{H})} \mathcal{R}(G)$ 。Tikhonov 正则给出 KRR (Koopman 岭回归) $\hat{G}_\gamma = \hat{C}_\gamma^{-1} \hat{T}$ (线性核 $\rightarrow$ DMD, 字典 $\rightarrow$ EDMD)。他们还提出降秩回归 (RRR)

$$\hat{G}_{r,\gamma} = \arg \min \{ \hat{\mathcal{R}}(G) + \gamma \|G\|_{\text{HS}}^2 : \text{rank}(G) \leq r \},$$

这是带显式秩约束的风险最小化。理论保证：定理 1 说明 Koopman 模式分解与特征值的误差被 $\|Z_\pi - S_\pi G\|$ 控制，也就是被 $\sqrt{\mathcal{E}(G)}$ 控制。

Bevanda 等人 (2023, NeurIPS) 的 KKR (Koopman 核回归) 则指出了一个问题。

KKR 的批评：EDMD/KORR 只在一个时间点上强制不变性 所有有限特征方法都固定特征映射 g ，只回归 A ，而且只最小化单一时间截面上的一步误差。于是 Koopman 不变性只是近似满足，“流形动力学泄漏出去” (spectral pollution)，多步预测随之退化。

KKR 的修法是让不变性由构造保证。他们用不变性变换 (Lemma 1)

$$\varphi_\lambda = \mathcal{I}_\lambda^T g(x) = \int_0^T e^{-\lambda(\tau-t)} g(F^{\tau(x)}) d\tau,$$

它把任意 g 变成特征值 λ 对应的 Koopman 特征函数。对应的 Koopman 特征函数核是

$$K^\lambda(x_T, x_{T'}) = \int_0^T \int_0^T e^{-\lambda(\tau-t)} k(x_{T(\tau)}, x_{T'}(\tau')) e^{-\lambda^*(\tau'-t)} d\tau d\tau',$$

它的 RKHS 对特征函数是通用的。对一组合适的特征值求和得到 Koopman 核 $\mathcal{K} = \sum_j K^{\mu_j}$ 。优势是：不变性精确成立（与优化结果无关）、通用性、以及一致性（定理 2： $\|M - \hat{M}\| \rightarrow 0$ ，不只是强算子拓扑收敛）。

统计分支的局限 这一支给出了最完备的理论，但它回答的是“如何正确地估计算子”，不是“潜在表示应该长什么样”。它的假设（有界 RKHS 范数、平稳性）也限制了适用范围。它同样没有给“潜在维度该多大”“信息该怎么分配”提供准则。

1.7.6 分支六：结构分支，组合、时间序列、图

CKO (Li et al. 2020, ICLR) 处理的是“物体数量变化”的场景（绳子 $5 \rightarrow 9$ 个质点，测试时 $10 \rightarrow 14$ 个）。它用 GNN 编码器生成物体中心表示 $g_i^t \in \mathbb{R}^m$ ，再让动力学分块线性：

$$g^{t+1} = Kg^t + Lu^t, \quad K = \sigma \times \hat{K}, \quad \sigma \in \mathbb{R}^{N \times N \times h}, \hat{K} \in \mathbb{R}^{h \times m \times m}.$$

其中 σ 是一个 one-hot 索引张量 (one-hot: 只有一个分量是 1、其余全为 0 的向量), 把每个 (i, j) 块分配给某个类型, $\hat{K}$ 存 h 个共享子矩阵。参数量从 $N^2 m^2$ 降到 hm^2 , 与 N 无关。

训练目标是 $\mathcal{L} = \mathcal{L}_{\text{ae}} + \lambda_1 \mathcal{L}_{\text{pred}} + \lambda_2 \mathcal{L}_{\text{metric}}$, 其中最后一项 $\sum_{i,j} \|\|g_i - g_j\| - \|x_i - x_j\|\|$ 让潜在距离有意义, 从而控制代价可以在潜在空间里定义 (线性动力学把 reach 问题降成一个 QP)。

Koopa (Liu et al. 2023, NeurIPS) 是时间序列版本。它抓住“非平稳”这个痛点: 用 Fourier Filter 把时间序列分解成时变分量与时不变分量, 分别用不同的 Koopman Predictor 推进。它还引入一个重要的工程改进: 把 Koopman 预测器嵌进深度残差结构, **绕开了之前 Koopman forecaster 必须有的重构损失** (因为潜在是残差而非重构目标)。

K²VAE (Wu et al. 2025) 把 Koopman 与 Kalman 滤波塞进概率时间序列预测的 VAE 里: KoopmanNet 把非线性序列转成线性动力系统, KalmanNet 在这个线性系统上做状态估计与不确定性建模, 从而降低长期预测的误差累积。

结构分支的局限 CKO 的物体/关系词表 a^o, a^r 和块类型指派 σ 都必须手工给定; 它假设同质、置换对称的交互; K, L 来自无约束最小二乘, **没有任何谱或稳定性保证**。Koopa 的 Fourier Filter 假设周期性, K^2 VAE 依赖线性系统的可观测性假设。三者都是“针对某类任务加结构”, 而不是给一个一般的表示准则。

1.8 六条分支的共同盲点

把所有分支并排看, 有一个共同点:

各分支补的是同一个欠定问题的不同侧面

分支	加的正则	解决的问题	没解决的问题
稳定	谱位置约束	$ \lambda > 1$ 的爆炸	潜在信息布局
一致	前/后向一致性	可逆性、噪声鲁棒	潜在信息布局
变分	谱下界分数	无解码器的谱估计	谱的分布形状
统计	风险 + 泛化界	估计误差	潜在维度选择
结构	对称/组合/残差	变量数、非平稳	一般性原则

用论文自己的话说, 这些工作“在受限的情形下是有效的, 但缺少引导 **Koopman 表示的一般原则**”。而且它们全都有一个具体症状: **潜在表示欠定**。训练信号只有重构 + 一步/多步预测, 这是一个自监督信号, 在潜在空间里留下一大片自由度。具体表现为三种可观察的失败:

三种失败模式 (论文归纳) **时间一致性 (temporal coherence) 丧失**: 潜在轨迹不再随时间一致地演化。自回归 (把模型自己前一步的输出当作下一步的输入, 逐步推进) 展开会放大小的偏差, 第 1 步的小误差到第 50 步可能是灾难。

预测充分性 (predictive sufficiency) 不足: 保留的模式太少, 系统行为被过度简化。典型症状是“模式坍缩”: 潜在协方差矩阵 (一批潜在向量的协方差, 其特征值给出方差 在各方向上的占比, 第 0 章末节有最小包) 的特征值高度倾斜, 有效维度接近 1。

结构一致性 (structural consistency) 被破坏：潜在空间不再支持 $z_n \rightarrow z_{n+1}$ 的线性演化。这是 Koopman 定义本身的要求，但比普通 VAE（变分自编码器，自编码器的概率版，第 0.7 节与第 2 章展开）的重构要求严格得多。




图 2 论文 Figure 6 的消融：从高维图像学倒立摆的潜流形。真实相空间是 $S^1 \times \mathbb{R}$ （角度 $\times$ 角速度）。没有互信息正则 ($\alpha = 0$) 时潜空间碎成散点；没有结构一致性 ($\beta = 0$) 时流形坍塌；去掉 von Neumann 熵 ($\gamma = 0$) 时圆环 S^1 保留但 $\mathbb{R}$ 维度被压没了。单独增大互信息会让表示集中到 S^1 上；加上熵正则后才恢复完整的 $S^1 \times \mathbb{R}$ 。这四张图是整篇论文的实证缩影。

这些失败不是调参能解决的。它们是同一个欠定表示问题在不同正则组合下的不同投影。论文的主张是：你需要一个原理性的准则，来说明每一项该不该有、有多强。

1.9 论文的重新定位

论文最关键的一步是一次视角转换，不是某个具体公式。

视角转换：从算子逼近到表示学习 过去的工作把 Koopman 学习看作算子逼近问题：找一个好的有限维子空间去逼近 $\mathcal{K}$ 。

论文主张把它看作表示学习问题： $z = \varphi(x)$ 就是一个表示，而它面对的核心张力是，表示要足够简单（才能线性推进、不过拟合、可解释），又要足够有表达力（保留足够多的动态模式）。

这个张力有一个名字，而且已经被研究了二十年：**信息瓶颈**。

为什么是信息瓶颈？因为 IB 的原始动机字面上一模一样：找一个表示，“尽可能压缩输入，同时保留与下游任务相关的信息”。把“下游任务”换成“预测未来状态”，就得到论文的核心提法：

$$\underbrace{I(x_{n-1}; z_{n-1})}_{\text{压缩 (简单)}} \text{ 要小, } \underbrace{I(z_{n-1}; x_n)}_{\text{预测未来 (表达力)}} \text{ 要大。}$$

问题于是从“怎么逼近一个算子”变成了一条信息论问题。而信息论给出的不是启发式，是界。下一节先把这条线索的工具箱备齐。

2 第二根线索：信息瓶颈谱系，从“压缩与相关性”到可训练的损失

上一节最后把问题重述成了：潜在表示要足够简单又要足够有表达力。这句话在 1999 年 就被人以几乎相同的措辞写过，而且写它的人给出了一个完整的数学框架。这一节把那条线索讲透，因为本文的拉格朗日量是它的直接后代。

按逻辑顺序，这条线索有四站：

1. **IB (Tishby 2000)**：一个原理性的拉格朗日量，但需要已知分布，不可训练。
2. **VIB (Alemi 2017)**：用变分界把 IB 变成可以反向传播的损失。
3. **InfoNCE (Oord 2018 / Wu 2020)**：当“相关性”是高维的、无法写出密度时，如何估计它。
4. **Time-lagged IB (Federici 2023)**：把 IB 用到动力系统上，本文最接近的替代品。

再加上一个几何工具 (von Neumann 熵 / 有效维度)，它不属于 IB 谱系，但本文用它修补 IB 的一个漏洞。

2.1 信息瓶颈：一个被写对了四十年的目标函数

2.1.1 它要解决的困难

回到那个根本张力。假设你有输入 x 和你想预测的目标 y (在本文里， y 就是未来的状态)。你想造一个中间表示 z ，通过 $x \rightarrow z \rightarrow y$ 这条链传递信息。两个互相冲突的愿望：

- z 要小，小到能抑制噪声、能避免过拟合、能让人看懂；
- z 要全，关于 y 的信息一点都不能少。

用互信息量化：第一个愿望是小化 $I(x; z)$ ，第二个愿望是最大化 $I(z; y)$ 。

定义 6 (信息瓶颈, Tishby–Pereira–Bialek 1999) 给定联合分布 $p(x, y)$ ，在所有编码器 (转移核) $q(z|x)$ 上求解

$$\min_{q(z|x)} I(x; z) \quad \text{s.t.} \quad I(z; y) \geq R,$$

意思是“在保住不低于 R 的相关性的前提下，码率越小越好” (码率指 $I(x; z)$ ，即编码器要把 x 记录成 z 需要花掉多少比特；它越小表示 z 压得越狠)。带约束的优化没有现成的梯度可以下降，标准做法是引入一个乘子，把约束作为罚项并进目标：约束被违反时罚项变正，把解顶回去。罚完之后是

$$\mathcal{L}_{\text{IB}} = I(x; z) - \beta(I(z; y) - R) = I(x; z) - \beta I(z; y) + \beta R, \quad \beta \geq 0,$$

其中乘子 β 的职责就是“守住相关性不低于 R 这条线”。末项 βR 与编码器无关，丢掉它就得到常见的拉格朗日形式 $\mathcal{L}_{\text{IB}} = I(x; z) - \beta I(z; y)$ 。

β 从哪来、是什么，现在可以一句话回答：它是带约束问题里那个“守约束”的乘子，语义是**兑换率**：在最优点处， β 等于“每多花一个 nat (以 e 为底的对数计的信息单位，见第 0 章) 的码率，能换回多少 nat 的相关性” (高斯 IB 一节会把这个说法精确化)。 β 取不同的值对应曲线上不同的工作点；从小到大大扫 β ，就扫过整条“码率 vs 相关性”曲线。

为什么 $y-x-z$ 这条马尔可夫链很关键 IB 假设 $y-x-z$ ，也就是“ z 是从 x 生成的， y 影响 z 的全部途径都要经过 x ”，用条件概率写是 $p(z|x, y) = p(z|x)$ ：给定 x 之后，知道 y 与否不改变 z 的分布。由数据处理不等式立刻得到 $I(z; y) \leq I(x; y)$ ：相关性项被输入端的可用信息封顶。整个博弈就是“每花一个 bit 的码率，能保留多少相关性”。

本文的编码器约定 (z 只依赖当前状态) 正是这个假设的动力学版本，这就是为什么 IB 可以直接搬过来用。

2.1.2 关键恒等式：把 IB 改写成“码率 + $\beta \times$ 失真”

定义 6 里还有一样东西没有定义： $I(x; y|z)$ 。它在这个改写里担任主角，先把它讲清楚。

什么叫“条件互信息” $I(x; y|z)$ 互信息 $I(x; y)$ 回答“ x 与 y 共享多少信息”。条件互信息 $I(x; y|z)$ 回答一个更细的问题：在已经知道 z 的前提下， x 与 y 还共享多少信息。定义为

$$I(x; y|z) = H(x|z) - H(x|y, z),$$

其中 $H(x|z)$ 是“看过 z 之后， x 还剩多少不确定”， $H(x|y, z)$ 是“看过 z 和 y 之后还剩多少”。两者相减，就是“ y 在 z 之外额外提供了多少关于 x 的信息”。

和普通互信息一样，它永远非负。用两个极端来记它的行为：若 z 已经把 x 与 y 的关系解释干净，则 $I(x; y|z) = 0$ ；若 z 完全不含相关线索，它退回普通互信息， $I(x; y|z) = I(x; y)$ 。

有了条件互信息，就可以把 IB 的拉格朗日量改写成一个更好读的形状。推导共三步，每步只用一条已经给过的事实。

第一步：用链式法则把 $I(y; (x, z))$ 拆成两种顺序。 链式法则说，联合变量提供的信息可以分步累加：先知道 x 再知道 z ，与先知道 z 再知道 x ，总信息量是一样的。两种顺序写出两个表达式：

$$I(y; (x, z)) = I(y; x) + I(y; z | x)$$

$$I(y; (x, z)) = I(y; z) + I(y; x | z)$$

同一个量，两种拆法，所以两条右边相等。

第二步：马尔可夫链砍掉一项。 $y - x - z$ （即 $p(z|x, y) = p(z|x)$ ）意味着：已知 x 之后， z 不再提供关于 y 的任何新信息：

$$I(y; z | x) = 0.$$

代入第一个拆法，左边变成 $I(y; x)$ 。

第三步：让两种拆法相等。

$$I(y; x) = I(y; z) + I(y; x | z) \implies I(z; y) = I(x; y) - I(x; y|z).$$

这条恒等式在说什么 用日常语言读： x 一共掌握 $I(x; y)$ 这么多关于 y 的信息； z 是从 x 复制出来的，所以“ z 带过去的部分”（ $I(z; y)$ ）加上“复制途中丢掉的部分”（ $I(x; y|z)$ ），必须恰好等于 x 原来有的。

于是 $I(x; y|z)$ 的含义固定下来： x 掌握的关于 y 的信息中，没有被 z 带过去的那部分。它永远非负，而且编码器压得越狠它越大。这个行为正是“失真”的形状，下面马上用它。

第四步：代回拉格朗日量。 把恒等式代入定义 6 的 $\mathcal{L}_{\text{IB}} = I(x; z) - \beta I(z; y)$ ：

$$\mathcal{L}_{\text{IB}} = I(x; z) - \beta [I(x; y) - I(x; y|z)] = I(x; z) + \beta I(x; y|z) - \beta I(x; y).$$

最后一项 $\beta I(x; y)$ 只由数据分布 $p(x, y)$ 决定，跟编码器 $q(z|x)$ 无关，优化时是常数。扔掉常数，优化目标变成

$$\min_{q(z|x)} I(x; z) + \beta I(x; y|z).$$

现在每一项都有名字了。第一项 $I(x; z)$ 是**码率**：编码器要花多少比特来记录 x 。第二项 $I(x; y|z)$ 是**失真**：经过 z 中转之后，关于 y 的信息丢了多少。（有的文献把它叫“相关性损失”，因为由恒等式 $I(x; y|z) = I(x; y) - I(z; y)$ ，它恰好等于“ x 原有的相关性减去 z 保住的相关性”。） β 是两种货币之间的汇率：每容忍一个 nat 的失真，可以省下多少码率。

也就是说，IB 拉格朗日量（差一个常数）就是**码率** + $\beta \times$ **失真**。这就是“IB 是一个率失真问题”这句话的准确含义，而率失真理论研究的正是这一对量之间的最优兑换曲线。

什么叫“率失真” 想象你要把一段消息压缩后传出去，接收端再还原。“码率”是每秒传多少 bit，“失真”是还原得有多不准。

率失真理论研究的正是这两个量之间的**最优兑换曲线** $R(D)$ ：在允许失真不超过 D 的前提下，最少需要多少码率。它回答的问题很实际，**多给一个 bit，能把误差压小多少。**

本文后面会反复用到这条曲线的一个特例：误差随码率**指数**下降 ($D \approx \sigma^2 e^{-2R}$)，所以“多保留 1 nat 信息”约等于“误差除以 e^2 ”。

2.1.3 最优解的结构

对 $q(z|x)$ 求变分（变分指对整个函数求导：把 q 在每个取值上的值当作独立变量，类比线性代数里对向量的每个分量求导）并加归一化约束，得到一组自治方程：

$$q(z|x) = \frac{p(z)}{Z(x, \beta)} \exp(-\beta D_{\text{KL}[p(y|x) \parallel p(y|z)]}), \quad p(y|z) = \frac{\sum_x p(y|x) q(z|x) p(x)}{p(z)}.$$

注意指数里是什么：**条件标签分布之间的 KL 散度**（KL 散度在第 0 章已定义：用 q 当作 p 的编码方案时平均多付的代价，永远非负）。这带来一个很重要的直觉：

IB 聚的是“函数”，不是“点” IB 把具有相同 $p(y|x)$ 的输入合并在一起。一个对 y 没用的坐标，占据码率却不带来相关性，于是在最优解里被剪掉。

我们想从 Koopman 观测函数里要的东西就是这个：**按“对预测未来有没有用”来选坐标**，而不是按“能不能重构输入”来选。

实践中用 Blahut–Arimoto 式的交替迭代求解（轮流更新 $q(z|x)$ 和 $p(y|z)$ ），并对 β 做退火（从小到大）以避免差的局部极小。

2.1.4 一个可解析的基准：高斯 IB 与 CCA

IB 一般很难解，但在联合高斯的情形有闭式解，而这个解对理解后面的东西极有帮助。

设 (x, y) 联合高斯。最优编码是 $t = Ax + \text{噪声}$ （噪声项不可省），其中 A 张成的正是 **CCA**（典型相关分析）的方向，即 $\Sigma_{x|y} \Sigma_x^{-1}$ 的特征向量，特征值记作 λ_i 。投影的秩会在某些临界值处**离散地跳变**：

$$\beta_i^* = \frac{1}{1 - \lambda_i}.$$

也就是说， $1/\beta$ 扮演了“软性秩选择器”的角色：调节 β 就是在调节有效维度。

标量情形可以完整算出来，而且每一步只用到第 0 章的材料。先把记号定下来： $y = x + n$, $n \sim \mathcal{N}(0, \sigma_n^2)$ 与 x 独立， $\sigma_x^2 = \text{Var}(x)$ ，于是 $\rho^2 = \sigma_x^2 / (\sigma_x^2 + \sigma_n^2)$ 。（任何联合高斯对都能写成这个形状：把 y 对 x 做线性回归，残差与 x 独立且是高斯，所以不失一般性。）用到的唯一外部公式是第 0 章的联合高斯互信息闭式：相关系数为 ρ_{XY} 的联合高斯 X, Y 满足 $I(X; Y) = -1/2 \ln(1 - \rho_{XY}^2)$ 。码率记 $R = I(x; z)$ 。

$$I(z; y) = -\frac{1}{2} \ln(1 - \rho^2(1 - e^{-2R})), \quad I(x; y | z) = \frac{1}{2} \ln \left(1 + \frac{\rho^2}{1 - \rho^2} e^{-2R} \right) \approx \frac{\rho^2}{2(1 - \rho^2)} e^{-2R}.$$

证明. 第一步：最优编码器的形状。 文献 (Chechik et al. 2005) 证明联合高斯下最优编码器是线性高斯的： $z = Ax + n_z$, $n_z \sim \mathcal{N}(0, \sigma_z^2)$ 与其它变量独立。来历是定义 6 末尾的自治方程：联合高斯时 $p(y|x)$ 与 $p(y|z)$ 都是高斯，KL 散度是 x 的二次函数，方程的解是高斯核。标量情形 A 只是把 x 缩放，而互信息对 z 的可逆缩放不变，所以不妨取 $A = 1$ ： $z = x + n_z$ 。整个编码器只剩一个自由参数 σ_z^2 ，它将由码率 R 决定。

第二步：算码率，反解 σ_z^2 。 z 与 x 的相关系数平方为 $\rho_{zx}^2 = \sigma_x^2 / (\sigma_x^2 + \sigma_z^2)$ ：分子是协方差 $\text{Cov}(z, x) = \mathbb{E}[(x + n_z)x] = \sigma_x^2$ （噪声与 x 独立，交叉项为零），分母是 $\text{Var}(z) = \sigma_x^2 + \sigma_z^2$ 。代入高斯公式：

$$R = I(x; z) = \frac{1}{2} \ln \left(1 + \frac{\sigma_x^2}{\sigma_z^2} \right).$$

两边乘 2 再取指数： $e^{2R} = 1 + \sigma_x^2 / \sigma_z^2$ ，移项得

$$\sigma_z^2 = \sigma_x^2 \frac{e^{-2R}}{1 - e^{-2R}}.$$

第三步：算相关性 $I(z; y)$ 。 $z = x + n_z$ 与 $y = x + n$ 共享同一份 x ： $\text{Cov}(z, y) = \mathbb{E}[(x + n_z)(x + n)] = \sigma_x^2$ （四个交叉项里，含独立噪声的三个期望为零）。于是 $\rho_{zy}^2 = \sigma_x^4 / [(\sigma_x^2 + \sigma_z^2)(\sigma_x^2 + \sigma_n^2)]$ ，代入高斯公式：

$$I(z; y) = -\frac{1}{2} \ln \left(1 - \frac{\sigma_x^4}{(\sigma_x^2 + \sigma_z^2)(\sigma_x^2 + \sigma_n^2)} \right).$$

剩下的代数是把分母里的 1 凑成目标形状。展开分子： $(\sigma_x^2 + \sigma_z^2)(\sigma_x^2 + \sigma_n^2) - \sigma_x^4 = \sigma_x^2 \sigma_z^2 + \sigma_x^2 \sigma_n^2 + \sigma_z^2 \sigma_n^2$ 。另一方面，把第二步的 $e^{-2R} = \sigma_z^2 / (\sigma_x^2 + \sigma_z^2)$ 代入 $1 - \rho^2(1 - e^{-2R})$ 并通分：分子是 $(\sigma_x^2 + \sigma_n^2)(\sigma_x^2 + \sigma_z^2) - \sigma_x^2 \sigma_z^2$ ，逐项展开后与上一行的分子相同，分母也相同。两个表达式相等：

$$I(z; y) = -\frac{1}{2} \ln(1 - \rho^2(1 - e^{-2R})).$$

第四步：算失真 $I(x; y|z)$ 。 用本节前面证过的恒等式 $I(x; y|z) = I(x; y) - I(z; y)$ ，其中 $I(x; y) = -1/2 \ln(1 - \rho^2)$ ：

$$I(x; y|z) = \frac{1}{2} \ln \left(\frac{1 - \rho^2(1 - e^{-2R})}{1 - \rho^2} \right) = \frac{1}{2} \ln \left(1 + \left(\frac{\rho^2}{1 - \rho^2} \right) e^{-2R} \right),$$

第二个等号来自 $(1 - \rho^2 + \rho^2 e^{-2R}) / (1 - \rho^2) = 1 + \rho^2 e^{-2R} / (1 - \rho^2)$ 。大码率时 $e^{-2R} \ll 1$ ，用 $\ln(1 + u) \approx u$ 得近似式。□

第五步：相变 $\beta_i^* = \frac{1}{1 - \lambda_i}$ 在标量时的样子。 标量时 $\Sigma_{x|y} \Sigma_x^{-1}$ 的特征值为 $\lambda = \sigma_{x|y}^2 / \sigma_x^2$ ，其中 $\sigma_{x|y}^2 = \sigma_x^2 - \text{Cov}(x, y)^2 / \sigma_y^2 = \sigma_x^2 \sigma_n^2 / (\sigma_x^2 + \sigma_n^2)$ ，故 $\lambda = \sigma_n^2 / (\sigma_x^2 + \sigma_n^2) = 1 - \rho^2$ ， $\beta^* = 1 / (1 - \lambda) = 1 / \rho^2$ 。它为什么出现：看小码率极限。 $e^{-2R} \approx 1 - 2R$ ，代入第三步的公式： $I(z; y) = -1/2 \ln(1 - 2\rho^2 R) \approx \rho^2 R$ ，这条分支从原点出发、斜率 ρ^2 。沿这条分支，拉格朗日量的值为 $I(x; z) - \beta I(z; y) \approx R(1 - \beta \rho^2)$ 。另一个候选解是“什么都不传”（ z 与 x 独立，两个互信息都为零，拉格朗日量为 0）。只有当 $1 - \beta \rho^2 < 0$ ，即 $\beta > \beta^* = 1 / \rho^2$ 时，加噪分支的目标值才低于退化解。所以 β 从小到大扫过 β^* 时，这一维突然被激活：这就是“秩离散跳变”的机制。多变量时每个特征方向有自己的阈值 β_i^* ，随 β 增大依次激活， $1/\beta$ 于是成了软性秩选择器。顺带把 β 的“兑换率”语义精确化：沿最优分支对 R 求导（在最优点，拉格朗日量对码率的一阶变化为零），得 $dI(z; y)/dR = 1/\beta$ 。

两个极端都看得见：小码率时相关性随码率**线性**增长（斜率 ρ^2 ，证明第五步的展开式），大码率时缺失的相关性**指数**衰减。

这三个公式后面还会用到

1. $1/\beta$ 是**边际兑换率**：在最优点，IB 曲线的斜率 $dI(z; y)/dI(x; z) = 1/\beta$ ，意思是“每多花一个 nat 的码率，能换回多少 nat 的相关性”。
2. $I(x; y|z) \sim e^{-2R}$ ：关于 y 的信息损失随码率**指数**衰减。后面 §3 的命题 2 会给出一个动力学版本同类界（率失真下界）。

3. **高斯最优解就是 CCA 投影**：任何非线性表示在相同码率下如果打不过 CCA，那它就没买到超越二阶结构的东西。这是一条现成的基准线。

2.1.5 IB 在深度学习里的成功叙事，以及它的裂缝

Tishby & Zaslavsky (2015) 把每一层看成一个中间表示 T_l ，在所谓“信息平面” $(I(x; T_l), I(T_l; y))$ 上描点，得到一个很吸引人的叙事：训练先“拟合”（两个量都上升），再“压缩”（ $I(x; T)$ 下降而 $I(T; y)$ 持平），压缩是泛化的机制，深度买的是更好的“每码率相关性”。

引用这个叙事时需要注意的问题

1. 对**确定性网络**， $I(x; T)$ 是退化的（离散数据下等于 $H(x)$ ，连续数据下是无穷）。早期观察到的“压缩相”部分是量化的假象。
2. 压缩相**不普适**。用 ReLU 的网络观察不到它；它跟饱和型非线性有关 (Saxe et al. 2018)。
3. 互信息对双射重参数化不变，所以它**无法自己衡量一个表示的可用维度**，这也是本文需要 von Neumann 熵的原因之一。

其中第 3 条对本文最重要：“信息量”和“有效维度”是两个不同的东西，前者对后者是盲的。

2.2 深度变分信息瓶颈：让 IB 可以训练

IB 需要已知 $p(x, y)$ 、并解一个非凸问题。深度学习的做法是给出**可以随机梯度优化的界**。

定义 7 (VIB, Alemi et al. 2017) 用变分编码器 $q(z|x) = \mathcal{N}(\mu(x), \text{diag } \sigma^2(x))$ 与变分解码器 $q(y|z)$ ，目标

$$\mathcal{L}_{\text{VIB}} = \mathbb{E}[-\log q(y|z)] + \beta_{\text{VIB}} \mathbb{E}[D_{\text{KL}(q(z|x) \parallel r(z))}], \quad r(z) = \mathcal{N}(0, I).$$

两个界的方向相反，这一点是理解 VIB 的关键：

(a) **码率侧给出的是上界**。对任意固定的先验 $r(z)$ 。推导分两步，每步只做一件事。

第一步：把真实码率写成一个 KL 的期望。

$$\mathbb{E}_{p(x)} D_{\text{KL}(q(z|x) \parallel p(z))} = \mathbb{E} \log \frac{q(z|x)}{p(z)} = \mathbb{E}[-\log p(z)] - \mathbb{E}[-\log q(z|x)] = H(z) - H(z|x) = I(x; z).$$

第一个等号是 KL 的定义；第二个等号把对数拆成两半， $\log q(z|x) - \log p(z) = -\log p(z) - (-\log q(z|x))$ ；后两个等号是熵的定义（第 0 章）： $\mathbb{E}[-\log p(z)]$ 对 z 的边缘分布取平均，是 $H(z)$ ； $\mathbb{E}[-\log q(z|x)]$ 对条件分布取平均，是 $H(z|x)$ 。两者之差正是互信息的定义 $I(x; z) = H(z) - H(z|x)$ 。

第二步：把真实的 $p(z)$ 换成可以选择的 $r(z)$ 。对 x 取平均之后，

$$\mathbb{E}_{p(x)} D_{\text{KL}(q(z|x) \parallel r(z))} = I(x; z) + D_{\text{KL}(p(z) \parallel r(z))} \geq I(x; z),$$

等号当且仅当 $r(z) = p(z)$ 。推导：把对数拆成 $\log q(z|x) - \log r(z) = [\log q(z|x) - \log p(z)] + [\log p(z) - \log r(z)]$ 。方括号里第一项平均出来就是第一步的 $I(x; z)$ ；第二项的被积函数只依赖 z ，先对 x 积分时被积函数外面拼出的权重恰好是 $\int q(z|x)p(x)dx = p(z)$ （ $p(z)$ 的定义就是 q 按输入分布的混合），于是这一项剩下 $D_{\text{KL}(p(z) \parallel r(z))}$ ，它非负。**最小化“到先验的 KL”是在压缩真实码率的一个上界**：多出来的那块 $D_{\text{KL}(p(z) \parallel r(z))}$ 衡量的正是先验选得有多不准。

代码上就是大家熟悉的那一项：

$$D_{\text{KL}(\mathcal{N}(\mu, \sigma^2) \parallel \mathcal{N}(0, I))} = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \ln \sigma_j^2 - 1).$$

(b) 相关性侧给出的是下界。推导两步。**第一步**：把 Gibbs 不等式（对任意两个分布，用错误分布编码的交叉熵总不会小于真实熵，即 $H(p) \leq \mathbb{E}_{p[-\log q]}$ ）用在条件分布上：取 p 为真实的 $p(y|z)$ 、 q 为模型 $q(y|z)$ ，得到 $H(y|z) \leq \mathbb{E}[-\log q(y|z)]$ 。**第二步**：代入互信息的定义 $I(z; y) = H(y) - H(y|z)$ ；从等式两边减去一个更大的数，得到更小的数，所以不等号方向翻转：

$$I(z; y) = H(y) - H(y|z) \geq H(y) + \mathbb{E}_{q(z|x)p(x,y)} \log q(y|z).$$

于是最大化“从 z 解码 y 的对数似然”是在最大化相关性的一个下界。

上下界配对为什么可行 因为两个界都朝着安全的方向偏（码率项只会高估、相关性项只会低估），所以用它们构造的目标函数是保守的。你不会因为用了近似而高估自己的信息效率。

而且（这是关键） β 成了一个可以用梯度调节的旋钮。

本文要做的事，就是把 VIB 的两个界搬到 Koopman 的动力学链上，再补上一项（von Neumann 熵）来堵住 IB 天生看不见的那个洞。

(c) **极端情形，用来说服自己界是有效的。** $\beta_{\text{VIB}} \rightarrow 0$ 得到一条几乎无损的信道（不压缩）； $\beta_{\text{VIB}} \rightarrow \infty$ 把 KL 推到零， $q(z|x) \rightarrow r(z)$ ，没有 bit 流过，相关性界坍缩到 $H(y)$ （欠拟合；后验坍缩指 $q(z|x)$ 不再依赖 x ，编码器输出与输入无关）。有用的工作点在这两者之间的“肘部”。

Alemi 等人后来的 **Fixing a Broken ELBO** 把它重新表述成率失真平面上的轨迹：码率 $R \approx \mathbb{E} D_{\text{KL}(q(z|x)||r(z))}$ ，失真 $D = \mathbb{E}[-\log q(x|z)]$ 。三个区域分别是： β 太大（码率坍缩、信道闲置）、 β 太小（高码率、积累无用 bit）、以及“好”区域（贴着 $R(D)$ 前沿走）。在固定码率下，模型仍可能不去使用这些 bit（ $I(x; z)$ 很高而 $I(z; y)$ 很低），这个诊断在本文的实验里会直接用到。

2.3 InfoNCE：当相关性无法写出密度时怎么估计它

VIB 的相关性下界需要 $q(y|z)$ 。在本文里 y 是未来状态，可能是 $64 \times 64 \times 2$ 的流场，写出一个参数化的 $q(y|z)$ 是可行的（就是个解码器），但另一种更轻的办法是**对比式**的。

2.3.1 互信息作为最优对数比

互信息有一个变分表述（Donsker-Varadhan）：

$$I(x; y) = \sup_f \mathbb{E}_{p(x,y)}[f(x, y)] - \ln \mathbb{E}_{p(x)p(y)}[e^{f(x,y)}],$$

最优的 $f^* = \ln[p(x|y)/p(x)] + \text{const}$ ，即密度比的对数。这条公式本身在下面的证明里用不到，它只是一个出发点：对比学习就是把这句话变成多样本、可经验估计的版本。

2.3.2 估计量

抽一个正样本对 $x_1 \sim p(x|c)$ ， $c \sim p(c)$ ，以及 $K-1$ 个负样本 $x_{2:K} \sim p(x)$ 。给定打分函数 f ，定义 softmax 分类器的交叉熵损失

$$\mathcal{L}_{\text{NCE}} = \mathbb{E} \left[-f(x_1, c) + \ln \sum_{j=1}^K e^{f(x_j, c)} \right], \quad \hat{I}_{\text{NCE}} := \ln K - \mathcal{L}_{\text{NCE}}.$$

InfoNCE 是互信息的一个下界 记 $I \in \{1, \dots, K\}$ 为“哪一个是正样本”的指示变量。两步：

1. **Gibbs 不等式**：任何预测器预测 I 的交叉熵都不低于条件熵，故 $\mathcal{L}_{\text{NCE}} \geq H(I | \text{data})$ 。
2. $H(I) = \ln K$ ，且 $I(I; \text{data}) \leq I(x; c)$ （因为 I 是采样对的函数）。

于是 $\mathcal{L}_{\text{NCE}} \geq \ln K - I(x; c)$ ，即

$$I(x; c) \geq \ln K - \mathcal{L}_{\text{NCE}} = \hat{I}_{\text{NCE}}, \quad \text{且} \quad \hat{I}_{\text{NCE}} \leq \ln K.$$

最优打分函数 $f(x, c) = \ln[p(x|c)/p(x)] + \text{const}(c)$ 让界取等。

两条实践含义

1. 估计量在 $\ln K$ 处饱和：批量 K 个样本时，你测不到（也追不动）远高于 $\ln K$ 的互信息。所以报告 InfoNCE 值必须同时报告批量大小。
2. 它是界，不是估计。它只和打分函数能否表达真实密度比一样好。报告出来的是地板值。

2.3.3 时间邻域正样本：CPC 的做法

在本文里，正样本是时间邻域。具体地（论文 Algorithm 1）：

$$I(z_n; \mathcal{P}_n) \approx \frac{1}{|\mathcal{P}_n|} \sum_{p \in \mathcal{P}_n} \log \frac{\exp(z_n^T z_p / \tau)}{\sum_{j=1}^B \exp(z_n^T z_j / \tau)}, \quad \mathcal{P}_n = \{z_{n \pm i} \mid 1 \leq i \leq k\}.$$

其中 k 是邻域窗口， τ 是温度。

为什么用时间邻域，而不是用 $I(z_n; z_{n+1})$

1. 抑制瞬时噪声。相邻两步的互联系里混着传感器噪声与高频内容；跨若干步的邻域 ($k > 1$) 把这部分压掉，剩下的是真正可预测的成分。
2. 给出一个可读的谱。由数据处理不等式，固定编码器几何下 $k \mapsto \hat{I}_{\text{NCE}(k)}$ 单调不增，这条曲线就是“这个表示能线性（或神经地）接触到未来多少 nat”的剖面图。
3. 它把“线性结构”变得有意义。对比训练把表示推向“其未来可由过去线性解码”的坐标，也就是朝一个近似不变 / 无 epoch 的观测空间靠。

定义 8 (T-IB, Federici et al. 2023, ICLR 2024) 目标是把马尔可夫过程映射到一个简化的表示空间，并在该空间里模拟大时间跳跃。Time-lagged Information Bottleneck 的形式是

$$\min I(x_t; z_t) - \beta I(z_{t+\tau}; x_{t+\tau}) \quad (\text{或其对偶形式}),$$

即“压缩当前状态，同时保留时间滞后 τ 之后未来状态的信息”，并在此过程中丢弃高频信息以简化模拟任务、降低推断误差。

T-IB 与本文的关系 相同点：都把 IB 用到时间序列上；都取 $y =$ 未来状态；都得到一个信息最优的潜在表示；论文自己在文献综述里承认 T-IB 证明了“时间滞后技巧可以利用互信息获得更好的潜在表示”。

不同点（三条，后面 §8 会展开）：

1. T-IB 的目标里没有任何控制“信息分布在几个方向”的量。它优化的是总量。论文的主张正是：只优化互信息会导致模式坍缩，必须有 von Neumann 熵。
2. T-IB 的潜在空间不需要支持线性演化。它要的是“能在 τ 之后模拟出来”，不要求 $z_{t+\tau} = \mathcal{K}^\tau z_t$ 。本文的结构一致性要求严格得多。
3. T-IB 面向“模拟大跳跃”的采样效率；本文面向“线性 Koopman 表示”的谱性质。

所以如果你问“如果没有这篇论文，最接近的替代品是什么”，答案就是 T-IB，再加上 VAMPnets 那条变分谱分数的路。

2.4 修补 IB 漏洞的工具：von Neumann 熵与有效维度

2.4.1 它要解决的困难（先给直觉）

IB 的目标是“让潜在变量尽可能好地预测未来”。如果你可以自由分配“注意力”，你会把全部注意力放在信号最强、最容易预测的那个方向上，因为那让“预测未来”得分最高。结果是你用掉了 d 维潜在空间，但实际只用了 1 维。

互信息是一个总量指标 它告诉你“一共有多少信息”，不告诉你“这些信息分布在几个方向”。

而 Koopman 表示恰恰需要后者，你要的是尽可能多的动态模式，而不是一个超级强的模式。

IB 本身鼓励模式坍缩 回忆高斯 IB 的解： $1/\beta$ 是软性秩选择器， β 越大截断得越狠。在 IB 自己的框架里，“更压缩”就意味着“更低的秩”。也就是说，纯 IB 不仅不反对模式坍缩，它**奖励**模式坍缩。

你需要第二个量来对抗它。这就是 von Neumann 熵的位置。

2.4.2 定义与性质

定义 9（密度矩阵） 实对称矩阵 $\rho \in \mathbb{R}^{d \times d}$ 称为密度矩阵，如果 $\rho \geq 0$ 且 $\text{tr}(\rho) = 1$ 。它有谱分解 $\rho = \sum_{i=1}^d p_i v_i v_i^T$ ， $p_i \geq 0$ ， $\sum_i p_i = 1$ ， $\|v_i\| = 1$ 。它的特征值构成一个概率分布。

这个术语来自量子力学（混态的密度算子），但这里纯粹是一个数学装置：任何半正定矩阵除以自己的迹就得到一个密度矩阵。§5 会取 $\rho := C / \text{tr}(C)$ ，其中 C 是潜在变量的协方差。

定义 10（von Neumann 熵） 对密度矩阵 ρ ，

$$S(\rho) = -\text{tr}(\rho \log \rho) = -\sum_{i=1}^d \lambda_i \log \lambda_i = H(\lambda),$$

其中 λ_i 是 ρ 的特征值。

最后那个等号把所有直觉打通了：von Neumann 熵就是特征值分布的香农熵。

- ρ 集中在一个方向 ($\lambda_1 \approx 1$): $H(\lambda) \approx 0$ ，谱多样性最低，就是模式坍缩；
- ρ 均匀铺满 ($\lambda_i = 1/d$): $H(\lambda) = \log d$ ，上界。

于是 $S(\rho) \in [0, \log d]$ 。

定义 11（有效维度，Roy & Vetterli 2007）

$$d_{\text{eff}(\rho)} := \exp(S(\rho)).$$

$\exp(S)$ 的含义是：“具有相同熵的均匀分布的支撑大小”。它回答“实际上用到了几个方向”，而不是“有几个方向的特征值不为零”。

为什么用 $\exp(S)$ ，而不是秩或 $1/\text{tr}(\rho^2)$ 秩不连续。数值计算中一个特征值是 10^{-6} 还是 10^{-9} 由浮点误差决定，秩却会从 5 跳到 4。这不适合做损失函数。

$\exp(S)$ 光滑、可微、且尺度不变 (ρ 本来已归一化)。把一个方向的权重从 0.01 降到 0.001，它只是平滑减小。

常见替代品是 participation ratio $1/\text{tr}(\rho^2)$ （「稳定秩」）：更便宜，但没有熵那么好的解释，也与后面的拉格朗日推导不匹配。

一个可用的下界（由 Rényi 熵的单调性；Rényi 熵是香农熵的一族推广，这里只用它们的单调性）：
 $\exp(S) \geq 1/(\sum_i \lambda_i^2)$ ，等号在谱平坦时成立。

熵正则不是越大越好 熵有上界 $\log d$ 。 γ 太大会把噪声方向也提权到与信号同等，反而损害预测。论文的消融（Figure 6）正好展示三档： $\gamma = 0$ 时 $\mathbb{R}$ 维度消失；适度时恢复 $S^1 \times \mathbb{R}$ ；过大时流形开始模糊。

这就是为什么论文把 γ 当作需要调节的拉格朗日乘子，而不是“越大越好”的正则项。

2.4.3 为什么互信息看不见这件事（技术上的原因）

如果编码器是确定性的， $I(x; z)$ 退化。即使它是随机的，互信息对双射重参数化不变，把 z 白化（把各方向方差拉平并去除相关性的线性变换）、缩放、旋转， $I(x; z)$ 不变。而**有效维度会变吗**？不会，有效维度也是尺度和基不变的（谱的熵）。但有效维度和互信息捕获的是**不同的东西**：

$I(x; z)$ 是总量 vs $\exp(S(\rho_z))$ 是形状。

一个 1 维的、但是极强的表示， $I(x; z)$ 可以很大而 $\exp(S) \approx 1$ 。这就是模式坍塌的数学刻画，IB 衡量不出来。

2.5 小结：五个工具，各自补什么

工具	补什么洞	本文怎么用
IB 拉格朗日	给出原理性的目标形状	拉格朗日的祖先；提供三项结构
VIB 变分界	让 IB 可训练（KL 上界 / 似然下界）	编码器随机化；ELBO 项的来源
InfoNCE	高维未来的相关性估计	$I(z_n; \mathcal{P}_n)$ 的时间邻域实现
von Neumann 熵	抗模式坍塌（IB 自己鼓励坍塌）	$S(\mathcal{C}/\text{tr}(\mathcal{C}))$ 这一项
有效维度	量化“用了几个方向”	实验里的诊断指标

工具箱齐了。下一节开始论文自己的提问链。

3 论文的论证链（上）：信息会丢吗？丢多少？

到这里两条线索汇合了。Koopman 一侧的问题（表示欠定、模式坍缩、缺乏一般原则）遇上信息论一侧的工具（IB、变分界、InfoNCE、von Neumann 熵）。

论文的论证链是五个依次递进的提问。这个顺序不是我加的，是论文自己在附录 B 里明确写出的：

论文自己的提问链

1. 信息会丢吗？（命题 1）
2. 如果会，丢多少？（命题 2）
3. 丢的是哪一类信息？（命题 3）
4. 如何优化信息保留？（命题 4）
5. 如何避免副作用（模式坍缩）？（命题 5）

命题块用蓝色边框标出；证明块给出完整推导，不跳步。建议先读命题再看证明。

3.1 先把信息流的结构写清楚

定义记号： $x_{1:t}$ 是 1 到 t 时刻的状态， $z_{1:t}$ 是自回归生成的潜在变量（自回归：把模型自己前一步的输出当作下一步的输入，逐步推进）。由两张表的对照（论文 Table 1），Koopman 表示诱导出的轨迹分布是

$$p_{\text{KR}}(x_{1:t} | x_0) = \int p(z_0 | x_0) \prod_{n=1}^t p(z_n | z_{n-1}) p(x_n | z_n) dz_0 dz_1 \dots dz_t,$$

三个因子各自对应架构的一个部件，必须认清楚：

- $p(z_0 | x_0)$ 是**编码器**，把初始状态映进潜在空间；
- $p(z_n | z_{n-1}) = \mathcal{N}(z_n | \mathcal{K}z_{n-1}, \Sigma)$ 是**潜在前向**，它是 Koopman 算子定义的式 1 的概率版本（ Σ 是噪声方差）；
- $p(x_n | z_n)$ 是**解码器**，通常是高斯的。




图 3 Koopman 表示的自回归信息流结构（对应论文附录 Figure 8）。上排实线是真实的非线性演化 T ；下排虚线是潜在空间里由 Koopman 算子 $\mathcal{K}$ 支配的线性演化。信息可能在三个位置流失：（1）编码 $x \rightarrow z$ ；（2）线性推进 $z \rightarrow z$ ；（3）解码 $z \rightarrow x$ 。整篇论文的理论绕这三个流失点展开。

这张表定义的对照关系

目标	一般表示学习	Koopman 表示
信息流	$x \rightarrow z \rightarrow y$	$x_{n-1} \rightarrow z_{n-1} \xrightarrow{\text{Koopman}} z_n \rightarrow x_n$
拉格朗日	$I(x; z) - \beta I(z; y)$	$I(x_{n-1}; z_{n-1}) - \beta I(z_{n-1}; x_n)$

右列多了一节： z 必须支持到 z' 的**线性**推进。这就是 Koopman 表示比普通表示学习严格的地方。

3.2 命题 1：信息会丢吗？

命题 1 (潜在演化中的信息丢失) 设 $x_{n-1} \rightarrow z_{n-1} \xrightarrow{\mathcal{K}} z_n \rightarrow x_n$ 表示 Koopman 表示中的信息传播，则

$$I(x_{n-1}; x_n) \geq I(z_{n-1}; x_n) \geq I(z_{n-1}; z_n).$$

先建立两条基础事实。

Fact F.1 (编码器只看当前状态) 设 z_t 由只依赖 x_t 的概率编码器 $p(z_t|x_t)$ 给出。于是

- (a) $H(z_t) \leq H(x_t)$ (数据处理不等式);
- (b) $I(z_t; \xi | x_t) = 0$, 即 $z_t \perp \xi | x_t$ (给定 x_t , z_t 与系统中任何变量 ξ 条件独立)。

(b) 是后面所有展开中“修正项归零”的来源。直觉：编码器是 x_t 的函数，所以给定 x_t , z_t 不再携带关于其它任何东西的额外信息。严格地说，(b) 背后的建模假设是：编码器的随机性是它自己的噪声，与系统中其它变量独立。因此给定 x_t 之后再多条件化一些变量（例如再给定 z_{t-n} ），条件独立性仍然保持；后面所有“修正项归零”引用的都是这一条。

证明. 第一步：证明 $I(x_{t-1}; x_t) \geq I(z_{t-1}; x_t)$ 。

用互信息的链式法则（引理 1）把 $I(x_{t-1}; x_t)$ 展开。注意

$$I((x_{t-1}, z_{t-1}); x_t) = I(x_{t-1}; x_t) + I(z_{t-1}; x_t | x_{t-1}).$$

由 Fact F.1(b)，给定 x_{t-1} 时 z_{t-1} 与 x_t 条件独立，故第二项为零。于是

$$I(x_{t-1}; x_t) = I((x_{t-1}, z_{t-1}); x_t).$$

再把右边的联合变量拆开（链式法则按另一种顺序，先 z_{t-1} 后 x_{t-1} ）：

$$I((x_{t-1}, z_{t-1}); x_t) = I(z_{t-1}; x_t) + I(x_{t-1}; x_t | z_{t-1}).$$

由互信息的非负性，第二项 ≥ 0 ，于是

$$I(x_{t-1}; x_t) = I(z_{t-1}; x_t) + I(x_{t-1}; x_t | z_{t-1}) \geq I(z_{t-1}; x_t). \quad \square$$

第二步：证明 $I(z_{t-1}; x_t) \geq I(z_{t-1}; z_t)$ 。

同样用链式法则：

$$I(z_{t-1}; (x_t, z_t)) = I(z_{t-1}; x_t) + I(z_{t-1}; z_t | x_t).$$

由 Fact F.1(b) (z_t 只依赖 x_t)，第三项为零，故 $I(z_{t-1}; x_t) = I(z_{t-1}; (x_t, z_t))$ 。再拆一次：

$$I(z_{t-1}; (x_t, z_t)) = I(z_{t-1}; z_t) + I(z_{t-1}; x_t | z_t) \geq I(z_{t-1}; z_t). \quad \square$$

把两步合起来，我们还顺带得到信息缺口的精确表达式（这是后面要用的）：

$$I(x_{t-1}; x_t) - I(z_{t-1}; z_t) = \underbrace{I(z_{t-1}; x_t | z_t)}_{\text{演化中损失}} + \underbrace{I(x_{t-1}; x_t | z_{t-1})}_{\text{编码中损失}}.$$

两条不等式的物理含义值得逐字读：

两条不等式的含义 第一条 $I(x_{t-1}; x_t) \geq I(z_{t-1}; x_t)$ ：映射 $x_{t-1} \rightarrow z_{t-1}$ 是有损压缩，它可能丢掉对未来状态 x_t 有用的信息。这是**编码器的责任**。

第二条 $I(z_{t-1}; x_t) \geq I(z_{t-1}; z_t)$: 潜在前向由 Koopman 算子 $\mathcal{K}$ 支配, 它从结构上限制了潜在空间能保留的信息。注意这里比较的两个量不对称, x_t 比 z_t 携带更多对 z_{t-1} 的依赖, 所以中间项通常更大。 $I(z_{t-1}; z_t)$ 就是 $\mathcal{K}$ 给 Koopman 表示设置的信息上限。

3.2.1 多步版本

单步不够用, 自回归预测是几十步展开的。多步版本可以递归地得到。

证明. 先从 $I(x_{t-n}; x_t)$ 出发, 完全重复单步的过程:

$$I(x_{t-n}; x_t) = I((x_{t-n}, z_{t-n}); x_t) = I(z_{t-n}; x_t) + I(x_{t-n}; x_t | z_{t-n}) = I(z_{t-n}; z_t) + I(z_{t-n}; x_t | z_t) + I(x_{t-n}; x_t | z_{t-n}).$$

(四个等号依次是: Fact F.1(b) 砍掉条件项; 链式法则按另一顺序拆开联合变量; 非负项放缩; 最后对 $I(z_{t-n}; x_t)$ 套用刚证完的单步结果。每一步都与上面两步完全同构。)

接下来处理最后一项 $I(x_{t-n}; x_t | z_{t-n})$ 。引入 z_{t-n+1} :

$$I(x_{t-n}; x_t | z_{t-n}) = I(x_{t-n}; z_{t-n+1} | z_{t-n}) + I(x_{t-n}; x_t | z_{t-n}, z_{t-n+1}).$$

这里之所以没有修正项, 是因为被积掉的修正项 $I(x_{t-n}; z_{t-n+1} | x_t, z_{t-n})$ 为零: 由 Fact F.1(b), z_{t-n+1} 只依赖 x_t , 给定 x_t 后它与 x_{t-n} 无关。再引入 z_{t-n+2} , 重复这一操作。记 $z_{t-n:i} := (z_{t-n}, \dots, z_i)$, 对 $i = t-n+1, \dots, t$ 逐次递归, 得到

$$I(x_{t-n}; x_t | z_{t-n}) = \sum_{i=t-n+1}^t I(x_{t-n}; z_i | z_{t-n:i-1}) + I(x_{t-n}; x_t | z_{t-n:t}).$$

合并, 多步信息缺口为

$$I(x_{t-n}; x_t) - I(z_{t-n}; z_t) = \sum_{i=t-n+1}^t \underbrace{I(x_{t-n}; z_i | z_{t-n:i-1})}_{\text{快速耗散}} + \underbrace{I(x_{t-n}; x_t | z_{t-n:t})}_{\text{残差}} + \underbrace{I(z_{t-n}; x_t | z_t)}_{\text{演化损失}}. \quad \square$$

这三项的含义在命题 3 里会被重新捡起来, 先记住它们:

- $I(x_{t-n}; z_i | z_{t-n:i-1})$: 在已知此前所有潜在状态条件下, 新的潜在变量 z_i 还能揭示多少关于过去状态 x_{t-n} 的信息。这是**快速耗散**的部分, 每多走一步它就迅速衰减。
- $I(x_{t-n}; x_t | z_{t-n:t})$: 由于压缩表示而无法被潜在序列完全表达的残差依赖。
- $I(z_{t-n}; x_t | z_t)$: z_{t-n} 中关于 x_t 的信息量减去 z_t 保留的部分。这一项为正说明潜在演化过程中信息丢失, 对应 $|\lambda| < 1$ 的 Koopman 模式。

3.3 命题 2: 丢多少?

命题 1 是抽象的, 它只说“信息会丢”, 没给出能算的量。要把它变成能上界的量, 需要三样工具, 这里先把它们各自的作用说清楚:

- **一把衡量“两个分布差多远”的尺子**。因为我们要比较的是“真实轨迹分布”与“Koopman 模型产生的轨迹分布”。下面用 KL 散度与全变差距离。
- **Pinsker 不等式**: 它把“KL 散度”换算成“全变差距离”, 也就是把抽象的分布差异换成更接近直觉的量, 两个分布有多少概率质量对不上。
- **率失真理论** (定义见 §2): 把“信息量”换算成“误差的量级”。这一步才让结论从“信息会丢”升级成“误差有多大”。

先建立一个变分分解。

引理 3 (变分分解, 论文式 18) 设 p 是真实轨迹分布, p_{KR} 是式 (2) 中的理想 Koopman 模型分布, q_{KR} 是它的变分近似。则

$$D_{\text{KL}}(p(x_{1:t}|x_0) \parallel q_{\text{KR}}(x_{1:t}|x_0)) \leq D_{\text{KL}}(p(x_{1:t}|x_0) \parallel p_{\text{KR}}(x_{1:t}|x_0)) + \mathcal{E}_{\text{enc}} + \mathcal{E}_{\text{tra}} + \mathcal{E}_{\text{rec}}.$$

证明. **第一步：插入理想模型。** 对数比按 $\log a/c = \log a/b + \log b/c$ 插入一项 p_{KR} ，再取期望（期望的线性性允许逐项处理）：

$$D_{\text{KL}}(p \parallel q_{\text{KR}}) = \mathbb{E} \log \frac{p(x_{1:t}|x_0)}{p_{\text{KR}}(x_{1:t}|x_0)} + \mathbb{E} \log \frac{p_{\text{KR}}(x_{1:t}|x_0)}{q_{\text{KR}}(x_{1:t}|x_0)}.$$

第一项就是 $D_{\text{KL}}(p \parallel p_{\text{KR}})$ 。

第二步：把两个模型分布按架构部件分解。 由式 (2)（三个因子的乘积，第 3 章开头逐个认过）：

$$p_{\text{KR}}(z_{0:t}, x_{1:t}|x_0) = p(z_0|x_0) \prod_{n=1}^t p(z_n|z_{n-1})p(x_n|z_n), \quad q_{\text{KR}}(z_{0:t}, x_{1:t}|x_0) = q(z_0|x_0) \prod_{n=1}^t q(z_n|z_{n-1})q(x_n|z_n).$$

两个乘积形状相同，对数比按位置相减，恰好分成三段：编码器段、转移段、解码段。

第三步：逐段边缘化。 期望在真实分布下取。以编码器段为例：被积函数 $\log p(z_0|x_0)/q(z_0|x_0)$ 只依赖 z_0 ，把联合期望写成先对 z_0 后对其余变量的两次积分时，内层对其余变量的积分恰好是总概率 1，于是这一段的期望就是 $D_{\text{KL}}(p(z_0|x_0) \parallel q_{\text{KR}}(z_0|x_0))$ 。转移段与解码段同理：每一项只涉及对应那对条件分布的变量，其余变量积掉后剩下条件分布之间的散度。合并即得

$$\mathbb{E} \log \frac{p_{\text{KR}}(z_{0:t}, x_{1:t}|x_0)}{q_{\text{KR}}(z_{0:t}, x_{1:t}|x_0)} = \underbrace{D_{\text{KL}}(p(z_0|x_0) \parallel q_{\text{KR}}(z_0|x_0))}_{\mathcal{E}_{\text{enc}}} + \sum_{n=1}^t \underbrace{D_{\text{KL}}(p(z_n|z_{n-1}) \parallel q_{\text{KR}}(z_n|z_{n-1}))}_{\mathcal{E}_{\text{tra}}} + \sum_{n=1}^t \underbrace{D_{\text{KL}}(p(x_n|z_n) \parallel q_{\text{KR}}(x_n|z_n))}_{\mathcal{E}_{\text{rec}}}. \quad \square$$

三个误差项分别对应三个架构部件： $\mathcal{E}_{\text{enc}}$ （潜在表示误差）、 $\mathcal{E}_{\text{tra}}$ （Koopman 算子误差）、 $\mathcal{E}_{\text{rec}}$ （重构误差）。下面记 $\mathcal{E} := \mathcal{E}_{\text{enc}} + \mathcal{E}_{\text{tra}} + \mathcal{E}_{\text{rec}}$ 。

引理 4（Pinsker 不等式） 对同一空间上的两个分布 p, q ，全变差距离

$$\|p - q\|_{\text{TV}} := \sup_X |p(X) - q(X)| = \frac{1}{2} \int |p(x) - q(x)| dx,$$

且它被 KL 散度控制：

$$\|p - q\|_{\text{TV}} \leq \sqrt{\frac{1}{2} D_{\text{KL}}(p \parallel q)}.$$

命题 2（Koopman 表示的自回归误差上界） 真实轨迹分布与 Koopman 诱导轨迹分布之间的分布差异被信息缺口控制：

$$\|p(x_{1:t} | x_0) - q_{\text{KR}}(x_{1:t} | x_0)\|_{\text{TV}} \leq \frac{1}{2} \left[D_{\text{KL}}(p(x_{1:t}|x_0) \parallel p_{\text{KR}}(x_{1:t}|x_0)) + \mathcal{E} \right] \leq \frac{1}{2} \left[\sum_{n=1}^t (I(x_{n-1}; x_n) - I(z_{n-1}; z_n)) + \mathcal{E} \right].$$

并且误差上界为

$$\|\mathbb{E}_{q_{\text{KR}}}[x_{1:t} | x_0] - \mathbb{E}_{p[x_{1:t} | x_0]}\|_2 \leq C_0 \sqrt{2 \sum_{n=1}^t (I(x_{n-1}; x_n) - I(z_{n-1}; z_n)) + \mathcal{E}},$$

其中 C_0 是正常数。

证明. **第一步：Pinsker 加变分分解。** 直接由引理 4 与引理 3：

$$\|p(x_{1:t}|x_0) - q_{\text{KR}}(x_{1:t}|x_0)\|_{\text{TV}} \leq \sqrt{\frac{1}{2}(D_{\text{KL}}(p \parallel p_{\text{KR}}) + \mathcal{E}_{\text{enc}} + \mathcal{E}_{\text{tra}} + \mathcal{E}_{\text{rec}})}.$$

第二步：把 KL 与信息缺口联系起来。 这是关键一步。先看单步：

$$I(x_{t-1}; x_t) - I(z_{t-1}; z_t) = \mathbb{E} \left[\log \frac{p(x_t|x_{t-1})}{p(x_t)} \right] - \mathbb{E} \left[\log \frac{p(z_t|z_{t-1})}{p(z_t)} \right].$$

(两个期望分别按互信息的定义展开；确定性动力学的转移“密度”按论文的惯例形式化处理。)

合并两个对数（对数相减等于商的对数，两个期望共享同一测度）：

$$= \mathbb{E} \left[\log \frac{p(x_t|x_{t-1})p(z_t)}{p(x_t)p(z_t|z_{t-1})} \right].$$

由贝叶斯法则 $p(x_t, z_t) = p(x_t)p(z_t|x_t) = p(z_t)p(x_t|z_t)$ ，故 $p(z_t)/p(x_t) = p(z_t|x_t)/p(x_t|z_t)$ 。代入：

$$I(x_{t-1}; x_t) - I(z_{t-1}; z_t) = \mathbb{E} \left[\log \left(\frac{p(x_t|x_{t-1})}{p(z_t|z_{t-1})} \cdot \frac{p(z_t|x_t)}{p(x_t|z_t)} \right) \right].$$

第三步（求和）：从单步到整条轨迹。 对 $n = 1, \dots, t$ 把上式相加，并用“对数之和等于乘积之对数”把 t 项并进一个对数。两个模型分布按式 (2) 的部件分解写开：

$$p_{\text{KR}}(z_{0:t}, x_{1:t}|x_0) = p(z_0|x_0) \prod_{n=1}^t p(z_n|z_{n-1})p(x_n|z_n), \quad p(z_{0:t}, x_{1:t}|x_0) = p(z_0|x_0) \prod_{n=1}^t p(x_n|x_{n-1})p(z_n|x_n),$$

右边第二个是真实联合：动力学确定性地给出 x 链（转移因子 $p(x_n|x_{n-1})$ ），编码器逐个生成 z_n 。逐因子对照后， t 步之和恰好拼成两个联合分布的对数比：

$$\sum_{n=1}^t (I(x_{n-1}; x_n) - I(z_{n-1}; z_n)) = \mathbb{E} \left[\log \frac{p(z_0|x_0)}{p(z_0|x_0)} \cdot \frac{\prod_{n=1}^t p(x_n|x_{n-1})}{\prod_{n=1}^t p(z_n|z_{n-1})} \cdot \frac{\prod_{n=1}^t p(z_n|x_n)}{\prod_{n=1}^t p(x_n|z_n)} \right] = \mathbb{E} \left[\log \frac{p(z_{0:t}, x_{1:t}|x_0)}{p_{\text{KR}}(z_{0:t}, x_{1:t}|x_0)} \right].$$

(第一个 $p(z_0|x_0)/p(z_0|x_0)$ 是两边都有的编码器初始因子，相消；剩下的三个乘积与上面两个分解逐位置对应。)

最后把联合分布的散度换成轨迹分布的散度。这里用的是引理 3 证明里同一类边缘化论证的不等式版本：把联合分布对 z 边缘化只会让散度变小（丢掉的信息不可能让两个分布更像），即

$$\mathbb{E} \left[\log \frac{p(z_{0:t}, x_{1:t}|x_0)}{p_{\text{KR}}(z_{0:t}, x_{1:t}|x_0)} \right] \geq \mathbb{E} \left[\log \frac{p(x_{1:t}|x_0)}{p_{\text{KR}}(x_{1:t}|x_0)} \right] = D_{\text{KL}}(p(x_{1:t}|x_0) \parallel p_{\text{KR}}(x_{1:t}|x_0)).$$

不等号方向正是需要的：第一步里被 Pinsker 使用的量是 $D_{\text{KL}}(p \parallel p_{\text{KR}})$ ，它不超过 逐项信息缺口之和，于是“ $D_{\text{KL}}(p \parallel p_{\text{KR}}) + \mathcal{E}$ ”可以合法地放大成“ $\sum_n [I(x_{n-1}; x_n) - I(z_{n-1}; z_n)] + \mathcal{E}$ ”。代回第一步即得全变差上界。

第四步：从全变差到 L^2 。 要估计的是两个条件期望之差。写成积分之差后，逐点使用范数的三角不等式（对积分的推广：先对每个 $x_{1:t}$ 用 $\| \int f_i \|_2 \leq \int \|f_i\|_2$ ，再把绝对值收进被积函数）：

$$\| \mathbb{E}_{q_{\text{KR}}}[x_{1:t}|x_0] - \mathbb{E}_{p[x_{1:t}|x_0]} \|_2 = \left\| \int x_{1:t} (q_{\text{KR}} - p) dx_{1:t} \right\|_2 \leq \int \|x_{1:t}\|_2 \|q_{\text{KR}} - p\|_2 dx_{1:t}.$$

状态位于紧空间 M 上（紧 = 有界且闭，因此状态变量取不到无穷大），故 $\|x_{1:t}\|_2 \leq C_0 < \infty$ ，把它提出积分号；剩下的积分按引理 4 的定义 $\int \|q_{\text{KR}} - p\|_2 dx = 2\|p - q_{\text{KR}}\|_{\text{TV}}$ 恰好是两倍全变差：

$$\int \|x_{1:t}\|_2 \|q_{\text{KR}} - p\|_2 dx_{1:t} \leq C_0 \cdot 2\|p - q_{\text{KR}}\|_{\text{TV}}.$$

再代入 Pinsker (引理 4) 与第三步的信息缺口表达式, 得到式 (6)。□

命题 2 的读法:

信息缺口与误差的关系 不等式右侧是 $\sum_n [I(x_{n-1}; x_n) - I(z_{n-1}; z_n)]$ 。

- $I(x_{n-1}; x_n)$ 度量原始系统中非线性映射 T 的内在动力学耦合强度;
- $I(z_{n-1}; z_n)$ 度量这种耦合在 Koopman 表示下还剩多少;
- 两者之差就是“用线性 Koopman 表示逼近非线性动力学时丢掉的信息”。

预测误差被这个逐项信息缺口控制。**想减小误差, 就要缩小这个缺口。**而 $I(z_{n-1}; z_n)$ 由命题 1 是信息上限, 所以缺口的缩小只能靠提升 $I(z_{n-1}; z_n)$, 这恰好就是拉格朗日量第一项的由来。

$|\lambda| = 1$ 特殊情形 (遍历系统) 值得一提, 因为它把命题 2 变成一句干净的话。

Remark F.4 (遍历系统) 对遍历系统, 条件在 x_0 上取长时间平均:

$$\lim_{t \rightarrow \infty} \frac{1}{t} D_{\text{KL}}(p(x_{1:t}|x_0) \parallel q_{\text{KR}}(x_{1:t}|x_0)) \leq \lim_{t \rightarrow \infty} \frac{1}{t} \sum_{n=1}^t (I(x_{n-1}; x_n) - I(z_{n-1}; z_n)).$$

左端是相对熵率, 右端是每步信息差的平均。也就是说, **在遍历系统上, 动态偏差由每步信息差控制。**

3.3.1 下界: 误差不能比什么更小

上界告诉我们“做得好有多好”, 下界告诉我们“做不做得更好”。

命题 2 的对偶 (率失真下界) 在 L^2 失真下经理想 Koopman 模型 p_{KR} , 最小可达失真 D 满足

$$D \geq \frac{nt}{2e} \exp\left(\frac{2}{nt} H(x_{1:t})\right) \exp\left(-\frac{2}{nt} \sum_{n=1}^t I(z_{n-1}; z_n)\right).$$

于是给定 x_0 后 t 步的累积均方误差有下界

$$\mathbb{E}_p[\|x_{1:t} - \mathbb{E}_{q_{\text{KR}}}[x_{1:t}|x_0]\|^2 | x_0] \geq C \exp\left(-\left(\frac{2}{nt} \sum_{n=1}^t I(z_{n-1}; z_n) + \mathcal{E}\right)\right),$$

其中常数 $C = \frac{nt}{2e} \exp\left(\frac{2}{nt} \sum_{n=1}^t I(x_{n-1}; x_n)\right)$ 吸收了轨迹的边缘熵。

证明. 经典率失真定理指出: $x_{1:t} \in \mathbb{R}^{n \times t}$ 在 L^2 失真下的最小可达失真 D 被 Shannon 下界控制。把轨迹视为 nt 个分量、总码率由潜在信道提供, 这个信道每步可传的信息量正是 $I(z_{n-1}; z_n)$, 于是

$$D \geq \frac{nt}{2e} \exp\left(\frac{2}{nt} H(x_{1:t})\right) \exp\left(-\frac{2}{nt} \sum_{n=1}^t I(z_{n-1}; z_n)\right).$$

又因为 $H(x_{1:t})$ 完全可以由原始动力学 T 的互信息和 $\sum_{n=1}^t I(x_{n-1}; x_n)$ 度量, 代入并合并常数即得第二式。□

下界的意义: 信息与精度的兑换率 $E \geq C \exp\left(-\frac{2}{nt} \sum_n I(z_{n-1}; z_n)\right)$, 预测误差随保留的信息**指数**衰减。

反过来读: **要让误差减少一个因子 e^2 , 潜在空间必须多保留 1 nat 的互信息。**这个“汇率”是后面所有实验解读的基础: 任何预测精度的改进都可以翻译成“多保留了 ΔR nat 关于未来的信息”。

同时它也解释了为什么“用掉 d 维但只用了 1 维”是实际发生的损失，多出来的维度本可以提供更多的 $I(z_{n-1}; z_n)$ ，但被浪费了。

现在两个问题回答完了：信息一定会丢（命题 1），丢多少有上下界（命题 2）。下一个问题是：**丢的是哪一类信息？** 这一问题把信息论接到 Koopman 的谱理论上。

4 论文的论证链（中）：丢的是哪一类信息？

前两个命题告诉我们信息一定会丢、丢多少有界。但“多少”是一个标量，它对丢失的机制一无所知。一个模型可能把信息丢在噪声方向上（无所谓），也可能丢在主导振荡模式上（致命）。这一节把信息按 Koopman 谱性质分类。

这一节的问题 潜在互信息 $I(z_{t-n}; z_t)$ 量化了误差的量级，但没有揭示这种损失与 Koopman 谱性质的关系。

为了推进，论文转而考察聚合量 $I(z_t; x_t)$ （解码器 $p(x_t|z_t)$ 能拿到的总信息量）并追问：其中有多少能从前面的潜在变量 z_{t-n} 稳定地传播过来？

4.1 第一步：潜在互信息的闭式

一切从潜在演化的显式解开始。

引理 5（潜在演化的显式解） 设一步前向为 $z_t = \mathcal{K}z_{t-1} + \varepsilon_{t-1}$, $\varepsilon_{t-1} \sim \mathcal{N}(0, \Sigma)$ 。递归代入得

$$z_t = \mathcal{K}^n z_{t-n} + \sum_{i=0}^{n-1} \mathcal{K}^i \varepsilon_{t-i}.$$

由于噪声项独立同分布，条件分布为

$$z_t | z_{t-n} \sim \mathcal{N}(\mathcal{K}^n z_{t-n}, M_n), \quad M_n := \sum_{i=0}^{n-1} \mathcal{K}^i \Sigma (\mathcal{K}^i)^T.$$

矩阵 M_n 值得单独个名字，因为它是整节的枢纽。

定义 12（ n 步前向协方差）

$$M_n := \sum_{i=0}^{n-1} \mathcal{K}^i \Sigma (\mathcal{K}^i)^T.$$

它是“ n 步之内累积的噪声协方差，每一步都被 $\mathcal{K}^i$ 搬运过”。它是潜在条件分布的协方差，也是后面所有闭式表达式的分母。

证明. 第一步：递归展开（对 n 归纳）。 $n=1$ 时就是模型方程 $z_t = \mathcal{K}z_{t-1} + \varepsilon_{t-1}$ 本身。设结论对 n 成立： $z_t = \mathcal{K}^n z_{t-n} + \sum_{i=0}^{n-1} \mathcal{K}^i \varepsilon_{t-i}$ 。再推一步，把 z_t 的表达式代进 $z_{t+1} = \mathcal{K}z_t + \varepsilon_t$ ：

$$z_{t+1} = \mathcal{K}^{n+1} z_{t-n} + \sum_{i=0}^{n-1} \mathcal{K}^{i+1} \varepsilon_{t-i} + \varepsilon_t.$$

令 $j = i+1$ 给求和换下标，并把末项写成 $\mathcal{K}^0 \varepsilon_{t+1}$ 并进同一个求和： $z_{t+1} = \mathcal{K}^{n+1} z_{t-n} + \sum_{j=0}^n \mathcal{K}^j \varepsilon_{t+1-j}$ 。归纳完成。

第二步：条件分布。 给定 z_{t-n} 之后，右端唯一的随机来源是 n 个相互独立的高斯噪声。线性变换保持高斯性，独立高斯变量之和仍是高斯，所以条件分布是高斯的。均值：噪声取期望为零，只剩确定项 $\mathcal{K}^n z_{t-n}$ 。协方差：逐项相加（独立性使所有交叉项 $\mathbb{E}[\varepsilon_i \varepsilon_j^T] = 0, i \neq j$ ），其中第 i 项按 $\text{Cov}(A\varepsilon) = A \text{Cov}(\varepsilon) A^T$ 搬运：

$$\text{Cov}(\mathcal{K}^i \varepsilon_{t-i}) = \mathcal{K}^i \Sigma (\mathcal{K}^i)^T.$$

求和正是 M_n 。于是 $z_t | z_{t-n} \sim \mathcal{N}(\mathcal{K}^n z_{t-n}, M_n)$ 。

第三步：两个熵。 高斯分布的微分熵。对 $y \sim \mathcal{N}(\mu, M)$,

$$H(y) = \frac{1}{2} \log[(2\pi e)^d \det M].$$

于是

$$H(z_t | z_{t-n}) = \frac{1}{2} \log[(2\pi e)^d \det M_n],$$

以及（无条件分布的协方差： $z_t = \mathcal{K}^n z_{t-n} +$ 独立噪声， z_{t-n} 的协方差是 $\mathcal{C}$ ，记 $\mathcal{C} = \text{Cov}(z_{t-n}) = \mathbb{E}[z_{t-n} z_{t-n}^T]$ ；两部分独立，协方差相加）

$$H(z_t) = \frac{1}{2} \log[(2\pi e)^d \det(\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T + M_n)].$$

两者相减：

命题 3a（潜在互信息的闭式，论文式 29）

$$I(z_{t-n}; z_t) = \frac{1}{2} \log \det(I + M_n^{-1/2} (\mathcal{K}^n) \mathcal{C} (\mathcal{K}^n)^T M_n^{-1/2}).$$

证明. 由 $I = H(z_t) - H(z_t | z_{t-n})$ 与上面算出的两个熵：

$$I(z_{t-n}; z_t) = \frac{1}{2} \log \det(\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T + M_n) - \frac{1}{2} \log \det M_n = \frac{1}{2} \log \frac{\det(\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T + M_n)}{\det M_n}.$$

（第二个等号用 $\log a - \log b = \log(a/b)$ ；减号搬进行列式符号里面。）

剩下的是把分母“提”进同一个行列式。记 $A := \mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T$ ，做对称的平方根分解：

$$M_n + A = M_n^{\frac{1}{2}} (I + M_n^{-\frac{1}{2}} A M_n^{-\frac{1}{2}}) M_n^{\frac{1}{2}}.$$

合法性：右边展开时中间的两个因子相消， $M_n^{\frac{1}{2}} \cdot M_n^{-\frac{1}{2}} A M_n^{-\frac{1}{2}} \cdot M_n^{\frac{1}{2}} = A$ （ M_n 半正定，平方根存在且 $M_n^{\frac{1}{2}} M_n^{-\frac{1}{2}} = I$ ）。两边取行列式，用 $\det(XY) = \det X \cdot \det Y$ ：

$$\det(M_n + A) = \det M_n \cdot \det(I + M_n^{-\frac{1}{2}} A M_n^{-\frac{1}{2}}).$$

代回即得 $1/2 \log \det(I + M_n^{-1/2} \mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T M_n^{-1/2})$ 。□

这个表达式的结构 括号里是 $I + M_n^{-1/2}(\text{信号})M_n^{-1/2}$ 。也就是说，这是一个**信噪比式**的量：分子是“由初始条件带来的信号协方差” $\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T$ ，分母是“ n 步累积的噪声” M_n 。

于是这一切的长期行为由**信号项与噪声项的竞赛**决定，而信号项的增长率由 $\mathcal{K}^n$ 的谱主导。这就是为什么 Koopman 的特征值会直接决定信息行为。

4.1.1 三种谱区间

命题 3a 的推论（谱三分） 记 λ 为 $\mathcal{K}$ 的任一特征值：

$|\lambda| > 1$ （爆炸区）： $\mathcal{K}^n$ 指数增长，信号项 $\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T$ 主导， $I(z_{t-n}; z_t)$ 随 n **发散**，反映初始不确定性的放大。

$|\lambda| \approx 1$ （时间相干区）： $\mathcal{K}^n \mathcal{C} (\mathcal{K}^n)^T$ 保持有界；当噪声很小时互信息近似守恒在一个常数水平。这就是“时间相干信息”。

$|\lambda| < 1$ (快速混合区) : $\mathcal{K}^n \rightarrow 0$ ($n \rightarrow \infty$), 信号项相对于 M_n 消失, 故 $I(z_{t-n}; z_t) \rightarrow 0$ 。远端过去的信息因为收缩与噪声累积而被渐近地遗忘。

证明. (三分的机制, 逐档核对) 先把互信息公式里真正起作用的东西挑出来: 命题 3a 的括号里是 $I + M_n^{-1/2}(\text{信号})M_n^{-1/2}$, 行列式在各特征方向上近似连乘, 每一方向的因子由“信号能量 / 累积噪声能量”决定。第 0 章复习过, $\mathcal{K}^n$ 在特征方向 i 上按 $|\lambda_i|^n$ 缩放, 所以信号 $\mathcal{K}^n \mathcal{C}(\mathcal{K}^n)^T$ 在该方向的能量按 $|\lambda_i|^{2n}$ 变化; 噪声 $M_n = \sum_{i=0}^{n-1} \mathcal{K}^i \Sigma (\mathcal{K}^i)^T$ 是同一些方向上被搬运过的噪声的累加, 按几何级数求和。三分就是对这两种速度的比赛分档。

$|\lambda| > 1$: 信号按 $|\lambda|^{2n}$ 增长。历史噪声虽然也被同一因子搬运, 但比值的量级由“初始信息方差 / 噪声方差”这个信噪比决定: 潜在前向的噪声越小, 比值越大, 行列式的对数随 n 上升得越猛 (在噪声趋于零的理想极限下发散)。远端过去的一个扰动被指数放大后送到现在, 模型在放大初始不确定性。

$|\lambda| \approx 1$: $|\lambda|^n \approx 1$, 信号既不放大也不消失; 噪声的累加退化为近似线性的增长。两个量都变化缓慢, 互信息停留在一个近似常数的水位上: 这就是“时间相干信息”。噪声越小, 这个水位越高。

$|\lambda| < 1$: 信号按 $|\lambda|^{2n} \rightarrow 0$ 消失; 噪声累加 M_n 收敛到有限值 (几何级数, 引理 8 给出对应的 Lyapunov 方程)。比值趋于零, $I(z_{t-n}; z_t) \rightarrow 0$: 远端过去被渐近遗忘。




图 4 Koopman 算子在两种区间下的谱行为 (论文 Figure 9)。左: $\mathcal{K}$ 的特征值落在复平面上 (橙点), $\mathcal{K}^n$ ($n = 7$, 蓝叉) 的特征值仍在单位圆上, 时间相干, 信息被保留。右: 特征值严格落在单位圆内, $\mathcal{K}^n$ 的谱随 n 增大向原点收缩, 快速混合, 信息耗散。这两张图是命题 3a 推论的图形化。

爆炸区为什么比“不精确”更严重 爆炸区不只是“预测不准”, 而是**互信息发散**, 模型会放大初始条件里的不确定性。对抗性地, 这意味着微小的输入扰动会被指数放大。所以“稳定化” (Pan & Duraisamy 分支) 确实解决了这一档问题。

但注意: 论文的目标函数里并没有显式的稳定项, 它靠的是第一项 $\log I(z_{t-n}; z_t)$ 与第三项熵正则的组合。为什么会这样, §5 会讲清楚。

4.2 第二步: 把 $I(z_t; x_t)$ 拆成三块

现在换一个角度: 不问“跨时间还剩多少”, 而问“解码器能拿到的总量怎么分”。

引理 6 (编码信息的分解)

$$I(z_t; x_t) = \underbrace{I(z_{t-n}; z_t)}_{\text{时间相干}} + \underbrace{I(z_t; x_{t-1} | z_{t-n})}_{\text{快速耗散}} + \underbrace{I(z_t; x_t | x_{t-1})}_{\text{残差}}.$$

证明. **第一步: 把 x_t 换成 (z_{t-n}, x_t) 。** 对同一个量 $I(z_t; (z_{t-n}, x_t))$ 用链式法则按两种顺序拆开:

$$I(z_t; (z_{t-n}, x_t)) = I(z_t; x_t) + I(z_t; z_{t-n} | x_t) = I(z_t; z_{t-n}) + I(z_t; x_t | z_{t-n}).$$

第一个等号是先 x_t 后 z_{t-n} 的顺序，第二个是先 z_{t-n} 后 x_t 的顺序。由 Fact F.1(b) (z_t 只依赖 x_t ，给定 x_t 后与任何其它变量条件独立)，中间的 $I(z_t; z_{t-n} | x_t) = 0$ ，于是第一种拆法等于 $I(z_t; x_t)$ 。比较两种拆法：

$$I(z_t; x_t) = I(z_{t-n}; z_t) + I(z_t; x_t | z_{t-n}).$$

第二步：给条件部分引入 x_{t-1} 。 把 (x_{t-1}, x_t) 合起来条件在 z_{t-n} 上，链式法则按两种顺序各拆一次：

$$I(z_t; (x_{t-1}, x_t) | z_{t-n}) = I(z_t; x_{t-1} | z_{t-n}) + I(z_t; x_t | z_{t-n}, x_{t-1}) = I(z_t; x_t | z_{t-n}) + I(z_t; x_{t-1} | z_{t-n}, x_t).$$

末项 $I(z_t; x_{t-1} | z_{t-n}, x_t) = 0$ ：按 Fact F.1(b) 背后的建模假设（本节开头 Fact F.1 下的备注），给定 x_t 再加条件不改变 z_t 与其余变量的独立性。于是第一个等号的右边少了一项，两种拆法给出

$$I(z_t; x_t | z_{t-n}) = I(z_t; x_{t-1} | z_{t-n}) + I(z_t; x_t | z_{t-n}, x_{t-1}).$$

第三步：把条件 z_{t-n}, x_{t-1} 换成 x_{t-1} 。 对 $I(z_t; (z_{t-n}, x_t) | x_{t-1})$ 再用两种顺序：

先 x_t 后 z_{t-n} ： $I(z_t; (z_{t-n}, x_t) | x_{t-1}) = I(z_t; x_t | x_{t-1}) + I(z_t; z_{t-n} | x_{t-1}, x_t)$ ，末项由 Fact F.1(b) 为零，故左边等于 $I(z_t; x_t | x_{t-1})$ ；先 z_{t-n} 后 x_t ： $I(z_t; (z_{t-n}, x_t) | x_{t-1}) = I(z_t; z_{t-n} | x_{t-1}) + I(z_t; x_t | z_{t-n}, x_{t-1})$ ，其中第一项也为零：给定 x_{t-1} ，确定性动力学使 x_t 完全确定， z_t 的分布随之固定，与 z_{t-n} 无关。两个等式联立：

$$I(z_t; x_t | z_{t-n}, x_{t-1}) = I(z_t; x_t | x_{t-1}).$$

代回第二步，合并即得引理的分解。□

三块各自的物理身份：

三种信息成分 (1) 时间相干信息 $I(z_{t-n}; z_t)$ ：沿潜在演化 $z_{t-n} \rightarrow \dots \rightarrow z_t$ 持续存在的信息。对应守恒或缓慢耗散的成分。谱上对应特征值靠近单位圆的 Koopman 模式 ($|\lambda| \approx 1$)。信息几乎无损地跨时间传播，于是远端过去与现在之间始终保持互信息。

(2) 快速耗散信息 $I(z_t; x_{t-1} | z_{t-n})$ ：来自最近状态 x_{t-1} 的短期依赖，是 z_{t-n} 已经编码的内容之外的部分。它提供瞬时的预测力，但很快泄漏，因为自回归的潜在演化 $z_{t-n} \rightarrow \dots \rightarrow z_t$ 无法持续访问外部输入 x_{t-1} 。谱上对应 $|\lambda| < 1$ 的模式，信息随前向步数指数耗散。

(3) 残差信息 $I(z_t; x_t | x_{t-1})$ ：当前状态中无法从过去解释的不可预测部分。对应在下注入的信息（噪声、异常），它干扰一致潜在状态的构造。它在 Koopman 算子中没有谱对应物，它不绑定任何特征值结构。从 IB 的角度，这种非预测性成分是可压缩的。

4.3 第三步：后两块的闭式

要给出 (2)(3) 的闭式，需要一个观测模型。

定义 13 (线性观测模型)

$$x_{t-1} = Dz_{t-1} + \eta_{t-1}, \quad \eta_{t-1} \sim \mathcal{N}(0, R),$$

且 η 与过程噪声独立。 D 是观测矩阵， R 是观测噪声协方差。

引理 7 (条件高斯下的互信息) 对条件高斯变量 $a, b | c$,

$$I(a; b | c) = \frac{1}{2} \log \frac{\det \Sigma_{a|c} \det \Sigma_{b|c}}{\det \Sigma_{a,b|c}},$$

其中 $\Sigma_{a|c}, \Sigma_{b|c}$ 是条件协方差, $\Sigma_{a,b|c} = \begin{pmatrix} \Sigma_{a|c} & \Sigma_{ab|c} \\ \Sigma_{ba|c} & \Sigma_{b|c} \end{pmatrix}$ 是联合条件协方差。

证明. 由定义 $I(a; b|c) = H(a|c) + H(b|c) - H(a, b|c)$ 。对三个高斯分布分别用熵公式 $H(y) = 1/2 \log[(2\pi e)^d \det \Sigma]$ 。维度相同 (都是 d)， $(2\pi e)^d$ 因子相消：

$$I(a; b|c) = \frac{1}{2} \log \frac{\det \Sigma_{a|c} \det \Sigma_{b|c}}{\det \Sigma_{a,b|c}}. \quad \square$$

证明. 求 $I(z_t; x_{t-1} | z_{t-n})$ 的闭式。条件在 z_{t-n} 上，

$$z_{t-1} | z_{t-n} \sim \mathcal{N}(\mathcal{K}^{n-1} z_{t-n}, M_{n-1}), \quad z_t | z_{t-n} \sim \mathcal{N}(\mathcal{K}^n z_{t-n}, M_n).$$

于是 $z_t = \mathcal{K} z_{t-1} + \varepsilon_{t-1}$ ，而 $x_{t-1} = D z_{t-1} + \eta_{t-1}$ ，两者共享 z_{t-1} 。条件协方差矩阵的四个块逐块算出来。以非对角块为例 (其余各块同法)：

$$\text{Cov}(z_t, x_{t-1} | z_{t-n}) = \text{Cov}(\mathcal{K} z_{t-1} + \varepsilon_{t-1}, D z_{t-1} + \eta_{t-1}) = \mathcal{K} \text{Cov}(z_{t-1}) D^T = \mathcal{K} M_{n-1} D^T,$$

展开成四项后，含噪声 ε, η 的三项期望为零 (两个噪声与 z_{t-1} 独立、且互相独立)，只剩信号对信号的协方差；协方差在左乘 $\mathcal{K}$ 、右乘 D^T 时按 $\text{Cov}(Au, Bv) = A \text{Cov}(u, v) B^T$ 搬运。两个对角块： z_t 的条件方差就是 M_n (引理 5)； x_{t-1} 的条件方差在信号部分 $D M_{n-1} D^T$ 之上加独立的观测噪声 R 。左下块由对称性是右上块的转置。于是

$$\Sigma_{z_t, x_{t-1} | z_{t-n}} = \begin{pmatrix} M_n & \mathcal{K} M_{n-1} D^T \\ D M_{n-1} \mathcal{K}^T & D M_{n-1} D^T + R \end{pmatrix}.$$

代入引理 7 (记 $\Sigma_{z_t | z_{t-n}} = M_n$, $\Sigma_{x_{t-1} | z_{t-n}} = D M_{n-1} D^T + R$)：

$$I(z_t; x_{t-1} | z_{t-n}) = \frac{1}{2} \log \frac{\det(M_n) \det(D M_{n-1} D^T + R)}{\det \begin{pmatrix} M_n & \mathcal{K} M_{n-1} D^T \\ D M_{n-1} \mathcal{K}^T & D M_{n-1} D^T + R \end{pmatrix}}. \quad \square$$

这一项的 n 依赖完全由 M_n 的增长决定，而 M_n 的增长由 $\mathcal{K}$ 的谱半径决定：

引理 8 (Lyapunov 方程与 M_n 的收敛) 设 $\rho(\mathcal{K})$ 是 $\mathcal{K}$ 的谱半径，即所有特征值模长的最大值。

- 若 $\rho(\mathcal{K}) < 1$ ，则 M_n 收敛到离散 Lyapunov 方程 $M = \Sigma + \mathcal{K} M \mathcal{K}^T$ 的唯一解，于是 $I(z_t; x_{t-1} | z_{t-n})$ 保持有界 (可压缩)。
- 若 $\rho(\mathcal{K}) > 1$ ，则 M_n 发散，信息在不稳定方向上无界增长。
- 若 $\rho(\mathcal{K}) \approx 1$ ，增长缓慢，反映长时间相干，此时它会被 $I(z_{t-n}; z_t)$ 吸收 (与式 29 相容，不矛盾)。

Lyapunov 方程为什么是自然的 M_n 是截断和 $\sum_{i=0}^{n-1} \mathcal{K}^i \Sigma (\mathcal{K}^i)^T$ 。在稳定情形下，这个无穷级数收敛到 M ，而 M 恰好满足 $M = \Sigma + \mathcal{K} M \mathcal{K}^T$ ，“当前的噪声协方差 = 本步噪声 + 上一步噪声被传递过来的一步”。它就是离散 Lyapunov 方程。

它的意义是：在稳定区， M_n 有上界，因此快速耗散信息有上界，它是可以安全压缩的。

证明. 求 $I(z_t; x_t | x_{t-1})$ 的闭式。由定义

$$I(z_t; x_t | x_{t-1}) = H(x_t | x_{t-1}) - H(x_t | z_t, x_{t-1}).$$

由观测模型 $x_t = D z_t + \eta_t$ ， $\eta_t \sim \mathcal{N}(0, R)$ ，在给定 z_t 时 x_t 的条件分布是 $\mathcal{N}(D z_t, R)$ ，与 x_{t-1} 无关，故

$$H(x_t | z_t, x_{t-1}) = \frac{1}{2} \log \det((2\pi e)^d R).$$

于是

$$I(z_t; x_t | x_{t-1}) = H(x_t | x_{t-1}) - \frac{1}{2} \log \det((2\pi e)^d R). \quad \square$$

为什么残差项“没有谱对应物” 最后这个表达式里只出现 $H(x_t|x_{t-1})$ （由原始动力学 T 决定）和噪声协方差 R 。 $\mathcal{K}$ 完全不在里面。

这就是“残差没有谱对应物”的精确含义：它是观测噪声与原始非线性动力学注入的，不对应任何 Koopman 特征值结构。从 IB 的角度，既然它不可预测，**压缩它没有任何代价**（压缩它不损失任何预测能力）。

这条观察是拉格朗日量第二项（惩罚 $I(z_t; x_t|z_{t-n})$ ）的来源。

4.4 命题 3 全貌与它给出的图像

命题 3（信息解耦与谱性质）

$$I(z_t; x_t)$$

可以解耦成三项之和，每项都有谱解释：

成分	谱性质	时间行为	信息含义
时间相干 $I(z_{t-n}; z_t)$	$\lambda \approx 1$	长期存活、持续	可预测、低熵
快速耗散 $I(z_t; x_{t-1} z_{t-n})$	$ \lambda < 1$	快速衰减、短命	瞬态、IB 下可压缩
残差 $I(z_t; x_t x_{t-1})$	无谱对应物	在当前步注入	噪声、异常、非预测性残留




图 5 论文 Figure 1。 (a) 整体架构与拉格朗日量； (b) 信息解耦：把原空间到潜在空间的映射与三类信息放到同一个复平面上，蓝色环对应 $I(z_{t-n}; z_t)$ （单位圆上的相干模式），橙色中心对应 $I(z_t; x_{t-1} | z_{t-n})$ （圆内的耗散模式），灰色散点对应 $I(z_t; x_t | x_{t-1})$ （无谱对应）； (c) 谱注水效应：MI（只有互信息）会把信息堆到少数几个模式上，VNE（只有熵）会均匀铺开，只有 MI+VNE 同时作用才得到既有侧重又不坍缩的分配。

这张图（论文 Figure 1）值得停留一会儿，因为它把整篇论文的三块内容画在了一张图上：

- (a) 是架构：编码器 $\rightarrow$ 潜在空间里的 Koopman 算子 $\rightarrow$ 解码器，底下是拉格朗日量；
- (b) 是命题 3：信息按谱分类，画在复平面的单位圆上；

- (c) 是命题 4 与 5：谱分配，也是整篇论文的结论所在。

三类信息的整体图景 潜在空间里的信息不是“一坨”，而是三层有不同时间常数的成分：

1. 慢变、相干、可预测的，对应单位圆附近的特征值。这是你想保留的。
2. 快变、耗散的、有界的，对应单位圆内的特征值。这就该被压缩掉，因为压缩它不损失长期预测能力，却节省了表示容量。
3. 不可预测的残差，没有谱对应。纯噪声，更该压缩。

信息论因此给出了一个选择原则：保留第 1 类，压缩第 2、3 类。而 IB 恰好就是这个原则的数学形式。

为什么只有第 1 类值得保留 第 2 类是有界的（引理 8），所以它不会随着预测步数增长而变得更重要。一个预测 50 步的模型，不需要 50 步之前那点瞬时依赖。

第 3 类是纯噪声，压缩它零成本。

只有第 1 类的贡献会随 n 增大而保持（甚至在近似守恒时完全保持），因此它是长期预测的唯一来源。这解释了为什么拉格朗日量的第一项是 $\log I(z_{t-n}; z_t)$ ，把 n 取大，就是专门优化这一类。

4.5 一个关键的转折：最大化它会出问题

命题 3 给出了“该保留什么”的答案，于是很自然地写出目标：

$$\max I(z_{t-n}; z_t).$$

论文接下来证明一件更根本的事：这个目标本身会导致失败。这是 §5 的主题，也是整篇论文最反直觉的一步，信息瓶颈式的“更好”反而会毁掉表示。

5 论文的论证链（下）：优化的陷阱与解药

这一节是整篇论文最有意思的部分。命题 3 告诉我们“保留时间相干信息”是对的，于是自然写出 $\max I(z_{t-n}; z_t)$ 。命题 4 将证明这个目标本身会把表示毁掉。命题 5 给出解药。

5.1 命题 4：为什么“更好的信息保留”反而会失败

5.1.1 把问题写成优化问题

考虑潜在变量，条件在 z_{t-n} 上：

$$z_t = \mathcal{K}^n z_{t-n} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, M_n), \quad \mathcal{C} := \mathbb{E}[z_{t-n} z_{t-n}^T].$$

矩阵 $\mathcal{C}$ 表征潜在变量的谱分布。我们要研究的是：在总量受限的前提下最大化潜在互信息，会不会在谱上产生什么特殊的结构。

总量约束写成 $\text{tr}(\mathcal{C}) \leq C_0$ (C_0 是有限常数)。这条约束不是技术性的，它有物理含义：它保证 Koopman 表示的总方差有界，排除方差无界增长的退化解。

于是优化问题是

$$\max_{\mathcal{C}} \frac{1}{2} \log \det(I + M_n^{-1/2} (\mathcal{K}^n) \mathcal{C} (\mathcal{K}^n)^T M_n^{-1/2}) \quad \text{s.t.} \quad \text{tr}(\mathcal{C}) \leq C_0.$$

5.1.2 化为注水问题

证明. **第一步：对角化增益。** 对 $M_n^{-1/2} \mathcal{K}^n$ 做奇异值分解（把任意矩阵写成“旋转、按对角元缩放、再旋转”三步的乘积，得到的对角元叫奇异值，它们总取非负值）。论文把奇异值写成 $\sqrt{g_i}$ ：

$$M_n^{-1/2} \mathcal{K}^n = U \text{diag}(\sqrt{g_i}) V^T, \quad g_i \geq 0,$$

即 g_i 是奇异值的平方（附录记号表称之为谱增益）。代入目标函数，并记 $G := \text{diag}(\sqrt{g_i})$ 、 $B := V^T \mathcal{C} V$ ：

$$I(z_{t-n}; z_t) = \frac{1}{2} \log \det(I + U G B G U^T).$$

第二步：把 U 移出行列式。 用恒等式 $\det(I + AB) = \det(I + BA)$ 。适用条件很宽：对任意可乘的方阵对成立（ A 可逆时一行证出： $\det(I + AB) = \det(A^{-1}(I + AB)A) = \det(I + BA)$ ，相似矩阵行列式相同； A 不可逆时两边都是 A 的连续函数，取极限即得）。这里取 $A = U$ （正交，必可逆）、 $B = G B G U^T$ ，中间的 $U^{-1}U = U^T U = I$ 恰好消掉：

$$\det(I + U G B G U^T) = \det(I + G B G).$$

第三步：把左边的 G 换到右边。 把 $G B G$ 看成 $(GB) \cdot G$ ，再用一次同一个恒等式（ $A = GB$ ， $B = G$ ）： $\det(I + (GB)G) = \det(I + G(GB)) = \det(I + G^2 B)$ ；再用第三次（ $A = G^2$ ， $B = B$ ）： $\det(I + G^2 B) = \det(I + B G^2)$ 。注意 $G B G$ 与 $B G^2$ 作为矩阵一般不相等（除非 B 恰好是对角的），相等的只是行列式。于是

$$I(z_{t-n}; z_t) = \frac{1}{2} \log \det(I + B \text{diag}(g_i)).$$

第四步：为什么最优解可以在对角的 B 里找。 对半正定 B 与半正定对角 $D = \text{diag}(g_i)$ ，由 Fischer 行列式不等式，

$$\det(I + BD) \leq \prod_i (1 + B_{ii} D_{ii}),$$

等号当且仅当 B 在这组基下是对角的。适用条件核对：这里的 $B = V^T \mathcal{C} V$ ， $\mathcal{C}$ 是协方差故半正定， V 正交变换保持半正定性； D 对角非负。另外， $B \leftrightarrow \mathcal{C} = V B V^T$ 是一一对应，且保持半正定与迹（迹的循环性：“ tr ”($V^T \mathcal{C} V$) = “ tr ”($\mathcal{C} V V^T$) = “ tr ”($\mathcal{C}$)，用“ tr ”(ABC) = “ tr ”(CAB)，取 $A = V^T, B =$

$\mathcal{C}, \mathcal{C} = V$)。所以在 “ $\text{tr}(B) = \text{tr}(\mathcal{C}) \leq C_0$ ” 约束下：上界只依赖 B 的对角元；把任何可行 B 的非对角元置零，得到的对角矩阵仍然半正定、迹不变、且恰好取到等号。于是**最优的 $\mathcal{C}$ 在 V 基下是对角的**。记其对角元为 p_i ，这些 p_i 就是 谱权 (spectral weights)，它们指示方差如何分配到各个观测方向 $\{\psi_1, \dots, \psi_d\}$ 。

于是优化问题化为标准注水问题：

$$\max_{p_i, \sum_i p_i \leq C_0} \frac{1}{2} \sum_{i=1}^d \log(1 + g_i p_i). \quad \square$$

这里 g_i 是“第 i 个方向的增益”。增益大意味着这个方向上的信号相对于累积噪声更强，而由 g_i 的定义（来自 $M_n^{-1/2} \mathcal{K}^n$ ）可知： g_i 大当且仅当对应方向的 $\mathcal{K}$ 特征值靠近单位圆。这就把信息分配和谱联系起来了。

5.1.3 KKT 与解

写出拉格朗日量 (μ 是总量约束的乘子, $\lambda_i \geq 0$ 是 $p_i \geq 0$ 的乘子)：

$$\mathcal{L} = \frac{1}{2} \sum_{i=1}^d \log(1 + g_i p_i) - \mu \left(\sum_{i=1}^d p_i - C_0 \right) + \sum_{i=1}^d \lambda_i p_i.$$

先说明为什么 KKT 条件足以刻画解：目标 $1/2 \sum \log(1 + g_i p_i)$ 在 $p_i \geq 0$ 上是凹函数（ $\log$ 凹，复合线性映射仍凹），约束全是线性的，可行集是凸集。凹目标在凸集上的最大化问题里，KKT 条件既必要又充分，解出来的驻点就是全局最优。

证明. 驻点方程。 对 p_i 求偏导 (μ, λ_i 与其它 p_j 都视为常数)：第一项用链式法则 $d/dp \log(1 + gp) = g/(1 + gp)$ 再除以 2；约束项各贡献 $-\mu$ 与 $+\lambda_i$ 。令其为零：

$$\frac{\partial \mathcal{L}}{\partial p_i} = \frac{g_i}{2(1 + g_i p_i)} - \mu + \lambda_i = 0.$$

互补松弛。 KKT 的互补松弛条件是 $\lambda_i p_i = 0$ ：每个 $p_i \geq 0$ 约束要么贴边 ($p_i = 0$)，要么不起作用 ($\lambda_i = 0$)，二者必居其一。据此分两种情形。

内部解 ($p_i > 0$)： 互补松弛给出 $\lambda_i = 0$ ，于是

$$\frac{g_i}{2(1 + g_i p_i)} = \mu \implies 1 + g_i p_i = \frac{g_i}{2\mu} \implies p_i = \frac{1}{2\mu} - \frac{1}{g_i}.$$

(第一个箭头是两边乘 $2(1 + g_i p_i)/g_i$ ；第二个箭头移项。每步都是可逆的代数变形， $g_i > 0, \mu > 0$ 保证除法合法。)

边界解 ($p_i = 0$)： 代回驻点方程， $g_i/2 - \mu + \lambda_i = 0$ ，即 $\lambda_i = \mu - g_i/2$ 。乘子的非负性要求 $\lambda_i \geq 0$ ，即 $g_i/2 \leq \mu$ ，等价于 $1/(2\mu) - 1/g_i \leq 0$ ：这一方向的“水位”不高于“门槛”，拿不到任何方差。

合并。 两种情形可以写成一条式子：内部解给出 $1/(2\mu) - 1/g_i > 0$ 时的值，边界解对应它 ≤ 0 的情形，正好是取 $\max$ 与 0：

$$p_i = \max\left(0, \frac{1}{2\mu} - \frac{1}{g_i}\right), \quad \text{其中 } \mu \text{ 由 } \sum_i p_i = C_0 \text{ 确定。}$$

(μ 的确定：目标对每个 p_i 严格递增，总预算约束必然取等号 $\sum_i p_i = C_0$ ，这个方程解出 μ 。□)

这个解的含义 p_i 是“第 i 个方向分到多少方差”， g_i 是“这个方向的增益”（增益大 = 特征值靠近单位圆 = 这个模式又强又持久）， $1/(2\mu)$ 是那个统一的**水位**。

所以这个公式说的就是一句话：

某个方向能分到的方差 = 水位 — 这个方向的“门槛”，且不小于零。

门槛是 $1/g_i$ ：增益越大，门槛越低，越容易拿到水。水位由总预算定，预算越多，水位越高，能分到水的方向也越多。

两个后果一眼可见：第一，**增益大的方向优先**（这是好事，正是时间相干的模式）；第二，**门槛高于水位的方向一点都拿不到**（这是坏事，就是坍缩）。

命题 4（潜在互信息的作用） 最大化潜在互信息 $I(z_{t-n}; z_t)$ 会把谱权分配给**时间相干的模式**，从而提升 Koopman 表示的相关性。然而**过度强调这个目标会导致模式坍缩**：表示集中在少数几个主导模式上，丧失有效维度。

注水解的后果 注水解 $p_i = \max(0, c - 1/g_i)$ 的意思是：**低于水位的方向一个 bit 都不给**。

增益 g_i 大的方向 ($|\lambda| \approx 1$ ，时间相干) 拿到的方差多，增益小的方向 ($|\lambda| < 1$ ，耗散) 方差为零。

当增益谱高度倾斜时（这在真实系统里很常见，往往只有少数几个模式真正主导），注水解**退化成一个低秩解**：只有少数几个 i 满足 $g_i > 2\mu$ 。信息被挤进这几个主导方向，潜在空间的有效维度崩塌。

这就是模式坍缩的**数学机制**。它恰恰是“最大化互信息”这个目标的**最优解**。

论文的立场需要分清 论文并不是说“互信息不该优化”。它说的是：**互信息是一个必要但不充分的目标**。

优化它是必要的，命题 2 的下界说，保留的信息越少，误差下界越高。但它是不充分的，因为“保留总量的最大化”和“分布形状的健康”是两件事。

用论文自己的话：这个现象发生在“谱高度倾斜”的时候，而倾斜恰恰是真实系统在单位圆附近只有少数主导模式时的普遍状态。

与 §2 的高斯 IB 对照，这件事其实早就藏在那里 回忆高斯 IB： $1/\beta$ 扮演软性秩选择器， β 越大截断越狠。

命题 4 说的是同一件事，只是换到动力学的语境里：**互信息最大化会自动把秩压下来**。在 IB 自己的框架里，“更压缩”就意味着“更低秩”。也就是说，纯 IB 不仅不反对模式坍缩，它**奖励**模式坍缩。

你需要第二个量来对抗它。这就是命题 5。

5.2 命题 5：用谱熵把有效维度买回来

5.2.1 思路

既然问题出在注水解会把某些 p_i 压到零，那就需要一项主动惩罚“谱过于集中”的东西。von Neumann 熵正好是这个：它在谱集中时很小，在谱平坦时很大。

把 $\mathcal{C}$ 归一化成密度矩阵 $\mathcal{C}/\text{tr}(\mathcal{C})$ ，于是

$$S\left(\frac{\mathcal{C}}{\text{tr}(\mathcal{C})}\right) = -\sum_{i=1}^d \frac{p_i(\mathcal{C})}{\text{tr}(\mathcal{C})} \log \frac{p_i(\mathcal{C})}{\text{tr}(\mathcal{C})}.$$

在这里，归一化的 $\mathcal{C}/\text{tr}(\mathcal{C})$ 可以看作希尔伯特空间里的密度矩阵，而有效维度就是 $\exp(S)$ （定义 11）。

5.2.2 修改后的拉格朗日量与求解

证明. 在注水问题里加上熵项 (系数 γ):

$$\mathcal{L} = \frac{1}{2} \sum_{i=1}^d \log(1 + g_i p_i) + \gamma \left(- \sum_{i=1}^d \frac{p_i}{\text{tr}}(C) \log \frac{p_i}{\text{tr}}(C) \right) - \mu \left(\sum_i p_i - C_0 \right) + \sum_i \lambda_i p_i.$$

对 p_i 求导, 逐项算。第一项与 KKT 一节相同, 是 $g_i/(2(1 + g_i p_i))$ 。熵项: 记 $u = p_i/T$ ($T := \text{tr}(C)$), 先对 u 求 $d/du[-u \log u] = -(\log u + 1)$ (乘积法则: $-(u' \log u + u \cdot 1/u)$), 再由 u 对 p_i 的导数是 $1/T$ 用链式法则, 得到 $-(1/T)(\log(p_i/T) + 1)$ 。线性约束项各贡献 $-\mu$ 与 $+\lambda_i$ 。(求导时把 $T = \text{tr}(C)$ 当作固定参数处理, 这是论文的约定: 相当于每一步先把归一化总量冻结在当前值, 再解逐方向的驻点方程。)

$$\frac{g_i}{2(1 + g_i p_i)} - \mu + \lambda_i - \frac{\gamma}{T} \left(\log\left(\frac{p_i}{T}\right) + 1 \right) = 0.$$

解出 $(\star)$ 。内部解 $p_i > 0$ 时互补松弛给出 $\lambda_i = 0$ (论文指出这是 KKT 条件下的情形)。移项把熵项单独放到一边, 两边乘 T/γ :

$$\log\left(\frac{p_i}{T}\right) + 1 = \frac{T}{\gamma} \left(\frac{g_i}{2(1 + g_i p_i)} - \mu \right).$$

两边取指数 ($\exp$ 是严格增函数, 取指数不改变方程的解):

$$\frac{p_i}{T} = \exp\left(\frac{T}{\gamma} \left(\frac{g_i}{2(1 + g_i p_i)} - \mu \right) - 1\right). \quad (\star)$$

这个方程没有直接的闭式解 (p_i 同时出现在指数上下的分母里)。论文做了一次代数变形, 把它化成广义 Lambert W 函数的定义式。

定义 14 (广义 / r -Lambert W 函数) W_r 定义为方程

$$W_{r(z)} e^{W_{r(z)}} + r W_{r(z)} = z$$

的解。当 $r = 0$ 时它退化成标准的 Lambert W 函数。

证明. **第一步: 把常数从指数里分出来。** 把 $(\star)$ 两边乘 T , 并按 $\exp(A + B) = \exp(A) \exp(B)$ 把指数拆成“常数 + 含 p_i 的部分”:

$$p_i = T \exp\left(-1 - \frac{T\mu}{\gamma}\right) \cdot \exp\left(\frac{Tg_i}{2\gamma(1 + g_i p_i)}\right).$$

常数因子记作 $C_1 := T \exp(-1 - \frac{T\mu}{\gamma}) > 0$; 两边同除以含 p_i 的那个指数 (等价于乘它的倒数, 指数变号), 得到

$$p_i \exp\left(-\frac{Tg_i}{2\gamma(1 + g_i p_i)}\right) = C_1.$$

第二步: 换元 $y := 1 + g_i p_i$ 。 于是 $p_i = (y - 1)/g_i$, 指数的分母 $1 + g_i p_i = y$ 。代入并两边乘 g_i :

$$(y - 1) \exp\left(-\frac{Tg_i}{2\gamma y}\right) = g_i C_1. \quad (\star\star)$$

第三步: 凑成广义 Lambert W 的定义式。 记 $a := T \frac{g_i}{2\gamma}$, 并设 $W := a/y$ (即 $y = a/W$; W 就是指数位置的量取了正号)。代入 $(\star\star)$:

$$\left(\frac{a}{W} - 1\right)e^{-W} = g_i C_1.$$

两边乘 W ($W \neq 0$, 因为 $a > 0$ 、 $y > 0$), 再乘恒正的 e^W :

$$a - W = g_i C_1 W e^W \implies W e^W + \frac{1}{g_i C_1} W = \frac{a}{g_i C_1}.$$

第二个式子正是定义 14 的形状 $W_{r(z)} e^{W_{r(z)}} + r W_{r(z)} = z$, 其中 $r = 1/(g_i C_1)$ 、 $z = a/(g_i C_1) = (T g_i)/(2\gamma g_i C_1)$ 。于是 $W = W_{1/(g_i C_1)}\left(\frac{T g_i}{2\gamma g_i C_1}\right)$, 代回 $y = a/W$:

$$y = \frac{T g_i / (2\gamma)}{W_{1/(g_i C_1)}\left(\frac{T g_i}{2\gamma g_i C_1}\right)},$$

第四步: 回到 p_i 。 $p_i = (y - 1)/g_i = a/(g_i W) - 1/g_i$, 其中 $a/g_i = T/(2\gamma)$:

$$p_i = \frac{T}{2\gamma} \cdot \frac{1}{W_{1/(g_i C_1)}\left(\frac{T g_i}{2\gamma g_i C_1}\right)} - \frac{1}{g_i}. \quad \square$$

命题 5 (有效维度与抗坍缩) Koopman 表示中的**低有效维度**表明信息坍缩到少数主导模式上, 限制了模型表达丰富模式的能力。**惩罚归一化协方差的 von Neumann 熵 $S(C/\text{tr}(C))$** 会鼓励更丰富、谱上更多样的表示。

为什么这个解保证了抗坍缩 这个解保证抗坍缩的原因, 藏在它蕴含的一个结构性事实里:

在熵正则下, 所有方向的谱权 p_i 都严格为正。

(依据在式 $(\star\star)$ 本身: 它要求 $y - 1 = g_i C_1 \exp(-(T g_i)/(2\gamma y))$, 右端是正常数 $g_i C_1$ 乘以恒正的指数函数, 严格大于零; 而 $y - 1 = g_i p_i$ 且 $g_i > 0$, 所以 $p_i > 0$ 。对比无熵正则时的 $p_i = \max(0, c - 1/g_i)$, 那里低于水位的方向直接被置零。)

于是谱权重在所有模式上都有正分配, 避免了退化的谱, 潜在空间 Z 的有效维度被可证明地提升。

熵正则的作用: 从集中在少数方向到分散到所有方向 无熵正则时, 注水把方差几乎全部分给增益最大的少数几个方向。加上熵正则后, 水位被整体抬高, 增益较小的方向也能分到少量方差。

这少量方差对弱方向是决定性的: 它让那些模式得以在表示中存在, 于是多步预测里那些模式的贡献不会被抹掉。

Figure 6 的消融 (§1 里的插图) 正是这个现象的图像化: $\gamma = 0$ 时 $\mathbb{R}$ (角速度) 维度被压没了, γ 适度时恢复。




图 6 含/不含 von Neumann 熵正则的潜在谱随训练的变化（论文附录 Figure 20(a) 的对应素材）。深蓝为“含 γ ”，浅蓝为“不含 γ ”。可以看到含正则时谱分布更均匀、更接近满秩；不含时谱迅速集中在少数几个特征值上。这是命题 5 的直接可视化。




图 7 回到论文 Figure 1(c)：从右上到左上是“只用 MI”（信息堆在少数模式）；中上是“只用 VNE”（谱被强行铺平，但没有侧重）；下排是“MI + VNE”，既有侧重（水位的形状）又保持所有模式非零。这就是命题 4 与 5 的合成图像。

5.3 到这里，三个目标已经齐了

把命题 3、4、5 合起来，得到一个由三个愿望构成的完整目标：

论文的最终原则

1. 保留时间相干信息：最大化 $I(z_{t-n}; z_t)$ ，它承载长期预测能力（命题 3）。
2. 压缩耗散与残差：最小化 $I(z_t; x_t | z_{t-n})$ ，它们可压缩且不贡献长期预测（命题 3）。
3. 保持谱多样性：最大化 $S(C/\text{tr}(C))$ ，防止前两项导致模式坍缩（命题 4、5）。

再加上 Koopman 结构本身的要求（潜在线性）与重构要求，就是论文的完整拉格朗日量。

下一节把它写下来。

6 从拉格朗日量到可运行的算法

理论到这里已经完整。这一节把它翻译成可以反向传播的损失函数，并给出两份算法。

6.1 统一拉格朗日量

定义 15（信息论拉格朗日量，论文式 8）

$$\max_z \alpha \log I(z_{t-n}; z_t) - \beta I(z_t; x_t | z_{t-n}) + \gamma S\left(\frac{\mathcal{C}}{\text{tr}}(\mathcal{C})\right) + \log p(x_t | z_t),$$

其中 α, β, γ 是拉格朗日乘子。

四项的来历，逐项对照前面三个命题：

项	管什么	来自哪个命题
$\alpha \log I(z_{t-n}; z_t)$	保留时间相干信息（长期预测能力的唯一来源）	命题 3、2 的下界
$-\beta I(z_t; x_t z_{t-n})$	压缩快速耗散 + 残差（可压缩的成分）	命题 3
$\gamma S(\mathcal{C}/\text{tr}(\mathcal{C}))$	维持谱多样性，防模式坍塌	命题 4、5
$\log p(x_t z_t)$	重构（解码器）	基础自监督目标

注意第二项里的一个恒等式，它说明一项惩罚覆盖了两个成分：

$$I(z_t; x_t | z_{t-n}) = I(z_t; x_{t-1} | z_{t-n}) + I(z_t; x_t | x_{t-1}).$$

也就是说，一个 β 同时惩罚了快速耗散信息与残差信息，这两者正是命题 3 里判定为“可压缩”的两类。

这一项是“最大化”的形式，容易看错符号 拉格朗日量是 $\max$ ，而第二项带负号，所以它是在最小化条件互信息。这符合直觉：耗散和残差成分不该被保留。

但落到代码里时，最小化形式会让符号反过来（见下面的 Algorithm 1）。阅读论文时请始终盯住它是在 $\max$ 还是在 $\min$ 。

6.1.1 为什么不能直接算

$I(z_{t-n}; z_t)$ 有个紧凑的闭式（命题 3a），但它在 d 很大时行列式代价高，而且当潜在是高维时数值不稳定。 $I(z_t; x_t | z_{t-n})$ 更是需要条件密度。 S 需要每步做一次特征分解。

所以论文给出一组可替代的、逐项的实现。

6.2 可训练损失

定义 16（可训练损失，论文式 9）

$$\max_n \sum_n \left[\alpha I(z_n; \mathcal{P}_n) + \beta \mathbb{E}_{p_{\theta}(z_n | x_n)} [\log q_{\psi}(z_n | z_{n-1})] + \beta H_{p_{\theta}}(z_n | x_n) + \log p_{\omega}(x_n | z_n) \right] + \gamma S\left(\frac{\mathcal{C}}{\text{tr}}(\mathcal{C})\right) + \mathcal{L}_{\text{ELBO}}.$$

下面逐项解释每一项是什么、为什么是它。

6.2.1 第 1 项：时间相干（InfoNCE）

$$I(z_n; \mathcal{P}_n)$$

把 z_n 与它的时间邻域 $\mathcal{P}_n = \{z_{n \pm i} \mid 1 \leq i \leq k\}$ 联系起来。实现上用 InfoNCE：

$$I(z_n; \mathcal{P}_n) \approx \frac{1}{|\mathcal{P}_n|} \sum_{p \in \mathcal{P}_n} \log \frac{\exp(z_n^T z_p / \tau)}{\sum_{j=1}^B \exp(z_n^T z_j / \tau)}.$$

为什么用邻域而不是只用相邻两步

1. 用 $k > 1$ 的邻域相当于把 n 取大，专门去捕捉 $|\lambda| \approx 1$ 的相干成分，同时把只有一步相关性的瞬时噪声压掉。
2. InfoNCE 是互信息的下界 (§2)，所以这一项是保守地优化时间相干。
3. 低维潜在时也可以用命题 3a 的闭式直接算，二者等价但代价不同。

6.2.2 第 2、3 项：结构一致性

这是最新颖的一项，也是把“信息论”和“Koopman 线性”扣在一起的那颗螺钉。

结构一致性的等价形式（论文式 50–51） 给定 z_{n-1} 时，条件互信息为

$$I(z_n; x_n | z_{n-1}) = H(z_n | z_{n-1}) - H(z_n | x_n, z_{n-1}).$$

由于编码器与 z_{n-1} 无关 (Fact F.1), $H(z_n | x_n, z_{n-1}) = H_{p_\theta}(z_n | x_n)$, 于是

$$I(z_n; x_n | z_{n-1}) = H(z_n | z_{n-1}) - H_{p_\theta}(z_n | x_n).$$

又按定义

$$I(z_n; x_n | z_{n-1}) = \mathbb{E}_{p(z_n | x_n)} \left[\log \frac{p(z_n | x_n)}{q(z_n | z_{n-1})} \right] = \mathbb{E}_{p(z_n | x_n)} [-\log q(z_n | z_{n-1})] - H_{p_\theta}(z_n | x_n).$$

证明. 第一式。 条件互信息的定义 $I(a; b | c) = H(a | c) - H(a | b, c)$ (第 2 章定义 6 之前给过) 取 $a = z_n$ 、 $b = x_n$ 、 $c = z_{n-1}$, 逐符号代入即得。

第二式，第一步：写成 KL。 条件互信息有 KL 形式： $I(a; b | c) = \mathbb{E}_{p(b, c)} D_{\text{KL}}(p(a | b, c) \parallel q(a | c))$, 它度量“真实的条件分布 $p(a | b, c)$ 与先验 $q(a | c)$ 差多远”。这里 q 是 Koopman 先验 $q_{\psi(z_n | z_{n-1})}$, 表达式里本来就不含 b ; 又由 Fact F.1, 编码器只看 x_n , $p(z_n | x_n, z_{n-1}) = p(z_n | x_n)$ 。两个实参都与 b 无关, 对 b 的期望积掉 (内层是常数):

$$I(z_n; x_n | z_{n-1}) = \mathbb{E}_{p(z_n | x_n)} \left[\log \frac{p(z_n | x_n)}{q_{\psi(z_n | z_{n-1})}} \right].$$

第二式，第二步：拆对数。 把对数拆成 $\log p - \log q = (-\log q) - (-\log p)$, 两项分别取期望: 第二项是 $\mathbb{E}[-\log p_{\theta}(z_n | x_n)] = H_{p_\theta}(z_n | x_n)$ (条件熵的定义), 于是

$$I(z_n; x_n | z_{n-1}) = \mathbb{E}_{p(z_n | x_n)} [-\log q_{\psi(z_n | z_{n-1})}] - H_{p_\theta}(z_n | x_n). \quad \square$$

这两步的结论值得单独列出:

结构一致性为什么是一个互信息

$$I(z_n; x_n | z_{n-1}) = \mathbb{E}_{p(z_n | x_n)} [-\log q_{\psi(z_n | z_{n-1})}] - H_{p_\theta}(z_n | x_n).$$

左端正是拉格朗日量第二项要**最小化**的东西。因此最小化它等价于在代码里**最大化**

$$\mathbb{E}_{p_{\theta}(z_n | x_n)} [\log q_{\psi(z_n | z_{n-1})}] + H_{p_\theta}(z_n | x_n).$$

这就是可训练损失里的第 2、3 项。

两个效应各自做什么:

- **与 Koopman 动力学对齐**: $\mathbb{E}[-\log q(z_n|z_{n-1})]$ 要求从编码器采样的点落在 Koopman 先验的高似然区域。因为先验被参数化为**线性高斯转移** $q(z_n|z_{n-1}) = \mathcal{N}(z_n | \mathcal{K}z_{n-1}, \Sigma)$, 最小化这个 KL 就迫使编码器输出 可以在线性结构下被预测。
- **熵正则**: $H_{p_\theta}(z_n|x_n)$ 防止编码器变成确定性的 (否则 $I(x; z)$ 在连续情形下退化, 见 §2 的警告)。

合起来, $p(z_n|x_n) \rightarrow q(z_n|z_{n-1})$, 也就是

$$p(z_n|x_n) \approx q(z_n|z_{n-1}) \iff z_n \text{ 在 } \mathcal{K} \text{ 下近似线性演化,}$$

这就是结构一致性。

6.2.3 第 4 项: 重构

$$\log p_{\omega}(x_n|z_n)$$

是解码器损失。在 AE 版里它退化成 L_2 : $\|x_n - g_{\omega}(z_n)\|^2$ 。

6.2.4 第 5 项: von Neumann 熵 (预测充分性)

从一个小批量里估计潜在协方差:

$$\mathcal{C} = \frac{1}{B} \sum_{i=1}^B (z_i - |z|)(z_i - |z|)^T, \quad |z| = \frac{1}{B} \sum_i z_i, \quad P = \frac{\mathcal{C}}{\text{tr}(\mathcal{C})}, \quad S(P) = -\sum_j \lambda_j \log \lambda_j,$$

其中 λ_j 是 P 的第 j 个特征值。这一项直接对应命题 5, 防坍塌。

6.2.5 第 6 项: ELBO

$$\mathcal{L}_{\text{ELBO}} = \log p_{\omega}(x_{n-1}|z_{n-1}) - D_{\text{KL}}(p_{\theta}(z_{n-1}|x_{n-1}) \parallel \mathcal{N}(0, I)).$$

这一项来自 VAE 的标准目标, 作用有两个: 训练稳定性, 以及额外的重构信号。它是把 IB/VIB 那套变分机制接到自编码器上的接口。

6.3 两份算法

6.3.1 VAE 版 (概率)

Algorithm 1 (论文版, 概率) 输入: 数据 $\mathcal{D} = \{x_n\}_{n=0}^T$; 拉格朗日乘子 (α, β, γ) ; 学习率 η ; 轮数 K ; 批量 B ; 邻域窗口 k ; 温度 τ 。

1. 初始化编码器 $p_{\theta}(z|x)$ 、解码器 $p_{\omega}(x|z)$ 、潜在动力网络 $q_{\psi}(z_n|z_{n-1})$ 。
2. for epoch = 1 to K :

1. for 每个小批量 $\{x_1, \dots, x_B\}$:

1. 采样潜在 $z_i \sim p_{\theta}(z|x_i)$ 。
2. **时间相干**: 对每个 z_n , 把时间邻居 $\mathcal{P}_n = \{z_{n \pm i} \mid 1 \leq i \leq k\}$ 当作正样本, 算 InfoNCE。
3. **结构一致性**: 算 $\mathbb{E}_{p_{\theta}(z_n|x_n)} [\log q_{\psi}(z_n|z_{n-1})]$ 。
4. **预测充分性**: 算 $\mathcal{C}$ 、 $P = \mathcal{C}/\text{tr}(\mathcal{C})$ 、 $S(P)$ 。
5. **ELBO**: 算 $\mathcal{L}_{\text{ELBO}}$ 。
6. 总损失:

$$\mathcal{L} = -[\alpha I(z_n; \mathcal{P}_n) + \mathbb{E}[\log q_{\psi}(z_n|z_{n-1})] + H_{p_\theta}(z_n|x_n) + \log p_{\omega}(x_n|z_n) + \gamma S(P) + \mathcal{L}_{\text{ELBO}}].$$

7. 用 Adam 更新 θ, ω, ψ 。

注意论文里两处的写法略有差别 式 (9) 把 β 显式写在 $\mathbb{E}[\log q]$ 与 H 前面; Algorithm 1 的总损失里没有显式写出 β (等价于把它吸收进了那两项的定义)。

这不是错误，只是同一件事的两种记法。但如果你要复现，必须知道：**实际起作用的是三个独立的乘子，一个管 InfoNCE (α)，一个管结构一致性 (β)，一个管熵 (γ)。**

6.3.2 AE 版（确定性）

当编码器是确定性的 $z_n = f_{\theta(x_n)}$ 时，概率量退化：

- $\mathbb{E}_{p(z_n|x_n)} [\log q_{\psi}(z_n|z_{n-1})]$ 退化成 L_2 一致性损失 $\mathcal{L}_{\text{Koop}} = \|z_{n+1} - \mathcal{K}_{\psi} z_n\|^2$;
- $\mathcal{L}_{\text{ELBO}}$ 退化成 AE 重构项。

Algorithm 2（论文版，确定性）

1. 初始化确定性编码器 $z_n = f_{\theta(x_n)}$ 、解码器 $\hat{x}_n = g_{\omega(z_n)}$ 、Koopman 算子 $\mathcal{K}_{\psi}$ 。
2. **for** epoch、**for** 小批量：
 1. 编码 $z_i = f_{\theta(x_i)}$ 。
 2. 时间相干：同一个 InfoNCE。
 3. 结构一致性（确定性）： $\mathcal{L}_{\text{Koop}} = \|z_{n+1} - \mathcal{K}_{\psi} z_n\|^2$ 。
 4. 预测充分性：从 $\mathcal{C}$ 算 $S(P)$ 。
 5. 重构： $\mathcal{L}_{\text{rec}} = \|x_n - g_{\omega(z_n)}\|^2$ 。
 6. 总损失：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} - \alpha I(z_n; \mathcal{P}_n) + \beta \mathcal{L}_{\text{Koop}} - \gamma S(P).$$

7. 用 Adam 更新。

AE 版更清楚，适合用来理解三项的作用 $\mathcal{L} = \underbrace{\mathcal{L}_{\text{rec}}}_{\text{重构}} - \underbrace{\alpha I(z_n; \mathcal{P}_n)}_{\text{时间相干（最大化）}} + \underbrace{\beta \mathcal{L}_{\text{Koop}}}_{\text{结构一致性（惩罚）}} - \underbrace{\gamma S(P)}_{\text{谱多样性（最大化）}}$ 。

四个符号：重构是“+”（要小），时间相干是“-”（要大，所以最小化时带负号），结构一致性是“+”（要小），熵是“-”（要大）。这份最简洁的式子把整篇论文讲完了。

6.4 架构细节

潜在空间里的线性算子在三种任务上有三种形态（论文 Table 5）：

环境	结构	关键特征
物理仿真	AE / VAE	$z_{t+1} = \mathcal{K} z_t$ ；重构；Koopman 线性前向；InfoNCE；von Neumann 熵
视觉输入（控制）	AE	$z_{t+1} = \mathcal{K} z_t + B a_t + \varepsilon$ （线性高斯）；VAE ELBO；InfoNCE；VNE
图结构动力学	AE	$z_{t+1} = \mathcal{K}(A) z_t$ （邻接条件化）；重构；InfoNCE；VNE

三个细节：

- **控制任务**里线性算子是 $\mathcal{K} z_t + B a_t$ 。这是控制理论里的标准线性时不变形式，它能“在潜在空间里做 LQR”变成一件合法的事，而 LQR 只有在潜在动力学线性时才成立。这是 Koopman 表示相对一般表示学习的**实际好处**，不只是美学上的。
- **图任务**里 $\mathcal{K}(A) := A \times \mathcal{K}$ ，即由邻接矩阵 A 调制的共享 Koopman 复合（沿用 CKO 的设定）。这样参数量与节点数无关，可以外推到更多节点。
- **架构主体**：物理仿真用卷积编码器（3 层，逐步下采样到 $H/16 \times W/16$ ）→ 展平 → 全连接到 d_s 维潜在 → 单层线性 $\mathcal{K}$ → 对称解码器。ERA5 任务用 factorized attention 编码器。视觉输入与图任务沿用 E2C 与 CKO 的原始设置 以保证公平比较。

超参数（论文 Table 12）：

含义	符号	物理仿真	视觉输入	图动力学
时间相干权重	α	2.00	3.00	2.00
结构一致性权重	β	—	2.00	—
von Neumann 熵权重	γ	0.10	0.50	0.10
InfoNCE 邻域	k	3	5	5

从这张表能读出两件事

1. **物理仿真任务里 β 是空的。**因为那里用的是 AE 结构, 结构一致性已经是一个硬性的 L_2 项($\mathcal{L}_{\text{Koop}}$), 不需要额外的概率权重。视觉与控制任务用 VAE 结构, 才需要 β 来平衡 KL。
2. **γ 的取值差了一个量级 (0.10 vs 0.50)。**这符合命题 5 的分析: 熵正则的合适强度取决于潜在协方差的谱有多倾斜。控制任务的高维图像输入 更容易坍缩, 所以需要更强的熵正则。

计算开销 (论文 Table 7) 加上 InfoNCE 与 von Neumann 熵后, 每个 epoch 的额外开销很小:

- Kármán 涡: 总 epoch 时间 201.23 s, 其中 InfoNCE 13.78 s、熵 0.97 s;
- Dam Flow: 18.92 s, 其中 0.76 s / 0.56 s;
- ERA5: 253.24 s, 其中 15.09 s / 7.43 s。

也就是说, 理论换来的收益额外付出的计算代价可以忽略。

7 实验：理论预测能被验证吗？

论文的实验组织方式值得学习：它不按数据集罗列，而是**按命题提问**。每个结果都在回答 前面五个命题中的一个。所以这一节也按那个顺序读。

7.1 任务与基线

三类动力学数据，覆盖三种“难度来源”：

类别	任务	难在哪
物理仿真	Lorenz 63($n = 3$)、Kármán 涡街($n = 64 \times 64 \times 2$)、Dam Flow、ERA5 天气预报	非线性、随机、高维、混沌；需要长时稳定性
视觉输入控制	Planar、Pendulum、Cartpole、3-Link (40×40 到 $80 \times 80 \times 2$ 像素)	从高维像素里抽出低维潜在动力学，且在潜在空间里可控
图结构动力学	Rope ($n \in [40, 56]$)、Soft ($n \in [160, 224]$)	变量数可变、需要外推到更多节点

基线覆盖了上一节梳理的几条分支：**VAE**（一般表示学习）、**KAE**（PyKoopman 的 NNDMD，LRA 系的默认实现）、**KKR**（核方法分支）、**PFNN**（结构分支，混沌 SOTA）、**E2C / PCC**（VAE 系的视觉控制）、**CKO**（结构分支，图动力学 SOTA）。

读结果时注意 KAE 的身份 KAE 就是 PyKoopman 里的 NNDMD，用的是**无约束的全矩阵 $\mathcal{K}$** ，没有任何一致性项、KL 项或熵项。它正是本文要挑战的“裸 LRA”。所以它在长时预测上的退化不是“调参没调好”，而是架构本身的症状。

指标有五个维度，各自对应一个命题的预测：

- **NRMSE**（短/长时），预测精度，对应命题 2 的误差上下界；
- **SDE**（谱分布误差，基于 1000 步序列），**物理一致性**，对应命题 3 的谱解释；
- **KLD**（状态分布散度），长期统计，对应命题 2 的遍历版本（Remark F.4）；
- **SSIM**，高维场的结构相似性；
- **控制成功率 / Percentage to Goal**，下游任务可用性。

7.2 问题（1）：潜在互信息真的决定预测极限吗？（验证命题 2）

论文的回答：是 论文原文的结论是：与命题一致，Koopman 表示下的预测误差不可避免地累积，并被潜在互信息界定；用潜在互信息做正则后，短期与长期预测都被改善。

看 Lorenz 63 与 Kármán 这两组（论文 Table 2），有三个具体观察：

1. **所有方法都随步数增长而退化，但退化速率不同**。Lorenz 63 上 5 步 NRMSE 从 0.005（VAE）到 0.003（本文），50 步从 0.019 到 0.013，差距在长时被放大。这符合“误差按信息缺口累积”的预测。
2. **KLD 的排序与 NRMSE 一致**：Lorenz 63 上 1.047（VAE） $\rightarrow$ 0.464（KAE） $\rightarrow$ 0.342（KKR） $\rightarrow$ 0.293（PFNN） $\rightarrow$ 0.285（本文）。分布层面的收敛与点预测精度同向，说明改进不是“运气好”，而是保留了正确的动力学。
3. **本文在物理一致性（SDE）上优势最大**。Kármán 上 SDE 从 0.799（KKR）降到 0.256。

最要紧的一条：本文打败了领域特化的 SOTA PFNN 是专门为混沌系统设计的（它显式注入耗散与酉结构），而本文只是用一个通用的信息论原则。

在 Lorenz 63 与 Kármán 涡这两个混沌任务上，本文与 PFNN 表现相当或更好（Kármán 的 5/20 步 NRMSE 和 SSIM 都更好，50 步略逊）。

这正是论文标题里“general principles”的分量所在：没有用任何领域知识，达到了领域知识方法的水平。

7.3 问题（2）：保留的信息如何塑造动力学相关的流形？（验证命题 4、5）

这一问的核心证据是 Kármán 涡的特征值分布与潜在流形可视化。




图 8 Kármán 涡街的谱与流形（论文 Figure 2）。左：本文与 KAE 的 Koopman 算子特征值分布。本文（蓝）的特征值分布在单位圆上，捕捉到极限环的循环结构；KAE（橙）的特征值塌向原点。右：五种方法学到的潜在流形的 t-SNE 可视化，灰色是真实极限环。本文的潜在轨迹（蓝方块，自回归预测）稳定地绕着真实轨道打转；KAE 塌成一条近一维的线，KKR 与 PFNN 虽能一步重构但长时偏离。

什么叫“极限环” 极限环是相空间里的一条闭合轨道：系统一旦走到它附近，就会被“吸”上去，然后永远沿着这条闭合曲线转圈，既不离开也不停。

流体绕过圆柱后形成的 Kármán 涡街就是典型例子，涡的脱落是周期性的，所以系统的状态（速度场）在相空间里画出一个闭合的圈。

它之所以适合用来检验表示质量：参数化必须能表达一个闭合的一维结构。如果模型的潜在空间塌成一条直线或一堆散点，就无法表示这条闭合轨道，长时预测必然漂走。

这一问的三条结论

1. **极限环结构由单位圆附近的模式承载。**本文保留的信息正体现在这些模式上，所以自回归轨迹能“绕着真实轨道转”。
2. **KAE 有特征值塌向零**，减少了有效潜在维度。这解释了它自回归预测的漂移，不是预测器不好，是表示坍缩了。
3. **KKR 与 PFNN 也能捕捉极限环结构**（通过一步重构），但会在长时偏离。因为它们的结构约束只作用在单步上（这正是 §1 里 KKR 的自我批评）。

第 2 条是最完整的因果链：**特征值塌陷** → **有效维度下降** → **长时漂移**。这正是命题 5 说的事，低有效维度导致表达力不足。

7.4 问题 (3): 信息论正则相比 VAE 与 Koopman 自编码器捕捉到了什么? (验证命题 4、5)




图 9 Planar 任务的潜在流形 (论文 Figure 3, 用局部线性嵌入 LLE 可视化)。第一张是真实流形 (颜色表示 y 轴位置), 后面是四种方法学到的。E2C (纯 VAE 架构) 的几何被严重扭曲, 这是一致性丧失的典型症状; KAE 的流形塌成近一维, 反映潜在空间缺乏有效维度; PCC (为改善流形构造而改造的 VAE) 有部分改进但仍与本文有差距; 本文的流形与真值最接近。

这张图是整篇论文最有说服力的一张, 因为它展示的是几何而不是数字: “信息论正则”的收益可以肉眼看见, 真实流形是一个规整的网格, E2C 把它揉成一团, KAE 把它压成一条线, 只有本文保留了网格结构。

控制任务上的数字 (论文 Table 9, 无噪声):

任务	E2C	PCC	KAE	本文
Planar	37.8	71.4	12.2	73.8
Pendulum	88.5	90.1	68.2	91.5
Cartpole	39.5	94.1	98.5	97.6
3-link	21.5	48.5	11.8	47.9

有噪声情形 (Table 8) 本文在四个任务里三个第一, 且优势更大 (Planar: 39.6 vs PCC 的 34.8; Cartpole: 61.9 vs KAE 的 57.2)。

为什么噪声情形优势更大, 而这是可以预测的 因为噪声正是命题 3 里的“残差信息”, 它没有谱对应物, 是可压缩的。

一个干净地实现了“压缩残差”的模型, 在噪声环境下应该更稳健。数据确实如此。这反过来支持了命题 3 的分解不是事后编的。

7.5 问题 (4): 噪声、长时程、大规模下稳健吗? (验证命题 1、2)

ERA5 天气预报是最严格的检验: 5 个通道 (500 hPa 位势、850 hPa 温度、700 hPa 比湿、850 hPa 风 u 与 v), 训练到 2016 年, 测试 2018 年之后, 也就是说测试期在时间上完全在训练期之外。




图 10 ERA5 全球湿度从 2018-01-01 到 2018-01-08 的连续预测（论文 Figure 4）。下排是误差图。相比其他模型，本文在 7 天的自回归展开里保持了更稳定、更准确的结果。

逐通道指标（论文 Table 6）显示，本文在所有通道、所有预测步长上都优于基线。几个代表性数字：

通道 / 指标	KAE	KKR	PFNN	本文
位势 5-NRMSE	0.058	0.061	0.046	0.023
位势 5-SSIM	0.860	0.852	0.882	0.964
风 v 5-NRMSE	0.051	0.051	0.050	0.031
风 v 5-SSIM	0.240	0.247	0.300	0.649

5-NRMSE 上几乎减半，风的 SSIM 上从 0.24 提到 0.65。这是相当大的差距。

为什么“时间外推的测试集”是有意义的检验 如果模型只是记住了训练分布, 那么在三年后的测试数据上会崩。

本文能撑住，说明它学到的是**动力学的结构**（时间相干模式），而不是统计相关性。这正好对应命题 2 里“ $I(z_{n-1}; z_n)$ 是信息上限”的说法：只有结构性的信息才能在分布漂移后存活。

7.6 问题（5）：拉格朗日量能推广到不同架构与下游任务吗？（验证命题 1–5）

三处证据：

(a) 图结构动力学。




图 11 100 步自回归的预测误差对比 (论文 Figure 5)。左二者是 Rope ($n \in [40, 56]$), 无噪声 / 有噪声), 右二者是 Soft ($n \in [160, 224]$)。红色 (本文) 在四种情形里 都低于蓝色 (CKO), 且差距随步数增大而拉开。注意两个任务都是**外推**: 训练 5–9 个物体, 测试 10–14 个。

(b) **消融**: 三个乘子各自的作用。论文 Figure 6 (§1 里的插图) 已经讨论过: $\alpha = 0$ 时潜空间碎成散点; $\beta = 0$ 时流形坍塌; $\gamma = 0$ 时 $\mathbb{R}$ 维度被压没。每个乘子对应一个可观察的失败模式, 且失败模式与命题的预测一一对应。

(c) **训练稳定性**。论文附录 Figure 20/21 显示: 加熵正则后, 潜在协方差从 “高度稀疏” 过渡到 “稠密且满秩”, 特征值分布在整个优化过程中保持接近均匀; 总损失与熵损失曲线稳定。这是命题 5 在训练动力学层面的验证。




图 12 再看 Figure 1(c)。它其实是整篇论文的实证摘要: “MI” 一栏表示只用互信息时的谱分配 (少数方向拿走全部信息), “VNE” 一栏表示只用熵时的分配 (均匀但无侧重), “MI + VNE” 一栏是两者合成的结果, 既有侧重又保持所有模式非零。实验中所有 “模式坍塌” 与 “维度恢复” 的现象都对应这三栏之间的差别。

7.7 实验部分的三条总结

读过实验后, 应该带走的判断

1. 信息论正则确实换来了可测量的几何改善, 不是只改了个数字。流形可视化 (Figure 3)、特征值分布 (Figure 2)、协方差热图 (Figure 20) 三个角度看都一致。
2. 在噪声与长时程这两个 “命题 3 预测会受益” 的场景下, 收益最大。这支持了 “残差/耗散成分可压缩” 的分析。
3. 收益的代价几乎为零 (Table 7: 额外开销只有几个百分点到十几个百分点)。

读论文时需要留意的几处

- Dam Flow 一组的数字在表格里对齐不太清晰, 引用具体数值时要回原文核对。
- PFNN 在 Dam Flow 上没有结果 (它本来就是为混沌设计, Dam Flow 不在其适用范围)。这是一个 fair comparison 的合理声明, 但也意味着 Dam Flow 上少了一个强基线。

- 所有任务都在 d_s 作为超参数的固定网格上跑，论文没有给出“如何选 d_s ”的准则。这与论文自己的局限性陈述（不处理样本复杂度）是一致的。

8 坐标：这篇论文站在哪里

前面的章节已经把两条线索各自的谱系讲完。这一节做三件事：把两条线索的汇合点标出来、回答“如果没有这篇论文最接近的替代品是什么”、以及“它出现后谁会被直接影响到”。

8.1 一次视角比较：Koopman 谱系与 IB 谱系的错位

把两边的核心目标并排放在一起，会看到一个很有意思的错位。

关心什么	Koopman 谱系的做法	IB 谱系的做法
表示要简单	让潜在动力学成为线性（谱位置约束）	压缩 $I(x; z)$
表示要有表达力	保留足够多的模式（谱数量约束）	保留 $I(z; y)$
怎么实现	改架构 / 加损失项	改目标函数
缺什么	没有一般原则来决定约束的强度	看不见“信息分布在几个方向”

两边的缺口恰好互补：Koopman 一侧有“多样性”的概念（模式、谱），但缺少一个原则性的目标函数；IB 一侧有原则性的目标函数，但它对“多样性”盲。

本文做的就是把这个错位补上。它借 IB 的目标形状（一个拉格朗日量），借 Koopman 的谱语言（特征值、模式），然后用 von Neumann 熵（一个本来属于量子信息的量）去补 IB 的盲区。

这个组合之所以成立，是因为协方差矩阵的谱同时说着两种语言：对 Koopman 它说“有哪些模式、在单位圆的哪里”；对数理统计它说“方差怎么分配、有效维度是多少”。

8.2 如果这篇论文不存在，最接近的替代品

按“替代的紧密程度”排序。

8.2.1 替代品一：T-IB (Federici et al. 2023/2024)

这是 IB 那一侧的最接近者。T-IB 的形式是

$$\min I(x_t; z_t) - \beta I(z_{t+\tau}; x_{t+\tau}),$$

即“压缩当前状态，保留 τ 之后的未来信息，丢弃高频以简化模拟”。

T-IB 与本文的三点差别

1. **T-IB 没有抗坍缩机制。**它的目标里没有任何控制信息分布形状的量。在高斯 IB 的分析里我们已经看到，纯 IB 会奖励低秩。所以 T-IB 在原理上就有模式坍缩的风险，只是它的任务（马尔可夫过程的模拟）可能对这一点不那么敏感。
2. **T-IB 不要求潜在线性演化。**它要的是“能在 τ 之后被模拟出来”，不要求 $z_{t+\tau} = \mathcal{K}^\tau z_t$ 。本文的结构一致性要求严格得多。
3. **T-IB 的目标是采样效率（大时间跳跃），本文的目标是谱性质的可靠性。**

所以：如果本文不存在，一个想用信息论做动力学表示的人，最可能落在 T-IB 上，然后发现它解决不了模式坍缩。

8.2.2 替代品二：VAMPnets (Mardt et al. 2018)

这是谱那一侧的最接近者。它用 VAMP-2 分数

$$\hat{R}_2 = \left\| c_{00}^{-1/2} c_{01} c_{11}^{-1/2} \right\|_F^2$$

作为训练信号，直接最大化被特征子空间捕捉到的 Koopman 奇异值。

VAMPnets 与本文的区别，在于“标量分数 vs 向量分配” VAMP-2 是一个标量。它对“这些奇异值是怎么分布的”不敏感：一个只抓到一个极强奇异值的子空间，和一个均匀抓到十个中等奇异值的子空间，在这个分数上可能一样好。

本文的 von Neumann 熵正是为了把“分布形状”这件事补进来。所以最接近的替代方案是“VAMPnets + 某个谱多样性正则”，而本文给出了那个正则应该是什么、以及为什么。

另一个区别：VAMPnets 没有解码器（它靠 Softmax 把 K 变成概率转移矩阵），本文保留了编解码器结构以支持重构与控制任务。

8.2.3 替代品三：PFNN (Cheng et al. 2025)

这是动力学结构那一侧的最接近者。它把耗散混沌拆成两个相位，各自用结构约束：

- **收缩相**： $\|G_c\| \leq 1$ ，实现为 $\Gamma_{\text{con}} = \text{ReLU}(\sigma(\hat{G}_c^T \hat{G}_c - I_d))$ ；
- **保测度相**：双向损失 + 酉约束 $\gamma_2(\|\hat{G}_m^* \hat{G}_m - I_d\|_F + \|\hat{G}_m \hat{G}_m^* - I_d\|_F)$ 。

PFNN 与本文的分工 PFNN 的约束是谱几何的（特征值几何），把谱推到单位圆上。本文的约束是信息分配的，保留什么、压缩什么、铺开多少。

两者的实验对比很有说服力：在混沌任务上它们性能相当（PFNN 在 Kármán 的 50 步指标上略好），但 PFNN 需要显式知道系统是耗散混沌且有全局吸引子，而本文不需要任何这类假设。

更重要的是：**PFNN 的所有约束都是外部验证的**（用 KLD/MMD/TKE 检查），训练过程中没有任何量控制潜在保留了多少信息。而本文的约束直接作用在信息上。

8.2.4 替代品四：KKR / KORR (Bevanda 2023 / Kostic 2022)

理论那一侧的最接近者。它们给出风险定义、泛化界、一致性保证，并且让 Koopman 不变性由构造保证（KKR）或秩由风险最小化决定（KORR 的 RRR）。

它们与本文回答的是不同的问题 KKR/KORR 回答的是：给定一个特征空间，如何正确地估计算子？
本文回答的是：特征空间应该长什么样？

两个问题互补，甚至可以组合：把本文的信息论损失当作 KKR 的特征学习阶段，再用 KKR 的核方法做最终的算子估计。论文的“未来方向”里提到的“kernel 方法与信息论的结合”（引用 Bach 2022）正是这个方向。

8.2.5 替代品五（一个平行的世界）：神经算子

有必要提一下这一支，因为很多读者的主场在这里。DeepONet（branch/trunk 架构）、FNO（傅里叶层做谱卷积）、KNO（把 PDE 求解表述为 Koopman 线性预测）解决的是同一个数学问题的不同侧面。

“学 PDE 的解算子”和“学 Koopman 算子”是同一件事吗？ 不是，但有交集。

- **神经算子学**的是 $\mathcal{G} : a \mapsto u$ ，即从参数（初值/边界/系数）到解的映射。它把时间也算进输入输出，学的是一个两点边值意义上的映射。
- **Koopman 算子学**的是 $\mathcal{K} : \varphi \mapsto \varphi \circ T$ ，即一步时间推进在观测量上的作用。它是单参数半群的生成元视角。

两者在“线性 PDE”上重合（此时解算子与 Koopman 算子都是线性的），但在非线性 PDE 上分道扬镳：神经算子学一个非线性映射，Koopman 学一个线性算子但作用在非线性观测上。

KNO 的价值在于它展示了这条路的可行性：把“解 PDE”换成“解一族线性预测问题”，并且声称获得了网格无关性与零样本外推。但它与本文的差别同样明显：KNO 关注的是解的高精度与泛化，本文关注的是潜在表示的谱结构。

8.3 这篇论文出现后，谁会被直接影响到

受影响的工作（按被影响的方式分类） 第一类：所有把 Koopman 表示塞进瓶颈结构的深度模型。 LRA、KAE/PyKoopman、CKO、KoopA、K²VAE、ResKoopNet..... 这些方法的共同特征是“自监督 + 无表示约束”。本文给出的是一个可以直接插进它们损失函数的正则项（三项都不依赖具体架构）。论文自己也强调了这一点：**architecture-agnostic**。

第二类：用 VAE 做动力学建模与控制的工作。 E2C、PCC、世界模型类方法。它们的潜在空间目标原本是“重构 + 预测”，本文指出这不够，还需要时间相干与谱多样性。

第三类：信息论动力学表示这条新兴的子方向。 T-IB 之后，“把 IB 用到动力学上”是一个自然的方向。本文给出了这个方向的 **第一个完整的负面结果**：纯 IB 会导致模式坍缩，必须有第二个量。这条负面结果比正面结果更有价值，因为它排除了一整类做法。

第四类：核方法与统计学习理论分支。 KORR/KKR 关心的是估计的正确性。本文提示了一个组合方向：用信息论的原则选特征空间，用核方法的理论保证估计质量（论文明确把“kernel 方法与信息论的结合”列为未来方向）。

第五类：神经算子方向。 KNO 把 PDE 求解表述为 Koopman 线性预测，它同样需要一个好的“观测/特征空间”（KNO 用傅里叶基或卷积层）。本文的谱分析直接告诉它**哪些模式值得保留**。

不应过度宣称的部分

- 本文没有解决样本复杂度与非渐近收敛。它给的是总体层面的界，没有说明需要多少数据。
- 本文没有处理连续谱的显式参数化。它靠“谱多样性”来间接处理，但在纯连续谱系统上（比如强混合的湍流）是否足够，论文没有答案。
- 本文的 γ, α, β 仍然是超参数，“原则性”体现在有**哪几项**，而不是**每项该多重**。这是一个真实的缺口。

8.4 逻辑阶梯：从最原始的想法到最复杂的理论

把前面所有工作按“概念复杂度”排成一条阶梯，这样能一眼看出本文处在哪一级。

级	工作	新加了什么概念
1	DMD (2015) / EDMD (2015)	固定字典，最小二乘估 $\mathcal{K}$ 。没有学习，只有回归。
2	Takeishi et al. 2017	用网络学观测函数。引入“残差为零 $\Leftrightarrow$ 子空间不变”。
3	LRA / Otto & Rowley 2019	完整编解码器 + 多步一致性 。暴露了“所有模式被同等训练”的问题。
4a	Pan & Duraisamy 2020	把稳定性写进 参数化 （三对角形式）。第一个结构化先验。
4b	Azencot et al. 2020	前/后向 一致性损失 ，分级前主子矩阵。把特征值推向单位圆。
4c	CKO / Li et al. 2020	组合结构 ：共享子算子 $\mathcal{K} = \sigma \times \hat{K}$ ，参数量与 N 无关。
4d	PFNN / Cheng et al. 2025	混沌的 耗散 + 酉结构 ，双向损失，不需要知道不变测度。
5	VAMPnets / Mardt et al. 2018	换掉解码器：用 变分谱下界 $\hat{R}_2$ 作训练信号。
6	KORR / Kostic et al. 2022	放进 统计学习理论 ：风险定义、泛化界、降秩回归。

级	工作	新加了什么概念
7	KKR / Bevanda et al. 2023	不变性由构造保证：Koopman 特征函数核，通用性 + 一致性。
8	T-IB / Federici et al. 2023	把 IB 用到时间序列。第一个信息论目标，但无多样性控制。
9	本文	把 IB 的变分界搬到 Koopman 链上，并用 von Neumann 熵 补 IB 的盲区。

这条阶梯的读法 第 1–3 级在解决“怎么表示”（字典、架构）。第 4 级在解决“加什么约束”（稳定性、一致性、结构）。第 5–7 级在换视角（变分分数、统计理论、构造性保证）。第 8–9 级才引入**信息论**。

每一级都在补上一级暴露的缺口，而本文处理的缺口是最后暴露出来的那个：**当你有了一个原则性的目标函数后，这个目标函数本身会不会把你带到沟里去？**

答案是会（命题 4），所以你需要第二个量（命题 5）。

8.5 一句总结

这篇论文的一句话定位 它把 Koopman 表示学习从“算子逼近问题”重新表述为“信息论表示学习问题”，证明了互信息决定误差界（命题 1、2）、揭示信息与谱的对应（命题 3）、并且发现了纯信息瓶颈目标的自毁机制（命题 4），最后用 von Neumann 熵给出了修补（命题 5）与一个架构无关的算法。

9 往前走：局限、开放问题与可行的下一步

这一节分成两层：论文自己承认的局限，以及从整个脉络看出去、论文没有说但显然存在的问题。

9.1 论文自己承认的两条

论文的局限性陈述（附录 D） (1) **不做样本复杂度与非渐近收敛分析**。本文的命题都是总体层面（population-level）的：它们说的是“如果分布已知，误差界是什么形状”。论文明确说“未来工作可以探索这个方向上更严格的理论分析”。

(2) **未把核方法与信息论结合起来**。论文引用 Bach (2022) 的 **Information Theory with Kernel Methods**，指出核方法（Kostic 等）与信息论之间已有联系，这是一个“有意思的延伸方向”。

第一条是真正要紧的。它意味着：

总体层面的界不能直接回答“要多少数据” 命题 2 说“误差被信息缺口控制”。但在实践中， $I(z_{n-1}; z_n)$ 是用有限样本估的，而 InfoNCE 又是它的下界。所以从“理论上的界”到“你的实验里能不能达到”之间，隔着一个统计估计误差。

KORR 那一支 (§1 分支五) 恰好提供了这个缺口所需的工具：把风险写成经验风险 + 泛化项。一个自然的下一步是：把本文的信息论目标放进 KORR 的风险框架里，给出非渐近界。

9.2 从脉络看出去四个问题

9.2.1 问题一：连续谱怎么办

命题 3a 的谱三分 ($|\lambda| > 1 / \approx 1 / < 1$) 全部建立在 $\mathcal{K}$ 有离散谱这个前提上。但 Koopman 与 von Neumann 1932 年就指出混合系统的谱可以是纯连续的。

这是一个真实的理论缺口 对纯连续谱系统，“时间相干信息 $I(z_{t-n}; z_t)$ ”这一项对应什么？谱上没有一个单位圆上的离散点集可以指认。

论文的“有效维度”思路（用谱的熵来度量多样性）其实对连续谱是更自然的，熵不要求离散。但论文的推导（式 29、注水问题）假设了离散特征值。

一个明确的下一步：**把命题 3-5 推广到测度谱（spectral measure）的框架**，用谱测度代替特征值计数。

9.2.2 问题二：拉格朗日量里的 $\log$ 是什么意思

式 (8) 写的是

$$\max_z \alpha \log I(z_{t-n}; z_t) - \dots,$$

注意第一项是 $\log I$ 而不是 I 。

这个 $\log$ 在数学上不改变最优解，但改变优化的几何 因为 $\log$ 是单调递增的， $\arg \max \log I = \arg \max I$ 。所以从“找最优表示”的角度两者等价。

但梯度不同： $\partial \log I / \partial \theta = (1/I) \partial I / \partial \theta$ 。当 I 很小时， $\log$ 版本的梯度被放大。这意味着训练早期（ I 小的时候） $\log$ 形式会给出更强的信号。

这是一种常见的技巧（类似 $\log$ -det 目标），但论文没有解释为什么选它。**这是一个值得追问的设计选择**：换成 I 本身，或者换成 $I^{1/2}$ ，对训练动力学的影响是什么？论文没有实验。

9.2.3 问题三：三个乘子怎么选

论文把 α, β, γ 当作拉格朗日乘子给出，并在实验中给出具体数值（ $\alpha = 2-3$, $\beta = 2$, $\gamma = 0.1-0.5$ ）。

“原则性”体现在有哪几项，不在每项该多重 这是一个诚实的评价：论文证明了哪几项应该存在（命题 3-5 各自的必要性，以及消融实验的验证），但没有给出每项该多重的准则。

从 §2 的率失真分析出发，其实有一个可能的准则：由 $D(R) \approx \sigma^2 e^{-2R}$ ，多保留 1 nat 的互信息把误差降一个 e^2 因子。于是乘子的选择应该使得“三项的边际收益相等”： $\alpha \cdot \partial I / \partial \theta = \beta \cdot \partial(\text{压缩}) / \partial \theta = \gamma \cdot \partial S / \partial \theta$ 。这只是一个思路，论文没有做。

更有意思的是 γ 与 d_s （潜在维度）的耦合：有效维度不能超过 d_s ，所以 γ 的最优值应该依赖于 d_s 。论文把 d_s 当固定超参数，没有探索这个耦合。

9.2.4 问题四：控制任务里的动作没有被信息论化

在视觉控制任务里，潜在动力学是 $z_{t+1} = \mathcal{K}z_t + Ba_t + \varepsilon$ 。但动作 a_t 没有出现在拉格朗日量里。

一个自然的延伸：动作条件下的信息瓶颈 控制任务的正确提法应该是

$$\max_z I(z_{t-n}; z_t | a_{t-n:t}) - \beta I(z_t; x_t | z_{t-n}, a_{t-n:t}) + \gamma S + \dots$$

即“在给定动作序列的条件下”衡量时间相干与压缩。

这不是吹毛求疵：在控制里，什么信息值得保留取决于动作。一个在自由演化下无关紧要的模式，在可被动作激发的意义下可能很关键。

动作条件 IB 在强化学习里已有零散的工作，但结合 Koopman 的谱解释还是一个空白。

9.3 三条具体可行的下一步

把上面的问题整理成三条可以立刻动手的方向。

9.3.1 方向 A：非渐近理论

目标：把命题 2 的界从总体层面降到有限样本层面。

路线：用 KORR 的风险分解 $\mathcal{R}(G) = \mathcal{R}_0 + \mathcal{E}(G)$ ，把信息论量代进去。具体地，把 $\sum_n [I(x_{n-1}; x_n) - I(z_{n-1}; z_n)]$ 用经验估计 (InfoNCE) 替换，用 Rademacher 复杂度或 PAC-Bayes 控制估计误差，得到形如

$$\text{误差} \leq \text{经验信息缺口} + O(1/\sqrt{N})$$

的界。关键的难点是 InfoNCE 的偏差（它本身是下界，且被 $\log K$ 封顶），需要仔细处理。

9.3.2 方向 B：连续谱与谱测度

目标：把命题 3-5 从离散特征值推广到谱测度。

路线： $\mathcal{K}$ 的谱分解写成 $\mathcal{K} = \int \lambda dE(\lambda)$ (E 是谱测度)。离散情形下的“靠近单位圆的模式”变成“谱测度在单位圆附近的密度”。von Neumann 熵的推广是谱熵 (spectral entropy)，注水问题变成“在单位圆附近分配多少谱密度”。

这条路线尤其适合与 PFNN 那条线结合：PFNN 实验里学到稠密分布在单位圆上的特征值，正是连续谱的离散近似。

9.3.3 方向 C：解决“该保留什么”的在线判定

目标：让模型自己判断哪些模式值得保留，而不是靠固定乘子。

路线：把 α, β, γ 变成可学习的（例如用对偶上升法解约束优化），或者让 γ 依赖当前的谱倾斜程度（自适应熵正则）。一个自然的想法是：当谱已经接近平坦时减小 γ ，当谱开始倾斜时增大它，即

$$\gamma_t = \gamma_0 \cdot (1 + \kappa \cdot \text{skew}(\lambda(\mathcal{C}_t))).$$

这直接把命题 4 的诊断（谱倾斜 $\rightarrow$ 坍缩）变成一个控制器。

9.4 读完之后应该能回答的问题

如果你读完了这份笔记，你应该能够回答下面这些问题。如果答不上来，可以回到对应章节。

自检清单

1. Koopman 算子为什么能“线性化”非线性动力学？代价是什么？ (§1)
2. 为什么有限维不变子空间对多不动点系统不存在？ (§1 Brunton 定理)
3. LRA 的架构里，线性性具体发生在哪一层？为什么不是“瓶颈层是线性的”？ (§1)
4. VAMPnets 与 Koopman 自编码器的三点本质差别是什么？ (§1)
5. IB 的拉格朗日量为什么可以写成“码率 + $\beta \times$ 失真”？失真项 $I(x; y|z)$ 是怎么从马尔可夫链推出来的？ (§2)
6. VIB 的两个界为什么一个高估、一个低估？这对目标函数的正确性意味着什么？ (§2)
7. InfoNCE 为什么在 $\log K$ 处饱和？这对报告数值有什么要求？ (§2)
8. 为什么纯互信息最大化会导致模式坍缩？给出注水解的推导。 (§5, 命题 4)
9. von Neumann 熵为什么能修复它？关键的结构性结论是什么？ (§5, 命题 5)
10. “结构一致性”这一项为什么等价于一个条件互信息？ (§6)

10 附录

10.1 A. 记号表

记号	含义
$x \in M \subseteq \mathbb{R}^n$	动力学系统的状态； n 是状态维数
$T : M \rightarrow M$	离散时间非线性映射， $x_t = T(x_{t-1})$
$H = L^2(M, \mu)$	可观测函数构成的希尔伯特空间
φ, ψ_i	观测函数 / 特征 (observable)
$z \in \mathcal{Z}$	潜在变量； $\mathcal{Z}$ 是由 $\{\varphi_1, \dots, \varphi_d\}$ 张成的潜在空间
d	潜在维数
$\mathcal{K}$	Koopman 算子；矩阵形式记作 $\mathcal{K}$ 或 K
$\mathcal{C}$	潜在协方差矩阵 $\text{Cov}(z)$
M_n	n 步线性前向协方差 $\sum_{i=0}^{n-1} \mathcal{K}^i \Sigma (\mathcal{K}^i)^T$
$I(a; b)$	互信息
$D_{\text{KL}(p \parallel q)}$	KL 散度
$H(x)$	(微分) 熵
$S(\rho)$	von Neumann 熵
ρ	密度矩阵 (半正定、迹为 1)
λ	特征值 (Koopman 算子或协方差矩阵的，视上下文)
γ_i (在注水问题里记作 g_i)	谱增益
p_i	注水问题里的谱权
α, β, γ	拉格朗日乘子 (时间相干 / 结构一致性 / 谱熵)
θ, ω, ψ	编码器 / 解码器 / 潜在动力学的网络参数
t	时间步； n 为滞后步数
$\mathcal{N}$	高斯分布
tr	矩阵的迹

10.2 B. 关键公式速查

定义与架构

- Koopman 算子: $(\mathcal{K}\varphi)(x) = \varphi(T(x))$
- 不变子空间条件: $\mathcal{K}\Psi(x) = K^T \Psi(x)$
- EDMD 估计: $K^T = \hat{Y}^T \hat{X} (\hat{X}^T \hat{X})^\dagger$
- Koopman 自编码器: $x \xrightarrow{f} z \xrightarrow{\mathcal{K}} z' \xrightarrow{g} \hat{x}$
- LRA 多步一致性: $\mathcal{L} = \mathbb{E}[(\dots) \text{多步重构} + \beta(\dots) \text{潜在一致性}] + \Omega$
- VAMP-2 分数: $\hat{R}_2 = \left\| \mathcal{C}_{00}^{-1/2} \mathcal{C}_{01} \mathcal{C}_{11}^{-1/2} \right\|_F^2$
- CKO 组合算子: $\mathcal{K} = \sigma \times \hat{K}$

信息论工具

- 互信息: $I(x; y) = \mathbb{E} \left[\log \frac{p(x, y)}{p(x)p(y)} \right] = H(x) - H(x|y)$
- 链式法则: $I(x; y) = I(x; (y, z)) - I(x; z|y)$
- DPI: $X \rightarrow Y \rightarrow Z \implies I(X; Z) \leq I(X; Y)$
- IB 拉格朗日: $\mathcal{L} = I(x; z) - \beta I(z; y)$, 等价于 $I(x; z) + \beta I(x; y|z) + \text{const}$
- VIB 码率上界: $I(x; z) \leq \mathbb{E} D_{\text{KL}}(q(z|x) \parallel r(z))$
- VIB 相关性下界: $I(z; y) \geq H(y) + \mathbb{E} \log q(y|z)$
- InfoNCE: $\hat{I} = \log K - \mathcal{L}_{\text{NCE}} \leq I(x; c)$
- von Neumann 熵: $S(\rho) = -\text{tr}(\rho \log \rho) = H(\lambda(\rho))$
- 有效维度: $d_{\text{eff}} = \exp(S(\rho))$

五个命题

- 命题 1: $I(x_{n-1}; x_n) \geq I(z_{n-1}; x_n) \geq I(z_{n-1}; z_n)$
- 命题 2: $\|p - q_{\text{KR}}\|_{\text{TV}} \leq \frac{1}{2} \left[\sum_{n=1}^t (I(x_{n-1}; x_n) - I(z_{n-1}; z_n)) + \mathcal{E} \right]$, 且 $\mathbb{E} \|x_{1:t} - \mathbb{E}_{q_{\text{KR}}} [x_{1:t}|x_0]\|^2 \geq C \exp\left(-\frac{2}{nt} \sum_n I(z_{n-1}; z_n)\right)$
- 命题 3: $I(z_t; x_t) = I(z_{t-n}; z_t) + I(z_t; x_{t-1}|z_{t-n}) + I(z_t; x_t|x_{t-1})$
- 命题 4: 注水解 $p_i = \max\left(0, \frac{1}{2\mu} - \frac{1}{g_i}\right) \rightarrow$ 谱倾斜时低秩 $\rightarrow$ 模式坍塌
- 命题 5: 加熵正则后所有 $p_i > 0 \rightarrow$ 有效维度被证明提升

拉格朗日量与损失

- 拉格朗日量: $\max_z \alpha \log I(z_{t-n}; z_t) - \beta I(z_t; x_t|z_{t-n}) + \gamma S(\mathcal{C}/\text{tr}(\mathcal{C})) + \log p(x_t|z_t)$
- 结构一致性等价: $I(z_n; x_n|z_{n-1}) = \mathbb{E} [\log q_{\psi(z_n|z_{n-1})}] - H_{p_\theta}(z_n|x_n)$
- AE 总损失: $\mathcal{L} = \mathcal{L}_{\text{rec}} - \alpha I(z_n; \mathcal{P}_n) + \beta \|z_{n+1} - \mathcal{K}z_n\|^2 - \gamma S(P)$

10.3 C. 补充: 命题 2 的率失真下界

命题 2 的第四个证明步骤值得单独展开, 因为它把“信息缺口”换算成了“误差的量级”。

证明. 出发点: Shannon 下界。对任意源 X 与 L^2 失真, 率失真函数满足

$$R(D) \geq h(X) - \frac{1}{2} \log(2\pi e D).$$

移项 (取自然对数、以 D 为主元):

$$D \geq \frac{1}{2\pi e} e^{2h(X) - 2R}.$$

这就是“误差随码率指数衰减”的一般形式。

应用到 Koopman 轨迹。把 $x_{1:t} \in \mathbb{R}^{n \times t}$ 看成 nt 维源 (n 是状态维数)。码率 R 由潜在信道提供, 而潜在信道每一步可传的信息量正是 $I(z_{n-1}; z_n)$, 所以单位维度的码率近似为

$$R \approx \frac{1}{nt} \sum_{n=1}^t I(z_{n-1}; z_n).$$

代入 Shannon 下界:

$$D \geq \frac{nt}{2e} \exp\left(\frac{2}{nt} h(x_{1:t})\right) \exp\left(-\frac{2}{nt} \sum_{n=1}^t I(z_{n-1}; z_n)\right).$$

吸收常数。 由 $\sum_{n=1}^t I(x_{n-1}; x_n)$ 决定了 $h(x_{1:t})$ 中与动力学相关的部分（剩余部分是加性常数），把这两项一起收进常数

$$C := \frac{nt}{2e} \exp\left(\frac{2}{nt} \sum_{n=1}^t I(x_{n-1}; x_n)\right),$$

得到

$$\mathbb{E}_p[\|x_{1:t} - \mathbb{E}_{q_{\text{KR}}}[x_{1:t}|x_0]\|^2 | x_0] \geq C \exp\left(-\left(\frac{2}{nt} \sum_{n=1}^t I(z_{n-1}; z_n) + \mathcal{E}\right)\right). \quad \square$$

这个下界的三种读法

1. **误差随保留的信息指数下降。** 多保留 1 nat，误差降 e^2 倍（约 7.4 倍）。
2. **常数 C 由原系统的熵决定。** 这意味着一个“更难”的系统（熵更高、动力学耦合更强）有更高的误差地板，这与 Koopman 表示无关，它是问题本身的难度。
3. **加上了 $\mathcal{E}$ 。** 近似误差的三个部分（编码、转移、解码）也进入了指数，这提醒我们“完美的信息保留”并不能弥补糟糕的参数化。

10.4 D. 补充：结构一致性的两个效应

§6 给出了 $I(z_n; x_n | z_{n-1}) = \mathbb{E}[\log q_\psi] - H_{p_\theta}$ 的等价性。它的两个效应值得分开看。

(1) 与 Koopman 动力学对齐。 期望项 $\mathbb{E}_{p_{\theta(z_n|x_n)}}[-\log q_\psi(z_n|z_{n-1})]$ 要求从编码器采样的点落在 Koopman 先验的高似然区域。因为先验被参数化为线性高斯转移，

$$q_{\psi(z_n|z_{n-1})} = \mathcal{N}(z_n | \mathcal{K}z_{n-1}, \Sigma),$$

最小化这项 KL 迫使编码器输出可以在**线性结构**下被预测。

换一种说法：如果你把编码器输出的点画出来，它们必须“看起来像是从一个线性系统采出来的”。这就是结构一致性的几何含义。

(2) 熵正则。 $H_{p_\theta}(z_n|x_n)$ 鼓励编码器保持随机性。

这一项为什么必要：确定性编码器会让互信息退化 如果编码器是确定性的（ $z_n = f_{\theta(x_n)}$ ），则 $H_{p_\theta}(z_n|x_n) = -\infty$ ，于是 $I(z_n; x_n | z_{n-1})$ 无定义，整个损失函数崩溃。

在代码层面这就是“后验坍塌”的反面问题：编码器方差趋零。加上 $+H$ 项（在最大化形式里）就是在防止这件事。

两者合起来：

$$p(z_n | x_n) \approx q(z_n | z_{n-1}) \iff z_n \text{ 在 } \mathcal{K} \text{ 下近似线性演化,}$$

这正是 Koopman 表示的定义要求，被写成了一个可微的损失项。

10.5 E. 参考文献与阅读顺序

10.5.1 核心论文

- X. Cheng, W. Yuan, Y. Yang, Y. Zhang, S. Cheng, Y. He, Z. Sun. **Information Shapes Koopman Representation**. ICLR 2026. arXiv:2510.13025. 代码: github.com/Wenxuan52/InformationKoopman

10.5.2 Koopman 理论基础

- B. O. Koopman. **Hamiltonian systems and transformation in Hilbert space**. PNAS, 1931. Koopman 算子的原始定义。
- B. O. Koopman, J. von Neumann. **Dynamical systems of continuous spectra**. PNAS, 1932. 连续谱现象。理解“为什么可能根本没有特征值”的关键。
- M. O. Williams, I. G. Kevrekidis, C. W. Rowley. **A data-driven approximation of the Koopman operator: extending dynamic mode decomposition**. J. Nonlinear Science, 2015. EDMD 的奠基工作。
- S. L. Brunton, B. W. Brunton, J. L. Proctor, J. N. Kutz. **Koopman invariant subspaces and finite linear representations of nonlinear dynamical systems for control**. PLoS ONE, 2016. 证明了多吸引子系统不存在包含状态的有限维线性表示 (§1 引用的 Brunton 定理)。
- N. Takeishi, Y. Kawahara, T. Yairi. **Learning Koopman invariant subspaces for DMD**. NeurIPS 2017. 第一次用网络学观测函数。
- S. L. Brunton, M. Budisic, E. Kaiser, J. N. Kutz. **Modern Koopman theory for dynamical systems**. SIAM Review, 2022. 综述，适合作为坐标系。

10.5.3 深度 Koopman 学习

- S. E. Otto, C. W. Rowley. **Linearly recurrent autoencoder networks for learning dynamics**. SIAM J. Appl. Dyn. Syst., 2019. LRA, 本文架构的祖先。
- B. Lusch, J. N. Kutz, S. L. Brunton. **Deep learning for universal linear embeddings of nonlinear dynamics**. Nature Communications, 2018. 同一时期的平行工作，同样值得读。
- S. Pan, K. Duraisamy. **Physics-informed probabilistic learning of linear embeddings of nonlinear dynamics with guaranteed stability**. SIAM J. Appl. Dyn. Syst., 2020. 结构参数化分支。
- O. Azencot, N. B. Erichson, V. Lin, M. Mahoney. **Forecasting sequential data using consistent Koopman autoencoders**. ICML 2020. 一致性分支。
- Y. Li, H. He, J. Wu, D. Katabi, A. Torralba. **Learning compositional Koopman operators for model-based control**. ICLR 2020. CKO, 图/组合结构分支。
- S. Pan, E. Kaiser, B. M. de Silva, J. N. Kutz, S. L. Brunton. **PyKoopman: A Python package for data-driven approximation of the Koopman operator**. 2023. KAE 基线。
- Y. Liu, C. Li, J. Wang, M. Long. **Koopa: Learning non-stationary time series dynamics with Koopman predictors**. NeurIPS 2023. 时间序列分支。
- X. Wu, X. Qiu, H. Gao, J. Hu, B. Yang, C. Guo. **K^2 VAE: A Koopman-Kalman enhanced variational autoencoder for probabilistic time series forecasting**. ICML 2025. Koopman + Kalman + VAE。
- Y. Xu, et al. **ResKoopNet: Learning Koopman representations for complex dynamics with spectral residuals**. ICML 2025. 谱残差分支。
- X. Cheng, Y. He, Y. Yang, X. Xue, S. Cheng, D. Giles, X. Tang, Y. Hu. **Learning chaos in a linear way**. ICLR 2025. PFNN, 混沌结构分支。

10.5.4 变分、核与统计理论

- A. Mardt, L. Pasquali, H. Wu, F. Noé. **VAMPnets for deep learning of molecular kinetics**. Nature Communications, 2018. 变分谱分数，必读。
- H. Wu, A. Nüske, F. Paul, S. Klus, P. Koltai, F. Noé. **Variational Koopman models**. J. Chem. Phys., 2017. 非平衡数据下的变分 Koopman。
- V. Kostic, P. Novelli, A. Maurer, C. Ciliberto, L. Rosasco, M. Pontil. **Learning dynamical systems via Koopman operator regression in RKHS**. NeurIPS 2022. KORR。
- V. Kostic, K. Lounici, P. Novelli, M. Pontil. **Sharp spectral rates for Koopman operator learning**. NeurIPS 2023。

- P. Bevanda, M. Beier, A. Lederer, S. Sosnowski, E. Hüllermeier, S. Hirche. **Koopman kernel regression**. NeurIPS 2023. KKR, 必读。
- P. Bevanda, et al. **Koopman-equivariant Gaussian processes**. 2025.
- S. Das, D. Giannakis. **Koopman spectra in reproducing kernel Hilbert spaces**. ACHA, 2020.

10.5.5 信息论与表示学习

- N. Tishby, F. C. Pereira, W. Bialek. **The information bottleneck method**. 1999. IB 的原始论文。
- N. Tishby, N. Zaslavsky. **Deep learning and the information bottleneck principle**. ITW 2015.
- A. A. Alemi, I. Fischer, J. V. Dillon, K. Murphy. **Deep variational information bottleneck**. ICLR 2017. VIB, 两块变分界的来源。
- A. van den Oord, Y. Li, O. Vinyals. **Representation learning with contrastive predictive coding**. 2018. InfoNCE 的来源。
- M. Wu, C. Zhuang, M. Mosse, D. Yamins, N. Goodman. **On mutual information in contrastive learning for visual representations**. 2020. 本文引用的 InfoNCE 参考。
- M. Federici, P. Forré, R. Tomioka, B. S. Veeling. **Latent representation and simulation of Markov processes via time-lagged information bottleneck**. ICLR 2024. T-IB, 最接近的替代品, 必读。
- O. Roy, M. Vetterli. **The effective rank: A measure of effective dimensionality**. EUSIPCO 2007. 有效维度。
- F. Bach. **Information theory with kernel methods**. IEEE Trans. IT, 2022. 论文点名的未来方向。
- E. Witten. **A mini-introduction to information theory**. 2020. 密度矩阵的入门读物。

10.5.6 神经算子 (平行线索)

- L. Lu, P. Jin, G. Pang, Z. Zhang, G. E. Karniadakis. **Learning nonlinear operators via DeepONet**. Nature Machine Intelligence, 2021.
- Z. Li, et al. **Fourier neural operator for parametric partial differential equations**. ICLR 2021.
- W. Xiong, X. Huang, Z. Zhang, R. Deng, P. Sun, Y. Tian. **Koopman neural operator as a mesh-free solver of non-linear PDEs**. J. Comput. Phys., 2024. KNO。

10.5.7 建议的阅读顺序

如果你只有两天 第一天 (理解问题)： §0 本文 (只读引言与 §3), 然后 Brunton et al. 2016 的摘要与结论 (不变子空间的根本困难), 然后 Otto & Rowley 2019 的架构图与损失函数。

第二天 (理解答案)： 本文 §3.1–3.3 加附录 F, 然后 Tishby & Zaslavsky 2015 (IB 的直觉), Alemi et al. 2017 (VIB 的界), 最后 Federici et al. 2024 (T-IB, 最接近的替代品)。

读完这两天, 你就有能力判断这篇论文的位置了。